

边缘智能驱动的数控系统数字孪生:架构与部署

摘要:

近年来,数字孪生(digital twin, DT)技术逐渐成为实现数控系统智能化的主要方式。然而,随着人工智能(AI)等下一代信息技术的发展及其在数控系统中的广泛应用,计算能力和网络资源的限制已成为数控系统 DT 必须解决的紧迫问题之一。针对这些问题,首先提出基于层次结构的数控系统理论建模方法,并引入边缘智能(edge intelligence, EI)技术支持 DT 模型的部署;同时,提出一种模型划分方法和模型选择算法,在模型部署过程中支持模型实时响应。此外,给出了 EI 驱动 DT 在数控系统中的应用实例,用于诊断和预测加工过程中的刀具磨损。

1. 介绍

新一代信息技术的快速发展及其与先进制造技术的深度融合,推动传统制造业向智能制造转型[1-3]。数字孪生技术[4]作为一种面向智能制造的使能技术,在数控机床中得到广泛应用。目前,对数控机床 DT 的研究主要集中在数据采集和仿真分析方面[5-9]。在弥补 DT 模型的建模、实现和部署之间的差距方面仍然存在一些困难。数控系统作为指导数控机床加工的大脑[10],是机床 DT 系统不可或缺的载体。为实现加工过程的泛在感知和智能控制,对数控系统 DT 关键技术进行了研究。

数控系统是由多个子系统组成的复杂系统,在加工过程中受到许多因素的影响。在这种情况下,需要以机器学习[11]为代表的人工智能(AI)算法来实现数控系统的 DT。AI 算法的快速发展为 DT 提供了更多的解决方案,但也提出了实时同步、精确制图、高保真度等更高的要求。现有 CNC 系统的计算能力有限,无法分析和处理海量数据,导致许多企业倾向于将设备上采集的所有数据上传到远程的云数据中心[12-14]。然而,车间网络资源受限,这种依赖云的数据处理会造成更高的传输成本、网络拥塞、数据交付滞后和隐私不充分[15, 16]。

与纯云计算相比,边缘计算适用于实时处理、短周期通信、本地决策等场景[17-19]。它通过提供分布式计算平台将可组合的 CNC DT 模型分布到靠近用户的网络边缘[20-22],可以有效地解决这些问题。为了加快数控系统的智能化进程,通过边缘智能(edge intelligence, EI)部署深度神经网络(Deep Neural Networks, DNN)模型来提升 AI 应用在数控系统 DT 中的性能。本文的贡献可以总结如下。

1)提出基于数控系统层次结构的理论建模方法,引入 EI 技术部署 DT 模型。提出了 EI 驱动的数控系统的 DT 体系结构,并给出了通用的 DT 建模方法。

2)在 DT 模型部署中,利用边缘计算的分布式特性,提出一种新的模型划分方法,在满足 DT 应用实时性要求的同时提高吞吐率。

3)提出一种自适应模型选择算法,根据不同的应用对实时性和系统精度的要求自动选择算法模型。

4)给出了 EI 驱动 DT 在机床加工过程刀具磨损诊断与预测中的应用实例。

本研究的整体结构分为六个部分,其中包括绪论部分。第 2 节对 DT 和 EI 领域的相关工作进行了全面综述。第 3 节介绍了 EI 驱动的数控系统。第 4 节介绍如何通过边缘计算划分和部署智能算法。第 5 节介绍了 EI 驱动的数控系统的一个案例研究。第 6 节总结了结论和未来的研究方向。

2. 相关工作

本节回顾了 DT 和 EI 的相关研究,总结了它们的发展现状,并说明了研究差距,概述了背景,说明了研究的意义和重要性。

2.1. 数字孪生

DT[5]是一个现有或未来物理实体对象的数字模型,通过实际测量、仿真和数据分析实时感知、诊断和预测物理实体对象的状态,调节物理实体对象的行为,通过相关数字模型之

间的相互学习进行自我进化,同时改善利益相关者在物理实体对象生命周期中的决策。随着工业智能化的快速发展,DT在智能制造领域显示出良好的应用前景。Tao等[23]提出了一种新的DT主导的产品设计、制造和服务方法,并给出了DT在这三个阶段的应用方法和框架。Liu等[24]提出了一种DT驱动的制造系统,以快速、个性化的设计方法实现自动化流程操作,并讨论了如何应用DT定义和优化系统行为。Lu等[25]探讨了工业4.0背景下dt驱动智能制造的内涵、应用场景和研究问题。Wang等[26]建立了车间DT模型,提出了车间主动物料搬运方法,提高了车间的生产效率。

许多领先的工业企业也在DT理念的指导下开发了各种应用。通用电气(GE)[27]基于Predix平台构建资产级、系统级和集群级DT,以了解产品健康状况并预测资产性能。微软[28]改进了其DT组合,以构建模拟真实世界的下一代物联网(IoT)解决方案。西门子[29]利用DT创建了一个制造过程生产系统的集成企业模型,将从设计、生产到运营的整个生产过程数字化。

学术界和工业界都介绍了各自的DT概念,明确了DT的发展前景。然而,DT建立的技术方面并不完善。此外,目前的研究主要集中在应用DT解决产品设计、运维问题[6],没有考虑DT在数控系统等单元级设备中的应用,忽略了DT技术在车间中的重要作用。

2.2. 边缘智能

边缘计算通过将计算和服务下沉到更靠近数据源的地方,减少了对云的压力,并提高了DT应用的效率。目前,工业现场庞大的计算需求与有限的计算资源之间的矛盾日益突出。针对这一问题,Zhou等人提出了EI的概念,将智能算法部署在靠近用户和网络边缘的位置。基于此,学术界出现了一系列面向EI的深度学习模型训练和推理优化技术,以解决过度依赖硬件资源的问题。Lane等[30]使用模型剪枝来压缩DNN模型,从而降低模型复杂度和资源需求,以更好地在资源受限的设备上实现低延迟的模型推理。Surat等人[31]提出了一种分布式的深度神经网络框架,通过处理更高级网络层的输出结果来提前结束模型推理并获得最终输出结果,从而加速深度学习模型推理。Kang[32]设计了轻量级调度器Neurosurgeon,以神经网络层粒度自动拆分设备与数据中心之间的计算,在边缘实现协同模型推理以获得最佳延迟。Zhao等人[33]提出了一种基于联邦学习的分布式边缘计算模型,利用轻量级神经网络减少模型训练时间,缓解对终端设备的推理压力。Li等[34]提出了一种基于端边协同的深度学习推理加速框架Edgent,结合了模型分割和模型提前退出两种技术手段,通过优化模型退出点和分割点的选择来满足应用需求。

现有工作虽然成功解决了资源受限环境下DNN的部署和推理问题,但仍在一定程度上存在模型剪枝、提前退出和模型轻量化带来的精度牺牲。同时,协同计算主要采用串行执行方式,难以满足工业生产的实时性要求。在数据频率较高的情况下,也给终端设备带来了更优秀的存储和计算压力。

Zhang等人[6]提出了信息物理机床(cyber-physical machine tools, CPMT)的概念,将边缘计算应用于机床的DT。减少了映射延迟,提高了DT应用的计算效率。然而,对于数控系统的DT,他们并没有给出明确的建模方法。此外,它们仅在数据融合阶段应用了边缘计算。复杂模型的计算仍然需要上传到云端进行处理,无法充分最大化利用边缘的计算资源。

针对上述研究的优缺点,本文第3节提出了一种面向边缘智能驱动的数控系统DT架构,可进一步增强物理实体与DTs之间的实时信息交互,加强DT在实际生产中的应用。

3. 数控系统的EI驱动的DT

根据智能制造的发展需求,提出了构建数控系统模式的理论方法。引入EI技术,提出一种EI驱动的数控系统DT架构,为实现数控系统DT提供解决方案。介绍了数控系统DT建模过程和基于边缘计算的智能算法部署。

3.1. 智能需求

数控系统是一种机电一体化的设备，其主要功能是插补操作和伺服控制。广泛应用于加工复杂、多品种、精密、小批量的零件[35, 36]。信息和通信的发展促使数控系统从传统的封闭式结构向开放式结构转变，在制造车间的使用率越来越高。随着万物互联(Internet of Everything, IoE)时代的到来，物联网、AI、边缘计算等技术的快速进步为智能数控系统的发展创造了条件。智能数控系统制造闭环如图 1 所示。传感和计算设备的引入，为现有数控系统[37]带来了自我感知、自我调整、自我预测、自我评估等自适应控制能力，丰富了数控系统的功能和服务，扩展了数控系统的结构。与此同时，它也为系统创建了新的需求。

- 1) 智能制造的发展趋势要求打破数据孤岛，实现数控设备互联。
- 2) 物联网带来的海量数据和日益增多的时延敏感应用对系统实时性提出了更加严格的要求。
- 3) 考虑到数据隐私，航空航天等领域的工业生产者不愿意将所有数据上传到云端。
- 4) 工业现场有限资源与准确性、质量和效率的生产目标之间日益紧张的关系，为平衡系统吞吐量和准确性创造了新的要求。




图 1 具有自适应控制的智能数控系统。

3.2. 建模模式与体系结构

数控系统的 DT 是实现数控系统智能化的必要手段。数控系统作为一个复杂的运动控制系统，由不同层次的功能部件组成。因此，数控系统的 DT 模型也可以由其部件的 DT 模型来构建。每个子组件可以抽象为三个功能组件共享一个 DT 模型，如图 2 所示。

- 传感。该子组件测量实际执行的运动并接收从传感器提取的信息，为 DT 模型的更新提供数据支持。
- 计划。该子组件根据需求和约束(如插值、路径生成器、预测和健康管理(PHM))制定工作计划。
- 控制。该子组件结合感知和决策结果，在 DT 模型的指导下向执行器发出控制命令。
- DT 模型。它由信息模型(IM)和机制模型(MM)两部分组成，负责管理上述三个功能子组件的细节。其中，IM 包含所关注的信息和描述信息[25]的规则的组合，MM 既能反映物理实体的行为，又能反映规则。稍后将提供详细信息。




图2 数控系统的感知-规划-控制-建模模式。

随着工业现场传感器种类和数量的增加,数据量呈爆炸式增长,IMs 的规模也随之变大。同时,人工智能技术的发展提高了机器学习算法的多样性,导致MMs 的复杂度增加。为了满足对计算资源的可观需求,Liu 等人[38]提出了一种基于云计算的机床DT 架构,为数控系统现有DT 的开发和实现提供了指导。在物理层,该架构通过CNC 控制器和不同类型的数据采集设备实时采集制造数据,然后通过网络层将其上传到IM;在网络层,云数据中心的超高计算能力将实时数据与智能算法相结合,模拟优化数控机床的加工过程,为用户提供增值服务。

然而,数控系统的一些关键功能,如误差补偿和轨迹规划,具有严格的时间限制。这种依赖云的数据处理方法由于带宽等因素引入了不确定的时间延迟。因此,实时数据处理的结果不能及时反馈到物理机。因此,传统的数控系统DT 架构无法保证DT 数据交互的一致性和同步性,从而导致物理机床与DT 模型的隔离。

EI 的关键优势是通过分布式协同计算为用户提供低延迟、高可靠性的计算服务。此外,数控系统层次结构的特点使其DT 模型能够以分布式方式部署。因此,将边缘计算引入数控系统的DT 中。

文中根据数控系统任务需求,将计算复杂、实时性要求低的功能抽象为云组件,将实时性要求高的功能抽象为边缘组件。如图3 所示,边缘组件收集感知信息并上传到云端。云组件根据功能的实时性要求划分计算任务,并将其卸载到合适的边缘组件进行数据处理。基于此,提出了一种EI 驱动的数控系统DT 架构。如图4 所示,分为三层。




图3 基于边缘计算的层次化构件模型

- 网络层。该层由分层的云组件和边缘组件组成。通过嵌入工艺优化、加工仿真、健康管理等智能算法,对实时加工数据进行分析,构建数控系统的MM,与IM 共同形成完整的DT 模型。最后,DT 模型通过数字线程与用户交互,并将相关数据处理结果和知识存储

在 DT 模型和数据库中，以支持后续的应用服务

- 物理层。这一层包括数控系统和数据采集设备。数据采集设备为感知提供数据源，将实时数据采集并上传至边缘和云端进行处理。数控系统从控制指令到调节和控制制造过程。
- 应用程序层。这一层为用户提供子组件的接口。基于部署在 cyber 层的不同算法，结合数控系统面临的各種工作需求，如机器状态实时监控、故障诊断和预测等，提供智能服务，实现生产过程的智能控制。




图 4 EI 驱动的数控系统 DT 架构

3.3. DT 模型

现有的数控系统结构只关注加工控制。DT 介绍了加工过程和加工结果，从而丰富了数控系统架构。DT 通过数字线程收集物理实体的数据，构建反映系统几何、物理、行为和规则特征的 IMs 和 MM，并对数据和模型进行集成和融合。在创建 DT 模型期间，CNCs 需要预先抽象为预定义的 IM，其中包含用于描述信息[25]的组件和规则。数控系统 DT 建模过程如图 5 所示。




图 5 DT 建模过程

信息模型-在加工过程中，数控控制器和数据采集设备实时采集加工过程中产生的数据，然后通过工业以太网、现场总线、4G/5G、RFID、WiFi 或蓝牙等方式将数据传输到外围设备进行处理，从而将多种类型的数据连接到数控系统。数控系统是由各种子系统/部件组成的复杂系统。因此，数控系统的 DT 也由各相应子系统/部件的 DT 模型组成。在前期研究中，我们通过分析数控设备[39]层次结构的特点，明确了数控设备基本 IM 的结构，描述了数控机床的具体数据属性，形成了标准 GB/T 39561.4-2020[40]。根据标准中规定的数控设备 IM

的结构，建立相应的数控系统 IM，描述其几何参数、物理属性、关系和特征等信息。如图 6 所示，数控系统 IM 由一组静态属性、一组工艺属性、一组配置属性和一组组件组成。静态属性集描述数控系统的固有属性，工艺属性集描述系统在运行过程中的特征，配置属性集是执行一项任务所需的相关配置。部件集是数控设备描述模型的物理或逻辑部分，包括数控控制器、伺服系统、I/O、PLC、辅助设备、刀具和夹具等部件。




图 6 数控系统的信息模型

数字线程-由于数控系统的多样性，不同设备供应商之间的通信端口和协议不能互操作，限制了通信。设备集成和信息共享不易实现。数字线程技术拓展了 DT 数据集成的范围和深度，通过模板映射消除异构性，实现了典型标准规范内的一致表达，为数控设备之间的互联互通提供了支持。国内外采用的领先数字线程技术是 MTConnect 和 OPC UA (OLE for Process Control Unified Architecture)。与 MTConnect 相比，OPC UA 采用面向对象的地址空间建立 IM，支持属性、特征、方法和事件等多种数据类型。OPC UA 可以在服务器运行时通过添加和删除节点来动态调整 IM，为用户定制模型提供了最大的便利[41, 42]。为促进虚实数据的交互与融合，采用 OPC UA 方法，利用前期研究开发的中间件[43]建立 DT 模型。

机制模型-目前 DT 模型的研究大多集中在建立几何和物理维度，而没有建立能够反映物理实体行为和规律的 MMs[44]。不充分和不完整的 DT 模型将破坏虚拟实体的真实感，进而影响模拟和预测的准确性。因此，除了 IM 之外，DT 模型还必须包含反映物理实体和规则行为的机制模型。该工作一方面以基于人工智能算法的理论推导为指导，将其与经验/控制理论模型相结合，共同构建具有高保真度和高精度的综合模型；一方面，以基于人工智能算法的理论推导为指导，将其与经验/控制理论模型相结合，共同构建具有高保真度和高精度的综合模型；另一方面，考虑到 CNC 系统是一个行为受多种因素影响的复杂系统，集成多学科、多尺度模型构建机理模型，以保证 DT 模型的完整性

模型部署和优化决策-IM 和 MM 能够从不同的时空角度描述物理实体的性质、行为和特征，反映其在加工过程中的运行状态及其随时间的变化。它们共同构成了一个 DT 模型，可以更好地描述数控系统在不同环境下的实时响应和行为，形成最优决策指令，进行反馈控制，指导加工过程[44, 45]。为了缓解云上的压力，基于数控系统的层次结构部署 EI 分布式的 DT 模型。在云端选择并训练智能算法，制定任务的划分策略，将划分后的模型分别下载到边缘节点和边缘服务器，由边缘节点和边缘服务器协同处理实时数据。

3.4. 基于 EI 的部署方法

与云计算相比，边缘计算提供了一种低延迟的方法。然而，随着物联网和人工智能的普及，越来越多的传感器部署在工业现场，算法的复杂度和数据规模也随之增长。此外，实时监测、故障诊断和预测等 DT 应用对实时数据处理要求更严格。传统的数据处理方法[46, 47]采用单服务器单节点串行执行的方式对数据处理任务进行划分，有助于减少延迟。将分区点之前的任务留给边缘节点，剩余任务卸载到边缘服务器。将两部分处理时间与数据传输时间叠加作为数据处理时间。然而，这种数据处理方法并不适用于数控系统的 DT。一方面，节点

与服务器之间的一一对应意味着较高的数据处理成本;另一方面,边缘服务器处理深度 DNN 的延迟更短。此外,这种以减少延迟为唯一评估指标的数据处理方法倾向于将更多的数据交给边缘服务器进行处理,而忽略了边缘节点。这种方法会导致服务器来不及处理的大量数据被丢弃,系统吞吐率会降低,对应用服务的质量帮助较小。

针对数控系统 DT 的实际应用场景,提出了一种新的任务划分方法,即为每个数控系统部署边缘节点,并在车间部署边缘服务器。该工作采用 MISD (Multiple Instruction stream Single Datastream)流水线结构,在边缘节点并行、边缘服务器串行的一对多关系下处理边缘服务器与边缘节点之间的数据。 τ 作为时间片,管道的每个处理级别都有专用的功能和重叠操作。该数据处理方法能够充分利用边缘节点,有效减少数据丢弃量,提高应用服务质量。下面将描述所提出方法的细节。

首先,将数据处理过程划分为 N 个子任务, S_i 表示第 i 个子任务,其中 $i = 1, 2, \dots, N$, D_i 表示执行 S_i 的输出数据大小, $f(S_i)$ 为执行 S_i 的时间延迟。通过边缘计算对数据处理任务进行划分, j 表示划分给边缘节点处理的子任务数,其中 $j = 0, 1, \dots, N$ 。当 $j = 0$ 时,所有子任务都卸载到边缘服务器执行,当 $j = N$ 时,所有子任务都在边缘节点执行。

在下一步中,给出了 MISD 流水线各段的延迟模型。数据处理延迟包括边缘节点执行、网络传输和边缘服务器执行。

1) 边缘节点任务模型

边缘节点并行批量处理多组数据。假设每个边缘节点接收到相同的数据处理任务,且节点具有相同的计算能力,对于任意节点的数据处理任务,边缘节点的执行延迟分为分裂点前节点处理子任务延迟和结果上传延迟两部分。将当前可用带宽定义为 B_{device} ,边缘节点执行延迟记为

$$t_{device} = \sum_{i=0}^j f(S_i) + D_j / B_{device}$$

公式 (1)

1) 边缘服务器任务模型

边缘服务器当前可用带宽记为 B_{edge} ,连接到单个节点时的执行延迟包括子任务处理延迟和数据下载延迟,记为

$$t'_{edge} = \sum_{i=j+1}^N f(S_i) + D_j / B_{edge}$$

公式 (2)

边缘服务器实际访问的节点数记为 m ,最大可访问的节点数记为 M ,其中 $m \leq M$ 。采用非抢占式 CPU 分配串行执行,可能会出现空闲时间。因此,边缘服务器的实际处理延迟 t_{edge} 应满足 $mt'_{edge} \leq t_{edge} \leq Mt'_{edge}$ 。

2) 通信模型

数据通信延迟 t_{tran} 由数据传播延迟和数据转发延迟组成。其中,传播延迟是数据在传输通道上传播所需的时间,只与传输通道长度有关;转发延迟包括数据在输入输出缓冲区中的排队延迟和对数据块进行转发处理所需的处理延迟。

最后给出了任务切片的条件。只有在管道加载到[48]的稳定状态下,才能保证每个时钟周期输出一个结果的最大速率。因此,在 3 级管道中执行最慢的组件所需的时间是时间片长度,即 $\tau = \max\{t_{device}, t_{tran}, t_{edge}\}$ 。流水线处理每个进程都需要等待上一个进程处理的数据,数据处理延迟为 $T = t_{device} + t_{tran} + t_{edge}$ 。当管道满时,系统吞吐率 $\theta = 1/\tau$,在满足时延要求的情况下,选择的时间片越小,系统吞吐率越大。高吞吐率意味着更少的数据丢弃,有利于提高模型的准确性

4. EI 驱动 DT 的任务部署算法

4.1. 任务划分算法

3.4 节利用边缘计算对智能算法进行划分和部署,以期在保证实时性的同时最大化系统吞吐率,进一步提高系统的应用效率。模型的最优划分点取决于 DNN 的拓扑结构、设备的计算能力和网络状态,表现为每个子任务的计算量和数据量的变化。具体的任务划分算法如下。

任务初始化-获取边缘节点和边缘服务器的计算能力,分析目标子任务。对于包含 N 个子任务的数据处理任务,分别为每个子任务 S_i 初始化其在边缘节点的执行延迟 TN_i 和在边缘服务器的执行延迟 TE_i 。由于子任务的推断延迟仅依赖于硬件设备的计算能力,相同的硬件只需要对相同的硬件进行一次初始化,并且设备执行每个子任务的延迟 $f(S_i)$ 可以从实际测量中获得。

任务分析-根据 3.4 节的描述,边缘节点并行执行分区点之前的子任务。数据处理时间是 $\sum_{j=0}^{N-1} TN_j$,上传时间是 D_i / B_{device} 。边缘服务器串行执行每个节点卸载到服务器的剩余子任务。由于节点在不确定的时间向边缘服务器发送任务,边缘服务器可能处于空闲状态。将边缘服务器的任务执行时间标记为 $M(\sum_{k=j+1}^N TE_k + D_j / B_{edge})$ 。由于数据传输时间 t_{tran} 计算复杂,本文采用实时监控的方式获取。

分区点的选择-本文用时间片长度来描述系统的吞吐率。此外,计算所有候选点对应的延迟和时间片长度。候选点位于每个子任务之后。对于满足延迟要求的候选点,逐个比较它们的时间片长度。选择时间片长度最小即系统吞吐率最广的时间片作为最优分区点。输出分区决策和相应的系统延迟。

4.2. 模型选择算法

对于给定的算法模型,算法 1 可以根据延迟需求为数据处理任务选择最优划分点,并使吞吐率最大化。然而,在工业现场,应用对吞吐率和模型精度有不同的考虑。模型剪枝等方法可以以模型精度为代价,有效提高吞吐率。因此,如何平衡模型准确率和吞吐率成为一个新的问题。

在算法 1 的基础上,提出了一种算法模型的自适应选择方法。它为应用程序提供了基于系统延迟、准确性和可选算法模型吞吐量的评估函数的不同模型的自动和及时评估。

```
Task Partitioning Algorithm
1: Input:
2:  $N$ : number of the subtasks
3:  $\{S_i | i = 1, \dots, N\}$ : the  $i$ -th subtask
4:  $\{D_i | i = 1, \dots, N\}$ : output data size of  $S_i$ 
5:  $f(S_i)$ : latency of executing  $S_i$ 
6:  $B_{device}$ : current available bandwidth of node
7:  $B_{edge}$ : current available bandwidth of edge server
8:  $M$ : maximum number of nodes that can connect to the server
9:  $l$ : latency requirement
10: Output:
11: Partition Decision
12: procedure
13: for each  $i$  in  $1, \dots, N$  do
14:  $TN_i \leftarrow f_{device}(S_i)$ 
15:  $TE_i \leftarrow f_{edge}(S_i)$ 
16: end for
17:  $\tau_{min} \leftarrow l$ , PartitionPoint  $\leftarrow 0$ 
18: for  $j = 0, j \leq N, j = j + 1$  do
19:  $t_{device} = \sum_{k=0}^j TN_k + D_j / B_{device}$ ,  $t_1 \leftarrow t_{device}$ 
20:  $t_2 \leftarrow t_{tran}$ 
21:  $t'_{edge} = \sum_{k=j+1}^N TE_k + D_j / B_{edge}$ ,  $t_3 \leftarrow M \cdot t'_{edge}$ 
22:  $t_j = \max\{t_1, t_2, t_3\}$ ,  $T_j = t_1 + t_2 + t_3$ 
23: if  $T_j \leq l$  then
24: if  $t_j \leq \tau_{min}$  then
25:  $\tau_{min} \leftarrow t_j$ , PartitionPoint  $\leftarrow j$ 
26: end if
27: end if
28: end for
29: return PartitionPoint and  $T_{min}$ 
```

算法 1

EI 驱动的 DT 主要应用机器学习来解决分类和回归问题。针对这两类问题,采用不同的指标来评估各自算法的性能。本文分别为它们定义了评价函数。

对于分类问题,评价函数定义如下:

$$h(acc, \theta, p) = (l\theta/p)^{a \cdot (acc - Y)}$$

公式 (3)

其中 acc 是 DNN 模型的准确率, l 是延迟需求, θ 是系统吞吐率, p 是管道段数, Y 是准确率阈值, a 是一个大于 0 的常数因子, 用户可以根据生产需求设置该常数因子

对于回归问题, 模型的拟合误差用损失表示, 评价函数为:

$$h(loss, \theta, p) = (l\theta/p)^{a \cdot (Y - loss)}$$

公式 (4)

其具体选择方法与分类问题相同, 评价函数由式(4)计算得到。备选模型的拟合误差越小, 评价值越高。输出评估值最高的备选模型。

DNN 模型自适应选择算法如算法 2 所示。首先, 输入满足应用最大可容忍延迟和精度要求的备选 DNN 模型; 初始化备选 DNN 模型的吞吐率、准确率或误差。然后, 计算所有备选 DNN 模型的评价值 $E(M_j)$; 最后, 选取评价值最高的样本作为最优 DNN 模型输出。

Model Selection Algorithm

```

1: Input:
2:  $\{M_j | j = 1, 2, \dots, R\}$ : the DNN model
3:  $l$ : latency requirement
4:  $Y$ : threshold
5:  $a$ : custom constant coefficient
6:  $E(M_j)$ : the evaluation of DNN model  $M_j$ 
7: Output:
8: Optimal DNN Model
9: Procedure
10: for ( $j = 1; j \leq R; j++$ ) do
11:  $h_{max} = 0, M_{optimal} = 0$ 
12: if  $Target == accuracy$  then
13:  $h_j(acc_j, \theta_j, p_j) \leftarrow E(M_j)$ 
14: else if  $Target == loss$  then
15:  $h_j(loss_j, \theta_j, p_j) \leftarrow E(M_j)$ 
16: end if
17: if  $h_{max} \leq E(M_j)$  then
18:  $h_{max} = E(M_j), M_{optimal} = M_j$ 
19: end if
20: end for
21: return the optimal DNN model  $M_j$ 

```

算法 2

5. 试验研究

数控铣床因其生产效率高, 被广泛应用于机械制造领域。刀具作为切削的直接执行者, 是数控铣床中最容易损坏的部件。传统的切削加工主要依靠加工人员的主观经验判断刀具磨损程度来更换刀具。这可能导致工具在磨损超出其限制之前就被收回, 或者工具严重磨损但没有更换[49]。未充分利用的工具会导致更高的生产成本。同时, 不及时更换刀具会影响产品质量和加工精度, 损坏机床, 危及人员安全。因此, 需要对刀具磨损进行实时监测和预测。

针对上述问题, 以 EI 驱动的数控系统 DT 为例, 建立刀具 DT 模型, 部署边缘计算环境, 并通过提出的任务划分和模型选择算法对 DT 模型进行部署。

5.1. 建立实验

如图 7 所示为数控控制器采用 Golding 数控系统 GJ430, 边缘节点采用树莓派 4B, 边缘服务器采用 SIMATIC NANOBOX PC 的实验环境和工作流程。GJ430 和数据采集装置实时采集处理过程中产生的数据构建 IM。在边缘节点和边缘服务器上部署智能算法, 对刀具磨损进行诊断和预测。最后通过可视化客户端实时监控工具状态, 并通过 GJ430 提供反馈控制。




图 7 实验环境和工作流程

5.2. 切削刀具的信息建模

本节按照 3.3 节的方法建立刀具的 IM，如图 8 所示。刀具是数控系统的重要组成部分，它包含工艺属性集和静态属性集。静态属性集的数据是工具列表。工艺属性集包括使用的刀具信息，如刀具 ID、类型、状态、寿命(设定寿命、预警寿命和实际寿命)、几何参数(刀具长度和半径)、额定主轴转速和进给速度、刀具磨损(实际磨损和预测磨损)以及传感器数据，包括机械、加速度和声发射(AE)信号。每个数据项包含索引、访问级别、数据类型和数据值的描述。

利用 OPC UA 实现了 IM 模型到 DT 模型的映射过程。IM 中的每个数据项对应 OPC UA 地址空间中的一个节点，节点之间的引用关系由 IM 的层次结构决定。用户可以通过支持 OPC UA 标准的各种客户端访问服务器，获取 OPC UA 地址空间中的工具信息，加载、浏览和修改工具 IM。

通过订阅 OPC UA 服务器节点的“磨损预测”，可以实现对工具的管理和维护。当磨损预测值达到预警寿命时，OPC UA 服务器可以通过数控系统提供的错误通道将故障信息实时发送给数控系统，触发报警并在数控系统的人机界面上显示相应的刀具故障信息，提示操作人员对刀具进行管理和维护。




图 8 刀具信息模型

5.3. 机理模型部署

5.3.1. 模型选择

刀具磨损是一个动态的、时变的、非线性的、随机的、有许多可能干扰的过程。深度神经网络具有良好的学习能力,可以通过多层表示建立传感器信号与实际刀具磨损之间的复杂关系。现有研究普遍认为,网络越深,模型越准确。然而,随着网络深度的增加,退化现象往往会发生。ResNet 在保证网络深度的同时,能够有效解决深度网络退化现象。文献[50]使用 ResNet 对刀具磨损进行实时监测。基于 ResNet 的刀具磨损实时监测模型如图 9 所示,其中 Conv 表示卷积层, BN 表示批量归一化层, Dense 表示全连接层。




图 9 基于 ResNet 的刀具磨损实时监测模型

在此基础上, Sun 等[50]利用 LSTM 对刀具磨损状况进行预测。然而, 时间卷积网络 (TCN) 具有梯度稳定、训练速度快、接受域大小灵活、输入长度可变的[51]等特点。为了选择合适的预测模型, 本文设计了一个 3 块 TCN 模型, 如图 10 所示。




图 10 基于 TCN 的刀具磨损预测模型

对现有的 LSTM 模型和设计的 TCN 模型分别进行了 200 个周期的训练。模型的输入数据大小为 15 个加工环节后的刀具磨损值, 预测步骤为 10 个加工环节。刀具磨损预测结果如图 11 所示。使用 RMSE (Root Mean Squared Error) 和 MAE (Mean Absolute Error) 来描述模型损失。如表 1 所示, TCN 模型实时性较好, 模型损失偏差较小。根据算法 2, 最终选择 TCN

模型进行刀具磨损状态预测。




图 11 刀具磨损预测的结果

Model Comparison				
DNN Model	RMSE	MAE	Node execution delay (ms)	Server execution delay (ms)
LSTM	7.47	6.21	12.27	6.82
TCN	3.67	3.17	20.45	11.37

表 1

5.3.2. 任务划分

利用 ResNet 和 TCN 对刀具磨损状况进行诊断和预测。数据处理流程如图 12 所示。根据算法 1 对数据处理任务进行划分和部署，在每个子任务之后定位候选点。子任务划分如表 2 所示。输入数据是由 x 轴力、y 轴力、z 轴力、x 轴振动、y 轴振动、z 轴振动以及传感器和 GJ430 采集到的 AE 信号组成的 7 维时间序列。具体的任务划分步骤如下：




图 12 数据处理流程

Subtask division			
stage	Subtask	Component	output
Data pre-processing	0	Down sampling	7*5000
		Wavelet transform	7*1255
Real-time tool wear monitoring	1	Residual block Post-activation	128*626
	2	Residual block Pre-activation [0]	128*313
	3	Residual block Pre-activation [1]	128*313
	4	Residual block Pre-activation [2]	128*157
	5	Residual block Pre-activation [3]	128*157
	6	Residual block Pre-activation [4]	128*79
	7	Residual block Pre-activation [5]	128*79
	8	Residual block Pre-activation [6]	128*40
	9	Residual block Pre-activation [7]	128*40
	10	Residual block Pre-activation [8]	128*20
	11	Residual block Pre-activation [9]	128*20
	12	Residual block Pre-activation [10]	128*10
	13	Residual block Pre-activation [11]	128*10
	14	Residual block Pre-activation [12]	128*5
	15	Residual block Pre-activation [13]	128*5
	16	Residual block Pre-activation [14]	128*3
	17	Residual block Pre-activation [15]	128*3
	18	Residual block Pre-activation [16]	128*2
	19	Residual block Pre-activation [17]	128*2
Tool wear forecasting	20	Dense	1*1
	21	TCN[0]	4*15
	22	TCN[1]	8*15
	23	TCN[2]	16*15
	24	Dense	1*15

表 2

首先，在边缘节点和服务器上初始化每个子任务的执行延迟。记录如图 13 所示。




图 13 子任务的执行延迟

然后，计算每个候选点的数据处理延迟和吞吐率。最佳分区点由两个指标定义:推理延迟和吞吐率。如图 14 所示，本文使用不同的颜色表示流水线不同阶段数据的处理延迟，并使用不同的符号来区分用于决策的不同度量。菱形符号表示吞吐率最高的分区点。星号标记推理时延满足实时性要求时吞吐率最高的分区点，即最优分区点。系统的最大可容忍延迟设置为 480ms。当边缘服务器连接两个边缘节点时(图 14 (a))，最优吞吐率对应的分区点的推理时延满足时延要求，即为最优分区点。当服务器连接到 4 个边缘节点时(图 14(b))，最优吞吐率对应的分区点的推理延迟超过了最大可容忍延迟。然后，在满足时延要求的候选点中选择吞吐率最高的点作为最优划分点进行模型划分。




图 14 PartitionPoint 选择

5.4. 数字孪生应用

边缘节点在 PartitionPoint 之前执行模型，并通过 WebSocket 将结果发送到边缘服务器。边缘服务器在 PartitionPoint 之后执行模型，并将结果发送给 OPC UA 服务器。用户通过客户端访问服务器，获取工具状态。OPC UA 提供了两种主要的通信方法：客户机-服务器和发布-订阅(PubSub)。服务器通过定义的服务[52]提供客户端访问信息，而 PubSub 允许 LAN(局域网)上的多个授权客户端(订阅者)访问 OPC UA 服务器(发布者)发布的数据。

本文开发了一种基于数控系统 IM 的 OPC UA 服务器，并将其集成到 GJ430 数控系统中。服务器的配置，如端口号、安全证书等，都是在服务器初始化阶段设置的。然后根据 XML 文件提供的 CNC 系统 IM 在 OPC UA 服务器端节点空间中定义节点属性和节点间引用关系，在服务器端建立相应的 OPC UA 模型。将数据节点的数据源绑定到 GJ430 CNC 动态链接库提供的数据库读取功能上，实现节点数据的实时更新。最后，启动服务器监听器，在控制台界面中返回服务器地址空间的访问地址。

为了实现刀具磨损的诊断和预测，OPC UA 服务器将“Warning Life”设置为事件的触发条件。当服务器检测到刀具磨损预测已达到“警告寿命”，即刀具磨损接近超出正常范围时触发该事件。此外，所有订阅该事件的客户端都可以从服务器获得通知信息。此外，现场操作人员应及时进行刀具维护。

任何支持 OPC UA 标准的客户端都可以通过 OPC UA 服务器提供的端口访问 CNC 系统的 DT 模型。DT 的实现不依赖于客户端，用户在应用 DT 模型时具有更大的灵活性。因此，本文使用开源客户端界面来呈现工具磨损和预测结果。

如图 15 所示，客户端包含三个主要区域。当客户端与服务器连接时，请在顶部的地址栏中输入 URL。客户端连接状态显示在屏幕底部。连接成功后，区域 1 显示当前连接的 CNC 系统(GJ430)的 IM。服务器提供的 OPC UA 模型节点以树形结构显示。用户可以通过浏览 IM 来了解 CNC 系统的逻辑结构和可访问的数据项。通过单击节点列表中的数据项，可以查看该节点在区域 2 中的属性，包括 AccessLevel、NodeId、NodeClass 和 Data Type。通过对实时数据的分析，在区域 3 中明确显示了不可见的变化，包括订阅事件警报、订阅数据项显示、服务器引用关系和图像显示。如图 15 所示，将预测磨损和实时磨损数据项加载到图块中。设置采样间隔为 250ms，可实时查看刀具磨损状态的变化曲线。横坐标表示时间，纵坐标表示磨损值(m)。



图 15 可视化客户端

这种基于 EI 的 DT 案例，使用户能够快速、可靠地实时获取工具状态。在此基础上，操作人员可以对刀具进行预测性维护，从而提高加工质量，进一步保证刀具剩余寿命利用率，降低生产成本。

6. 结论

数控系统的检测是实现智能制造最有前途的技术之一。本文从智能制造的发展需求出发，开展了基于边缘智能的数控系统检测关键技术的研究，并针对工业领域有限的计算和网络资源，不能满足智能化和实时性的要求，提出了数控系统检测的解决方案。主要贡献概述如下。

本文首先分析了智能数控系统的需求，提出了一种基于边缘计算的数控系统分层建模的理论方法，以突破实时服务的瓶颈。在此背景下，本文提出了 EI 驱动下的数控系统的 DT 体系结构，并详细描述了数控系统的 DT 建模方法。此外，在数控系统分层 DT 模型的分布式部署过程中，在保证实时服务的基础上，提出了提高模型吞吐量的模型划分算法。为了进一步减少安装阶段模型分析的人工开销，本文提出了一种模型选择算法，为应用程序提供及时的自动模型评估。满足了对吞吐量和模型精度的各种要求。最后，以加工过程中 EI 驱动的 DT 诊断与预测刀具磨损为例。

实现数控系统的智能化是其主要目标。本文的研究工作仅对数控系统 DT 模型的构建方法和部署方法进行了初步探讨，提出的 EI 驱动的数控系统 DT 体系结构还有待丰富和完善。在未来的研究中，我们将为用户提供更多的功能和服务，以丰富其机构模型，并将所提方法的应用扩展到轨迹规划、表面粗糙度检测和刀具抖振等实际功能。并且本文假设 DT 模型部署时，所有边缘节点的任务模型都是相同的，下一步将根据车间的实际情况，研究当未来边缘节点的任务模型不同时，如何对智能算法模型的部署进行划分。

信用作者贡献表

于浩宇:概念化、方法论、软件、形式分析。

于东:监理，项目管理。

王楚婷:资源，数据策划，撰写原创稿。

胡毅:李岳:。

竞争利益声明书

所有作者均未披露相关关系。

数据可用性

资料将应要求提供。

致谢

辽宁省高水平创新创业团队项目 XLYC1902091。