



中国科学院大学

University of Chinese Academy of Sciences

博士学位论文

基于云边协同的数控系统智能化关键技术研究与应用

作者姓名：于皓宇

指导教师：于东 研究员

中国科学院沈阳计算技术研究所

学位类别：工学博士

学科专业：计算机应用技术

培养单位：中国科学院沈阳计算技术所

2023 年 6 月

**Research and application of key technologies for the intelligence
of numerical control systems based on cloud-edge collaboration**

**A dissertation submitted to
University of Chinese Academy of Sciences
in partial fulfillment of the requirement
for the degree of
Doctor of Philosophy**

In Technology of Computer Application

By

YU Haoyu

Supervisor: Professor Yu Dong

**Shenyang Institute of Computing Technology,
Chinese Academy of Sciences**

June 2023

中国科学院大学 研究生学位论文原创性声明

本人郑重声明：所呈交的学位论文是本人在导师的指导下独立进行研究工作所取得的成果。承诺除文中已经注明引用的内容外，本论文不包含任何其他个人或集体享有著作权的研究成果，未在以往任何学位申请中全部或部分提交。对本论文所涉及的研究工作做出贡献的其他个人或集体，均已在文中以明确方式标明或致谢。本人完全意识到本声明的法律结果由本人承担。

作者签名：

日 期：

中国科学院大学 学位论文使用授权声明

本人完全了解并同意遵守中国科学院大学有关收集、保存和使用学位论文的规定，即中国科学院大学有权按照学术研究公开原则和保护知识产权的原则，保留并向国家指定或中国科学院指定机构送交学位论文的电子版和印刷版文件，且电子版与印刷版内容应完全相同，允许该论文被检索、查阅和借阅，公布本学位论文的全部或部分内容，可以采用扫描、影印、缩印等复制手段以及其他法律许可的方式保存、汇编本学位论文。

涉密及延迟公开的学位论文在解密或延迟期后适用本声明。

作者签名：

日 期：

导师签名：

日 期：

摘 要

信息技术不断突破并与制造技术进一步深度融合,为制造业高端化、智能化、绿色化发展提供了新的历史机遇,智能制造在全球正掀起新一轮的产业变革。以美国、日本、德国等国家为代表的制造强国进一步围绕智能制造制定相关计划,力图提高国家智能制造水平,抢占全球制造业新一轮竞争制高点。作为智能制造的重点研究对象,数控系统将信息技术、控制技术和网络化技术有机结合,实现了对系统的全面感知以及对加工过程的智能控制,能够增强系统加工处理能力,是实现智能制造的核心因素。随着“十四五”智能制造发展规划的提出,数控系统的智能化发展已成为必然趋势。数字孪生充分集成多学科技术,能够实现物理空间和信息空间的交互融合,为数控系统提供自主感知、自主学习、自主决策等能力,是实现数控系统智能化,驱动智能制造发展的重要使能技术。边缘智能技术基于边缘计算这一新型计算模式产生和发展,能够在资源受限的设备边缘和终端高效部署数字孪生机理模型,从而改善智能应用性能,降低应用成本,为智能数控系统的发展提供了新的解决方案。

本文以数控系统为研究对象,针对智能制造对数控系统提出的智能化需求,将数控系统主要智能因素抽象为可实现的领域模型,提出了基于云边协同的智能化数控系统体系结构。在此基础上,开展智能化数控系统数字孪生通用建模方法研究,提出了基于映射的数控系统信息模型构建方法。此外,本文将边缘智能技术引入智能数控系统,开展数控系统数字孪生机理模型部署实现方法研究,并给出两个边缘智能驱动的数控系统数字孪生应用实例,验证了文中所提的数字孪生信息模型和机理模型建模以及部署方法的有效性。论文的主要研究内容将从以下几个方面展开:

(1) 对智能化数控系统体系结构展开研究。从系统角度和实现角度深入分析了智能系统的概念及特征,基于数控系统层次化结构对智能化数控系统进行抽象,提出了以数控系统数字孪生模型为核心,以感知处理、价值评估、任务决策为主要智能元素的智能数控系统领域模型,详述了领域模型中智能元素的具体功能与实现方法。针对智能化应用带来的性能、成本和安全需求,引入边缘智能技术,对以云计算为核心的现有数控系统数字孪生体系结构进行优化,结合数控系统层次化结构特点将系统智能元素进一步抽象为可以分布式部署的边缘组件和云组件,提出了基于云边协同的智能化数控系统数字孪生体系结构。

(2) 对数控系统数字孪生建模方法展开研究。在数控系统信息模型方面,对智能化数控系统互联互通互操作应用场景进行概括,在数控系统层次化体系结构基础上提出了以静态属性、过程属性、配置属性和组件等数据集为主要构成的

数控系统基础信息结构,并通过数据字典的方式描述数据集中每项数据的语义信息。在此基础上提出基于映射的技术架构,将数控系统结构化信息映射为符合通用协议规定的信息模型,通过通用的互联互通与互操作协议与生产线中的其他数控装备以及上位机管理系统实现交互。最后在蓝天数控 GJ430 上采用 OPC UA 方法构建数控系统信息模型,验证了所提信息模型构建方法的有效性;在机理模型方面,对现有数控系统机理模型构建方法以及关键技术进行研究,分析了物理/数学模型驱动的机理模型以及以人工智能为代表的驱动机理模型的特征,结合数控系统智能化需求提出一种人工智能辅助机理模型的通用建模方法。

(3) 对数控系统数字孪生模型部署方法展开研究。数控系统智能化应用对计算资源以及网络资源的需求日益增高,本论文将边缘智能技术应用到智能化数控系统体系结构中,以计算、网络和数据等智能应用主要资源的优化分配为研究对象,开展了云边端协同任务中机理模型卸载优化方法研究。在计算/网络资源优化方面,在现有的以时延为主要指标的优化方法基础上补充了系统数据吞吐率指标,提出了一种综合考虑任务实时性与系统吞吐率的机理模型任务切分算法,提高了系统数据处理效率。在此基础上,针对以模型剪枝、模型量化为代表的模型推理优化方法,以实时性和准确性为指标提出一种自适应的模型选择算法,提升了数控系统的边缘自治能力。在数据资源优化方面,本论文以分布式深度神经网络为应用场景,考虑机理模型的复杂性、边缘以及终端设备的计算能力,构造了一个最优化问题来最小化数据处理时间。在此基础上提出最优数据分配策略,设计仿真实验深入研究参数对分配策略的影响,验证了数据划分方法的有效性。

(4) 对数控系统智能化应用展开研究。搭建边缘智能应用环境,采用 OPC UA 方法建立刀具磨损与加工轨迹信息模型。基于自适应的模型选择算法采用残差神经网络和 TCN 搭建刀具磨损机理模型,对神经网络按层划分任务,并通过吞吐率优化模型卸载算法实现对刀具磨损情况的实时诊断与预测。在数控系统加工轨迹信息模型基础上,将 G 代码优化任务划分为文件解析、轨迹生成、轨迹优化、轨迹可视化等时序任务,采用流水线结构并行执行方式提高应用实时性。针对轨迹优化任务,提出了一种采用聚类分析的路径缺陷特征识别方法以路径法向量起伏程度为指标对路径缺陷进行等级划分,在此基础上针对不同的缺陷特征采用相应的滤波平滑算法实现了缺陷路径自适应滤波与 G 代码优化。

关键词: 数控系统, 云边协同, 数字孪生, 边缘智能, 智能应用

Abstract

A new generation of information technology continues to break through and integrate with advanced manufacturing technologies, which provides new historical opportunities for the high-end, intelligent, and green development of the manufacturing industry. Smart manufacturing has set off a new round of industrial changes in the world. Manufacturing powerhouses represented by the United States, Japan and Germany have further developed relevant plans around smart manufacturing. These countries seek to improve the national level of intelligent manufacturing and seize a new round of competitive high ground in the global manufacturing industry. The CNC system is the key research object of intelligent manufacturing, which enhances the processing capacity of the system by organically combining information technology, control technology and networking technology to achieve comprehensive sensing and intelligent control of the processing process. Therefore, the CNC system has become the core factor of intelligent manufacturing. With the "Fourteenth Five-Year Plan" intelligent manufacturing development plan, intelligent has become the inevitable trend in the development of CNC systems. Digital twin technology integrates multidisciplinary technologies to achieve the interactive integration of the physical world and cyber space, which provides CNC systems with autonomous sensing, learning and decision-making capabilities. Therefore, digital twin technology is an important enabling technology to implement the intelligence of CNC systems and drive the development of smart manufacturing. Edge intelligence technologies, generated and developed based on edge computing, enable the efficient deployment of digital twin mechanism models at resource-constrained device edges and terminals. This new technology enables improved performance and reduced application costs for intelligent applications, providing a new solution for the development of intelligent CNC systems.

This paper takes CNC systems as the research object, abstracts the main intelligent factors of CNC systems into an achievable domain model for the intelligent needs of CNC systems, and proposes an intelligent CNC system architecture based on cloud-edge collaboration. On this basis, this thesis carries out research on the digital twin generic modelling method for intelligent CNC systems and proposes a mapping-based method for constructing information models of CNC systems. In addition, this paper introduces edge intelligence technology into intelligent CNC systems, carries out research on the implementation method of the digital twin mechanism model deployment of CNC systems, and gives an edge intelligence-driven CNC system digital twin application example to verify the feasibility and effectiveness of the modelling method and the model deployment method. The main research contains the following aspects:

- (1) This paper carries out a study on the architecture of intelligent CNC systems.

The paper analyses the concept and characteristics of intelligent systems from a system and implementation perspective. On this basis this paper abstracts the intelligent CNC system based on the hierarchical structure of the CNC system and proposes a domain model of the intelligent CNC system. The domain model takes the digital twin model of the CNC system as the core, with perception processing, value assessment and task decision making as the main intelligent elements. The functions and implementation methods of each intelligent element in the domain model are described in detail in the paper. The existing digital twin architecture of CNC systems with cloud computing at its core is optimized for the performance, cost and security requirements arising from intelligent applications. The new optimization scheme applies edge intelligence technology to intelligent CNC systems, further abstracts the intelligent elements of CNC systems into distributed deployment of edge components and cloud components in combination with the hierarchical structure characteristics of CNC systems, and proposes a digital twin architecture for intelligent CNC systems based on cloud-edge collaboration.

(2) Research is carried out on the digital twin modelling method for CNC systems. In terms of the CNC system information model, an overview of the application scenarios of interconnection and interoperability of intelligent CNC systems is presented. Based on the hierarchical architecture of the CNC system, a basic information structure of the CNC system is proposed with static attributes, process attributes, configuration attributes and component data sets as the main components. The semantic information of each data item in the CNC system information model data set is described by means of a data dictionary. On this basis, a mapping-based technical architecture is proposed to map the structured information of the CNC system into an information model that conforms to the provisions of common protocols and enables data interaction with other CNC equipment and management systems through a unified and common interconnection protocol. Finally, the OPC UA method is used to build the information model of the CNC system on the Blue Sky CNC GJ430, and the effectiveness of the proposed information model building method is verified. In terms of the mechanism model, the existing CNC system mechanism model construction methods and key technologies are studied, the characteristics of the mechanism model driven by physical/mathematical models and the data-driven mechanism model represented by artificial intelligence are analyzed, and a general modelling method of artificial intelligence-assisted mechanism model is proposed in combination with the intelligent needs of the CNC system.

(3) A digital twin model deployment method for CNC systems is studied. Intelligent applications of CNC systems have an increasing demand for computational and network resources, and edge intelligence technologies are applied to the architecture of intelligent CNC systems. In this paper, the optimization of the main resources of intelligent applications, such as computation, network and data, is studied,

and research on the optimization method of mechanism model offloading in cloud-edge collaborative tasks is carried out. In terms of computation/network resource optimization, a throughput rate indicator is added to the existing optimization method with latency as the main indicator, and a mechanistic model task slicing algorithm that integrates task real-time and system throughput rate is proposed to improve the system data processing efficiency. On this basis, an adaptive model selection algorithm is proposed for model inference optimization methods represented by model pruning and model quantization, with real-time and accuracy as indicators, to improve the edge autonomy of the CNC system. In terms of data resource optimization, this paper takes distributed deep neural networks as an application scenario and constructs an optimization problem to minimize data processing time by considering the complexity of the mechanism model, the computational capacity of end devices and edge servers. Based on this, an optimal data allocation strategy is proposed, simulation experiments are designed to investigate the influence of parameters on the allocation strategy, and the effectiveness of the data allocation method is verified.

(4) This paper develops research on intelligent applications for CNC systems. An edge intelligence application environment is built and a tool wear and machining trajectory information model is established using the OPC UA method. In this paper, a tool wear mechanism model is built based on an adaptive model selection algorithm using residual neural networks and TCN. The neural network is divided into several subtasks by layer and the throughput rate optimization model offloading algorithm is used to achieve real-time diagnosis and prediction of tool wear. Based on the CNC machining trajectory information model, the G-code optimization task is divided into file parsing, trajectory generation, trajectory optimization and trajectory visualization timing tasks, which are executed in parallel using a pipeline structure to improve the application real-time. For the trajectory optimization task, a path defect feature identification method using cluster analysis is proposed to classify path defects by using the degree of path normal vector undulation as an indicator, on the basis of which the corresponding filter smoothing algorithm is used to achieve the defect path adaptive filtering and G-code optimization for different defect features.

Key Words: CNC system, Cloud-edge collaboration, Digital twin, Edge intelligence, Intelligent application

目 录

第 1 章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 数控系统智能化需求.....	1
1.3 国内外研究现状.....	3
1.3.1 智能数控系统研究现状.....	3
1.3.2 数控系统数字孪生研究现状.....	7
1.3.3 数控系统边缘智能研究现状.....	12
1.4 主要内容与组织结构.....	13
第 2 章 智能化数控系统领域模型及云边协同体系结构.....	15
2.1 智能数控系统领域模型.....	15
2.1.1 数字孪生.....	18
2.1.2 感知处理.....	19
2.1.3 价值评估.....	21
2.1.4 任务决策.....	23
2.2 基于云边协同的智能化数控系统体系结构.....	27
2.3 本章小结.....	30
第 3 章 数控系统数字孪生建模方法研究.....	31
3.1 数字孪生建模方法.....	31
3.2 智能化数控系统信息模型.....	32
3.2.1 互联互通应用场景.....	32
3.2.2 信息模型基本结构.....	33
3.2.3 基于映射的技术架构.....	35
3.2.4 基于 OPC UA 的映射方法.....	37
3.2.5 蓝天数控系统应用验证.....	40
3.3 智能化数控系统机理模型.....	43
3.3.1 通用机理模型.....	43
3.3.2 基于人工智能的机理模型.....	44
3.4 本章小结.....	48
第 4 章 基于边缘智能的模型部署方法研究.....	49
4.1 边缘智能关键技术.....	49
4.2 模型卸载方法.....	51
4.2.1 任务建模.....	51

4.2.2 模型切分算法.....	53
4.2.3 模型选择算法.....	54
4.3 数据划分方法.....	55
4.3.1 算法应用场景.....	55
4.3.2 任务建模.....	57
4.3.3 数据划分策略.....	59
4.3.4 实验分析.....	61
4.4 本章小结.....	65
第 5 章 智能数控系统应用服务研究	66
5.1 刀具磨损诊断及预测.....	66
5.1.1 刀具信息模型.....	66
5.1.2 刀具磨损诊断及预测机理模型.....	67
5.1.3 刀具磨损监控应用开发.....	74
5.2 加工轨迹优化.....	75
5.2.1 加工轨迹信息模型.....	77
5.2.2 加工轨迹优化机理模型构建及实验验证.....	80
5.2.3 加工轨迹优化应用开发.....	89
5.3 本章小结.....	91
第 6 章 结论与展望	92
6.1 主要内容和创新点.....	92
6.2 研究展望.....	93
参考文献.....	94
致 谢.....	103
作者简历及攻读学位期间发表的学术论文与其他相关学术成果	105

图目录

图 1-1 西门子 MindSphere PaaS 平台	4
图 1-2 发那科开放式 IIoT 平台	5
图 1-3 INC 体系结构	5
图 1-4 数控系统智能化硬件平台体系结构	6
图 1-5 智能数控系统二次开发软件平台	6
图 1-6 数字孪生五维模型	8
图 1-7 OPC 统一架构[57]	9
图 1-8 论文组织结构	13
图 2-1 数控系统层次化结构	15
图 2-2 数控系统智能体 UML 图	16
图 2-3 智能数控系统领域模型	17
图 2-4 感知处理信息来源	19
图 2-5 智能体层次结构	21
图 2-6 价值评估元素 UML 图	22
图 2-7 任务决策元素层次化结构	24
图 2-8 任务决策元素功能	25
图 2-9 任务决策元素 UML 图	26
图 2-10 智能化数控系统边缘组件和云组件	27
图 2-11 智能化数控系统云边协同体系结构	29
图 3-1 智能化数控系统数字孪生	31
图 3-2 数控装备互联互通应用场景	33
图 3-3 数控系统基础信息模型结构	34
图 3-4 内置式实现方式	36
图 3-5 外置式实现方式	37
图 3-6 XML 描述文件	38
图 3-7 基于 OPC UA 的机床实时监控系统结构	39

图 3-8 服务端运行控制台界面	41
图 3-9 基于 OPC Monitor 的客户端访问界面	42
图 3-10 基于 UA Helper 开源库的客户端访问界面	42
图 3-11 基于 OPC UA 的模型验证客户端界面	43
图 3-12 机器学习分类	45
图 3-13 LSTM 单元结构	46
图 3-14 TCN 深度神经网络结构	46
图 3-15 TCN 卷积层结构	47
图 4-1 基于 DDNN 的应用场景	56
图 4-2 基于 DDNN 的分类任务	57
图 4-3 数据分配策略	60
图 4-4 数据分配比例与数据处理总时间	63
图 4-5 参数 θ 对最优分配比例的影响	64
图 4-6 参数 θ 和 β 对惩罚系数 ξ 的影响	65
图 5-1 实验环境及工作流程	66
图 5-2 刀具信息模型	67
图 5-3 基于残差网络的刀具磨损监测模型	68
图 5-4 基于 TCN 的刀具磨损预测模型	69
图 5-5 刀具磨损预测结果	70
图 5-6 刀具磨损预测数据处理流程	72
图 5-7 子任务执行时延	73
图 5-8 子任务切分点选择	74
图 5-9 客户端功能展示	75
图 5-10 数控系统加工流程	76
图 5-11 实验环境及工作流程	77
图 5-12 轨迹优化流程	78
图 5-13 流水线处理方式	79
图 5-14 加工轨迹信息模型	80
图 5-15 CAD 模型及 G 代码	81

图 5-16 G 代码生成轨迹	82
图 5-17 轨迹点云及其局部放大	82
图 5-18 轨迹片段	84
图 5-19 点云聚类结果	84
图 5-20 轨迹法向量变化	85
图 5-21 滤波优化结果	87
图 5-22 轨迹滤波优化效果	89
图 5-23 G 代码优化结果	89
图 5-24 轨迹优化可视化客户端	90

表目录

表 2-1 任务词汇表	23
表 3-1 数据字典条目结构	34
表 3-2 OPC UA 节点信息描述	38
表 3-3 机理模型建模方法比较	47
表 3-4 通用机理模型与人工智能模型结合方式	48
表 4-1 模型优化方法	51
表 4-2 关键符号说明	58
表 4-3 参数设置	62
表 4-4 实验 1 结果	62
表 5-1 预测模型对比	69
表 5-2 子任务列表	71
表 5-3 特征统计与分级	86

第1章 绪论

1.1 研究背景与意义

以工业互联网、人工智能、云/边缘计算为代表的新一代信息技术正在高速发展,在于先进制造技术不断融合的过程中推动了以智能制造为代表的新一轮全球产业变革^[1]。德国“工业 4.0”提出将传感器、机器学习、云计算和物联网技术等应用于制造业生产中,实现数字化、智能化、自动化和网络化与制造业的充分融合,依靠信息物理系统打造数字工厂,提高生产效率和产品质量^[2]。美国工业互联网则提出将新一代传感技术、工业软件与生产设备深度集成,实现设备与人的互联互通,从实际生产过程中采集数据信息并进行深入挖掘,实现系统资源优化以及工作效率提升^[3]。日本产业重振计划提出,重点发展人工智能、大数据、物联网等新一代信息技术,通过产学研结合来加快相关技术的研发与应用,重构传统制造业的生产、销售与物流环节以提高生产效率^[4]。我国 2035 远景目标中提出需要推动制造业优化升级,深入实施智能制造,发展服务型制造新模式,推动制造业高端化智能化^[5]。通过“上云用数赋能”推进制造业数字化转型,培育先进制造业集群,推动集成电路、航空航天、高端数控机床等产业创新发展;“十四五智能制造发展规划”提出多项专项行动攻关智能制造技术,推进建设智能制造示范工厂,开展相关行业的智能化升级,并进一步推进智能制造装备与工业软件创新^[6]。

数控系统是实现智能制造的核心因素,是智能制造生产过程的关键环节,它能够直接影响到制造成本和生产效率^[7]。随着人工智能、工业物联网和云计算等智能制造技术的日益普及,作为先进制造技术与新一代信息技术深度融合的产物,数控系统正面临着新的发展机遇。通过新一代智能制造技术与数控系统的深度融合,可以实现生产数据的实时分析和预测,优化生产流程和生产质量,实现设备的远程监控和管理,提高生产效率和资源利用率。拥有感知、学习、决策并自主执行的新一代智能数控系统,是制造业向高端化、智能化方向发展转型的必然趋势^[10],也为数控系统的研制提出了新的需求。

1.2 数控系统智能化需求

数控系统的智能技术目前已经取得了大量的研究成果^[11],但到目前为止,大多数智能化技术只实现了感知、分析、反馈和控制等简单功能,相关技术和应用仍处于发展的早期阶段,尚未取得重大突破。为满足功能安全、可靠性等数控系统加工需求,传统数控系统往往采用相对独立的封闭式体系结构。开放式计算机技术的发展推进了数控系统发展,开放式数控技术使得数控系统的开发和使用成

本大大降低,也为新技术应用奠定了基础^[14]。近年来传感技术、工业物联网、工业大数据、人工智能以及云计算和边缘计算等新一代信息技术的蓬勃发展,为智能化数控系统的创新提供了更为充分的有利条件。与此同时,数控系统智能化发展也相应提出了新的需求。

(1) 智能数控系统缺少明确的定义,其技术框架和理论体系尚不完善。目前,人们往往认为具有一定智能技术水平的数控系统就是智能数控系统^[15]。事实上,它们通常是积累和组合一些简单的智能功能,智能化程度较低。为实现智能数控系统智能化需要构建智能化数控系统领域模型以及相应的体系结构,明确数控系统智能化概念,进而实现智能化数控系统认知的通用性和规范性。

(2) 需要建立通用建模方法,将信息技术和人工智能技术融合到数控系统中,以提高系统加工的精度、质量和效率。传统数控系统仅仅依靠理论分析和软件仿真实现系统建模和加工优化^[16]。然而,数控系统是一个复杂的动态系统,系统包含机械、动力、材料、控制等多种复杂系统元素^[17],这些系统元素在系统工作过程中相互关联影响,很难建立一个完整而准确的理论模型来描述系统结构和性能。此外,理论模型中的许多参数难获得准确的数值,基于理论建模和仿真结果的准确性是十分有限的,很难通过基于仿真结果的智能决策和控制实现最佳的加工结果。因此,实现数控系统智能化一方面需要建立语义清晰,结构完整的数控系统信息模型实现数据标准化反馈;另一方面需要将传统机理模型与人工智能算法结合,更精确的映射机床的加工过程。

(3) 需要发展数据实时感知处理技术。随着传感技术和人工智能技术在数控系统中的广泛应用,带来了网络传输延迟、数据处理成本加大、数据存储压力高导致的实时计算、数据安全等相关问题^[18]。作为云计算的有力补充,边缘计算结合人工智能形成的边缘智能技术为这些问题提供了有效的解决方案^[19]。边缘计算充分利用边缘以及终端的网络、计算和数据存储资源,将部分云服务从远离终端的云环境部署到设备边缘,有效降低了数控系统智能化应用的数据处理和网络传输过程产生的延迟^[21]。边缘计算采用以 Docker 和 Kubernetes 为代表的容器化架构部署数控系统智能化应用服务,在拥有一定数据处理能力的终端和边缘设备上部署深度学习模型,减少数据处理和数据传输成本,降低数据泄露风险,从而提高数控系统智能化应用的实时性和安全性。将边缘智能应用于数控系统,可以一定程度上满足系统实时性及隐私性要求并确保智能系统做出高效反馈控制。

(4) 近年来,智能制造技术在航空航天等精密加工领域的推广与应用对数控系统提出了更多的智能化应用服务需求。数控系统作为柔性生产单元不仅是加工设备,也是数字化车间以及智能工厂的重要组成。批量化、定制化的智能制造需求,要求新一代智能化数控系统具备现场感知、数据处理、价值评估等智能化功能应用,从而建立以数字孪生为核心的数控系统智能化制造过程闭环,实现数控系统在不确定加工环境中的智能决策行为。

1.3 国内外研究现状

1.3.1 智能数控系统研究现状

智能化数控系统是一种结合了人工智能和数控技术的新型数控系统。它具有自主决策、学习能力和自适应控制等特点，能够提高加工效率和精度，降低成本和能源消耗^[22]。当前德国、日本等工业发达国家的数控技术均开始进入智能化阶段，其研究机构和企业数控系统智能化技术的研究方面处于领先地位。

现有的数控系统智能化技术从应用角度出发主要集中于工艺优化、加工过程实时监测、误差补偿、质量监测以及系统预测性维护等方面。在工艺优化方面，Li 等^[25]以铣削过程为研究对象，建立包含表面粗糙度、材料去除率和加工能耗为优化目标的多目标优化模型实现工艺参数优化，以提高系统生产率和加工质量；Ghosh T 等^[26]基于改进的非主导排序遗传算法（NSGA-III），提出了一种机器学习和遗传算法混合的多响应加工工艺优化的通用技术，并在数控加工中应用这种多目标优化算法提高零件生产的收敛速度和性能。

在加工过程实时监测方面，You Z 等^[27]在刀具管理系统开发过程中，在保证数据质量和丰富性的前提下，采用数据增强技术解决数据规模问题，并构建基于云边协同的轻量级网络，引入自适应激活功能避免信息丢失，降低激活功能成本，解决了模型参数、数据规模、云迁移等问题。

在误差补偿方面，聂鹏^[28]基于神经网络的进给系统跟随误差建模方法，通过感知系统指令数据进行深度学习与训练，建立机床进给系统跟随误差预测模型，实现轮廓误差补偿，提高加工精度；Liang 等^[29]以机床为研究对象，提出了数据模型与物理模型混合建模的方法，优化热传感器在数控机床的数量和位置部署，并基于 LSTM 网络，在预测精度和计算效率方面对热误差进行建模。

在质量监测方面，Zhang W^[30]和 Chen C^[31]团队结合主轴转速、进给率、切削深度和铣削距离等铣削参数对表面粗糙度的影响，通过深度学习方法预测加工工件的表面粗糙度；Balasubramanian AN 等^[32]针对球头铣削过程，通过深度神经网络分析了球头铣削过程中施加在刀具上的切削力与切削参数之间的关系；Moreira L C 等^[33]则针对数控加工中表面质量和加工参数优化问题设计并开发了一套基于模型的参数优化控制闭环系统，包含表面粗糙度预测模型和多变量控制器，能够实现进给率和主轴转速实时监测和实时反馈控制，从而有效支持高质量的加工过程。

针对数控系统智能化技术，国内外众多数控系统及其相关企业进行了广泛的研究、开发与实践。德国西门子（Siemens）^[34]标准型数控系统 SINUMERIK 808、中端数控系统 SINUMERIK 828 以及 SINUMERIK 840 系列数控系统提供高可靠性的产品生命周期管理（Product Lifecycle Management, PLM），其中 Safety Integrated 软件通过安全停机、转速、传感器与执行器监控等功能进一步实现人

员和数控装备安全保障；高端数控系统 SINUMERIK ONE 将数字孪生技术引入数控系统，通过数字孪生体对 G 代码编程、工艺参数优化等工作流程进行完整的仿真和测试，并对机床生产能力和利用率进行优化；基于云计算技术的开放式物联网操作系统 MindSphere 通过 MindConnect 方案支持包括 MQTT、OPC UA、Modbus、S7、HTTP、HTTPS 等多种通信协议，能够实现从设备端到云端无障碍的互联互通以及互操作；此外，MindSphere 基于如图 1-1 所示开放式 PaaS 平台构建，通过高度可扩展的微服务架构提供应用程序编程接口（Application Programming Interface, API），可以提供丰富的工业应用和智能化服务组合满足客户需求。



图 1-1 西门子 MindSphere PaaS 平台
Figure 1-1 Siemens MindSphere PaaS platform

日本发那科（FANUC）高性能 0I 系列数控系统（包含 0I-A、0I-B、0I-C、0I-D 版本）提供进给轴加减速、反向间隙补偿、机床前端点控制，以及主轴温度控制、负载监控、主轴加减速控制等多种智能化功能应用。此外，如图 1-2 所示的 FANUC 工业物联网（Industrial Internet of Things, IIoT）平台 FIELD 系统（FANUC Intelligent Edge Link & Drive）^[35]将工业物联网与边缘计算技术引入数控系统，一方面基于平台开放性允许连接工厂中所有制造商的不同的数控装备，并且可以通过 FIELD 系统 App Store 以及第三方平台开发的应用实现用户的定制化需求；另一方面，FIELD 系统通过边缘计算/雾计算平台本地部署，允许客户选择生产数据是否上云，既降低了云计算过程中的通信成本，保证了智能化应用的实时性，又降低了用户数据泄露的风险。




图 1-2 发那科开放式 IIoT 平台

Figure 1-2 Fanuc open IIoT platform

国产数控系统厂商在数控系统智能化技术研究与实践过程中也取得了一定的成果。如图 1-3 所示，华中数控^[36]研制的华中 9 型智能数控系统（Intelligent Numerical Control, INC）通过加工过程指令、响应数据以及传感数据实时采集，建立物理机床响应模型构成数字孪生，实现了结合 G 代码和 i 代码双码联控模具加工质量优化，基于大数据学习的车削加工工艺参数优化，以及基于动力学及深度学习的机床进给系统混合建模及误差补偿等智能化功能和应用。




图 1-3 INC 体系结构

Figure 1-3 INC system architecture

沈阳中科数控^[37]基于“蓝天数控”已有的开放式数控系统开发平台，构建了

可重构的系统软硬件平台。其中，如图 1-4 所示的智能化硬件平台提供可重构式人机接口单元（HMU）和控制单元（NCU），可以根据客户需求，可实现人机接口单元和控制单元的多对多连接模式。此外，通过如图 1-5 所示的具有自适应、自调节能力的智能化软件开发平台，应用人员可以进一步开发出具有可扩展、可伸缩、可移植的智能化数控系统应用软件，满足工件原型分析、CAD/CAM 工艺设计、加工程序管理、刀具管理维护、机床控制调度、系统诊断维护等数控工艺链的应用需求。




图 1-4 数控系统智能化硬件平台体系结构

Figure 1-4 Hardware platform architecture for intelligent numerical control systems




图 1-5 智能数控系统二次开发软件平台

Figure 1-5 Secondary development software platform for INC systems

1.3.2 数控系统数字孪生研究现状

1.3.2.1 数字孪生相关概念

数字孪生概念起源于 Michael Grieves 教授于 2003 年在密歇根大学演讲中提出的“物理产品的虚拟数字化表达”^[38]。美国国家航空航天局 (NASA) 在 2012 年针对空军飞行器设计发表论文,首次明确了数字孪生相关概念^[39]。随着数字化、网络化和智能化的发展,数字孪生的定义也在不断发生变化,学术界和产业界对数字孪生的定义也各有不同。

学术界主要侧重于通过数字孪生的理论研究。例如 Chen 等^[40]对数字孪生体进行定义,认为它是一个物理设备或物理系统的计算机模型,代表所有功能、特征与组成元素之间的关系。Liu 等^[41]将数字孪生体视为能够反映物理设备或物理系统生命活动的计算模型,可以随着设备或系统任务的发展适应操作变化,并基于实时采集的数据和信息,预测相应的物理设备或系统未来的发展。Rv A 等^[42]将数字孪生体看作是一个物理实体的“数字代表”或“数字表示”,其中“数字代表”拥有来自多个贯穿产品生命周期的多个来源的持续更新的信息,并以各种方式进行可视化以预测当前和未来的条件,在设计和操作环境中提高决策水平。Madni 等 (2019)^[43]认为数字孪生体是一个物理系统在 Cyber 空间的虚拟实例,在其全生命周期过程中更新性能和健康状况数据。但上述研究大多没有针对实际应用,Wagg 等^[44]主要关注工程应用背景下的建模和仿真技术,在这种情况下,数字孪生可以被定义为是一个由模型和数据融合而成的系统的虚拟复制品,可以通过使用最先进的算法、专业人员和数据将模型和数据结合起来实现,与传统方法相比提高了系统的预测能力。Semeraro 等^[45]将工业领域的数字孪生看作是嵌入一个不断与现实同步的“虚拟”图像,为现实提供合理的知识模型,并对其进行解释以制定合理的决策。Kantaros 等^[46]把数字孪生体看作是一个准确反映人工或物理系统的非物理模型,通过放置传感器以获取有关该系统性能的各种数据,当数据更新时虚拟模型可根据数据变化进行模拟,通过对模型更新创造有价值的信息,并应用到物理世界中存在的原始系统对其改进。

在工业界中,企业通常结合自身产业发展开展数字孪生的相关研究。通用电气 (General Electric, GE)^[47]在 2016 年的一项专利申请中首次描述了对数字孪生的使用方法,并根据专利中提出的概念开发名为“Predix”平台的应用程序。该平台是一个用于创建数字双胞胎的工具,被用来运行数据分析和监控。西门子^[48]采用了工业 4.0 的概念,以云为基础的系统将机器和物理设备连接起来,在此基础上开发“MindSphere”平台。它使用所有的连接设备和数十亿以上的数据流进行分析和决策,能够为企业提供数字孪生解决方案。美国参数技术公司 (Parametric Technology Corporation, PTC)^[49]创建“ThingWorx”工业创新平台,其主要特点是采集 HoT/IoT 数据,并通过使用基于角色的用户界面进行展示,为用户提

供有价值的信息。

数字孪生体系结构的发展由简到繁可以分为三个阶段^[50]。

第一阶段是数字模型阶段，建模方法通过对现有的物理系统或理论模型进行数字表示。数字模型利用从物理系统收集的数据构建一个数字系统，根据仿真结果对物理系统进行仿真和控制，但是数字模型无法根据仿真结果对物理系统进行自动操纵。例如 Jay 等^[51]提出数字孪生是一种在云平台上与真实流程并行运行的设备耦合模型，可以利用数据驱动的分析算法模拟真实设备的健康状态等信息。

第二阶段是以虚映实阶段，数字孪生体以数字阴影为表现形式，是对数字模型的建模能力的进一步扩展。数字阴影集成了从物理对象到数字表示的单向数据流，物理系统状态的变化可以动态的改变数字模型，但数字模型状态难以反馈到物理系统。Kritzinger 等^[52]提出用户可以通过数字影子了解到设备实例的实时状态，在智能制造中需要高稳定性和高安全性的设备适合使用数字影子作为映射来分析数据。

当前，数字孪生体系结构已发展到第三阶段虚实结合。作为数字模型和数字阴影的延伸，与前两个阶段相比，现阶段数字孪生物理系统和数字模型之间是双向链接的。物理系统的变化可以通过数字模型反映，输出基于系统变量可能的结果，通过数字模型与物理系统的交互，实现系统仿真和预测。北京航空航天大学陶飞教授团队^[53]于 2019 年提出数字孪生五维模型通用参考架构，如图 1-6 所示将数字孪生抽象为物理实体 (PE)、虚拟实体 (VE)、孪生数据 (DD)、服务 (SS)、连接 (CN)，通过多尺度、多物理量的动态虚拟模型对物理实体进行仿真，实现了物理实体和数字模型之间的双向映射。




图 1-6 数字孪生五维模型

Figure 1-6 Digital twin five-dimensional model

作为实现智能制造的重要手段,数字孪生目前被广泛应用于数控系统智能化。Luo 等^[54]为了使数控系统变得更加智能,研究针对数控系统的多领域统一的数字孪生建模方法,探讨了物理空间和数字空间之间的映射策略,可以优化运行模式,降低突发故障的概率,提高数控系统的稳定性。

1.3.2.2 数控系统信息模型研究现状

数控系统数字孪生核心可分为信息模型和机理模型两个方面,其中构建数控系统信息模型实现互联互通互操作,是数控系统数字孪生的基础,也是数控系统智能化的关键使能技术,已经成为各国研究的热点。

OPC (OLE for process control) 标准于^[55]1996年由 OPC 基金组织发布,是工业自动化领域和其他行业中提供安全可靠数据交换的互操作协议标准。标准通过将不同总线通讯协议下的 PLC 抽象为标准接口,实现 PLC 与上位机 HMI 和 SCADA 系统间的互联互通。但原有的 OPC 标准基于 OLE/COM 和 DCOM 技术实现,受限于 Microsoft 平台。为解决该问题,2006年 OPC 基金会在 OPC 基础上将 OPC (Open Platform Communications) 重新定义为开放平台通信,发展了新的架构 OPC 统一架构 (OPC Unified Architecture, OPC UA)^[56]。



图 1-7 OPC 统一架构^[57]

Figure 1-7 OPC Unified Architecture

如图 1-7 所示的 OPC UA 多层信息框架通过定义元模型、通用基础模型到专属信息模型实现复杂系统的建模和扩展,并且通过定义特定的存取和会话机制实现对信息模型的访问。在此基础上,OPC 基金会在各个领域提供信息模型参考标准,如 OPC 40501 机床信息模型^[57]定义了机床的作业流程,实现了机床和上位机软件系统(如 MES、SCADA、ERP)之间的信息交互;2017 年德国机械工业协会 VDM 与 OPC 基金会联合发布 OPC 40502^[58],定义了计算机数控(CNC)

系统接口和数据交互方式的 OPC UA 信息模型。

美国机械制造技术协会 (The Association for Manufacturing Technology, AMT) 于 2006 年提出 MTConnect 标准^[59], 采用 HTTP 协议实现数控系统、设备与上位机应用软件之间的数据交互。MTConnect 信息模型面向数控机床数据采集, 更具针对性, 但对远程操作方法调用缺乏有效支持。从 2010 年开始, OPC 基金会与 AMT 展开合作, 针对 OPC UA 和 MTConnect 两种标准的异同在 2013 年发布了 MTConnect-OPC UA 结合规范^[60], 确保了 MTConnect 规范与 OPC UA 规范以及实现这些标准的制造技术装备、设备、软件或其他产品之间的互操作性和一致性。

国内针对数控系统数字孪生信息模型相关研究起步较晚, 但发展迅速, 目前已经取得了一定研究成果。2018 年, 中国数控机床互联互通协议标准联盟提出了自主研发的 NC-Link (Numerical Control Links) 协议^[61]。协议提供标准化接口和数据结构, 能够支持数控装备多源异构数据采集和反馈控制。

2020 年, GB/T 39561《数控装备互联互通及互操作》系列标准发布^[62], 标准率先解决了互联互通及互操作中的核心语义问题, 通过建立数控装备的两项对象字典标准^[63], 为数控机床和工业机器人装备的主要信息进行了准确的语义建模。在标准实现方面, GB/T 39561 提出了一种基于映射的技术架构^[64], 通过建立数控装备的设备描述模型, 能迅速且方便地采用多种现存通信协议, 可以充分利用现有通信协议成果 (如 OPC UA, MTConnect 等), 同时具有对未来新出现的各种通信协议的兼容和适配能力。

1.3.2.3 数控系统机理模型研究现状

机理模型是数字孪生的核心, 过程采用数学、物理等相关模型以仿真的方式描述物理实体, 可以通过数字孪生算法快速建立^[69]。常见的数控系统机理模型主要针对数控机床加工过程, 包含机床动力学、误差补偿等主要内容。

在机床动力学建模方面, 王煜天等^[70]在数控机床运动学分析基础上, 提出了一种基于 Jacobian 矩阵的加载机构速度传递性能的评价方法, 并对加载机构的动力学模型、速度传递性能及加速性能进行了仿真研究; 张星等^[71]探讨了数控机床多轴联动铣削加工动力学集成建模方法, 对多轴联动、铣削加工与零件加工精度和效率之间的量化关系与影响进行了深入研究; Hanjing Lu 等^[72]针对超精密飞切机床进行建模和仿真, 探讨了飞切头的气承刚度和切削工艺参数对加工表面的影响; Bilgili D^[73]提出一种计算高效的多体动力学模型, 从机床结构的降阶弹性模型模拟机床结构的位姿相关动力学, 极大程度减少了动力学模型参数;

机床误差建模方面, 刘阔等^[74]设计了机理驱动的机床进给轴时变误差模型, 对卧式加工中心进行了实时补偿, 大幅提高了机床的精度和稳定性; Chao Liang 等^[75]为了获得机床各轴的影响, 确定机床的关键轴, 提出了机床各轴的几何误差贡献建模和灵敏度评估方法; Martin M 等^[76]提出了一种基于传递函数的热误差

补偿模型,在大型卧式加工中心的机床管理软件中实现了热误差实时补偿的数学模型。

物理和数学模型驱动的机理模型,可以更合理的解释的建模过程和输出结果,对系统有很好的表达能力。但传统机理模型难以描述复杂对象,对由机床、控制器、伺服等数控系统组件耦合形成的复杂加工系统建模能力有限^[77]。作为机理模型的补充, AI+机理模型^[78]的建模方式一方面能够满足机理模型可解释性和通用性需求,更能兼顾深度学习等人工智能方法便捷精确的优势。

目前人工智能方法在数控系统智能化技术中应用广泛, Liang 等^[79]基于数字孪生概念,提出一种用于刀具磨损监测与寿命预测的数字孪生模型,根据刀具的不同磨损阶段,提出了 3 种监测和预测模式,充分利用了多维数据信息的价值;孟博洋等^[80]详述了以人工智能、数字孪生以及云服务为代表的新一代信息技术在智能数控系统中的应用和挑战,并对智能化数控系统发展进行了展望; Kiswanto G 等^[81]实现了数字孪生技术在微铣削过程中的应用,所提出的数字孪生模型能够通过主轴电机的电流数据预测微型工具的磨损状况。

此外,在机床误差补偿方面, Li B 等^[82]针对机床工作环境复杂、热误差预测建模困难、传统热误差预测模型精度低的问题,通过改进粒子群优化方法与反向传播神经网络结合实现主轴热误差预测模型; Ma C 等^[83]为提高复杂零件的加工精度,提出一种基于数字孪生自学习的精密机床热误差控制方法,通过误差机理分析,从理论上和数值上揭示热误差的记忆性,证明长短期记忆(long short-term memory, LSTM)神经网络在自学习误差模型训练中的适用性; Lu C 等^[84]为了提高激光切割的加工精度,基于数字孪生体技术的时变特性,建立了热弹塑性有限元(TEP-FEM)和 T-XGBoost 算法相结合的混合模型,该策略解决了切削过程中不可控的热变形问题,为实现预测加工和质量监控等智能操作策略提供了理论解决方案。

在机床工艺优化研究方面, Liu L 等^[85]提出一种数字孪生驱动表面粗糙度预测与工艺参数自适应优化方法,实现了加工过程实时监控、准确预测与优化决策的有机结合,解决了加工过程质量与效率不一致的问题; Yang 等^[86]提出了一种用于预测传动系统的性能退化的数字孪生技术混合方法框架,将物理退化过程的机理与实时和历史数据相结合; Tong X 等^[87]在数字孪生中开发了多种形式的人机交互接口和应用程序,用于数据可视化和分析,包括加工轨迹、加工状态和能耗。

目前关于数字孪生中机理模型的研究主要集中在数控系统及其配套制造设备的模型精度和系统实时性方面,以支持智能制造系统的发展。将现有机理模型构建方法与人工智能、云/边缘计算等技术相结合能有效提高数控系统数字孪生的准确性、效率和可靠性^[88],支持数控系统智能化的发展。

1.3.3 数控系统边缘智能研究现状

数控系统是一种由不同子系统组合而成的复杂系统,其加工过程受多方面因素影响,需要通过以机器学习为代表的人工智能算法^[89]来实现数字孪生。但现有数控系统计算能力不足,无法承载海量数据的分析处理,数控系统数字孪生更倾向于将采集到的设备数据上传至远程云数据中心进行处理^[90]。

数控系统网络资源有限,这种依赖云的数据处理方式将会导致数据传输代价高、网络拥塞、数据传递滞后和隐私性差等问题^[93]。边缘计算作为一种新型的计算模型^[18],能为数控系统提供下行的云服务以及上行的互联互通服务,是云计算的有效补充。与云计算相比,边缘计算适用于高实时性、短周期数据、本地决策等场景^[95],通过将算法应用服务从云计算中心下沉到设备终端和设备边缘,能够有效解决上述问题^[99],在学术和企业界产生了大量成果。

作为边缘计算思想的早期实践,1998年 Akamai 公司^[103]提出内容分发网络(Content Delivery Network, CDN),通过在网络边缘部署缓存服务器提供网络负载均衡服务,降低终端网络访问延时,提高网络响应速度和命中率。物联网和 5G 技术的发展进一步推动了边缘计算技术的发展。2014 年,欧洲电信标准化协会成立移动边缘计算(Mobile Edge Computing, MEC)工作组^[104],美国电话电报公司(AT&T)、思科(Cisco)、通用电气(GE)等公司成立工业互联网联盟(Industrial Internet Consortium, IIC),推进边缘计算以及工业互联网的标准化发展。与此同时,国内科研机构和企业也开始了边缘计算相关研究工作,中国自动化学会于 2017 年成立了边缘计算专业委员会,边缘计算产业联盟于 2018 年发布《边缘计算参考架构 3.0》。

近年来,随着算法、算力等相关技术的进步,深度学习正在飞速发展并极大程度深入工业领域,为智能制造的实现提供了极大的支持。然而如何将深度学习为代表的人工智能模型高效部署在数据存储、计算和网络资源相对受限的设备边缘和终端,解决人工智能在现实应用场景的落地,仍然是边缘计算技术面临的关键问题。在此基础上 Zhou 等人^[19]提出了边缘智能的概念,旨在将人工智能算法部署在靠近用户和网络边缘,学术界同时涌现了一系列面向边缘智能的深度学习模型训练和推理优化技术。

在模型推理技术方面, Lane^[105]等人采用模型剪枝的方法对 DNN 模型进行压缩,从而降低模型复杂度,更好地在资源受限的设备终端和边缘实现满足延迟需求的模型推理; Surat^[106]等人提出一种分布式深度神经网络框架,通过提前结束模型推理获得最终输出结果,加速了深度学习模型的推理。在模型训练优化方法方面, Kang Y^[107]设计了一个轻量级的调度器 Neurosurgeon,以层为单位在设备和数据中心之间自动划分 DNN 计算,实现边缘协同模型推理,从而获得更好的实时性能; Yu Z^[108]等人提出基于联邦学习的分布式边缘计算模型,采用轻量

级神经网络减少模型训练时间,缓解终端设备的推理压力;Li E^[109]等人联合模型分割和模型提前退出两种技术手段提出了基于端边协同的深度学习推理加速框架 Edgent,通过优化模型退出点与分割点的选择来满足应用需求。

1.4 主要内容与组织结构

数控系统作为数控机床的大脑,其智能化程度是智能制造推进和发展的支撑和保障。本文针对数控系统的智能化需求,从数控系统领域模型出发,提出了基于云边协同的智能化数控系统体系结构,开展了智能化数控系统数字孪生通用建模方法和基于云边协同的模型部署方法研究,并在此基础上给出两个边缘智能驱动的数控系统数字孪生应用实例。论文组织结构如图 1-8 所示,主要内容如下:




图 1-8 论文组织结构

Figure 1-8 The structure of this paper

第1章:本章主要阐述了对数控系统智能化相关技术研究的背景与意义,介绍了数控系统数字孪生以及边缘智能技术的国内外研究现状,最后给出了本文的主要内容和组织结构。

第2章:本章从数控系统智能化需求出发,基于智能化系统概念、特征对智能化数控系统进行抽象,围绕数控系统数字孪生模型提出了基于包含感知处理、价值评估、任务决策等智能要素的智能化数控系统领域模型,详细阐述了模型各个智能元素的功能与实现方法,由云端负责模型构建及部署,边缘执行实时任务,以云边协同的方式实现数控系统的智能化。在此基础上,将数字孪生和边缘计算

等智能化关键技术引入智能化数控系统,优化以云计算为核心的传统数控系统体系结构,提出了基于云边协同的智能化数控系统体系结构,发表论文《Edge intelligence-driven digital twin of CNC system: architecture and deployment》。

第3章:本章基于第2章提出的智能化数控系统领域模型和体系结构,描述了智能化数控系统互联互通互操作应用场景,提出基于映射的信息模型构建方法,通过 OPC UA 构建了智能化数控系统基础信息模型;依托于2016年智能制造综合标准化项目“面向智能制造的数控装备互联互通及互操作 标准及试验验证”,参与起草了系列标准《数控装备互联互通及互操作》(标准成果已经发布),并在蓝天数控 GJ430 实现应用验证,发表论文《Research on CNC Machine Tool Monitoring System Based on OPC UA》;在此基础上,分析智能化数控系统机理模型构建方法以及关键技术,提出一种人工智能辅助机理模型的通用建模方法。

第4章:本章在智能化数控系统体系结构中引入边缘智能技术,详细阐述了云边端协同任务中机理模型的卸载优化方法。针对模型切分问题,在单一的任务实时性指标基础上补充了系统数据吞吐率指标,提出了混合指标机理模型任务切分算法,并在此基础上以实时性和准确性为指标提出一种自适应的模型选择算法。此外,针对边缘数据资源,提出了以分布式深度神经网络(Distributed Deep Neural Network, DDNN)为应用场景的数据划分优化方法,并进行实验分析验证了算法的有效性,发表论文《IIoT Based Hierarchical Data Distribution Strategy over Edge and End Device》。

第5章:本章基于第3章提出的智能化数控系统信息模型和机理模型通用建模方法以及第4章提出的基于云边协同的模型部署方法,搭建边缘智能应用环境,在刀具的信息模型基础上部署了基于残差神经网络和 TCN 的刀具磨损机理模型,实现了刀具磨损实时监测与预测,发表论文《Edge intelligence-driven digital twin of CNC system: architecture and deployment》。此外,在轨迹优化应用中建立数控系统加工轨迹信息模型,提出了一种基于聚类分析的缺陷路径优化方法,实现了缺陷路径自适应滤波优化与可视化。

第6章:本章对本论文的研究工作和取得的研究成果进行了总结,指出了本文的不足之处,并对后续的研究工作进行了展望。

第2章 智能化数控系统领域模型及云边协同体系结构

数控系统是一种以插补运算、伺服控制为主要功能的机电一体化设备，能够有效解决复杂、精密、小批量、多品种的零件加工问题。信息与通信技术的发展，推动数控系统从传统的封闭式结构走向开放，使其在制造车间得到普及。随着万物互联时代的到来，物联网、人工智能和边缘计算等技术的飞速进步为智能化数控系统的研制创造了条件。图 2-1 显示了智能化数控系统的制造闭环，传感设备和计算设备为现有数控系统带来自感知、自调整、自预测和自评估等自适应控制能力，丰富了数控系统的功能和服务，也进一步扩展了其层次结构。




图 2-1 数控系统层次化结构

Figure 2-1 Hierarchical structure of CNC system

本章首先梳理了系统智能化概念，提出了智能化系统领域模型建模方法，并根据数控系统智能化需求以及数控系统层次化结构特点构建了智能化数控系统领域模型和基于云边协同的系统体系结构。

2.1 智能数控系统领域模型

智能系统概念多种多样，本文引用^[110]对智能的定义，将智能理解为系统在不确定环境中的自适应能力，其程度水平通过以下因素决定：系统(或计算机)的计算能力；系统用于感知、建模、评估、执行和信息传输的算法复杂度；系统存储的信息和知识。




图 2-2 数控系统智能体 UML 图

Figure 2-2 UML diagram of CNC system intelligent elements

为了更好的表达数控系统的智能化水平，抽象出数控系统智能体，本文从计算能力、算法、数据信息三个角度描述系统的智能程度，并建立了其模型图如图 2-2 所示。

抽象的智能体类具有算法、算力、数据属性以及与其它智能体交互通信的方法，算法、算力、数据属性由各自的类进行封装。算法类是工具类，集成常用机器学习(如 Sklearn)、深度学习(如 Pytorch)、强化学习（如 OpenAI Baselines）等框架提供的算法或自行编码实现的算法。算力类也是工具类，提供该智能体总算力、可用算力等属性，并提供算力评估方法，算力评估方法的具体实现需要考虑逻辑计算能力、并行运算能力、神经网络运算能力、实时性能指标上的表现等因素。数据类由基类和其派生出的其他子类实现，基类对数据抽象，表述数据的基本特征，其派生出的子类表示多样化的数据，如图片、视频、声音等数据类分别由数据基类的派生类实现。通信方法的实现中由支持的通信协议类分别实现，利用通信方法的参数进行通信协议、通信端口等的选择。

为便于智能化数控系统的设计和实现，在数控系统数字孪生体系结构基础上，将智能数控系统分解为内部智能元素和外部应用组件^[110]。其中系统的输入和输

出通过以传感器为代表的数据采集装置和以数控装置为代表的执行器两个外部功能部件实现。系统的智能体则围绕数控系统数字孪生体构建，将包含感知处理、价值评估、任务决策的系统功能抽象为智能元素，实现智能化数控系统自主感知，自主控制和自主学习功能。下面本章将对智能化数控系统领域模型进行详细介绍，如图 2-3 所示。




图 2-3 智能数控系统领域模型

Figure 2-3 Field model of intelligent CNC systems

(1) 执行器：智能数控系统的输出由执行器产生。一个智能系统针对不同应用场景可能有多种执行方式和执行机构，在数控系统中执行器可以为主轴电机、伺服系统、传感器等多种功能组件，为了执行任务和实现目标，所有这些机构都必须进行协调。

(2) 传感器：智能系统的输入是由传感器产生的，传感器可以包括视觉、亮度、力、力矩、位置、速度、振动、声学、量程、压力和温度等多种传感装置。传感器用于监控数控系统外部加工环境状态和数控系统本身的内部实时加工状态，为感觉处理系统提供输入。

(3) 感知处理：数据处理过程发生在感知处理系统元素中，该智能元素将感知到的系统状态与数控系统数字孪生模型生成的预测以及仿真结果进行比较。感知处理算法通过时间、空间等多个角度分析观测和系统预测结果的相似和差异性，从而实现特征提取、模式识别和分类等具体功能。

(4) 数字孪生：数字孪生模型是智能系统对外部环境和系统本身的数字孪生建模。数字孪生模型包括一个关于世界的知识数据库，以及一个存储和检索信息的数据库管理系统。数字孪生模型与其他智能元素实时交互并由感知处理系统元素保持更新。

(5) 价值评估：价值评估模块对系统任务评估和优化。在此过程中，价值评估系统元素对观测到的系统状态，加工成本和收益等价值因素进行评估，在此基础上，结合数字孪生模型预测的加工计划执行结果对系统任务进行优化。

(6) 任务决策：智能数控系统的任务决策组件将系统任务递归分解为子任务，并对子任务进行排序和规划，以实现任务目标。智能数控系统在执行加工任务过程中通过任务决策，数字孪生和价值评估元素之间的循环交互完成任务目标。任务决策系统首先根据任务需求制定任务目标和加工计划；数字孪生模型预测这些计划的结果，并通过价值评估元素对系统任务进行评估和优化；最后，任务决策系统选择具有最高评价的计划执行系统任务。任务决策系统元素还监视计划的执行，并在情况需要时修改现有计划。

2.1.1 数字孪生

数字孪生模型是智能系统对系统外部世界的内部表达，该模型为智能系统提供物理实体或外部环境的属性、结构、状态、性能、功能和行为等信息，以便智能系统观察、认知、理解、控制并改造物理实体或外部环境。

智能系统数字孪生模型由信息模型和机理模型两部分组成。其中，信息模型描述物理实体或外部环境的几何参数（形状、尺寸、位置等）、实体关系（如从属关系）、物理属性（如温度、湿度等）、约束等可以通过数据结构表征的显式知识。显式的信息模型需要能够映射转换、协议传输、寻址和列表处理的计算模块，这部分的具体实现将在第3章中讨论。机理模型描述物理对象的行为（如演化行为、功能行为、性能退化行为等）和规则（经验、标准、准则等）等隐性表示的知识，这类模型需要嵌入到感知处理、价值评估以及任务决策模块的算法中，因此机理模型的实现需要物理模型，数学模型，机器学习，边缘计算等多学科技术辅助实现，具体的实现和部署机制将在第4章和第5章讨论。

作为智能系统的核心，数字孪生模型与感知处理、任务决策以及价值评估模块之间的交互关系如图2.3所示。数字孪生模型模块一方面将新识别的实体、状态和事件输入到知识库中，丰富现有信息模型和机理模型；另一方面维护存储信息模型和机理模型的数据库的时效性和一致性，根据模型预测结果和感知结果的相关性和差异更新数字孪生模型的状态。

在与感知处理模块的交互过程中，数字孪生模型模块对原始的传感器输入数据进行数据处理，形成对物理实体以及环境变量的状态信息预测，供感知处理模块进行相关性分析、模式识别和分类。例如，在刀具磨损监测过程中，刀具数字

孪生模块可以通过实时监测得到的刀具磨损信息预测若干轮加工后刀具的磨损情况，从而对刀具进行及时的管理和维护。

在与价值评估模块和任务决策模块的交互过程中，智能化数控系统的数字孪生模型获取价值评估模块对感知处理结果的判断，对当前数字孪生模型状态进行评估和标记，更新和优化数控系统数字孪生模型中各个子系统的数字孪生体；任务决策模块查询系统的对应数字孪生模型获取当前数控系统的外部环境和内部加工状态，并在此条件下制定和划分加工任务；系统数字孪生模型对任务决策模块产生的任务计划进行仿真，预测任务产生的预期结果，并将数字孪生模型仿真得到的预测结果发送到价值评估模块进行评估和优化。任务决策-数字孪生-价值评估循环使任务决策模块能够选择产生最佳评估的假设行动序列作为将要执行的计划。

2.1.2 感知处理

在智能系统领域模型中，感知处理过程是在传感器获得的系统信息以及环境信息基础上实施的。对应于智能化数控系统，这些信息包括传感器采集到的数控系统生产加工环境信息以及加工过程产生的信息。感知处理过程与数字孪生模型密不可分，它对传感器数据进行操作，提取物理实体以及工作环境的特征信息，创建并更新数字孪生模型，向数字孪生模型提供维护系统知识所必须的信息。

智能系统中感知处理模块的输入是由感知设备获得的，一切可感知的数据均可对智能系统的优化和决策做出贡献。在智能化数控系统应用场景中，数据采集过程分为两类^[11]，一部分数据采集过程由各种传感设备间接完成，对应数控系统外部加工环境数据，另一部分数据则由数控系统内部程序直接获取，对应数控系统实时加工数据，如图 2-4 所示。智能化数控系统的感知对象包括数控装置、伺服驱动、机床、PLC 等。




图 2-4 感知处理信息来源

Figure 2-4 Sources of information for the perception process

对于数控机床,可采集的数据类型主要为外部加工环境数据,包括振动、温度、噪声等。这些数据均可通过传感器等数据采集装置感知获得。对于伺服系统,可采集的数据包括内部数据和外部数据两类,其中内部数据包括伺服系统实时反馈的进给速度、位置信息等,这些内部信息需要通过数据采集程序获得;外部数据包括主轴电压、主轴电流等,需要通过传感器获得。

对于数控装置,可采集的数据主要为内部数据,包括加工参数、加工指令、工艺参数等相关数据,这些数据可以通过数据采集程序获得。对于 PLC 等设备,核心数据包括状态位等相关数据,也可以通过数据采集程序获得。

感知处理模块主要执行数据预处理以及数据特征提取两类数据处理过程。在实际的数据处理过程中,传感器提供给感知处理过程的原始数据一般是多数据源且数据格式多样化的数据^[112],而这些多源异构数据往往还存在数据准确性、完整性、一致性、时效性等一系列相关问题,严重影响算法执行以及数字孪生模型的创建和更新。数据预处理将尚未组织成实体的基本信息单元规范约束为被泛化的实体,对收到的信息运用不同形式的数据清洗、数据集成、数据归约以及数据变换功能来初步筛查有用信息,得到标准、干净、连续的数据,以便后续的特征提取。

感知处理模块的特征提取过程认知和识别前一阶段数据预处理后的信息,对数据预处理阶段后数据的进行标记和分类,从而实现智能数控系统对物理实体和环境的状态感知,也为数字孪生模型更新做准备。这一过程主要实现两个目标:首先需要获取数控系统加工实体属性和状态的最佳估计,在此基础上对产生的最佳估计计算置信度。

前者通过各传感测量,将预处理信息加载到已知的环境变量和实体变量中,通过数字孪生模型提供的预测值与传感器采集的观测值进行回归估计操作。后者利用观测和预测值之间的方差更新最佳估计,并计算此最佳估计的置信度,从而确定数字孪生模型创建的实体模型的精确程度实现模型的更新。

智能系统的各节点闭合一个控制回路。传感器输入的数据经感知处理模块处理,并被数字孪生模型使用,以更新知识数据库。这一过程提供了当前实体和环境的最佳估计和预测状态。实际加工过程中,数字孪生模型通过行为生产模块将反馈信号施加于执行器加工过程,执行器如伺服系统通过计算获得所需的补偿指导电机的加工,使期望和预测之间的反馈误差达到最小。




图 2-5 智能体层次结构

Figure 2-5 Hierarchy of Intelligent agents

如图 2-5 所示，在各模块内感知处理过程进行特征提取和模式识别工作，规划和控制功能都是以在数字孪生模型知识库中维护的知识为基础进行实施。高层次智能体系统元素识别低层次智能体元素，维持并更新数控系统内部和外部环境模型，使有关此节点的规划和控制功能得以实现。在各智能体内的数字孪生体驱动感知处理模块分析实时数据和历史数据，指导任务决策模块制定实时或未来任务，从而实现数控系统自主感知、自主决策、自主执行。

感知处理功能是任务相关和目标导向的。任务决策模块获得的任务命令指定实体对象执行具体相关任务，此时数字孪生模型从知识库中选择含有任务对象的信息模型和机理模型。然后，将该任务相关子模型部署到能快速响应的短期存储器中。在短期存储器中，任务子模型可以用于产生感知处理过程的期望和分组假设。任务命令也通过价值评估模块评估任务目标和诸如优先级的任务参数，与感知处理、任务决策模块共同执导执行器加工过程。

2.1.3 价值评估

智能数控系统作为智能体，其行为由目标导向，因此我们将强化学习概念引入数控系统实现智能化。在执行加工任务时需要结合感知处理模块提供的环境状态对加工任务/动作的可能结果进行预测和评估，从而获得更高的收益。在此过程中，价值评估模块作为实现数控系统智能化的重要智能要素，负责评估数控系统各项任务计划的成本、风险和收益，以及加工过程中各种相关事件的可取性和可能性。智能系统中的价值评估模块产生可以表示为强化信号的激励。强化信号可以标记智能数控系统加工对象（工件材料等）、加工工具（刀具和夹具等）、加工

环境、加工任务和计划（工艺文件等）等目标实体的好坏程度、重要性，可靠性。任务决策模块通过强化信号记录各项任务的累计回报，并采用累计回报最高的策略制定任务规划。

强化信号主要包括以下主要属性：优良度、优先级、驱动力。其中优良度提供任务好坏的估计，可被分配到实体、事件、任务的属性列表中，为在各种情形下如何对行为做出决策提供了判断依据；优先级提供重要性的估计，可将其分配给任务列表中，使任务决策模块规划器和执行器能决定任务的优先级，从而制定任务计划。驱动力为加工任务需求进行估计，可将驱动力分配给数控系统加工任务的各个环节中，说明内部系统的需求，如物料剩余量、排产压力、刀具磨损量以及任务剩余时间等相关信息。

当感知处理模块感知环境时，强化信号提供了对环境状态的评估。在模型中，强化信号是智能的重要组成部分，通过强化信号评估感知输入，选择目标，指导行为和学习控制。强化信号由位于价值评估模块中的状态-动作值函数计算，价值评估模块输入实体、事件的情况和状态，通过值函数计算成本、风险和效益输出策略。

如图 2-6 所示，在智能数控系统中可以通过 UML 图表述如何实现价值评估模块的方法。其中，优良度主要包括 good、bad 等相关属性，优先级主要包括 cost、risk 等相关属性，驱动力需要根据不同应用任务提供相关信息，属性名可以根据不同任务需求产生变化。




图 2-6 价值评估元素 UML 图

Figure 2-6 UML diagram of value judgement elements

价值评估模块在智能系统中提供做决定的基础。在智能数控系统中，价值评估是系统执行任务时做出选择的主要参考。面对智能数控系统具体应用场景，需

要通过价值评估模块评估数字孪生模型的观察状态和评估假设计划的预测结果，同时计算观察到的情况和计划活动的成本、风险和收益。例如数控系统的刀具管理，针对传统数控系统中常见的加工出现断刀等相关问题，在智能数控系统中，感知模块对刀具当前情况等数据进行数据采集，价值评估模块根据刀具的状态、寿命(设定寿命、预警寿命和实际寿命)、几何参数(刀具长度和半径)、额定主轴转速和进给速度、刀具磨损等数据做出是否进行换刀任务的决策，可以很好的解决刀具断刀及由于磨损导致的加工精度问题。

2.1.4 任务决策

任务决策模块主要作用为选择目标、计划和执行任务，它将任务递归分解为子任务，并对子任务进行排序以实现任务目标，通过任务决策、数字孪生体和价值评估元素之间的循环交互，选择任务目标并制定任务计划。在三者交互过程中，任务决策模块制定任务实施的计划，数字孪生模型结合感知处理模块提供的系统和环境状态预测计划的结果，价值评估模块基于数字孪生模型预测的结果对任务计划进行评估，最后任务决策模块选择具有最高评价的计划执行。此外，在执行过程中，任务决策模块还负责对任务状态进行实时监控，并在情况需要时修改现有计划。

数控系统功能的层次化结构特点决定了任务决策本质上是一个分层的过程。在任务决策层次结构的每一层，任务都被分解为子任务，这些子任务成为下一层的总体任务。在任务决策层次结构的每个级别上都存在一个如表 2-1 所示的任务词汇表和一组相应如图 2-7 所示的任务框架。

表 2-1 任务词汇表

Table 2-1 Task List

名称	描述
任务名称	描述任务名称；
任务类别	任务为通用任务或特定任务；
任务执行者	任务执行代理；
任务动作	任务需要执行的操作步骤；
任务对象	任务执行面向的对象；
任务目标	任务执行需要达到的目标；
任务参数	包含任务优先级、风险、实时需求等相关参数；
任务需求	刀具、加工时间、工件原料、工艺需求等；
任务程序	任务加工计划的状态图或状态表，包含可能需要的功能或算法；




图 2-7 任务决策元素层次化结构

Figure 2-7 Hierarchical structure of behavior-generating elements

任务决策包括空间分解和时间分解。空间分解将任务划分为由不同子系统执行的子任务。空间任务分解形成树状结构，每个节点对应一个任务决策模块，树的每个弧线对应信息流和控制流。时间分解沿着时间线将每个任务划分为顺序的子任务。结果是所有子任务完成后，实现任务目标。

任务目标和任务分解函数通常具有特定的空间和时间属性。对于任何任务，都存在一个任务层次，以数控系统的机床加工运行过程为例：

第一级是协调机床加工的刀具速度和加速度命令分解为针对单个进给轴执行器的运动命令；

第二级是将数控系统的机动指令分解为平滑、协调、动态、高效的轨迹；

第三级是将操作、运动命令分解为避免障碍和奇点的无碰撞路径；

第四级将生产单元的加工任务分解为单个数控系统启动和加工排序；

在此基础上还可以将任务进一步类推扩展到生产线层以及车间层；

在智能数控系统的架构中，层次结构的每一层都包含一个或多个任务决策模块，并且在每个级别上，每个被控制的子系统都有一个任务决策模块。任务决策模块的输入主要包括来自更高层次的任务决策模块的命令和优先级，来自相邻价值评估模块的评估，以及来自相关数字孪生模型中的系统和环境状态信息。任务决策模块的输出通常包括对下一层的任务决策模块的子任务命令，当前系统状态，以及对应任务中每个动作对应的状态-动作值函数。

如图 2-8 所示，任务决策模块的具体实现主要包括三个子功能模块，分别为任务分配子模块、任务规划子模块、任务执行子模块，通过这三个子模块实现整个任务决策过程。




图 2-8 任务决策元素功能

Figure 2-8 Function of the Behavior Generation element

任务分配子模块负责在空间角度对任务进行分解。它将输入任务命令划分为若干个空间上的不同任务，同时将工具和物理资源分配给每个从属子系统，并由不同的子系统执行。在三轴数控系统加工任务中，加工过程被分解为 X、Y、Z 轴三个方向的运动轨迹，并由控制器分配给 X、Y、Z 进给轴伺服系统分别完成。

任务计划子模块在时间角度对任务进行分解，将分配给子系统的工作分解成子任务的时间序列。简单的任务计划可以由基于具体任务的规划者实现，规划者只需从任务框架的过程部分中选择相应的计划即可实现。例如速度控制伺服系统，只需要按照给定的速度指令进行运转即可完成加工任务。这些任务所涉及的执行器动作和相关激励较为单一，因而制定的相关策略也较为简单。

但每个层次上的任务计划(每个计划包含许多条件分支和错误恢复例程)所生成的动作范围可能非常复杂，难以对任务计划的值状态函数进行直接计算。此时任务计划也可以由基于策略搜索方法实现，这些规划器搜索可能的操作空间，对所有子任务时间序列进行采样，数字孪生模型模块预测这些行动的影响，价值评估模块计算得到的预期状态的值，以累积回报期望增大为目标改进现有的任务决策。

以时间敏感加工任务为例，分配给一个子系统的任务也需要与分配给其他子系统的任务进行同步或协调。这些约束和协调需求一般通过任务优先级确定。每个计划子模块负责与同一级别的其他规划者进行沟通，监视生成的计划是否存在

冲突。如果发现冲突，则需要规划者之间进行协商寻找解决方案。如果找不到解决方案，规划者向任务分配子模块报告失败，可以尝试新的任务分配，或者向下一级任务决策模块报告失败信息。

每个计划子模块都对应一个任务执行子模块。执行子模块负责执行由各自的计划子模块生成的计划。在数字孪生与任务决策模块的每个通信周期，执行器都度量当前数字孪生模型状态和它的当前计划子目标状态之间的差异，并发出子命令。当数字孪生模型表明当前计划中的某一个子任务已成功完成时，执行器将进入该计划中的下一个子任务。当前计划中的所有子任务都成功执行后，执行器将转向下一个计划中的第一个子任务。如果反馈表明计划中的子任务失败，则执行器立即转移到预先计划的紧急子任务。与此同时，它的计划者开始选择或生成一个新的计划，以替代失败的前一个计划。以进给系统跟随误差补偿为例，在数控系统运动控制过程中，伺服系统实际位置总是滞后于指令位置，造成跟随误差。智能数控系统可以基于机床历史运行数据，采用人工智能方法学习跟随误差与指令数据之间的关系，构建进给系统跟随误差预测模型，在每个插补周期针对进给系统反馈当前位置信息对位置指令进行补偿，从而提高加工精度。

如图 2-9 所示，在智能数控系统中可以通过 UML 图表述如何实现任务决策模块的方法。任务决策模块需要提供任务分配功能，从而实现任务规划子模块。规划子模块分解的任务由子系统提供的计划功能和执行功能实现。任务词汇表中主要存储任务相关的信息。




图 2-9 任务决策元素 UML 图

Figure 2-9 UML diagram of behavior generating elements

在智能数控系统中，任务决策模块将不同应用的相关功能分解成子任务，子任务按照先后顺序或优先级等信息进行排序，根据功能需求的不同，可将任务分

解和调度工作通过云边端实现提升处理效率。同时任务决策模块还需监测当前任务的执行状态，在情况需要时修改现有的计划。

2.2 基于云边协同的智能化数控系统体系结构

随着工业现场传感器种类和数量的增多，数据量呈爆炸性增长，信息模型规模随之变大。同时，人工智能技术的发展带来了多样化的机器学习算法，进而导致智能化数控系统机理模型的复杂度增加。为了满足数控系统智能化对计算资源的巨大需求，刘超提出了一种基于云计算的数控系统数字孪生体系结构^[113]，该体系结构在物理层，通过 CNC 控制器和不同种类的数据采集装置采集数控机床的实时制造数据，并通过网络层上传至信息模型中。在 Cyber 层，利用云数据处理中心的强大算力将实时数据与智能算法、数据库相结合进行仿真、优化，并为用户提供增值服务。

然而随着数控系统智能化需求的进一步深化加强，单一的以云为核心的智能化数控系统体系结构面临更多的挑战。一方面云计算面临规模日益庞大的数据处理和模型存储压力。另一方面，误差补偿、路径规划等数控系统的核心功能有严格的性能（如实时性、系统吞吐率等）需求，这种依赖云的数据处理方式会引入多种因素（如通信带宽、网络稳定性等）带来的不确定性时延，这使得一些实时性要求较高的数据处理结果难以及时反馈给数控系统。因此，传统的数控系统体系结构无法保证数据交互的实时性与一致性，进而可能导致智能化数控系统外部实体与内部智能元素之间的隔离，对数控系统的智能化带来了很大的制约。

边缘智能的重要优势在于可以通过分布式协同计算为用户提供低延迟、高可靠性的计算服务，而数控系统的层次化结构特点允许分布式部署智能元素，因此本文将边缘智能技术引入智能化数控系统体系结构，提出一种基于云边协同的智能化数控系统体系结构。




图 2-10 智能化数控系统边缘组件和云组件

Figure 2-10 Intelligent CNC system edge components and cloud components

如图 2-10 所示, 本文根据数控系统任务的需求, 将智能体划分为位于云端的云组件和位于边缘的边缘组件两大类, 每类组件依据应用情况酌情划分层次结构。

在每个层次上, 组件和组件内的智能元素通过通信系统彼此紧密相连。在每个组件内, 通信系统提供模块间通信。在数字孪生模型和感知处理之间, 数字孪生模型预测的外部环境的状态并将预测结果传递给感知处理模块, 感知处理模块通过比较处理结果和预测结果更新数字孪生模型。于此同时, 感知处理模块将观察到的实体、事件和状态信息发送至价值评估模块, 价值评估对分配得到的实体、事件和状态进行评估并将结果发送给数字孪生模型; 在任务决策与数字孪生模型之间, 任务决策模块向数字孪生模型模块查询并反馈任务状态。最终任务的制定和执行发生在价值评估, 任务决策和数字孪生模型之间, 任务决策制定计划, 并把计划经过数字孪生模型模块发送至价值评估模块进行评估, 评估结果最后从价值评估模块传回制定相应计划的任务决策模块。

通信系统还可以在不同级别的节点之间进行通信。命令从上一层级行为模块向下传递到下级模块。状态报告通过数字孪生模型从下级任务决策模块向上传递到上级任务决策模块, 并从上级模块接收任务指令。感知处理模块在一个级别上检测到的观察到的实体、事件和情况向上通信到更高级别的感知处理模块进行进一步的特征提取。存储在较高级别的数字孪生模型中的实体、事件和情况的预测属性向下传递给较低级别的数字孪生模型模块。底层感知处理模块的输入通过传感器进行通信, 并在底层模块进行简单的数据清理。底层任务决策模块的输出被发送到执行器驱动任务的最终执行。

在此基础上, 边缘组件与云组件间的交互通过如图所示的数据流, 控制流和模型部署方式实现。边缘组件收集传感信息并通过感知处理过程将提取的特征信息汇总到上层组件, 并最终将抽象出的知识汇总到云; 云组件中的任务决策元素划分任务, 价值评估元素结合任务的实时性、优先级等激励对计划任务进行评估, 将划分完成的任务指令以这种方式逐层下达, 并最终发送到合适的组件中执行; 云组件管理完整的数控系统信息模型和机理模型, 在协同任务中机理模型和信息模型按照具体任务需求卸载到对应的下层组件数字孪生模块中, 提高模型的应用效率。

在此基础上, 本文提出了基于云边协同的智能化数控系统体系结构。如图 2-11 所示, 智能化数控系统体系结构包含如下三层:




图 2-11 智能化数控系统云边协同体系结构

Figure 2-11 Cloud edge collaborative architecture for intelligent CNC systems

物理层：这一层主要包含数控系统和数据采集设备，对应智能化数控系统领域模型中的传感器和执行器。作为传感器，数据采集设备采集加工过程产生的电流、扭矩、振动、噪声等数据，结合数控系统控制器提供的进给轴坐标、加速度等实时加工数据上传到边缘组件和云组件以便对应感知处理模块进行处理。此外作为执行器，数控系统还可以接收来自上层组件任务决策模块下达的控制指令，实现对数控系统加工过程的反馈控制。通过配置物理层设备，可以对数控系统实现泛在感知，从而对生产过程进行监控和识别。

Cyber 层：这一层通过映射的方式构建数控系统的数字孪生模型，其中信息模型和机理模型实现的具体方法见第 3 章。在数字孪生模型构建过程中，我们通过嵌入过程优化、加工仿真和健康管理等智能算法分析实时加工数据，构建数控系统的层次化机理模型与信息模型，并根据需要将模型分别部署和存储在云组件和边缘组件中。在云计算环节中，任务决策模块面向不同应用场景对数字孪生模型提供的算法进行任务划分，制定不同的任务计划。在此基础上，价值评估模块针对不同应用场景下的任务需求对计划任务的实时性、准确性等性能进行评估，将评估结果反馈给任务决策模块进行相应对比和优化，并选择不同场景下的最优

任务计划下达给下层任务决策模块，最终实现基于云边协同的智能化模型部署策略。与此同时，我们通过开发边缘节点和边缘服务器，一方面作为感知处理模块向数字孪生模型提供感知的事件、实体和状态，另一方面也作为下级任务决策模块接受任务指令，指导物理层中相应的伺服系统、刀具管理系统等执行器执行加工指令。最后，数字孪生模型通过数字线程与操作者进行交互，并将相关的数据处理结果和知识存储在孪生模型和数据库中，以支持后续应用层的应用服务。

应用层：这一层是智能化数控系统内部智能元素对外交互层，根据 Cyber 层部署的不同算法和数控机床面对的不同工作需求在不同的应用层级提供智能应用服务 API 接口，支持如机床状态实时监测、故障诊断、刀具磨损诊断及预测等智能化应用服务，支持在各个层级间的智能化应用服务集成，最终实现管理者对生产过程的智能管理和控制。

2.3 本章小结

本章从智能化数控系统概念出发，针对数控系统智能化需求，提出了基于智能化数控系统领域模型的云边协同智能数控系统体系结构，主要研究内容如下：

(1) 阐述了智能化数控系统主要概念、特征，并详细分析了数控系统智能化需求；(2) 为便于智能化数控系统的设计与实现，引入智能数控系统领域模型，详细阐述了模型各个智能元素的功能与实现方法；(3) 引入边缘计算，优化以云计算为核心的传统数控系统体系结构；(4) 详细分析数控系统层次化结构特点，提出一种基于云边协同的智能化数控系统体系结构。

第3章 数控系统数字孪生建模方法研究

3.1 数字孪生建模方法

数字孪生技术作为智能制造的使能技术是实现数控系统智能化的必要手段。数字孪生通过数字线程采集物理实体数据,构建信息模型和能够反映系统的几何、物理、行为和规则特征的机理模型,并进行数据与模型的集成融合。具体建模过程如图 3-1 所示。




图 3-1 智能化数控系统数字孪生

Figure 3-1 Digital twins of intelligent CNC systems

为使数字孪生进一步在数控系统领域进行落地应用,本章基于智能化数控系统领域模型提出了以数控系统信息模型和机理模型为核心的数控系统数字孪生通用建模方法,如公式(3-1)所示:

$$\text{CNC DT} = (\text{PE}, \text{IM}, \text{MM}, \text{DiT}) \quad (3-1)$$

其中 CNC DT 代表数控系统数字孪生, PE (Physical Entity) 代表数控系统物理实体, IM (Information Model) 代表信息模型, MM (Mechanism Model) 代表机理模型, DiT (Digital Thread) 代表数字线程。

首先, CNC DT 是在数控系统上通用的数字孪生体系参考架构,能充分适应数控系统加工过程和加工结果中分层和反馈的特性,达到在数控系统中进行物理空间和孪生空间实时交互的目的。其次,四维孪生模型结构足以囊括数控系统真实物理数据和虚拟信息数据,满足加工过程真实数控机床实体信息与孪生虚拟空

间机床实体信息实时互联互通互反馈,提供全流程全要素全时刻的数据一致性和数据同步性以及数据的可拓展性。并且,融合当前最新的最有效的物联网、大数据及人工智能技术,集合数控加工运行原理,四维数字孪生模型结构能够在物理加工条件受到相应限制的情况下最大程度优化加工算法、加工流程和加工机器的加工轨迹,并以期在虚拟空间利用虚拟实体模拟和预测真实物理数控系统智能体的运行过程和运行结果,达到以虚仿实、以虚优实的目的^[53]。

物理实体 PE 是数控系统四维数字孪生模型的组成基础。对于数控系统而言,PE 可以分成控制系统、伺服驱动系统和位置测量系统等主要组成部分,对这三大部分的准确分析和模拟是 PE 存在的前提,也是信息模型实现的前提,同时更是数控系统数字孪生模型建立的首要保证。

信息模型 IM 依赖于真实物理数控系统加工过程中所采集到的实时数据,在数控系统中可分为包含多层次结构信息,包括三大属性和一大组成部分,具体介绍可参考下文详细的数控系统信息模型构建过程。基于信息模型 IM 实现的数字线程 DiT 是物理实体 PE 和虚拟孪生实体之间进行互联互通的重要通道,信息模型的好坏关乎整个数字孪生模型构建的成功与否,是组成数控系统四维数字孪生模型所不可或缺的元素之一。

在数控系统中需要通过特定的工业通讯协议如 OPC UA、MTConnect 等将数控系统信息模型转化为数字线程。数字孪生体通过数字线程获取物理实体的实时加工数据,以能够反映物理实体行为、规则的经验模型/控制理论为基础,结合有限状态机、隐马尔可夫模型、深度神经网络等深度学习技术来构建基于物理实体的同步数控系统机理模型。在此基础上辅以适当的深度强化学习算法如 DQN、PPO 算法等与数控系统加工环境进行交互来训练智能化数控系统中的感知处理、价值评估、任务决策功能,从而使得数控系统数字孪生体不仅仅能实时映射的物理实体,更能自我学习和预测物理实体的运行轨迹和运行状态,达到加工过程仿真、预测和优化。同时,数字孪生体能够将模拟和训练得来的结果实时高效反馈给物理实体,指导物理实体对生产加工过程中的行为进行一定程度一定范围的调度和优化,使数控系统生产加工过程更加合理更加安全可靠,以及对数控系统后期相应维护成本的降低,形成数控系统数字孪生的闭环。

3.2 智能化数控系统信息模型

3.2.1 互联互通应用场景

构建智能化数控系统信息模型的根本目的,是通过 CNC 控制器、传感器等数据采集设备捕获加工产生的实时和非实时数据,通过工业以太网、现场总线、4G/5G、RFID、Wi-Fi 或 Bluetooth 等多种通信方式实现数控装备之间、数控装备与上位机管理系统间的互联互通以及互操作,从而进一步满足信息采集、时序控

制、启停控制、过程控制、加工程序传输以及故障信息诊断报警等智能化应用，其典型应用场景一般包括以下3种^[62]，如图3.2所示。

- (1) 多台数控装备组合起来形成一套更复杂的组合数控装备或者生产线时，需要数控装备之间的互联互通；
- (2) 数控装备与生产线集成系统之间的互联互通；
- (3) 数控装备与数据采集系统、上层管理系统之间的互联互通。




图 3-2 数控装备互联互通应用场景

Figure 3-2 Application scenarios for the interconnection of numerical control equipment

3.2.2 信息模型基本结构

在上述应用场景中，符合要求的数控系统通过应用服务 API 接口允许其他系统获取信息并进行反馈控制。与此同时，为了方便理解服务器提供的信息语义以及客户端的自动识别和集成，系统同时需要通过服务器接口对外提供数据的语义信息。

数控系统是复杂系统，由不同子系统/部件组合而成，因此数控系统的数字孪生模型也是由各个子系统/部件的模型组成^[54]。本课题通过分析数控装备的层次结构特点，从信息的角度对数控系统进行描述，将设备本身提供的数据、功能等信息组织成层次结构，规定了如图3-3所示的数控系统基础信息模型结构。




图 3-3 数控系统基础信息模型结构

Figure 3-3 Basic information model structure of CNC systems

数控系统信息模型由静态属性、过程属性、配置属性和组件属性等数据集构成，针对特殊应用还可以包含扩展属性集^[63]。其中静态属性集描述数控系统固有属性，过程属性集描述系统运行过程中所显现特性，配置属性集为完成某一任务而需要进行的相关配置。组件集是数控系统设备描述模型物理或逻辑上的一部分，包括数控装置、可编程控制器、伺服系统、输入输出装置、辅助系统、刀具和夹具等组件。

每一类属性集和组件集中组件的信息均通过数据字典的方式描述，数据字典由数据条目组成，数据条目结构及具体说明见表 3-1。

表 3-1 数据字典条目结构

Table 3-1 Structure of data dictionary entries

条目名称	条目说明
索引	采用 16 位的索引值寻址，范围在 0X1000 至 0X7FFF 之间。对象与索引号唯一对应，在系统服务器与客户端连接后，客户端可以通过索引值来访问相应对象；
属性名称	数据字典条目目标对象名称；
属性英文名	为方便与后续机理模型中程序开发，条目中还包含属性名称对应的英文名；
建模规则	M 表示信息模型必须提供的数据项，O 表示可选数据项；
属性说明	对属性含义的具体描述，便于用户在客户端对数据项的理解；

表 3-1 数据字典条目结构 (续表)

Table 3-1 Structure of data dictionary entries (continued)

条目名称	条目说明
访问权限	信息模型以数控装备互联互通及互操作为应用目标, 因此提供两种访问权限。其中 R 代表数据项只读, 对应客户端不可更改数据。RW 代表可读可写, 为客户端提供互操作能力;
数据类型	数据类型参见标准 GB/T 33863.3-2017 及 GB/T 33863.5-2017 中定义的数据类型;
数据值	数据条目对应的数据项具体值, 由数据类型决定;
工程单位	单位度量;
属性类型	属性类型支持多种数据形式, VAR 数据类型代表简单变量, ARRAY 代表数组型数据;
语义值	向客户端用户解释数据值所代表的含义;

3.2.3 基于映射的技术架构

数控系统种类繁多, 且通信受限于不同厂商的通讯端口和协议, 难以实现设备集成与信息共享^[114]。数字线程通过模型映射的方法消除数字孪生数据的异构性, 能够拓展数字孪生数据的范围和深度, 实现通用标准规范下的一致性表达, 为数控装备间的互联互通及互操作提供支持。

本文提出了一种基于映射的技术架构^[64], 将从本地数控系统采集的数据按照数控系统基础信息模型结构组织为信息模型, 在此基础上映射为符合 OPC UA、MTConnect 等通用数据传输协议的信息模型, 实现从数控系统本地源模型到目标模型的映射。完成模型映射后, 数控系统通过服务器向客户端提供目标模型的信息访问接口, 并通过互联互通协议与其他数控装备和上位机管理系统实现数据交互。

目前, 国内外主要使用的数字线程技术是 MTConnect 和 OPC UA。MTConnect 协议主要针对机床数据采集而建立, 因而对数控系统互操作缺少必要的支持, 并且该协议基于 HTTP 的文本方式, 通信效率相对比较低, 因此并不满足数控装备互联互通互操作所需要的实时性要求。与 MTConnect 相比, OPC-UA 协议对支持面向对象建模, 支持更丰富易用的数据类型, 可自定义系统数据项的属性、方法进而事件, 天然支持数据采集、事件报警、历史数据等多种应用服务 API。OPC UA 服务器地址空间由节点组成, 可以通过引用表示节点间关系, 用户可对节点数据值进行读写。OPC UA 可在服务器运行时通过添加、删除

节点动态调整信息模型，能够最大程度为用户自定义模型提供方便。OPC UA 可在服务器运行时通过添加、删除节点动态调整信息模型，能够最大程度为用户自定义模型提供方便^[115]。因此在具体实现过程中本文选用 OPC UA 方法，实现虚实数据的交互、融合，构建目标信息模型。

模型映射方法相对灵活，可采用内置式接口映射和外置式中间件两种映射实现方式^[64]。

内置实现方式应用了进程间通信技术(IPC)，实现数控系统控制系统软件(进程)与设备描述模型的软件实现(进程)直接的进程通信，读取信息或者发出控制。其中通信机制是由数控机床控制系统确定，是指实现控制层软件内部实施数据库信息与外部通信协议 TCP/IP 之间信息格式和通信协议的变换、握手、解除、定时等机制。设备描述模型软件实现提供统一的插件接口，此时，将具体的通信协议变换开发出插件式驱动，并与软件插件接口相连，即可实现采用 NC 内置方式的装备互联互通。NC 内置实现方式如图 3-4 所示。




图 3-4 内置式实现方式

Figure 3-4 Built-in implementation method

外置适配器实现方式对现有数控系统提供更灵活的实现方式。不需重新开发数控系统，只需要开发与数控系统适配的软件或者软硬件一体的适配器装置，采用厂商特定的 API 组件即可实现互联互通及互操作。厂商特定 API 组件可以实现为设备描述模型实现软件的进程内组件，也可以采用进程间通信机制。还可以增加传感器对数控装备原数控系统未能提供的信息进行采集，实现对数控装备信息模型更完整支持。外置适配器方式如图 3-5 所示。




图 3-5 外置式实现方式

Figure 3-5 External implementation method

3.2.4 基于 OPC UA 的映射方法

传统的信息模型采用编码的方式严格定义模型结构，模型不具有鲁棒性，不便于扩展。可扩展标记语言(extensible markup language, XML)^[116]由于具有良好的格式可提供抽象化信息模型，使得信息模型的组织方式可以随着输入模型文件改变，因此具备更强的扩展性。当数控机床的信息模型发生改变需要更新时，只需要修改对应的 XML 文件即可。

本文使用如图 3-6 所示的 XML 源模型描述文件实现数控系统信息模型向 OPC UA 信息模型的映射转换。在 XML 源模型描述文件中根据各数据项和数据集的从属关系建立信息模型树状结构。



图 3-6 XML 描述文件

Figure 3-6 XML model description file

OPC UA 信息模型各个数据项节点属性由 XML 源模型描述文件中节点信息和节点属性定义，节点之间的引用方式由 XML 文件中数据项与数据集的包含关系确定。表 3-2 所示为 XML 源模型描述文件的节点信息与 OPC UA 节点信息之间的对应关系。OPC UA 具有平台独立性，其接口可以集成于嵌入式、Linux 和 Windows 等多种平台，与此同时，OPC 节点对应的数据值对客户端可读可写，这也为不同数控系统提供互操作的可能^[57]。

表 3-2 OPC UA 节点信息描述

Table 3-2 Description of OPC UA node information

属性	数据类型	说明	数据集信息	数据项名称
NodeId	NodeId	在服务器内唯一确定一个节点	NodeId	AttributeNodeId
NodeClass	NodeClass	定义节点的类	TypeDefinition	AttributeDataType
BrowseName	QualifiedName	客户端浏览服务器定义节点	BrowseName	AttributeBrowseName

表 3 2 OPC UA 节点信息描述 (续表)

Table 3-2 Description of OPC UA node information (continued)

属性	数据类型	说明	数据集信息	数据项名称
Display Name	LocalizedText	显示节点名称	DisplayName	AttributeDisplayName
Description	LocalizedText	显示节点的描述	Description	AttributeDescription
WriteMask	UInt32	定义节点数据可读写性		AttributeAccessLevel

本文设计的基于 OPC UA 的数控系统监控系统结构如图 3-7 所示, 包括建立数控机床信息模型, OPC UA 服务端和 OPC UA 客户端三个部分, 主要实现如下功能:

(1) 建立数控装备信息模型

根据数控机床信息模型层次结构建立数控机床源信息模型, 并采用 XML 文件进行描述。源信息模型中的各类过程属性集数据通过数控系统提供的 API 接口获取, 保证源信息模型过程属性数据实时更新。

(2) 映射面向 OPC UA 的信息模型

开发信息模型映射中间件, 根据数控系统 XML 源模型描述文件实现信息模型与 OPC UA 服务器信息模型地址空间的映射。

(3) 访问 OPC UA 服务器地址空间

利用 OPC UA 客户端读取服务器地址空间, 获取信息模型的全部内容, 实现数控装备信息模型的加载、浏览、修改等功能。




图 3-7 基于 OPC UA 的机床实时监控系统结构

Figure 3-7 Real-time CNC monitoring system based on OPC UA

3.2.5 蓝天数控系统应用验证

不同的数控系统采用不同的数据格式和通信协议,因而需要针对不同系统开发不同的适配器,本文在实现数控系统信息模型映射的过程中将数控系统 API 封装为动态链接库,只要动态链接库接口满足 OPC UA 模型中数据项的定义,即可将数据项与 OPC UA 节点绑定,实现客户端与服务端的信息交互。

基于上述设计方案,本文依托于 2016 年智能制造综合标准化项目“面向智能制造的数控装备互联互通及互操作 标准及试验验证”,参与起草了数控装备互联互通及互操作系列标准^[62],并在项目试验验证过程中实现了应用于蓝天数控系统 GJ430 的 OPC UA 信息模型。由于 GJ430 数控系统动态链接库基于 Windows 平台,本文的 OPC UA 服务端和客户端同样使用 Windows 系统,服务端使用 open62541 开源动态库开发完成。数控系统信息模型的各个数据集节点属性信息通过 XML 源模型描述文件的节点信息元素定义。其中,属性集节点对应 OPC UA 地址空间的文件夹对象节点,数据项节点对应 OPC UA 地址空间的各个数据类节点。

数控系统过程属性集在 OPC UA 节点空间中为文件夹节点,具体节点信息 XML 描述文件如下所示:

```
<NodeInfo>
  <NodeId>ProcessAttributeSet</NodeId>
  <DisplayName>ProcessAttribute</DisplayName>
  <ReferenceType>HASCOMPONENT</ReferenceType>
  <BrowseName>ProcessAttribute</BrowseName>
  <TypeDefination>FOLDERTYPE</TypeDefination>
  <Description>ProcessAttributeSet</Description>
</NodeInfo>
```

数控系统过程属性集中数据项机床运行时间为数据节点,包含节点索引、数据值、访问权限、数据单位等相关属性。该数据项在 XML 信息模型描述文件中的定义如下:

```
<Attribute>
  <AttributeNodeId>0X0104</AttributeNodeId>
  <AttributeDisplayName>RunningTime</AttributeDisplayName>
  <AttributeDescription> Running time of NC machine tools</AttributeDescription>
  <AttributeAccessLevel>ReadOnly</AttributeAccessLevel>
  <AttributeBrowseName>RunningTime</AttributeBrowseName>
  <AttributeDataType>UINT32</AttributeDataType>
</Attribute>
```


数控系统信息模型映射到 OPC UA 节点列表后, OPC UA server 具体实现流

程如下。

(1) 设定 OPC UA 服务器端口号和安全证书等服务器配置，调用 OPC-UA_Server_new() 初始化服务器，此时 OPC UA 服务器将提供一个空的地址空间；

(2) 根据 OPC UA 协议的信息模型建模规则，将数控系统 XML 源模型描述文件加载到 OPC UA 地址空间，确定信息模型中各个 OPC UA 节点空间中的节点属性和节点间的引用关系，分别调用根节点、文件夹节点以及数据项节点加载方法在 OPC UA 节点地址空间添加数控系统信息模型中对应的数据集和数据项；

(3) 启动服务器监听程序，允许客户端订阅 OPC UA 地址空间中的数据节点，服务器访问地址在控制台界面返回。如图 3-8 所示为本文开发的数控系统外置式 OPC UA 服务器。客户端连接服务器后，服务端的控制台界面显示客户端与服务端通过 TCP 建立连接，建立 SecureChannel。



```
C:\Users\Administrator\Desktop\GJ430_OPCUA_Server\Debug\GJ430_OPCUA_Server.exe
[2018-12-26 16:41:40.538 (UTC+0800)] info/network TCP network layer listening on opc.tcp://BF-201806080917:4840/
[2018-12-26 16:41:54.173 (UTC+0800)] info/network Connection 500 | New connection over TCP from 192.168.168.110
[2018-12-26 16:41:54.188 (UTC+0800)] info/channel Creating a new SecureChannel
[2018-12-26 16:41:54.188 (UTC+0800)] warn/securitypolicy No PKI plugin set. Accepting all certificates
[2018-12-26 16:41:54.188 (UTC+0800)] info/channel Connection 500 | SecureChannel 1 | Opened SecureChannel
[2018-12-26 16:41:54.204 (UTC+0800)] info/channel Connection 500 | SecureChannel 1 | CloseSecureChannel
[2018-12-26 16:41:54.204 (UTC+0800)] info/network Connection 500 | Closed by the server
[2018-12-26 16:41:54.219 (UTC+0800)] info/network Connection 512 | New connection over TCP from 192.168.168.110
[2018-12-26 16:41:54.219 (UTC+0800)] info/channel Creating a new SecureChannel
[2018-12-26 16:41:54.219 (UTC+0800)] warn/securitypolicy No PKI plugin set. Accepting all certificates
[2018-12-26 16:41:54.219 (UTC+0800)] info/channel Connection 512 | SecureChannel 2 | Opened SecureChannel
[2018-12-26 16:41:54.219 (UTC+0800)] info/session Connection 512 | SecureChannel 2 | Session 622336ed-a0a1-41af-9a19-31e3a16af63f | ActivateSession: Session activated
```

图 3-8 服务端运行控制台界面

Figure 3-8 Server-side console runtime interface

OPC UA 客户端通过访问服务器端口访问 OPC UA 服务器的地址空间，为验证服务端模型是否满足 OPC UA 建模规则需要采用不同的 OPC UA SDK 构建的客户端对服务端进行访问。本文使用开源客户端 OPC Monitor 以及基于 OPC UA Helper 开源库开发的客户端访问服务端实施验证，图 3-9 所示为 OPC Monitor 客户端对服务端的访问结果。图 3-10 为基于 UA Helper 开源库开发的客户端访问服务端的访问结果。




图 3-9 基于 OPC Monitor 的客户端访问界面

Figure 3-9 Client access interface based on OPC Monitor




图 3-10 基于 UA Helper 开源库的客户端访问界面

Figure 3-10 Client access interface based on UA Helper

如图 3-9 所示，界面左侧为服务端提供的 OPC UA 模型节点列表，通过点击节点列表中的数据项可以获取节点属性名称、属性 ID、数据类型、属性描述以及数据值等信息，结果显示客户端能够成功访问服务端地址空间。

除此以外，客户端还应验证服务端提供的 OPC UA 模型是否与数控机床源信息模型相一致。由于数控机床信息模型 XML 描述文档面向客户端透明，因而在开发验证客户端时，本文将 XML 文档导入数据库，在客户端读取服务端数据项过程中将数据项信息与源信息比对完成实验验证。




图 3-11 基于 OPC UA 的模型验证客户端界面
Figure 3-11 Results from OPC UA model validation client

图 3-11 为验证客户端的运行界面，如图所示客户端可以通过修改 ItemID 中的数据项索引获取节点信息并与数据库中源模型相比较，比较结果显示于 Test Result 中，经过实验验证源模型到 OPC UA 模型的映射并无出入。

3.3 智能化数控系统机理模型

目前，大多数关于数字孪生模型构建的研究都集中在对几何与物理维度模型的构建上，对于能够反映物理实体行为、规则的机理模型的构建缺乏关注^[117]。数字孪生模型的不充分、不完整不仅会影响虚拟实体真实性，还会进而影响仿真、预测的准确性。因此，在信息模型基础上，DT 模型还应包含能够反映物理实体行为以及规则的机理模型。一方面，我们以人工智能算法为基础，理论推导为指导，与经验模型/控制理论相结合，共同构建高保真、高精度的综合模型。另一方面，考虑到数控系统是复杂系统，其行为受多方面因素影响，为保证 DT 模型的完整性，我们融合多学科、多领域、多尺度模型共同构建机理模型。

其中机理模型的关键技术有有限元分析、多体动力学等；人工智能模型的关键技术有数据预处理、特征工程、机器学习和深度学习等等。通过上述方法，以人工智能方法为基础，与机理模型相结合，进行多领域融合、多属性交叉耦合、多维度建模^[16]，实现数字孪生对象在虚拟场景中的高保真、高精度的准确仿真与虚实同步。

3.3.1 通用机理模型

通用机理模型是建立数字孪生模型的基础和关键。通用机理模型的本质是将需要研究的对象抽象为数学模型或物理模型。其建模方法是通过对系统中各结构之间的物理关系进行推导的建模方式，因其阐述的规律、特性、结构等在现实中已然存在，所以更能清晰地表述数控机床内部和外部之间的响应与联系。通用机

理模型的建立是研究数控系统的数字孪生体的基础,在数字孪生体中通过算法建立系统对应的机理模型,需要对研究系统的本质逻辑有深入的了解和本质的认识。

通用机理模型建立的过程属于白盒建模,建模过程和仿真结果是可解释的。由于机理模型的建立过程无需遍历,即可对系统的响应做出精准的预测,因此可以实现使用前的仿真,降低生产试错成本,便捷准确地对系统的各方面性能进行研究分析及优化设计,减少迭代周期,满足个性化需求。通用机理模型这种特性,使得其在环境恶劣、样本难以得到的场景下,相对于人工智能建模具有一定优势。

3.3.2 基于人工智能的机理模型

人工智能建模根据样本数据训练建立模型,不关注具体的物理过程和原理,只学习输入输出之间的非线性关系^[118]。但由机床、控制器、伺服等数控系统组件耦合形成的加工系统是一套复杂的动态系统,子系统中包含大量难以建模的环节,模型中的大量参数难以定量描述,导致机理模型难以完整、精确描述数控系统。人工智能建模的过程属于黑盒建模,可以得到输入和响应之间的直接关系模型,由于输入和响应的数据都是实际的数据,因此人工智能模型在数据采样准确充足情况下相比通用机理模型可以更准确地逼近物理世界。针对实现复杂系统的建模,使得更多场景下人工智能算法可以与数控机床机理模型结合,从而提升了机理模型的稳定性和准确性,也使得机床具有更好的知识学习、积累与应用能力。通用的人工智能建模流程包含数据预处理、特征提取、模型构建等关键步骤:

(1) 数据预处理技术

预处理是指从高质量数据中提取出与目标问题相关的分量。数控机床中的主要预处理方式为,在数据搜集时,对大数据中存在的错误数据、冗余数据和异常点数据清洗之后进行滤波。应用于数控机床数据预处理的主要滤波方法有滑动平均滤波、IIR 和 FIR 滤波器滤波、基于小波分析的滤波和基于 EMD 滤波。

(2) 特征工程技术

特征工程是指用一系列工程化的方式从原始数据中筛选出更好的数据特征,以提升模型的训练效果。特征工程对原始数据进行特征提取、特征选择、特征降维等方面的工作。特征的选择对模型训练的质量起着关键的作用,常用的特征选择方法有,过滤式、包裹式、嵌入式等。在数控机床的机理模型建立过程中,通过将原始数据转化为特征,可以获取更好的训练数据,使预测模型更好地处理实际问题,提升模型的准确率。

(3) 人工智能技术

人工智能技术是数字孪生建模过程的核心技术,可以解决数控机床模型建立过程中知识学习和预测的问题。从广义的角度讲,深度学习是机器学习的分支;但是从狭义的角度讲,机器学习属于浅层学习器;深度学习属于深层学习器。

机器学习结合数字孪生赋予了数控机床学习能力,使之可以归纳学习、总结

经验、推理预测。基于机器学习建模在传感器收集海量数据之后，利用工业大数据实现虚拟空间对物理空间的实时反映与预测，利用机器学习算法积累“经验”最终构建虚拟孪生空间。

如图 3-12 所示，机器学习可分为监督学习和强化学习。其中监督学习按照训练数据是否有标签可分为传统监督学习、半监督学习和非监督学习。传统监督学习中训练数据都有对应标签，相应算法包括支持向量机、人工神经网络、深度神经网络等；半监督学习中只有一部分训练数据有标签；无监督学习所有训练数据都没有标签，相应算法包括聚类、EM 算法、主成分分析等。机器学习按照训练数据是否离散可分为回归问题和预测问题。




图 3-12 机器学习分类

Figure 3-12 Machine learning methods classification

深度学习包含多层网络结构，使其具有优异的特征学习能力。数控系统实时加工数据多为时间序列数据，需要通过对这些时序数据的分析，发现系统状态发展变化规律，并将这些学习得到的知识和信息用于仿真和预测。典型的时间序列深度学习方法包含基于循环神经网络 RNN 的模型、基于卷积神经网络 CNN 的模型等。

循环神经网络 RNN 是一类以序列数据为输入，单元之间连接形成有向循环的递归神经网络。长短时记忆网络 LSTM 是 RNN 的变体之一，网络神经元之间存在反馈连接，也被称作“时间参数”，能在学习新信息的同时动态记忆历史信息^[119]。而数控机床中刀具磨损信息数据是一个动态的时间序列，当前状态与历史状态相互关联。因此，刀具磨损预测模型与 LSTM 高度契合。长短时记忆(LSTM)单元结构如图 3-13 所示。




图 3-13 LSTM 单元结构

Figure 3-13 LSTM cells

卷积神经网络 CNN 是一类可以接收并行输入的前馈神经网络，不仅学习了各状态之间的时间上的相关性，也提取了各状态之间的耦合关系。




图 3-14 TCN 深度神经网络结构

Figure 3-14 TCN deep neural network structure

如图 3-14 所示时域卷积网络 TCN 作为卷积神经网络中处理时序数据的代表，能捕捉时间序列的复杂组合模式，对时延具有鲁棒性^[120]。TCN 相比 LSTM 不止框架设计更简洁清晰，而且留住长远信息能力更强，TCN 卷积层结构如图 3.15 所示。




图 3-15 TCN 卷积层结构

Figure 3-15 TCN block structure

通用机理模型和人工智能模型是对数控机床响应过程建模的主要方式，二者各有优势与缺陷，基于物理和数学模型的机理模型能更好的反应数控系统加工过程本质逻辑，但是面对复杂系统难以顾及全局条件，建模相对较为困难；与之相对的基于人工智能的数据驱动模型在数据采样充足情况下能更好的满足模型精度，但面对极端数据容易陷入过拟合问题，模型属于黑盒结构，更针对具体场景，其中变量物理意义难以解释，导致其全局性较差。具体分析比较如表 3-3 所示。

表 3-3 机理模型建模方法比较

Table 3-3 Comparison of mechanism models

建模方法	优势	缺陷
通用机理模型	揭示过程本质逻辑，外延性能良好。	对复杂系统难以建立模型。
人工智能模型	拥有数据即可建模，方法成熟有体系，过程便捷。	需要大量样本数据，物理含义难以直观表示。

对于数控系统任何一种建模方式都具有局限性，可以将通用机理模型和人工智能模型进行结合，使其既能揭示响应过程本质逻辑，又能具有良好的数据精度。

对数控系统这种复杂系统而言，使用单一的建模方式为其构建模型过于局限，可以将通用机理模型和人工智能模型进行结合，构建基于人工智能的机理模型，使其既能揭示响应过程本质逻辑，又能具有良好的数据精度。

通用机理模型通过对象和生产过程的内部机制构建数学模型来反映变量间的逻辑关系，能够保证模型的可解释性和泛化能力，更强调因果性。为保障专家经验的传承，使隐形知识显性化、共享化，并弥补通用机理模型在复杂系统建模时存在的准确性及稳定性等问题，引入 AI 辅助感知视频、数据等多模数据，构建基于人工智能的机理模型，实现多目标、全局优化和决策。通用机理模型与人工智能模型的结合方式分为三种，即串联、并联与混联^[16]。其中，串联方式适用于机理模型的结构确定，但含有未知参数的高维非线性问题，人工智能模型通过

大量神经元学习多维数据能够拟合出模糊的复杂数学模型，从而辨识未知部分，提高模型精度。在并联方式中，人工智能模型从数据规律出发，用以解决通用机理模型中的未建模部分，即由于系统不确定性、扰动等因素产生的建模误差。混联方式就是将串联与并联方式相结合，最大限度地利用系统的通用机理知识和历史数据，保障混合模型的可解释性和建模精度。具体实现方法如表 3-4 所示。

表 3-4 通用机理模型与人工智能模型结合方式

Table 3-4 The combination of general mechanism model and AI model

结合方式	实现方法
串联	利用先验知识建立机理模型，使用人工智能模型对非线性参数进行辨识，并将其带入机理模型。
并联	使用人工智能模型来补偿通用机理模型中建模误差，并将其叠加到通用机理模型的输出上。
混联	串联+并联

3.4 本章小结

本章基于智能化数控系统领域模型和体系结构，提出了智能化数控系统信息模型与机理模型通用建模方法，并基于蓝天数控 GJ430 数控系统对通用信息模型建模方法进行了应用验证，主要研究内容如下：（1）结合智能化数控系统应用需求，基于智能化数控系统领域模型提出了以数控系统信息模型和机理模型为核心的数控系统数字孪生通用建模方法；（2）面向智能化数控系统互联互通应用需求和应用场景，构建智能化数控系统基础信息结构模型；（3）在此基础上提出一种基于模型映射的信息模型技术架构，构建基于 OPC 统一架构的数控系统信息模型；（4）依托于 2016 年智能制造综合标准化项目“面向智能制造的数控装备互联互通及互操作 标准及试验验证”，参与起草了数控装备互联互通及互操作系列标准并在蓝天数控 GJ430 实现应用验证；（5）分析智能化数控系统机理模型构建方法以及关键技术，提出一种人工智能辅助机理模型的通用建模方法。

第4章 基于边缘智能的模型部署方法研究

4.1 边缘智能关键技术

信息模型与机理模型能够从不同时空角度描述物理机床的属性、行为及特征,反映其随时间推进的运行状态、加工过程的变化。它们共同构成的智能化数控系统数字孪生模型能够智能化的描述数控系统在不同环境下的实时响应及行为,形成优化决策指令,实现反馈控制,指导加工过程。随着数控系统智能化的进一步深入,智能算法的飞速发展在为数控系统信息模型和机理模型提供丰富功能的同时,也带来了实时同步、忠实映射、高保真度的要求^[14]。现有数控系统计算能力有限,无法承载海量实时加工数据的分析处理,更多的智能化模型应用倾向于设备数据全部上传至远程云数据中心,利用数据中心的高性能计算平台来对大数据进行计算和存储^[19]。然而,随着传感设备数量和数据量的不断增加,给云计算模式带来了新的挑战:

(1) 实时性:随着人工智能应用的普及,现有的数控系统智能化应用对数据处理的实时性要求越来越高。以云计算为核心的集中式数据处理方式,需要将大量设备终端数据上传至云计算数据中心处理。这种集中式云计算处理方式会引入网络传输、数据存储等多种问题,从而给数控系统智能化应用服务的端到端响应时间增加不确定影响。在工业生产中,这种延迟响应极易引发安全事故;

(2) 数据隐私和安全:工业生产往往涉及工艺数据等隐私数据,这类数据的上传会产生隐私泄露的风险。

为了解决以上问题,由云计算、边缘计算与人工智能互动融合而成的边缘智能应运而生。不同于将终端数据全部上传的集中式云计算模式,边缘计算引入从数据源到数据中心路径之间的任意网络和计算资源,包括路由器、网关、交换机、接入点和基站等具有一定计算、存储、网络等资源的服务器或者开发平台。边缘计算通过将原本运行在云计算数据中心上的全部计算任务或者部分计算任务迁移到距离终端用户近的边缘设备上,来降低数据中心的计算负载与巨大的带宽消耗,同时提供低延迟与数据安全与隐私保护的服务^[99]。与此同时,受益于算法、算力等方面的进步,以深度学习为代表的人工智能技术得到了突飞猛进的发展。此外,硬件体系结构和平台不断保持快速发展,满足了计算密集型深度学习模型的要求。因此,AI在功能上对于快速分析大量数据和数据分析的要求,促进了边缘计算和AI的集成,产生了边缘智能的概念^[99]。

边缘智能充分利用部署于数控系统边缘和终端的嵌入式计算能力,与云计算结合,通过交互协作为研制智能化数控系统创造了条件,并对数控系统提出了新的需求:

(1) 将边缘智能应用于数控系统,以满足系统实时性及隐私性要求;

(2) 将智能控制技术与自动化技术融合数控系统, 以提高加工的精度、质量和效率;

(3) 通过工业互联网技术实现加工过程的感知及与智能工厂的融合, 实现数控系统与数字化车间的互联互通;

(4) 通过数字化技术实现工件设计与编程、机床配套调试的优化、加工过程仿真等工序链的一体化;

相较于传统数控系统, 智能化数控系统中 AI 应用的计算和数据都更为密集, 对延迟和隐私保护要求也更为严苛, 边缘智能在更加靠近用户和数据源头的网络边缘侧这一位置训练和部署深度学习模型, 从而改善 AI 应用的性能、成本和隐私性^[19]。广义的边缘智能主要包含两个方面^[100], 一方面是人工智能的边缘化部署, 即将面向用户的人工智能服务部署到边缘, 通过设备-边缘协同运行 AI 模型的训练和推理框架, 为用户提供低延迟、高精度、具有安全保障的人工智能服务; 另一方面, 是人工智能驱动的边缘计算, 致力于借助有效的 AI 技术为边缘计算中的约束优化问题提供更好的解决方案, 使得边缘计算系统资源高效利用, 降低系统成本。为满足智能化数控系统信息模型和机理模型模型的实时性和应用效率, 减轻云端压力, 本章依据上文提出的智能化数控系统层次结构, 利用边缘智能技术分布式部署智能化数控系统数字孪生模型。选择在云端部署价值评估和任务决策智能元素, 通过价值评估选择存储在数字孪生模型中的智能算法, 协同任务决策模块制定并下发智能任务的模型切分以及数据划分策略, 将切分好的模型和数据分别卸载到边缘节点、边缘服务器以及云数据中心进行感知处理, 由云边协同处理智能化数控系统加工过程产生的实时数据。

在智能化数控系统模型部署过程中, 在设备算力和网络带宽等系统资源相对受限的边缘和终端设备上实现快速高效的模型推理, 现有的模型部署优化技术主要包含模型压缩、模型分割、模型提前退出、模型选择、面向应用优化等若干优化方法^[100]。而这些优化方法通过优化对象进行划分可分为模型优化和资源分配两大类, 如表 4-1 所示。

以联邦学习和迁移学习为代表的模型优化方法主要作用在于通过迁移学习特征和分布式模型训练来降低模型训练的复杂度, 更多优化集中在模型的训练过程, 因此功能更集中于云数据中心, 对模型推理过程影响较小; 模型剪枝和模型轻量化等模型优化方法在不同程度上优化了神经网络的模型结构, 以牺牲 DNN 模型的精度为前提提高了模型推理的效率, 然而在实际应用中, 应用程序对于模型效率和模型精度的需求具有较大的差异, 因而还需考虑如何平衡模型精度与吞吐率, 为不同应用程序选择合适的模型优化方法。

计算资源、通信资源和数据作为数控系统智能应用的主要资源, 其合理分配是提高系统效率和实时性的重要手段。现有的资源分配优化方法研究更多集中在计算资源和通信资源, 对数据资源分配优化方法的研究较少; 云边协同计算模式

大多采用串行执行方式，且以时间延迟为唯一参考指标，一方面难以满足工业生产的实时性要求，在数据频率较高时还会对终端设备造成较大的存储和计算压力。

表 4-1 模型优化方法

Table 4-1 Model optimization methods

优化方法		作用
模型优化	模型剪枝	去除冗余参数，优化神经网络模型结构。
	模型量化	牺牲参数精度，压缩神经网络模型存储。
	迁移学习	迁移学习特征，降低神经网络训练复杂度。
	联邦学习	分布式训练模型，保护用户数据隐私安全。
资源优化	计算资源	提高系统计算资源利用率，降低计算时延。
	通信资源	提高系统网络吞吐率，降低通信时延。
	数据资源	提高数据利用效率，缩短数据处理时间。

针对以上问题，本章在现有研究基础上添加系统数据吞吐率指标，提出了一种在保证实时性需求基础上提高吞吐率的模型切分算法。进一步，提出一种自适应模型选择算法，为对实时性和准确性有不同要求的智能化应用自适应选择模型。最后，综合考虑深度学习模型的复杂性和推断错误率，终端设备和边缘服务器的计算能力构造了一个最优化问题来最小化数据处理时间，并以此提出最优数据分配策略。

4.2 模型卸载方法

4.2.1 任务建模

与云计算相比，边缘计算提供了一种低延迟的方法，但随着物联网和人工智能的普及，工业现场部署的传感器越来越多，数据规模随之增长，算法复杂度逐渐增加，实时监测、故障诊断和预测等数字孪生应用对数据处理提出了更加严格的实时性要求^[97]。传统的数据处理方式以降低时延为目标^[20]，采用单服务器单节点串行执行的方式将数据处理任务进行切分卸载，将切分点前的任务留在本地进行处理，其余任务卸载到边缘服务器处理，将两部分处理时间与数据传输时间进行简单叠加作为数据处理时间。然而，这种数据处理方式并不适用于数控机床数字孪生。一方面，节点与服务器一一对应意味着更高的数据处理成本，另一方面，边缘服务器处理深层 DNN 的时延更短，这种以降低时延为唯一考核指标的数据处理方式倾向于将数据更多的交给边缘服务器进行处理，而忽略了边缘节点，这会导致大量服务器来不及处理的数据被丢弃，系统吞吐率降低，应用服务质量下降。

本文考虑数控机床数字孪生的实际应用场景，提出新的任务划分方法，为每

台机床部署边缘节点，在车间现场部署边缘服务器，边缘服务器与边缘节点为一对多关系，采用 MISD (Multiple Instruction stream Single Data stream) 流水线结构处理数据^[98]。以 τ 为一个时间片，边缘节点并行，边缘服务器串行，流水线各处理级功能专用、操作重叠。这种数据处理方式能够充分利用边缘节点，有效减少数据丢弃量，提高应用服务质量。具体划分方法描述如下。

首先，将数据处理过程划分为 N 个子任务， S_i 表示第 i 个子任务，其中 $i = 1, 2, \dots, N$ ， D_i 表示 S_i 执行结束输出数据的大小， $f(S_i)$ 为 S_i 执行的时延。利用边缘计算对数据处理任务进行切分， j 表示划分给边缘节点处理的子任务数，其中 $j = 0, 1, \dots, N$ 。当 $j = 0$ 时，全部子任务卸载到边缘服务器执行，当 $j = N$ 时，在边缘节点执行全部子任务。

下一步，给出 MISD 流水线每段的时延模型。数据处理时间由边缘节点执行时延、网络传输时延和边缘服务器执行时延三部分构成。

(1) 节点计算模型

边缘节点并行批量处理多组数据，假设每个边缘节点接收的数据处理任务相同，且节点计算能力一致，对于任意节点的数据处理任务，边缘节点的执行时延分为两部分：节点处理分割点之前子任务时延与结果上传时延。定义当前可用带宽为 B_{device} ，则边缘节点执行时延记为公式(4-1)：

$$t_{device} = \sum_{i=0}^j f(S_i) + \frac{D_j}{B_{device}} \quad (4-1)$$

(2) 边缘服务器计算模型

边缘服务器当前可用带宽记为 B_{edge} ，连接单个节点时的执行时延包含子任务处理时延和数据下载时延，记为：

$$t'_{edge} = \sum_{i=j+1}^N f(S_i) + \frac{D_j}{B_{edge}} \quad (4-2)$$

边缘服务器实际接入节点数记为 m ，最大可接入节点数记为 M ，其中 $m \leq M$ ，采用非抢占式 CPU 分配串行执行，可能出现等待空闲，故边缘服务器实际处理时延 t_{edge} 应满足 $mt'_{edge} \leq t_{edge} \leq Mt'_{edge}$ 。

(3) 通信模型

数据传输时延 t_{tran} 包含数据传播时延和转发时延。其中，传播时延是数据在传输信道上传播所需的时间，只与传输信道长度有关；而转发时延包含数据在输入输出缓冲区的排队时延和进行转发处理数据块所需的处理时延。

最后，给出任务切分标准。只有在流水线装满的稳定状态下，才能保证每个时钟周期输出一个结果的最高速率^[98]。因此，3 段流水中最慢部件执行所需时间即为时间片长度，即 $\tau = \max \{t_{device}, t_{tran}, t_{edge}\}$ 。流水线处理每个流程都需等待上一流程处理后的数据，数据处理时延 $T = t_{device} + t_{tran} + t_{edge}$ 。当流水线充满时，系统吞吐率 $\theta = \frac{1}{\tau}$ ，在满足时延要求的情况下，选取的时间片越小，系统吞吐

率越大。

4.2.2 模型切分算法

为提高数控系统数字孪生应用效率,本节提出利用边缘计算切分、部署智能算法,期望在保证实时性的基础上最大化系统吞吐率。由于每一个子任务的计算特性和数据大小不同,且计算负载和网络状态动态变化,模型的最佳划分点位置由模型的拓扑结构、设备计算能力和网络状态共同决定,具体任务切分算法如下,具体包含三个阶段。

Algorithm 1 Task Partitioning Algorithm

1: **Input:**

2: N : number of the subtasks

3: $\{S_i | i = 1, \dots, N\}$: the i -th subtask

4: $\{D_i | i = 1, \dots, N\}$: output data size of S_i

5: $f(S_i)$: latency of executing S_i

6: B_{device} : current available bandwidth of node

7: B_{edge} : current available bandwidth of edge server

8: M : maximum number of nodes that can connect to the server

9: l : latency requirement

10: **Output:**

11: Partition Decision

12: **procedure**

13: for each i in $1, \dots, N$ do

14: $TN_i \leftarrow f_{device}(S_i)$

15: $TE_i \leftarrow f_{edge}(S_i)$

16: end for

17: $\tau_{min} \leftarrow l$, PartitionPoint $\leftarrow 0$

18: for $j = 0, j \leq N, j = j + 1$ do

19: $t_{device} = \sum_{k=0}^j TN_k + \frac{D_j}{B_{device}}$, $t_1 \leftarrow t_{device}$

20: $t_2 \leftarrow t_{tran}$

21: $t'_{edge} = \sum_{k=j+1}^N TE_k + \frac{D_j}{B_{edge}}$, $t_3 \leftarrow Mt'_{edge}$

22: $\tau_j = \max\{t_1, t_2, t_3\}$, $T_j = t_1 + t_2 + t_3$

23: if $T_j \leq l$ then

24: if $\tau_j \leq \tau_{min}$ then

25: $\tau_{min} \leftarrow \tau_j$, PartitionPoint $\leftarrow j$

26: end if

27: end if

28: end for

29: return PartitionPoint and T_{min}

任务初始化: 对于包含 N 个子任务的数据处理任务, 获取边缘节点和边缘服务器计算能力, 初始化各个子任务 S_i 在节点的执行时延 TN_i 和在边缘服务器的执行时延 TE_i 。由于子任务的推理时延仅依赖于硬件设备的计算能力, 对于相同的硬件只需初始化一次。

任务分析: 边缘节点并行执行切分点前的子任务, 数据处理时间为 $\sum_{k=0}^j TN_k$, 数据上传时间为 $\frac{D_i}{B_{device}}$ 。边缘服务器串行执行各节点卸载到服务器的剩余子任务, 其任务执行时间记为 $M(\sum_{k=j+1}^N TE_k + \frac{D_j}{B_{edge}})$, 数据传输时间 t_{tran} 通过实时监测的方式获取。

切分点选择-备选切分点位于每个子任务执行完成之后, 使用时间片长度描述系统吞吐率, 计算所有备选切分点对应的时延和时间片长度。对于满足时延要求的切分点, 一一比较对应的时间片长度, 选择时间片长度最小, 即系统吞吐率最大的作为最佳切分点, 输出切分策略和对应的数据处理时延。

4.2.3 模型选择算法

本章提出的模型切分算法能够为指定算法模型选择数据处理任务的最佳划分点进行切分, 在满足时延要求的情况下最大化吞吐率。然而在工业现场, 应用程序对于吞吐率和模型精度的考量不同, 模型剪枝等方法能够以牺牲模型准确率为代价有效提高吞吐率^[100], 如何平衡模型精度与吞吐率, 为不同应用程序选择合适的算法模型成为新的问题。

本节提出一种自适应选择算法模型的方法, 在模型切分算法的基础上, 根据备选算法模型的系统时延、准确率和吞吐率, 利用评价函数进行评估, 为应用程序提供自适应且及时的模型评估。

基于边缘计算的数控机床数字孪生主要应用机器学习解决分类和回归问题, 对于这两类问题, 评估其算法能力的指标不同, 本文分别为其定义了评价函数。

对于分类问题, 我们定义评价函数如下:

$$h(acc, \theta, p) = \left(\frac{l\theta}{p}\right)^{a \cdot (acc - Y)} \quad (4-3)$$

其中, acc 为 DNN 模型的准确率, l 为系统可容忍时延, θ 为系统吞吐率, p 为流水线段数, Y 为准确率阈值, a 为大于 0 的常系数, 用户可根据生产需求自行设置。

对于回归问题, 我们用 $loss$ 表示模型的拟合误差, 评价函数如下:

$$h(loss, \theta, p) = \left(\frac{l\theta}{p}\right)^{a(Y - loss)} \quad (4-4)$$

具体的 DNN 模型选择方法与分类问题相同, 由式(4-4)计算评价函数, 备选模型的拟合误差越小, 评价值越高, 输出评价值最高的备选模型。

DNN 模型自适应选择算法如算法 2 所示, 输入备选 DNN 模型, 应用程序最大可容忍时延与准确率要求。初始化备选 DNN 模型的吞吐率、准确率或误差, 计算所有备选 DNN 模型的评价值 $E(M_j)$, 选择评价值最高的作为最优 DNN 模型输出。

Algorithm 2 Optimal DNN Model Selection Algorithm

1: **Input:**

2: $\{M_j | j = 1, 2, \dots, R\}$: the DNN model

3: l : latency requirement

4: Y : threshold

5: α : custom constant coefficient

6: $E(M_j)$: the evaluation of DNN model M_j

7: **Output:**

8: Optimal DNN Model

9: **Procedure**

10: for ($j = 1; j \leq R; j++$) do

11: $h_{max} = 0, M_{optimal} = 0$

12: if $Targe == accuracy$ then

13: $h_j(accuracy, \theta_j, p_j) \leftarrow E(M_j)$

14: else if $Targe == loss$ then

15: $h_j(loss, \theta_j, p_j) \leftarrow E(M_j)$

16: end if

17: if $h_{max} \leq E(M_j)$ then

18: $h_{max} = E(M_j), M_{optimal} = M_j$

19: end if

20: end for

21: return the optimal DNN model M_j

本节提出的任务切分以及模型选择方法在原有的时延基础上提出了系统吞吐率作为新的指标, 在保证任务实时性基础上提高系统数据利用效率。本文第 5 章进一步将该算法应用于刀具磨损检测和预测性维护中, 算法的应用验证也将于本文第 5 章详细描述。

4.3 数据划分方法

4.3.1 算法应用场景

DDNN 支持可伸缩的分布式计算架构, 将传统的 DNN 任务进行跨区域切片划分, 并根据划分后神经网络的大小和规模将分片任务分布到边缘和终端进行执行^[106]。我们采用图 4-1 所示基于 DDNN 的工件分类作为应用示例。算法应用场

景主要包含聚合器、带有计算能力的终端传感设备和位于边缘的服务器等实体设备。位于不同位置的传感器装置实时获取工件不同角度的图像数据，通过部署在设备本地和边缘侧的神经网络算法识别工件。




图 4-1 基于 DDNN 的应用场景

Figure 4-1 An application scenario based on DDNN

如图 4-2 所示，多个终端传感器实时采集数据，并将原始数据缓存到内存中。然后，传感装置根据设备计算能力和计算时间等相关参数决定数据的划分策略并对数据进行处理。划分到本地的数据经过预处理后传输给本地的神经网络，但由于本地的传感设备计算资源有限，只能部署经过预训练的浅层神经网络(SNN)，SNN 为只含有一层隐藏层的神经网络，因而在执行分类任务时可能出现分类结果不可信的情况；划分到边缘服务器的数据将传输到边缘服务器的神经网络，我们假设边缘服务器资源充足，可以部署复杂的深度神经网络(DNN)，且 DNN 分类结果绝对可信。




图 4-2 基于 DDNN 的分类任务

Figure 4-2 A classification task based on DDNN

当数据被划分给本地时，由 SNN 模型对数据进行分类，并将结果传输到聚合器。聚合器通过比较信息熵 η 和预先设定好的阈值 T 判断分类结果是否可信。这里我们采用归一化信息熵作为置信度标准：

$$\eta(x) = - \sum_{i=1}^{|C|} \frac{x_i \log x_i}{\log |C|} \quad (4-5)$$

其中 $0 < \eta < 1$ ， η 越接近 0 表示对样本的分类结果越有信心。

若 $\eta \leq T$ ，则聚合器判定分类结果可信，依据 DDNN 的提前退出原则数据在本地提前退出，计算结果发送到聚合器。当聚合器判定该设备分类结果不可信，即 $\eta > T$ ，此时将经过预处理的数据上传到边缘服务器。边缘服务器将 DNN 的分类结果发送给聚合器，最后由聚合器综合分类结果并根据结果产生控制决策。

4.3.2 任务建模

在基于 DDNN 的分类任务中，每个本地传感设备采集的原始数据都可以进行划分。我们以单个传感器为例进行建模。将传感器采集到的原始数据集记为 $D = \{d_1, d_2, \dots, d_m\}$ ，其中 m 为内存中缓存的待处理数据总量， $d = |d_i|$ 为数据大小， $i \in [1, m]$ 。

将原始数据划分为两部分， α 作为数据划分的比例， αm 的数据在本地处理， $(1 - \alpha)m$ 的数据分配给边缘服务器处理。传感器设备与边缘服务器连接，并可以将数据传输到边缘服务器。影响系统时间延迟的主要因素包括数据的传输时间和计算时间，本地的数据处理时间主要由 SNN 模型的计算能力决定。 p_l 表示本地完成单位数据处理所需要的时间，即数据预处理时间和 SNN 计算时间。边缘服

服务器的数据处理时间由 DNN 模型的计算能力与数据的传输效率共同决定。基于 DDNN 的应用场景要求尽量减少边缘与终端的数据交互，因而数据传输的方向是单向的。在边缘的数据处理与传输同时进行，在考虑连续数据集时，总时延的计算不是计算时间与传输时间的简单叠加关系。当计算时间占主导时（即 $p_c > p_t$ ），可以忽略传输时间的影响，反之亦然。因此我们可以将边缘服务器单位数据处理时间 p_e 近似为 $\max\{p_c, p_t\}$ 。

验证过程中我们假设数据从终端传输到边缘服务器的时间远小于边缘服务器对数据的计算时间，可以忽略传输时间对总时延的影响。 σ 表示该终端设备的最大可容忍延迟。 α 为分配到本地处理的数据比例，本地数据处理的总时延为：

$$\tau_{local} = \alpha m d p_l \quad (4-6)$$

$(1 - \alpha)$ 为分配给边缘服务器的数据比例，边缘服务器处理这部分数据的时延为：

$$\tau_{edge}^1 = (1 - \alpha) m d p_e \quad (4-7)$$

由于本地设备计算精度有限，被聚合器判定分类结果不可信的数据需上传到边缘服务器处理。该部分数据经过终端设备的预处理，数据大小为 kd ，其中 $0 < k \leq 1$ 。

M 为该设备处理的历史数据总量， F 为 M 中终端统计得到的本地分类结果不可信的总数据量，则记 $\frac{F}{M}$ 为聚合器不信任本地分类结果的概率。边缘服务器计算这部分数据的时延可以近似处理为：

$$\tau_{edge}^2 = \alpha m \frac{F}{M} k d p_e \quad (4-8)$$

因本地分类结果不可信而被传输到边缘服务器的数据是离散分布的，边缘服务器在等待这些数据的过程中会产生空闲，记空闲时间为 τ_0 ，则边缘服务器处理本地分类失败的数据的总时延为：

$$\tau_{edge}^3 = \alpha \frac{F}{M} m k d p_e + \tau_0 \quad (4-9)$$

空闲时间与本地分类失败的数据正相关，因此，我们引入 ξ 作为终端分类失败数据产生额外时间延迟的惩罚系数。 τ_0 近似为 $\xi \alpha \frac{F}{M} k m d p_e$ 。根据 (4-7)，(4-8) 归纳得到边缘服务器数据处理的总时延为：

$$\tau_{edge} = (1 - \alpha) m d p_e + \alpha \frac{F}{M} k m d p_e + \xi \alpha \frac{F}{M} k m d p_e \quad (4-10)$$

数据同时在本地和边缘进行处理，数据处理的总时延可以表示为：

$$\Gamma = \max\{\tau_{local}, \tau_{edge}\} \quad (4-11)$$

为了方便参考，我们在表中列出关键符号及符号说明。

表 4-2 关键符号说明

Table 4-2 Description of key parameters

符号	描述
m	总数据量
d	单个数据大小（单位：比特）
T	本地聚合器上预先设定的阈值
x	终端设备 SNN 神经网络输出
C	所有可能分类的集合
$\eta(x)$	信息熵
σ	终端设备的最大可容忍延迟
α	分配给本地处理的数据比例
p_l	终端设备处理单位数据所用时间
p_e	边缘服务器处理单位数据所用时间
p_c	边缘服务器计算单位数据所用时间
p_t	终端与边缘服务器间单位数据传输时间
M	该设备处理的历史数据总量
F	聚合器判定本地分类结果不可信的总数据量
τ_0	边缘服务器空闲时间
ξ	惩罚系数
τ_{local}	本地数据处理时延
τ_{edge}	边缘服务器数据处理时延
Γ	数据处理总时延

4.3.3 数据划分策略

在基于 DDNN 的工件分拣场景中，使得总时延最小的问题可构造为最优化问题 **P**。

P:

$$\underset{\{\alpha, \frac{F}{M}, p_l, p_e, \xi\}}{\text{minimize}} \Gamma \quad (4-12)$$

$$\text{s. t. } C1: \max\{\tau_{local}, \tau_{edge}\} < \theta \quad (4-13)$$

$$C2: 0 < \alpha \leq 1 \quad (4-14)$$

$$C3: 0 < k \leq 1 \quad (4-15)$$

$$C4: 0 \leq \frac{F}{M} < 1 \quad (4-16)$$

$$C5: \xi \geq 0 \quad (4-17)$$

其中，C1 确保数据处理时间不超过最大可容忍延迟；C2 说明数据分配比例的可用范围；C3 表明数据预处理对原始数据规模调整比例的可用范围；C4 表明统计得到的本地设备分类的错误率；C5 表明惩罚系数的可用范围。

传统分配策略将所有原始数据在本地处理，则：

$$\tau_{local}(\alpha = 1) = mdp_l \quad (4-18)$$

$$\tau_{edge}(\alpha = 1) = (1 + \xi) \frac{F}{M} k mdp_e \quad (4-19)$$

$$\Gamma = \max \{ mdp_l, (1 + \xi) \frac{F}{M} k mdp_e \} \quad (4-20)$$

由(4-18)和(4-19)可知，当数据在本地全部分类正确，即 $\frac{F}{M} = 0$ 时，总时延式(4-20)最小。

然而，在实际应用中，传统的分配策略会导致本地终端设备计算压力过大，而边缘服务器长期处于空闲状态，造成资源浪费，数据处理时间过长，难以满足时间敏感任务要求。为解决上述问题，本文提出一种新的 IIoT 边缘协同数据分配策略。




图 4-3 数据分配策略

Figure 4-3 Data allocation strategy

数据分配策略如图 4-3 所示，将原始数据划分为两部分：将比例为 α 的原始数据直接在本地处理，将比例为 $(1 - \alpha)$ 的数据划分给边缘服务器处理，其中， $0 < \alpha < 1$ 。可以将问题 **P** 转化为 **P1**。

P1:

$$\text{minimize } \Gamma_{\{\alpha, p_l, p_e, \xi\}} \quad (4-21)$$

$$\text{s. t. } C1: \max \{ \tau_{local}, \tau_{edge} \} < \theta \quad (4-22)$$

$$C2: 0 < \alpha \leq 1 \quad (4-23)$$

$$C3: 0 < k \leq 1 \quad (4-24)$$

$$C4: 0 \leq \frac{F}{M} < 1 \quad (4-25)$$

$$C5: \xi \geq 0 \quad (4-26)$$

考虑极端情况，所有数据都划分给边缘服务器处理，即 $\alpha = 0$ ，此时：

$$\tau_{local}(\alpha = 0) = 0 \quad (4-27)$$

$$\tau_{edge}(\alpha = 0) = mdp_e \quad (4-28)$$

$\forall \alpha \in (0,1)$, $\tau_{edge} < \tau_{edge}(\alpha = 0)$ ，由式(4-28)，边缘服务器处理数据的时延可记为：

$$\tau_{edge} = mdp_e + [(1 + \xi) F/M k - 1] \alpha mdp_e \quad (4-29)$$

则由此可以推导得到新的约束条件：

$$C6: (1 + \xi) F/M k - 1 < 0 \quad (4-30)$$

在以上约束条件基础上，我们可以通过讨论 α 对 Γ 的影响，从而求得该优化问题的最优解。

当 $\tau_{local} \geq \tau_{edge}$ 时， $\alpha \geq \frac{1}{\frac{p_l}{p_e} - (1+\xi)\frac{F}{M}k+1}$ ，此时 $\Gamma = \tau_{local}$ ， Γ 随 α 的增加而单调递增。

当 $\tau_{local} \leq \tau_{edge}$ 时， $\alpha \leq \frac{1}{\frac{p_l}{p_e} - (1+\xi)\frac{F}{M}k+1}$ ，此时 $\Gamma = \tau_{edge}$ 。

已知 Γ 随 α 的增加而单调递减，P1 可以视为凸优化问题，故而我们可以得到结论当 $\alpha = \frac{1}{\frac{p_l}{p_e} - (1+\xi)\frac{F}{M}k+1}$ 时，总时延 Γ 最小， $\Gamma = \frac{mdp_l}{\frac{p_l}{p_e} - (1+\xi)\frac{F}{M}k+1}$ ，记最优解为 $\alpha^* = \frac{1}{\frac{p_l}{p_e} - (1+\xi)\frac{F}{M}k+1}$ 。由此我们推出总延时 Γ 最小时 $\tau_{local} = \tau_{edge}$ ，即终端与边缘数据处理时间相同时，总时延最小。

4.3.4 实验分析

为评估本文提出的数据分配策略的性能，我们考虑一个由若干终端传感设备和一个边缘服务器构成的系统，其中每个终端对应边缘服务器 CPU 中的一个核。

为方便计算，我们将最优解 $\alpha^* = \frac{1}{\frac{p_l}{p_e} - (1+\xi)\frac{F}{M}k+1}$ 简化为 $\alpha^* = \frac{1}{\theta - (1+\xi)\beta k+1}$ ，具体参数含义如下：

$\theta = \frac{p_l}{p_e}$ ，表示终端与边缘的数据处理能力的比值，在实验中设置 $\theta \in \{0.2, 0.5, 1.0, 2.0, 5.0, 10.0\}$ ，以终端数据处理时间 p_l 为单位时间，即 $p_l = 1$ ，则 $p_e = \frac{1}{\theta}$ ；

$\beta = \frac{F}{M}$ ，表示统计得到的终端设备历史数据分类失败比例。 k 与 β 对总时延和 α 影响相同，在实验中联合考虑 $k\beta$ ，设 $k = 1$ ， $\beta \in [0, 0.5)$ 。

实验 1：验证是否存在使总时延 Γ 最小的最优解 α^* 。

实验设置参数 $\Upsilon_{i,j}(\theta_i, \beta_j)$ 如表 4-3 所示。对每组参数随机生成 1000 组数据集，

其中一组数据集包含 100 个数据，每个数据在终端设备上分类错误的可能性设为 β ，数据大小 $d = 1$ ，设置 $\xi = 0.1$ 。对每组参数，我们通过仿真程序统计不同 α ($\alpha \in [0.005, 1]$ ，步长 0.005) 条件下 1000 组数据集的平均 Γ ，获取最小值 Γ_{min} ，及其对应 α' ，结果见表 4-4 实验 1 结果

Table 4-4 Results of experiment 1。

表 4-3 参数设置

Table 4-3 Parameter settings

参数	θ_1	θ_2	θ_3	θ_4	θ_5	θ_6
β_1	(0.2, 0.1)	(0.5, 0.1)	(1, 0.1)	(2, 0.1)	(5, 0.1)	(10, 0.1)
β_2		(0.5, 0.2)	(1, 0.2)	(2, 0.2)	(5, 0.2)	(10, 0.2)
β_3		(0.5, 0.3)	(1, 0.3)	(2, 0.3)	(5, 0.3)	(10, 0.3)
β_4		(0.5, 0.4)	(1, 0.4)	(2, 0.4)	(5, 0.4)	(10, 0.4)

表 4-4 实验 1 结果

Table 4-4 Results of experiment 1

$Y_{i,j}$	$Y_{1,1}$	$Y_{2,1}$	$Y_{2,2}$	$Y_{2,3}$	$Y_{2,4}$	$Y_{3,1}$	$Y_{3,2}$
α'	92.0%	72.0%	78.0%	84.0%	91.5%	52.5%	56.0%
α^*	91.7%	71.9%	78.1%	85.5%	94.3%	52.9%	56.2%
Γ_{min}	96.17	73.31	79.71	86.72	95.25	53.43	56.72
$Y_{i,j}$	$Y_{3,3}$	$Y_{3,4}$	$Y_{4,1}$	$Y_{4,2}$	$Y_{4,3}$	$Y_{4,4}$	$Y_{5,1}$
α'	58.5%	62.5%	34.5%	35.0%	36.5%	38.0%	17.0%
α^*	60.0%	64.1%	34.6%	36.0%	37.5%	39.1%	17.0%
Γ_{min}	60.13	63.85	34.77	36.13	37.41	38.93	17.06
$Y_{i,j}$	$Y_{5,2}$	$Y_{5,3}$	$Y_{5,4}$	$Y_{6,1}$	$Y_{6,2}$	$Y_{6,3}$	$Y_{6,4}$
α'	17.0%	17.0%	17.0%	9.0%	9.0%	9.0%	9.0%
α^*	17.3%	17.6%	18.0%	9.2%	9.3%	9.4%	9.5%
Γ_{min}	17.31	17.63	17.96	9.19	9.28	9.37	9.45

由图 4-4 可知，存在最优解使总时延 Γ 最小。根据表 4-4 得到的结果计算 21 组数据的 α^* 和 α' 的 NRMSE 为 1.38%，即实验得到的使得总时延 Γ 最小的 α' 与推导得到的 α^* 近似相等。




图 4-4 数据分配比例与数据处理总时间

Figure 4-4 Data allocation ratio and data processing time

实验 2：参数 θ 和 β 对数据最优分配比例的影响。

实验 2.1：参数 β 对最优分配比例的影响。

本实验研究 $\theta = 0.5$ 和 $\theta = 1$ 条件下不同 β 对最优分配比例 α' 的影响。与实验 1 相同，本组实验（包括实验 2.1，实验 2.2）对每组参数随机生成 1000 组数据集，其中一组数据集包含 100 个数据，每组数据获取一个使总时延 Γ 最小的 α' ，并与计算推导的 α^* 进行比较。设置 $\beta \in [0, 0.5)$ ，步长 0.05，验证 β 对最优分配比例的影响。

实验 2.2：参数 θ 对最优分配比例的影响。

本实验研究 $\beta = 0.1$ 和 $\beta = 0.4$ 条件下不同 θ 对最优分配比例 α' 的影响，分别设置 $\theta \in \{0.2, 0.5, 1, 2, 5, 10\}$ 和 $\theta \in \{0.5, 1, 2, 5, 10\}$ ，验证 θ 对最优分配比例的影响。

实验 2.1 与实验 2.2 结果如图 4-5 所示， α' 与 β 正相关， α' 与 θ 负相关，且 α' 与本文推导得到的 α^* 基本吻合，进一步证明了实验 1 得到的结论。由式(4-6)，(4-10)可知， β 对边缘数据处理时间影响更为明显。随着 β 的增加，边缘数据处理时间 τ_{edge} 随之增加，因而更多的数据被分配给终端处理， α' 也随之增加； θ 表示终端设备与边缘服务器数据处理时间的比值。随着 θ 的增加边缘服务器处理数据速度更快，更多的数据被分配给边缘服务器处理， α' 也随之减少。



 图 4-5 参数 θ 对最优分配比例的影响


 Figure 4-5 Effect of the parameter θ on the optimal allocation ratio

实验 3: 不同 θ 和 β 对惩罚系数 ξ 的影响。

本实验研究 $\beta = 0.1$ 条件下不同 θ 以及 $\theta = 0.5$ 条件下不同 β 对惩罚系数 ξ 的影响。我们通过仿真程序统计下最小值 Γ_{min} 及对应 α' 。通过 $\alpha' = \frac{1}{\theta - (1+\xi)\beta k + 1}$ 计算得到最优数据分配策略下对应的惩罚系数 ξ 。参数集 $\theta \in \{0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 1\}$, $\beta \in [0.05, 0.5)$, 步长为 0.05。

如图 4-6 所示, ξ 与 β 负相关。 $\beta = \frac{F}{M}$ 表示本地分类错误的概率, 随着本地分类错误率增高, 更多的数据被分配给边缘服务器处理, 因此边缘服务器空闲时间减少, 惩罚系数降低。

ξ 与 θ 负相关。 $\theta = \frac{p_l}{p_e}$ 表单位数据在本地与边缘的处理时间之比, θ 越大表示边缘服务器处理数据越快, 因而分配到边缘的数据越多, 边缘服务器利用率升高, 惩罚系数随之降低。

图 4-6 参数 θ 和 β 对惩罚系数 ξ 的影响Figure 4-6 The effect of parameters θ and β on the penalty coefficient ξ

根据以上分析结果，在终端执行分配策略时，应综合考虑边缘系统特性，针对不同参数动态调整 ξ ，使终端设备计算得到的数据分配比例更接近最优分配，从而提高整个边缘系统的数据处理效率。

4.4 本章小结

本章将边缘智能概念引入智能化数控系统，详细介绍边缘智能关键技术，提出了基于云边协同的任务卸载以及数据划分优化方法，主要研究内容如下：（1）在现有任务时延基础上添加系统数据吞吐率指标，提出了一种在保证实时性需求基础上提高系统吞吐率的模型切分算法；（2）针对任务模型实时性和准确性自适应需求提出一种自适应模型选择算法；（3）基于 DDNN 分布式深度神经网络架构，综合考虑终端设备和边缘服务器的计算能力构造了一个最优化问题来最小化数据处理时间，并以此提出最优数据分配策略。

第 5 章 智能数控系统应用服务研究

5.1 基于云边协同的刀具磨损诊断及预测

刀具作为数控系统的重要组成部分，也是加工过程的直接执行者，是最易受损的部件^[121]。在传统切削加工过程中，主要依靠加工人员主观经验判断刀具磨损情况进行换刀，这会造成刀具磨损量未超过正常磨损范围却被卸下，或刀具剧烈磨损却未更换刀具的情况^[122]。刀具使用不足将导致生产成本上升，而未及时换刀则会影响产品质量、加工精度，甚至造成机床损坏，危害人员安全，因此需要对刀具磨损情况进行实时监控及预测。

为解决上述问题，本章给出一个边缘智能驱动的数控系统数字孪生应用实例，建立刀具的 DT 模型，搭建边缘计算环境，并通过本文提出的模型切分和模型选择算法部署 DT 模型。

5.1.1 刀具信息模型

图 5-1 显示了我们搭建的应用环境和工作流程。CNC 控制器采用“蓝天数控”GJ430 数控系统。将 RaspberryPi 4B 部署为边缘节点，将 SIMATIC NANOBOX PC 部署为边缘服务器。GJ430 和数据采集装置采集加工过程中产生的实时数据，通过边缘节点和边缘服务器对数据进行分析处理，构建并部署 DT 模型，对刀具磨损情况进行诊断及预测。开发可视化客户端方便操作者监控刀具状态，并通过 GJ430 进行反馈控制。




图 5-1 实验环境及工作流程

Figure 5-1 Experimental environment and workflow

本节根据文章第三章给出的信息模型通用建模方法建立刀具的信息模型，如图 5-2 所示。刀具是数控机床的重要组件，包含过程属性集和静态属性集。刀具的静态属性集为刀具列表；过程属性集包括正在使用的刀具 ID、刀具类型、刀具状态、刀具寿命（设定寿命、警告寿命和实际寿命）、几何参数（刀长和半径）、额定主轴转速、额定进给率、刀具磨损（实际磨损量和预测磨损量）以及包括力学、加速度和声发射信号的传感器数据。每个数据项都包含索引、访问权限、数据类型和数据值等描述。

从信息模型到 DT 模型的映射采用 OPC UA 实现。信息模型中每个数据项对应 OPC UA 地址空间中的一个节点，节点间的引用关系由信息模型的层次结构确定。用户通过可视化客户端访问服务器，获取 OPC UA 地址空间中的刀具信息，实现对刀具信息模型的加载、浏览及修改。

最后，OPC UA 服务器订阅节点“磨损预测值”，当磨损预测值达到警告寿命时，触发报警并显示在数控系统 HMI 上，提示操作人员对刀具进行维护。




Figure 5-2 Information model of machine tool

5.1.2 刀具磨损诊断及预测机理模型

5.1.2.1 刀具磨损诊断及预测机理模型构建

刀具磨损是一个动态的、时变的、非线性的和随机的过程，有许多可能的干扰因素。而深度神经网络具备良好的学习能力，能够通过多层表示来建立传感器

信号和实际刀具磨损之间的复杂关系。现有研究普遍认为网络越深，模型准确度越高，然而，伴随网络深度的增加往往会出现退化问题。残差网络能够在保障网络深度的同时有效解决深层网络退化现象，文献^[123]将其应用于刀具磨损量的实时监测，基于残差网络的刀具磨损量实时监测模型如图 5-3 所示。




图 5-3 基于残差网络的刀具磨损监测模型

Figure 5-3 A real-time monitoring model of tool wear based on residual network

在此基础上，Sun 等人^[122]使用 LSTM 预测刀具磨损状态。然而，与 LSTM 相比，时间卷积网络（TCN）梯度稳定、训练速度快、接受域大小灵活、输入长度可变，更适合解决时序预测问题^[120]。为选择合适的预测模型，本文设计了如图 5-4 所示的 3 层 TCN 模型。




图 5-4 基于 TCN 的刀具磨损预测模型

Figure 5-4 A real-time prediction model of tool wear based on TCN

分别对已有的 LSTM 模型和本文设计的 TCN 模型训练 200 轮，模型输入数据大小为 15 次加工后的刀具磨损值，预测步长为 10 次加工，刀具磨损预测结果如图 5-5 所示。使用均方根误差和平均绝对误差描述模型损失，得到模型损失和执行时如表 5-1 所示，在模型损失差距较小的情况下，TCN 模型的实时性更佳。根据模型选择算法，本文最终选择 TCN 模型对刀具磨损状态进行预测。

表 5-1 预测模型对比

Table 5-1 Predictive model comparison

模型	RMSE	MAE	节点执行时间(ms)	服务器执行时间(ms)
LSTM	7.47	6.21	20.45	11.37
TCN	5.67	5.17	12.27	6.82





图 5-5 刀具磨损预测结果

Figure 5-5 Prediction results of tool wear based on TCN and LSTM

5.1.2.2 基于云边协同的部署方法及实验验证

本文采用 RCNN 和 TCN 进行刀具磨损状态的诊断及预测，数据处理流程如图 5-6 所示。根据本文提出的吞吐率优化模型切分算法对数据处理任务进行切分部署，备选切分点位于每个子任务执行完成之后。子任务划分如表 5-2 所示，输入数据为 X、Y、Z 扭矩、加速度和 AE 信号组成的 7 维时间序列。具体任务切

分步骤如下。

表 5-2 子任务列表
Table 5-2 List of subtasks

任务	子任务	组成	输出数据维度
数据预处理	0	降采样	7*5000
		小波变换 (wavelet transform)	7*1255
刀具磨损实时监测	1	Residual block Post-activation	128*626
	2	Residual block Pre-activation[0]	128*313
	3	Residual block Pre-activation[1]	128*313
	4	Residual block Pre-activation[2]	128*157
	5	Residual block Pre-activation[3]	128*157
	6	Residual block Pre-activation[4]	128*79
	7	Residual block Pre-activation[5]	128*79
	8	Residual block Pre-activation[6]	128*40
	9	Residual block Pre-activation[7]	128*40
	10	Residual block Pre-activation[8]	128*20
	11	Residual block Pre-activation[9]	128*20
	12	Residual block Pre-activation[10]	128*10
	13	Residual block Pre-activation[11]	128*10
	14	Residual block Pre-activation[12]	128*5
	15	Residual block Pre-activation[13]	128*5
	16	Residual block Pre-activation[14]	128*3
	17	Residual block Pre-activation[15]	128*3
	18	Residual block Pre-activation[16]	128*2
	19	Residual block Pre-activation[17]	128*2
	20	Dense	1*1
刀具磨损量预测	21	TCN[0]	4*15
	22	TCN[1]	8*15
	23	TCN[2]	16*15
	24	Dense	1*15




图 5-6 刀具磨损预测数据处理流程

Figure 5-6 Data processing of tool wear prediction

首先,初始化并记录各子任务在边缘节点和边缘服务器的执行时间,如图 5-7 所示,数据在设备上的推理时延和数据上传/下载时延使用不同颜色区分。




图 5-7 子任务执行时延

Figure 5-7 Execution delay of subtasks

接下来, 计算所有备选切分点对应的数据处理时延和吞吐率。最佳切分点由两个指标定义: 推理时延和吞吐率, 由于吞吐率与时间片成反比, 我们使用时间片长度描述吞吐率。如图 5-8 所示, 使用不同颜色表示数据在流水线不同阶段的处理时延, 并使用不同符号来区分用于决策的不同度量。绿色表示边缘服务器的执行时延, 橙色表示数据传输时延, 蓝色表示边缘节点的执行时延, 菱形符号标记吞吐率最大的切分点, 星型符号标记推理时延满足实时性要求情况下吞吐率最大的切分点, 即最佳切分点。设置系统最大可容忍延迟为 480ms, 当边缘服务器连接 2 个边缘节点时, 最佳吞吐率对应的切分点推理时延满足时延要求, 即为最佳切分点。当服务器连接 4 个边缘节点时, 最佳吞吐率对应的切分点推理时延超出最大可容忍时延, 则在满足时延要求的候选切分点中选择吞吐率最大的作为最佳切分点进行模型分割。




图 5-8 子任务切分点选择
Figure 5-8 Partition point selection

5.1.3 刀具磨损监控应用开发

边缘节点执行最佳切分点前的模型，并将计算结果通过 websocket 发送给边缘服务器，边缘服务器执行切分点之后的模型，将计算结果以 OPC UA 方式发送给 OPC UA 服务器，用户通过客户端访问服务器获取刀具状态。OPC UA 提供两种主要通信机制：客户端-服务器模式和发布订阅模式。其中，客户端通过定义的服务访问服务器提供的信息^[124]；发布订阅模式允许局域网内多个授权的客户端（订阅者）获取服务器（发布者）发布的信息。

本文基于数控系统信息模型开发 OPC UA 服务器，并将服务器集成于 GJ430 数控系统中。在服务器初始化阶段设定端口号、安全证书等服务器配置。随后根据 XML 文件提供的数控系统信息模型定义 OPC UA 服务端节点空间中的节点属性和节点间引用关系，在服务端建立相应的 OPC UA 模型，并将数据节点的数据源与 GJ430 数控系统动态链接库提供的数据读取函数绑定，从而实现节点数据的实时更新。最后启动服务器监听，在控制台界面返回服务器地址空间访问地址。

为实现刀具磨损情况的诊断及预测，OPC UA 服务器将刀具的磨损阈值设置为事件的触发条件，当服务器检测到刀具磨损预测达到阈值，即刀具磨损即将超出正常范围时触发事件，所有订阅该事件的客户端均可从服务器获得通知信息，提示现场操作人员进行刀具维护。任何支持 OPC UA 标准的客户端均可通过访

问服务器提供的端口解析机床的 DT 模型，DT 的实现并不依赖客户端，用户对 DT 模型的使用方式也更为灵活。因此本文使用开源客户端界面展示刀具磨损情况和预测结果。

客户端访问界面如图 5-9 所示，包含 3 个主要区域。首先，在页面顶端地址栏输入 OPC UA 服务器的 URL，连接客户端与服务器，页面底部显示客户端连接状态。连接成功后，区域 1 显示当前连接数控机床（GJ430）的信息模型，服务端提供的 OPC UA 模型节点以树状结构显示，用户可以通过浏览信息模型来了解数控系统的逻辑结构及可供访问的数据项。点击节点列表中的数据项即可在区域 2 中查看所选节点的属性信息，如 NodeId, NodeClass, AccessLevel 以及 DataType 等。区域 3 提供数据可视化和分析功能，包括事件提醒、数据项订阅、引用关系和数据可视化。如图 5-9 所示，可将“刀具磨损”和“磨损量预测”数据项加载到数据可视化模块，设定数据采样间隔即可实时监测刀具磨损状态的变化曲线。其中横坐标表示加工轮次，纵坐标表示磨损量（mm）。

这个边缘智能驱动的数控系统数字孪生应用实例允许用户快速、可靠的获取刀具实时状态。在此基础上，操作人员可以实现对刀具的预测性维护，提高加工质量，降低生产成本。




图 5-9 客户端功能展示

Figure 5-9 Functions of the visualization client

5.2 基于云边协同的加工轨迹优化

如图 5-10 所示，数控系统加工过程较为复杂，首先针对生产需求通过 CAD 工具进行产品设计，该过程包含任务规划、概念设计、结构设计以及加工设计等

阶段；随后进行工艺设计过程，进行工艺路线设计、工序设计以及刀量夹具设计等；最后通过 CAM 工具生成刀具路径进行加工。刀具路径常常由转化成的一系列数控程序（NC 代码）指定，切削加工的效率、质量、精度等受到 NC 程序质量、操作者经验和技术水平、工件形状、材料、刀具材质等客观因素的影响和制约。

然而，NC 代码通常是由 CAD/CAM 根据静态模型生成的，这时的刀具路径只关注位置上的连续，欠缺加工过程中刀具运动状态等相关因素的考虑。CAM 系统生成的刀具路径通常是位置连续的分段线性路径，程序段之间不连续，即切向不连续，会导致数控系统频繁降速，影响加工效率。此外，根据 CAM 生成的 G 代码在实际加工时也会出现“槽点”以及刀具路径之间的不均匀，这会导致进给速度和加速度出现频繁的波动，如果在加工时降速不充分，还会造成机床的剧烈振动，这会对工件表面质量带来很大的影响，同时也会降低加工的效率。因此在实际加工前优化加工工艺是一个切实必要的实践领域，直接完善 G 代码比编辑 CAM 刀具路径之后重新进行后置处理更有效。




图 5-10 数控系统加工流程

Figure 5-10 The machining process of CNC systems

在以往的工作中，CAM 系统的数据输入仅在程序设计阶段、并且不允许根据加工过程中收集的数据做出工艺决策，CAM 与机床控制器之间的数据传输是单向的。对于这些负面路径点的去除通常依赖于人工的方法，通过 CNC 程序设计人员识别路径缺陷。然而随着工艺复杂度以及工艺需求的提高，工艺文件规模

也随之变大。基于人工的优化处理方式需要编程人员付出大量时间精力处理工艺文件,另一方面受到操作者技术水平以及工件形状等客观因素的影响和制约,难以对数控系统加工过程的最终效果进行实时有效的控制。

为解决以上问题,本章给出了一个基于数字孪生的数控系统工艺优化应用实例,设计了基于多线程的轨迹优化处理流程,提出路径解析算法和基于聚类的自适应路径缺陷优化算法用于定位并优化刀具路径,实现了轨迹优化过程的实时可视化。

5.2.1 加工轨迹信息模型

实验环境与工作流程如图 5-11 所示。数控系统控制器采用 Golding GJ430 数控系统,数据收集器为搭建有 OPC UA 服务的主机,搭载 Intel i9 11900K CPU, NVIDIA GeForce RTX 3090 GPU。工作基本流程如下:首先将 CAD/CAM 模型经过后置处理生成 NC 工艺文件,通过边缘服务器对工艺文件进行解析和数据分析,构建加工工艺的信息模型。最后经过工艺优化算法建立工艺优化机理模型,并将处理生成的结果在应用端进行可视化展示。




图 5-11 实验环境及工作流程

Figure 5-11 The experimental environment and workflow

本文将轨迹优化的整体流程分为工艺文件解析、加工轨迹生成、轨迹优化、轨迹可视化 4 个阶段。如图 5-12 所示，数字孪生应用分为前端 UI 和后端逻辑处理。在工艺解析阶段，系统后端首先对 G 代码和辅助代码（包括 M、T 代码）等加工工艺文件进行解析，分析工艺文件中隐含的价值信息，获取插补方法、插补周期、加工指令等相关信息，并将加工过程分解为一系列加工轨迹。在轨迹生成阶段，对前一步骤中获得的相关工艺信息进行轨迹生成，在此过程中可获取各个轨迹的进给轴位置信息，并利用位置信息生成轨迹与点云图像。




图 5-12 轨迹优化流程

Figure 5-12 Machining trajectory optimization process

进给轴位置信息在每个插补周期顺序生成，时序相关，在本文开发的应用中轨迹生成以及轨迹优化过程中以时间序列数据的方式存储为位置向量信息；轨迹优化过程通过本章提出的轨迹优化算法，对轨迹生成的进给轴位置时序数据进行优化，并将优化后的位置信息反馈给加工工艺文件对工艺文件进行相关优化。

系统前端在轨迹生成以及轨迹优化过程基础上通过可视化框架在客户端向用户实时反馈轨迹生成和优化的相关过程。在加工复杂结构件时，加工工艺文件中会包含大量加工指令，其轨迹生成和轨迹优化过程会产生较大的时延，因此这种串行方式难以实现加工轨迹的实时可视化。

如图 5-13 所示为改进后的前端流水线结构，优化过程首先基于系统后端工艺文件解析过程分解得到的若干加工轨迹，按轨迹机理模型中的轨迹切分算法将轨迹分解为若干轨迹片段，轨迹片段记录的数据为进给轴时序位置信息。部署在系统前端的可视化客户端将轨迹优化过程划分为轨迹生成、轨迹优化以及实时可视化三个进程，三个进程按流水线结构依次对轨迹片段进行处理。当优化过程的流水线充满时，轨迹生成、轨迹优化以及实时可视化过程并行执行，每个轨迹片段对应的处理周期均可输出轨迹优化的实时可视化结果，这样可大大提高可视化过程的实时性，便于操作人员对优化过程的实时监控和调试。



图 5-13 流水线处理方式
Figure 5-13 Pipeline method

本节根据文章第 3 章给出的信息模型通用建模方法建立加工轨迹的信息模型，如图 5-14 所示。加工轨迹信息是数控系统的信息的重要组成部分，其信息模型包含反应数控系统和工艺文件固有属性的静态数据集和反应工艺优化过程的过程数据集两种数据集。其中，静态数据集包括工艺文件名称、G 代码、辅助代码和插补信息等属性，其中数控系统插补信息进一步包含系统包含的插补算法、插补周期等配置属性。过程数据集包括轨迹优化过程中产生的轨迹编号、主轴信息、进给轴信息等实时信息。其中主轴信息包含主轴转速等主轴相关数据，进给轴信息进一步包含进给轴加速度与轴坐标。上述数据信息均含有数据项索引、可读性、数据类型、数据值等属性，时间戳等属性。

与刀具信息模型相同，从信息模型到 DT 模型的映射同样采用 OPC UA 实现。OPC UA 服务将加工轨迹信息类映射为 OPC UA 地址空间中的对象节点并将加工轨迹信息类中的每一个数据项映射为变量节点。轨迹生成、轨迹优化以及轨迹可视化三个进程均可通过访问或修改地址空间中变量节点的值进行交互，因此应用可以根据需求更加灵活的部署于数控系统、边缘服务器以及可视化终端中。





Figure 5-14 Trajectory information model

5.2.2 加工轨迹优化机理模型构建及实验验证

高速加工数控机床的高速高精度运动控制是提高加工效率和质量的重要手段，而 G 代码是数控系统中最常用的一种运动控制语言，G 代码是目前使用最广泛的计算机数控编程语言，已经成为发比较完善的 NC 代码，它主要用于计算机辅助制造以控制自动化机床，并且有许多变体^[125]。G 代码指令被提供给数控控制器，该控制器告诉电机移动到哪里、移动多快以及遵循什么路径。本文中所使用的 G 代码遵循标准 ISO6983，是通常使用的 G 代码标准中的一种。

如图 5-15 所示，是一个由 Mastercam 软件生成的五角星凸台模型，由该模型生成的 G 代码共有 16225 行。



(a)

(b)

图 5-15 CAD 模型及 G 代码

Figure 5-15 CAD model and G-code

而对于 G 代码的工艺解析过程，包含词法分析以及轨迹分解两个步骤。其中词法分析主要是对以下运动控制的功能进行词法分析，通过定义关键词的正则匹配，把 G 代码、坐标位置、圆弧参数等数据进行定位、提取。

(1)功能 G 代码：G00（快速空程移动）、G01（直线加工）、G02(顺时针圆弧加工)、G03(逆时针圆弧加工)、G90（绝对坐标）、G91（相对坐标）等。

(2)坐标位置：X、Y、Z（位置点的三维空间坐标）。

(3)圆弧参数：I、J、K（圆弧运动中位置点与圆心间的关系）和 R（圆弧半径）。

(4)加工参数：F（进给速度）。

轨迹生成阶段对工艺解析后保存的数据文件进行轨迹生成和点云生成工作。点云具有排列、平移和旋转不变性的特点，可局部放大和伸缩，便于对工艺的检查和分析工作。如图 5-16 是进给轴坐标数据的轨迹生成的点云，图 5-17 是其相应的点云局部放大。通过对轨迹和点云生成结果的审查分析，可初步确定存在的轨迹缺陷。




图 5-16 G 代码生成轨迹

Figure 5-16 G-code generated trajectories




图 5-17 轨迹点云及其局部放大

Figure 5-17 The point cloud of the trajectory and local magnification

为了对轨迹缺陷进行定位，需要对全局的加工轨迹进行分析以确定缺陷集中的区域。刀具路径的总体走势为水平的环状层级路径，轨迹分解算法通过一个与 z 轴垂直，跟随路径点移动的判定平面来将刀具环状路径进行层级分解，找到该轴上的跃迁点，将整段的复杂路径分解为若干相对连续的部分。在此基础上，算法使用指数加权平均确定判定平面，以减少异常点或者抖动的影响。路径层级分解算法流程如下：

Algorithm 3 Path decomposition algorithm**1: Input:**

2: points: All the three-dimensional coordinates.

3: axis: Divide the plane according to the direction of the coordinate axis.

4: b: The distance threshold of the current point from the partition plane.

5: min_n: The minimum of the number of point sets in a plane.

6: alpha: The weight of the exponentially weighted average.

7: Output:

8: blocks: List of path sets after partitioning.

9: procedure10: blocks $\leftarrow$ []11: current_block $\leftarrow$ []12: n $\leftarrow$ 013: plane_position $\leftarrow$ points[0][axis]

14: for each point in points do

15: distance $\leftarrow$ point[axis] - plane_position16: n $\leftarrow$ n+1

17: if abs(distance) < b then

18: currentBlock $\leftarrow$ getpoint(currentBlock, point)19: n $\leftarrow$ n+120: step_size $\leftarrow$ alpha21: plane_position $\leftarrow$ plane_position + step_size * distance

22: else

23: if len(current_block) $\geq$ min_n then23: blocks $\leftarrow$ getpoint(blocks, current_block)

24: end if

25: current_block $\leftarrow$ point26: plane_position $\leftarrow$ point[axis]27: n $\leftarrow$ 1

28: end if

29: end for

30: if len(current_block) $\geq$ min_n then31: blocks $\leftarrow$ getpoint(blocks, current_block)

32: end if

33: return blocks

本文实验中算法的参数输入值分别为 axis=2, 即按照 Z 轴分解路径, b=0.01, min_n=10, alpha=0.1, move=True。经该算法处理后一共得到 37 条轨迹, 部分轨迹在 Z 轴平面投影如图 5-18 所示。通过分解后的片段可以看到, 轨迹不均匀的位置主要集中在轨迹段 (d) 上, 放大后的图像如图所示。




图 5-18 轨迹片段

Figure 5-18 Trajectory fragments

为提高对缺陷路径的处理精确度，对上述步骤处理后的缺陷路径进行环形分割，将缺陷路径进行环状剥离，共得到 13 个星型环状路径的数据集。




图 5-19 点云聚类结果

Figure 5-19 The clustering results of point cloud

基于欧式距离的聚类算法能够将数据集中的点进行自动划分，对于球状凸集

的处理效果较好,但是难以推广到任意的形状。而基于密度的聚类方法有较强的自适应性,便于发现无规则形状的簇。为了进一步揭示缺陷路径的局部特性以提高优化流程的自适应性,使用基于密度的聚类方法 DBSCAN 算法对环状星性路径进行聚类分割操作,部分星型环状路径的示例如图 5-19 所示。

为了便于区分上述聚类结果中簇间路径点集的局部特征,我们使用法向量来刻画和反应簇中点集的局部变化特性。法向量是散乱点云轨迹模型的一个重要属性,可用来描述模型特征信息。如果一个簇内的轨迹点相对较为平坦时,邻域内各点法向量方向变化也相对平缓;反之,簇内轨迹点起伏变化较大时,相邻点法向量方向变化也相对较大,因此,可通过估算簇的法向量方向变化,进而决定使用不同的滤波算法。




图 5-20 轨迹法向量变化

Figure 5-20 Trajectory normal vector changes

图 5-20 展示了聚类结果中某个簇内部分轨迹的法向量方向变化情况,为量化这项指标,突出点序列的局部特征,我们以大小为 k 的邻域分别统计各簇内相邻点间的法向量,以相邻法向量夹角作为点相邻点跨越的弧度来反映点序列平坦度,并该弧度在 k 邻域内的累积值的平均反应 k 邻域内数据序列的整体起伏。

设 $p_1, p_2, \dots, p_k (k > 2)$ 为数据点序列, $v_1, v_2, \dots, v_k$ 分别为 $\overrightarrow{p_1 p_2}, \overrightarrow{p_2 p_3}, \dots, \overrightarrow{p_{k-1} p_k}$ 的法向量,则 k 邻域内数据序列起伏程度指标为:

$$Avgdeg = \frac{\sum_{i=1}^{k-2} \arccos\left(\frac{v_i v_{i+1}}{|v_i| |v_{i+1}|}\right)}{k} \quad (5-1)$$

该值越大,则点集轨迹凹凸不平程度越明显。基于实验的实际观察,当 $k=20$ 时特征的区分度明显,表 5-3 展示了进一步的统计结果,表明了 381 个长度为 k 的片段中 $Avgdeg$ 的大小和占比情况,以及对数据特征做了描述,并在表中对数据序列的起伏程度制定了等级。

表 5-3 特征统计与分级
Table 5-3 Feature statistics and grading

Avgdeg	数目	占比	特征描述	缺陷等级
$Avgdeg \geq 10$	154	40.42%	路径凹凸不平, 偏移点多, 对加工影响大。	III
$Avgdeg \in (3,10)$	149	39.12%	路径缺陷较严重, 部分路径不平坦, 对加工有影响。	II
$Avgdeg \leq 3$	78	20.46%	路径缺陷较轻, 对加工影响小。	I

综合上述特征序列的分析及统计结果可知, 由于各个 k 邻域内的数据序列存在特征差异, 单一的优化方案难以对所有数据序列起到良好的效果, 因此, 我们决定针对不同的缺陷特征采用相应的滤波平滑算法, 下面对所采用的滤波平滑算法做介绍。

高斯滤波: 高斯滤波器是一种线性低通滤波器, 能够有效的抑制噪声, 平滑数据。其本质是带权值的加权均值滤波, 权值大小与滤波器中元素到滤波中心距离有关, 卷积核中心权重数值最大, 并向四周减小。高斯滤波器对于抑制服从正态分布的噪声非常有效。二维高斯函数表达式见公式:

$$f(x, y) = f(x)f(y) = \frac{1}{\sqrt{2\pi}\sigma_x} e^{-\frac{(x-\mu_x)^2}{2\sigma_x^2}} \frac{1}{\sqrt{2\pi}\sigma_y} e^{-\frac{(y-\mu_y)^2}{2\sigma_y^2}} \quad (5-2)$$

二阶指数平滑: 指数平滑是一种移动平均算法的改进, 可用于短期趋势性的数据平滑。对于数据序列没有明显趋势变化时可采用一阶指数平滑, 而二阶指数平滑是在一阶指数平滑的基础上, 再一次进行指数平滑, 适用于具有一定线性趋势的数据序列, 其公式为:

$$\begin{cases} S_{t+1}^{(1)} = ax_t + (1-a)S_t^{(1)} \\ S_{t+1}^{(2)} = aS_t^{(1)} + (1-a)S_t^{(2)} \end{cases} \quad (5-3)$$

其中 $a \in [0,1]$ 表示平滑系数, x_t 表示真实值, S_t 表示上一个平滑后的数据值, S_{t+1} 表示本次平滑后的数据值, 上标(1)、(2)分别表示了一阶平滑和二阶平滑。

Savitzky-Golay 滤波: S-G 滤波被广泛地应用于数据序列的平滑去噪处理, 是一种对某一窗口中 $2m+1$ 个离散数据进行最小二乘法拟合的滤波方法, 通过卷积实现局部区间的多项式拟合, 从而去除数据中的噪声信号, 突出数据中的特征信息, 减少不必要的信息对数据的影响。S-G 滤波器最大的特点是去除信号噪声的同时保持信号的形状、宽度不变, S-G 平滑滤波的效果与选取窗的宽度紧密相关, 可以满足多种不同场合的需求。

假设连续数据为 x_i , $i = -m, \dots, 0, \dots, m$, 其 n 阶拟合多项式为:

$$y(n) = \sum_{k=0}^n b_k i^k = b_0 + b_1 i + b_2 i^2 + \dots + b_n i^n \quad (5-4)$$

其中, b 为多项式的系数, k 为多项式的阶数, i 为多项式的权数。数据与拟合的多项式之间的均方误差 ε_D 为:

$$\varepsilon_D = \sum_{i=-m}^m [y(n) - x_i]^2 = \sum_{i=-m}^m \left[\sum_{k=0}^n b_k i^k - x_i \right]^2 \quad (5-5)$$

要使均方误差最小, 则 ε_D 各项系数的导数应为 0, 即:

$$\frac{\partial \varepsilon_D}{\partial b_r} = 0 \quad (r = 0, 1, 2, \dots, n) \quad (5-6)$$

展开后可得:

$$\sum_{k=0}^n b_k \sum_{i=-m}^m i^{k+r} = \sum_{r=-m}^m x_i i^r \quad (5-7)$$

通过求解式(5-6)即可求出多项式各项系数 b_k , 从而得到拟合的 n 阶拟合多项式 $y(n)$ 。

图 5-21 展示了不同特征的部分 k 邻域内序列数据滤波优化结果, 由图中所示结果可知(a)数据序列凸凹不平、相对散乱, 线性关系或者趋势不明显, 高斯滤波算法效果更好; (b)数据序列前后具有线性关系或者趋势、凸凹特征不明显, 二阶指数平滑方法效果更好; (c)数据序列相对平滑, 起伏较少, SG 滤波算法对该类数据的优化和拟合效果更好。




图 5-21 滤波优化结果

Figure 5-12 The results of filtering optimization

据此, 我们提出以下自适应滤波优化算法, 算法中 $\text{len}()$ 为计算数据序列长度的函数, $\text{getNormVect}()$ 为计算法向量的函数, $\text{GaussianFilter}()$ 为高斯滤波函数, $\text{QuadExpFilter}()$ 为二阶指数平滑函数, $\text{SG_filter}()$ 为 SG 滤波函数, $\text{getPoint}()$ 为将数据序列加入集合的函数。

Algorithm 4 自适应滤波优化算法

- 1: Input:
- 2: $C = \{c_1, c_2, \dots, c_m\}$: The set of clusters formed after clustering segmentation
- 3: k : Size of neighborhood

```

4: wsize: Gaussian window size
5:  $\sigma$ : Standard deviation of Gaussian filtering
6:  $\alpha$ : Parameters of exponential filtering
7: sgwsize: Window size of SG filter
8:  $\beta$ : The order size of the SG filter
9: III: Avgdeg larger than this value is suitable for Gaussian filtering
10: II: Avgdeg smaller than this value uses SG filtering
11: Output:
12:  $C'$ : The set of optimized data sequences
13: Procedure
14: for each cluster in C do
15:      $vect \leftarrow []$ 
16:      $C' \leftarrow []$ 
17:      $p \leftarrow []$ 
18:     for  $i \leftarrow 0$  to  $len(cluster) - 1$  do
19:          $v \leftarrow getNormVect(p_i, p_{i+1})$ 
20:          $p[i] \leftarrow p_i$ 
21:          $vect[i] \leftarrow v$ 
22:         if ( $i > 0$  and  $i \bmod k == 0$ ) then
23:              $deg \leftarrow 0$ 
24:             for  $j \leftarrow 0$  to  $len(vector) - 1$  do
25:                  $deg += \arccos((vect[j]vect[j+1])/|vect[j]| |vect[j+1]|)$ 
26:             end for
27:              $Avgdeg \leftarrow deg / len(vector)$ 
28:              $vect \leftarrow []$ 
29:             if  $Avgdeg > A$  then
30:                  $p \leftarrow GaussianFilter(p, wsize, \sigma)$ 
31:             end if
32:             if  $Avgdeg < A$  and  $Avgdeg > B$  then
33:                  $p \leftarrow QuadExpFilter(p, \alpha)$ 
34:             end if
35:             if  $Avgdeg < C$  then
36:                  $p \leftarrow SG\_filter(p, sgwsize, \beta)$ 
37:             end if
38:              $C' \leftarrow getPoint(C', p)$ 
39:         end if
40:     end for
41: end for
42: return  $C'$ 

```

应用以上算法的优化前后的结果如图 5-22 所示，优化前后的 G 代码如图 5-23 所示。




图 5-22 轨迹滤波优化效果

Figure 5-22 The effect of trajectory filtering optimization

G1 X-28.361 Y10.006 Z26.976	G1 X-27.637 Y10.089 Z26.979
G1 X-28.056 Y1.0088 Z26.976	G1 X-26.863 Y10.147 Z26.982
G1 X-27.797 Y10.104 Z26.977	G1 X-26.187 Y10.207 Z26.985
G1 X-27.219 Y10.107 Z26.981	G1 X-25.686 Y10.298 Z26.986
G1 X-26.571 Y10.156 Z26.984	G1 X-25.288 Y10.418 Z26.986
G1 X-26.176 Y10.200 Z26.985	G1 X-24.852 Y10.530 Z26.987
G1 X-25.841 Y10.363 Z26.984	G1 X-24.293 Y10.624 Z26.988
G1 X-25.554 Y10.446 Z26.984	G1 X-23.705 Y10.727 Z26.989
G1 X-24.952 Y10.507 Z26.986	G1 X-23.224 Y10.862 Z26.990
G1 X-24.294 Y10.604 Z26.988	G1 X-22.840 Y11.018 Z26.989
G1 X-23.881 Y10.696 Z26.989	G1 X-22.416 Y11.155 Z26.989
G1 X-23.53 Y10.895 Z26.987	G1 X-21.869 Y11.269 Z26.990
G1 X-23.231 Y11.006 Z26.987	G1 X-21.292 Y11.389 Z26.991
G1 X-22.619 Y11.094 Z26.989	G1 X-20.819 Y11.538 Z26.991
G1 X-21.962 Y11.210 Z26.990	G1 X-20.438 Y11.705 Z26.990
G1 X-21.54 Y11.322 Z26.991	G1 X-20.017 Y11.851 Z26.990

(a)

(b)

图 5-23 G 代码优化结果

Figure 5-23 The result of G-code optimization

5.2.3 加工轨迹优化应用开发

本文通过 PyQt 结合 PyVista 库开发了数字孪生应用客户端的 GUI(图形用户

界面)。PyVista 是 Visualization Toolkit (VTK) 的辅助程序模块,它是一套继承自 VTK 数据格式的 Python 工具包,与 VTK 数据对象兼容。该软件包提供齐全的接口和文档,能够完成空间参考数据集的快速原型制作,分析和可视化集成。

可视化客户端与 OPC UA 服务器交互,而 OPC UA 服务器集成在 GJ430 数控系统中,从而实现加工数据的实时传输与可视化。服务器通过设定端口号、安全证书等完成初始化配置。分析与优化后的轨迹信息通过基于数控系统加工轨迹信息模型完成模型映射,并传输给 OPC UA 服务器生成工艺文件,数控系统则据此进行加工工作。

本文的数字孪生客户端如图 5-24 所示,包括两个主要区域, G 代码等工艺文件信息可以通过区域 1 查看,区域 2 则展示了 G 代码解析得到的轨迹点云图像。客户端后端程序对加工轨迹信息进行即时的分析和优化,并将改进的 G 代码反馈到区域 1。




图 5-24 轨迹优化可视化客户端

Figure 5-24 Trajectory optimization visualization client

通过这个客户端,数控系统实体与数字孪生应用之间能够实时交互加工工艺数据,提高了数控系统加工的质量与可靠性,同时,降低了手动编程操作员的技

术门槛，操作员无需使用手工的方式通过修正 G 代码而提高加工效果，大大降低了生产成本。

5.3 本章小结

本章基于智能化数控系统通用建模方法以及基于云边协同的模型部署方法，给出两个边缘智能驱动的数控系统数字孪生应用实例，主要研究内容如下：（1）搭建边缘计算环境，建立刀具的信息模型以及基于残差神经网络和 TCN 的刀具磨损机理模型，并通过本文提出的模型切分和模型选择算法部署 DT 模型，实现了刀具磨损实时监测与预测；（2）建立数控系统加工轨迹信息模型，提出了一种基于聚类分析的缺陷路径优化方法，实现了缺陷路径自适应滤波优化与可视化。

第 6 章 结论与展望

6.1 主要内容和创新点

工业物联网、云计算、边缘计算技术的高速发展以及人工智能技术与制造技术的深度融合,推动制造业向高端化、智能化方向发展。数控系统作为制造业的核心元素,其智能化水平是实现智能制造的基础和保障,数控系统智能化正成为智能制造发展的重要研究方向。本文以数控系统为研究对象,从数控系统智能化需求出发,提出了基于云边协同的智能化数控系统数字孪生体系结构,结合边缘智能技术给出了一种通用的数控系统数字孪生模型构建与模型部署方法,并在刀具磨损监控及预测和轨迹优化等方面进行了应用验证。本文主要研究内容和创新点如下:

(1) 对智能化数控系统体系结构展开研究。分析了智能化系统的概念及特征,对智能化数控系统进行抽象,提出了智能化数控系统领域模型,并详述了领域模型中智能元素的功能与实现方法;在智能化数控系统中引入数字孪生和边缘计算技术,对以云计算为核心的传统数控系统体系结构进行优化,提出了基于云边协同的智能化数控系统数字孪生体系结构。

(2) 对数控系统数字孪生建模方法展开研究。对智能化数控系统互联互通互操作应用场景进行概括,在智能化数控系统领域模型和体系结构基础上提出基于映射的信息模型构建方法;依托于 2016 年智能制造综合标准化项目“面向智能制造的数控装备互联互通及互操作 标准及试验验证”,参与起草了数控装备互联互通及互操作系列标准,并在蓝天数控 GJ430 采用 OPC UA 方法构建了数控系统信息模型;分析智能化数控系统机理模型构建方法以及关键技术,提出一种人工智能辅助机理模型的通用建模方法。

(3) 对数控系统数字孪生模型部署方法展开研究。将边缘智能技术引入到智能化数控系统体系结构中,详细阐述了云边端协同任务中机理模型的卸载优化方法,补充了系统数据吞吐率指标,提出了一种综合考虑系统实时性与吞吐率的机理模型任务切分算法;以实时性和准确性为指标,提出一种自适应的模型选择算法,提升了数控系统的边缘自治能力;针对边缘数据资源受限的问题,提出了以分布式深度神经网络为应用场景的数据划分方法。

(4) 对数控系统智能化应用展开研究。基于智能化数控系统信息模型和机理模型通用建模方法以及基于云边协同的模型部署方法搭建边缘智能应用环境,采用 OPC UA 方法建立刀具磨损与加工轨迹信息模型;在此基础上部署基于残差神经网络和 TCN 的刀具磨损机理模型,实现对刀具磨损情况的实时诊断与预测;在数控系统加工轨迹信息模型基础上,提出了一种基于聚类分析的缺陷路径优化方法,实现了缺陷路径自适应滤波与可视化。

6.2 研究展望

本文在系统分析智能制造背景下的数控系统智能化需求的基础上,围绕数字孪生和边缘智能,对数控系统智能化关键技术展开研究,并给出了智能化数控系统数字孪生应用方案。然而,数控系统是一种复杂系统,随着数控技术与智能化技术的进一步深度融合将有更多问题被提出。针对数控系统建模方法以及边缘智能资源优化,下一步研究计划如下:

(1) 进一步丰富完善智能化数控系统机理模型。

本文研究仅对刀具磨损和轨迹优化构建了机理模型,针对数控系统功能的多样性和复杂性特点还需进一步丰富和完善。后续将进一步应用本文方法对系统其他功能和智能化需求进行应用服务开发和验证,丰富智能化数控系统机理模型。

(2) 扩展模型部署应用场景,进一步优化模型部署方法。

本文探讨的模型切分部署优化方法,是基于所有边缘节点任务模型一致的假设提出的,因而方法提出的各个节点的切分策略相同。下一步将扩展模型部署应用场景,研究在边缘节点任务不同时的模型切分部署策略,进一步优化模型部署方法。

(3) 开展边缘智能模型优化方法研究。

现有的边缘智能模型推理优化技术按优化对象可以分为模型优化和部署方法优化两类。本文提出的边缘智能优化技术仅针对模型部署优化方法提出,后续将针对数控系统机理模型进一步开展模型剪枝、模型参数量化等模型压缩方法的研究,从而丰富现有的边缘智能研究工作。

参考文献

- [1] 走向智能机床[J]. 陈吉红;胡鹏程;周会成;杨建中;谢杰君;蒋亚坤;高志强;张成磊.Engineering,2019(04).
- [2] 工业 4.0 工作组, 德国联邦教育研究部. 德国工业 4.0 战略计划实施建议(上)[J]. 机械工程导报, 2013(3):23-33.
- [3] 中华人民共和国科学技术部: 美国出台国家先进制造战略计划[EB/OL].[2012-03-20]. http://www.most.gov.cn/gnwkjdt/201203/t20120319_93215.html.
- [4] “十四五”智能制造发展规划 专家系列解读[J].智能制造,2022(01):9.
- [5] 中华人民共和国国民经济和社会发展第十四个五年规划和 2035 年远景目标纲要[N]. 人民日报,2021-03-13(001).DOI:10.28655/n.cnki.nrmrb.2021.002455.
- [6] 董凯.“十四五”智能制造发展规划解读及趋势研判[J].中国工业和信息化,2022(01):26-29.DOI:10.19609/j.cnki.cn10-1299/f.2022.01.004.
- [7] 蔡锐龙,李晓栋,钱思思.国内外数控系统技术研究现状与发展趋势[J].机械科学与技术,2016,35(04):493-500.DOI:10.13433/j.cnki.1003-8728.2016.0401.
- [8] 陈吉红. 国产数控系统的技术进步与应用成果 [J]. 金属加工 (冷加工),2023,No.859(02):9-14.
- [9] 王磊, 卢秉恒, 中国工作母机产业发展研究[J]. 中国工程科学, 2020,22(2):29-37.
- [10] 国务院关于印发新一代人工智能发展规划的通知[J]. 中华人民共和国国务院公报,2017(22):7-21.
- [11] 刘强.数控机床发展历程及未来趋势[J].中国机械工程,2021,32(07):757-770.
- [12] 高舒凯,毕果.适用于智能制造的数控机床全信息监控系统[J].厦门大学学报(自然科学版),2022,61(06):1090-1096.
- [13] 陈晓光.智能化是数控系统的发展趋势[J].现代制造,2019(04):10-11.
- [14] 于东,毕筱雪,刘劲松,郎言书,于皓宇,黄艳.开放式、智能化“蓝天数控”系统及应用实践 [J]. 航空制造技术,2019,62(06):22-29.DOI:10.16080/j.issn1671-833x.2019.06.022.
- [15] Chen JH, Hu PC, Zhou HC, et al. Toward Intelligent Machine Tool[J]. Engineering,2019, 5(4):679-790. <https://doi.org/10.1016/j.eng.2019.07.018>.
- [16] 陈吉红, 杨建中, 周会成. 新一代智能化数控系统[M]. 北京: 清华大学出版社, 2021.
- [17] Luo W, Hu T, Ye Y, et al. A hybrid predictive maintenance approach for CNC machine tool driven by Digital Twin[J]. Robotics and Computer-Integrated Manufacturing, 2020, 65:101974.

- [18] 施巍松, 孙辉, 曹杰,等. 边缘计算:万物互联时代新型计算模型[J]. 计算机研究与发展, 2017, 54(5):18.
- [19] Zhou Z, Chen X, Li E, et al. Edge Intelligence: Paving the Last Mile of Artificial Intelligence with Edge Computing: Proceedings of the IEEE, 10.1109/JPROC.2019.2918951[P]. 2019.
- [20] W. Shi, J. Cao, Q. Zhang, Y. Li and L. Xu, "Edge Computing: Vision and Challenges," in IEEE Internet of Things Journal, vol. 3, no. 5, pp. 637-646, Oct. 2016, doi: 10.1109/JIOT.2016.2579198.
- [21] Salman O, Elhajj I, Kayssi A, et al. Edge computing enabling the Internet of Things[C]// 2015 IEEE 2nd World Forum on Internet of Things (WF-IoT). IEEE, 2015.
- [22] 樊留群,刘琛,丁凯,黄云鹰. 迈向智能数控系统的需求与展望[J]. 航空制造技术, 2020, 63(Z2):32-39. DOI:10.16080/j.issn1671-833x.2020.23/24.032.
- [23] 储佳倩,任尧,肖旺群,庄德红. 智能数控机床[J]. 机械设计, 2022, 39(04): 162. DOI: 10.13841/j.cnki.jxsj.2022.04.017.
- [24] 从数字化到智能化——数控机床先进制造技术研究进展[J]. 王伟;张振族;黄璞;范磊;李海;曹雪;杨平. 电子机械工程, 2022(05).
- [25] Li B, Tian X, Zhang M. Modeling and multi-objective optimization method of machine tool energy consumption considering tool wear[J]. International Journal of Precision Engineering and Manufacturing-Green Technology, 2021, 21:1-15.
- [26] Ghosh, T., Martinsen, K. Generalized approach for multi-response machining process optimization using machine learning and evolutionary algorithms[J]. Engineering Science and Technology, an International Journal, 2020, 23(3):650-663.
- [27] Z. You, H. Gao, S. Li, L. Guo, Y. Liu and J. Li. Multiple Activation Functions and Data Augmentation-Based Lightweight Network for In Situ Tool Condition Monitoring[J]. IEEE Transactions on Industrial Electronics. 2022, 69(12): 13656-13664.
- [28] 聂鹏. 基于运行数据的机床进给系统跟随误差预测方法研究[D]. 武汉:华中科技大学, 2019.
- [29] Y.C. Liang, W.D. Li, P. Lou, J.M. Hu, Thermal error prediction for heavy-duty CNC machines enabled by long short-term memory networks and fog-cloud architecture[J]. Journal of Manufacturing Systems, 2022, 62:950-963. <https://doi.org/10.1016/j.jmsy.2020.10.008>.
- [30] W. Zhang. Surface roughness prediction with machine learning[C]. Journal of Physics: Conference Series. 2021, 1856(1): 012040.
- [31] Chen C-H, Jeng S-Y, Lin C-J. Prediction and Analysis of the Surface Roughness in CNC End Milling Using Neural Networks[J]. Applied Sciences. 2022; 12(1):393. <https://doi.org/10.3390/app12010393>.

- [32] Balasubramanian A N, Yadav N, Tiwari A . Analysis of cutting forces in helical ball end milling process using machine learning[J]. Materials Today: Proceedings, 2020, 46: 9275-9280.
- [33] Moreira L C, Li W D, Lu X, et al. Supervision Controller for Real-time Surface Quality Assurance in CNC Machining using Artificial Intelligence[J]. Computers & Industrial Engineering, 2019, 127(JAN.):158-168.
- [34] 曹楷楠. 西门子数控系统:为机床行业数字化转型按下加速键[J]. 今日制造与升级, 2022(10):2.
- [35] FANUC. FIELD 系统介绍[EB/OL]. https://www.fanuc.eu/uk/en/field_system.
- [36] 华中数控“华中 9 型智能数控系统”正式发布[J].智能制造,2021(03):9.
- [37] 吴天驰,刘本刚,金光云.国产蓝天数控系统在机床升级改造中的应用[J].机械工程与自动化,2020(05):200-202.
- [38] Grieves M . Digital Twin: Manufacturing Excellence through Virtual Factory Replication. 2015.
- [39] Glaessgen E, Stargel D. The Digital Twin Paradigm for Future NASA and U.S. Air Force Vehicles[C]// Aiaa/asme/asce/ahs/asc Structures, Structural Dynamics & Materials Conference Aiaa/asme/ahs Adaptive Structures Conference Aiaa. 2012.
- [40] Chen Y. Integrated and Intelligent Manufacturing: Perspectives and Enablers[J]. 工程(英文), 2017, 3(5):8.
- [41] Liu Z, Meyendorf N, Mrad N. The role of data fusion in predictive maintenance using digital twin[C]// AIP Conference Proceedings. AIP Publishing LLC AIP Publishing, 2018.
- [42] Rv A, Jae B, Pb A, et al. Digital twins: Understanding the added value of integrated models for through-life engineering services[J]. Procedia Manufacturing, 2018, 16:139-146.
- [43] A. Madni, C. Madni, and S. Lucero, Leveraging Digital Twin Technology[J]. Model-Based Systems Engineering. 2019, 7: 7.
- [44] Wagg D, Worden K, Barthorpe R, et al. Digital Twins: State-of-The-Art Future Directions for Modelling and Simulation in Engineering Dynamics Applications[J]. ASCE-ASME J Risk and Uncert in Engrg Sys Part B Mech Engrg, 2020.
- [45] Semeraro C, Lezoche M, Panetto H, et al. Digital twin paradigm: A systematic literature review[J]. Computers in Industry, 2021(130-):130.
- [46] Kantaros A. Digital Twins in the Automotive Industry: The Road toward Physical-Digital Convergence[J]. Applied System Innovation, 2022, 5.
- [47] Predix platform. GE Digital[EB/OL]. [2019-4-22]. <https://www.ge.com/digital/iiot-platform>.
- [48] Siemens. Digital twin[EB/OL]. [2019-4-24]. <https://www.plm.automation.siemens.com/global/en/our-story/glossary/digital-twin/24465>.
- [49] Chen X, Kang E, Shiraishi S, et al. Digital Behavioral Twins for Safe Connected

- Cars[C]// the 21th ACM/IEEE International Conference. ACM, 2018.
- [50] Qian C, Liu X, Ripley C, Qian MA, Liang F, Yu W. Digital Twin—Cyber Replica of Physical Things: Architecture, Applications and Future Research Directions[J]. 2022, 14(2): 64.
- [51] Jay, Lee, Edzel, et al. Predictive Manufacturing System - Trends of Next-Generation Production Systems[J]. Ifac Proceedings Volumes, 2013.
- [52] Kritzinger W, Karner M, Traar G, et al. Digital Twin in manufacturing: A categorical literature review and classification[J]. IFAC-PapersOnLine, 2018, 51(11):1016-1022.
- [53] 陶飞,刘蔚然,张萌,胡天亮,戚庆林,张贺,隋芳媛,王田,徐慧,黄祖广,马昕,张连超,程江峰,姚念奎,易旺民,朱恺真,张新生,孟凡军,金小辉,刘中兵,何立荣,程辉,周二专,李洋,吕倩,罗椅民.数字孪生五维模型及十大领域应用[J].计算机集成制造系统,2019,25(01):1-18.DOI:10.13196/j.cims.2019.01.001.
- [54] Luo W, Hu T, Zhang C, et al. Digital twin for CNC machine tool: modeling and using strategy[J]. Journal of Ambient Intelligence and Humanized Computing, 2018, 10(3):1-12.
- [55] 工业互操作性标准™. OPC 协议[EB/OL]. [2015]. <https://www.opcfoundation.cn/about/what-is-opc>.
- [56] 工业互操作性标准™. OPC UA[EB/OL]. [2015]. <https://www.opcfoundation.cn/about/opc-technologies/opc-ua>.
- [57] 工业互操作性标准™. OPC 40501 [EB/OL]. [2015].https://www.opcfoundation.cn/guifan/60_83.
- [58] 工业互操作性标准™. OPC 40502 [EB/OL]. [2017].https://www.opcfoundation.cn/guifan/60_31.
- [59] 美国机械制造技术协会. MTConnect standardizes factory device data [EB/OL]. [2023-1-12]. <https://www.mtconnect.org/>.
- [60] 工业互操作性标准™. OPC UA-MTConnect 配套规范[EB/OL]. [2015]. <https://www.opcfoundation.cn/developer-tools/specifications-opc-ua-information-models/opc-unified-architecture-for-mtconnect>.
- [61] Jeon Y, Yoo J, Lee J, et al. NC-Link: A New Linkage Method for Efficient Hierarchical Clustering of Large-Scale Data[J]. IEEE Access, 2017:5594-5608.
- [62] GB/T 39561.1-2020, 数控装备互联互通及互操作 第1部分:通用技术要求[S].
- [63] GB/T 39561.2-2020, 数控装备互联互通及互操作 第2部分:设备描述模型[S].
- [64] GB/T 39561.3-2020, 数控装备互联互通及互操作 第3部分:面向实现的模型映射[S].
- [65] GB/T 39561.4-2020, 数控装备互联互通及互操作 第4部分:数控机床对象字典[S].
- [66] GB/T 39561.5-2020, 数控装备互联互通及互操作 第5部分:工业机器人对象

字典[S].

- [67] GB/T 39561.6-2020, 数控装备互联互通及互操作 第6部分:数控机床测试与评价[S].
- [68] GB/T 39561.7-2020, 数控装备互联互通及互操作 第7部分:工业机器人测试与评价[S].
- [69] 陶飞,程颖,程江峰等.数字孪生车间信息物理融合理论与技术[J].计算机集成制造系统,2017,23(08):1603-1611.DOI:10.13196/j.cims.2017.08.001.
- [70] 王煜天,丘嘉豪,吴军,张彬彬.一种新型数控机床可靠性试验加载机构动力学评价方法[J].清华大学学报(自然科学版),2020,60(12):1023-1029.DOI:10.16511/j.cnki.qhdxxb.2020.25.031.
- [71] 张星,赵万华.数控机床多轴联动铣削加工动力学集成建模研究[J].机械工程学报,2020,56(09):214.
- [72] Hanjing Lu, Yuanyuan Ding, Yu Chang, Gangli Chen, and Xiaoting Rui. Dynamics Modelling and Simulating of Ultra-precision Fly-Cutting Machine Tool[J]. International Journal of Precision Engineering and Manufacturing, 2020(21):189-202.
- [73] Bilgili D, Budak E, Altintas Y. Multibody dynamic modeling of five-axis machine tools with improved efficiency[J]. Mechanical Systems & Signal Processing, 2022(171-):171.
- [74] 刘阔,宋磊,陈虎,等.机理驱动的数控机床进给轴时变误差建模和补偿方法[J].机械工程学报, 2022, 58(3):251-258.
- [75] Fu H. Geometric error contribution modeling and sensitivity evaluating for each axis of five-axis machine tools based on POE theory and transforming differential changes between coordinate frames[J]. International Journal of Machine Tools & Manufacture: Design, research and application, 2019, 147.
- [76] Martin M, Otakar H, Michal S, Jiri S, Tomas K. An update of thermal error compensation model via on-machine measurement[J]. MM Science Journal, 2022. Doi: 10.17973/MMSJ.2022_12_2022150.
- [77] Lee K.H.,Barton D.A.W.,Renson L.. Modelling of physical systems with a Hopf bifurcation using mechanistic models and machine learning[J]. Mechanical Systems and Signal Processing,2023,191.
- [78] Raymond William S,Ghaffari Sadaf,Aguilera Luis U,Ron Eric,Morisaki Tatsuya,Fox Zachary R,May Michael P,Stasevich Timothy J,Munsky Brian. Using Mechanistic Models and Machine Learning to Design Single-Color Multiplexed Nascent Chain Tracking Experiments.[J]. bioRxiv : the preprint server for biology,2023.
- [79] Liang C, Mo W A, Tang J, et al. Construction and application of digital twin model for tool wear monitoring and life prediction[C]//2022 5th World Conference on

- Mechanical Engineering and Intelligent Manufacturing (WCMEIM). IEEE, 2022: 678-684.
- [80] 孟博洋,李茂月,刘献礼等.机床智能控制系统体系架构及关键技术研究进展[J].机械工程学报,2021,57(09):147-166.
- [81] Christiand, Kiswanto G. Digital Twin Approach for Tool Wear Monitoring of Micro-Milling[J]. Procedia CIRP, 2020, 93:1532-1537.
- [82] Li B, Tian X,Zhang M. Thermal error modeling of machine tool spindle based on the improved algorithm optimized BP neural network[J]. International Journal of Advanced Manufacturing Technology. 2019, 105 (1-4): 1497-1505.
- [83] Ma C, Gui H, Liu J. Self learning-empowered thermal error control method of precision machine tools based on digital twin[J]. Journal of Intelligent Manufacturing. 2021. Doi: 10.1007/s10845-021-01821-z.
- [84] Lu C, Fei J, Meng X, Li Y, Liu Z. Thermal Error Prediction and Compensation of Digital Twin Laser Cutting Based on T-XGBoost[J]. Sensors. 2022, 22(18): 7022.
- [85] Liu L, Zhang X, Wan X, et al. Digital twin-driven surface roughness prediction and process parameter adaptive optimization[J]. Advanced Engineering Informatics, 2022, 51:101470-.
- [86] Yang X, Ran Y, Zhang G, et al. A digital twin-driven hybrid approach for the prediction of performance degradation in transmission unit of CNC machine tool. 2022.
- [87] Tong X, Liu Q, Pi SW, Xiao Y. Real-time machining data application and service based on IMT digital twin[J]. Journal of Intelligent Manufacturing. 2020, 31(5): 1113-1132.
- [88] 宁之成,刘潇翔,王淑一.机理与数据融合的航天器控制系统数字孪生建模方法[J].空间控制技术与应用,2022,48(02):1-7.
- [89] Jinjiang Wang,Yulin Ma,Laibin Zhang,Robert X. Gao,Dazhong Wu. Deep learning for smart manufacturing: Methods and applications[J]. Journal of Manufacturing Systems,2018,48.
- [90] Zheng P, Xu X, Chen C H. A data-driven cyber-physical approach for personalised smart, connected product co-development in a cloud-based environment[J]. Journal of Intelligent Manufacturing, 2018:1-16.
- [91] Lee C, Lin B, Ng K, et al. Smart robotic mobile fulfillment system with dynamic conflict-free strategies considering cyber-physical integration[J]. Advanced Engineering Informatics, 2019, 42:100998.
- [92] F Tao, Cheng J, Qi Q. IIHub: an Industrial Internet-of-Things Hub Towards Smart Manufacturing Based on Cyber-Physical System[J]. IEEE Transactions on Industrial Informatics, 2017:1-1.
- [93] Zolanvari M, Teixeira M A, Gupta L, et al. Machine Learning Based Network Vulnerability Analysis of Industrial Internet of Things[J]. IEEE Internet of Things Journal, 2019, 6(4):6822-6834.

- [94] Liu B, Zhang Y, Zhang G, et al. Edge-cloud orchestration driven industrial smart product-service systems solution design based on CPS and IIoT[J]. *Advanced Engineering Informatics*, 2019, 42:100984.
- [95] Mach P, Becvar Z. Mobile Edge Computing: A Survey on Architecture and Computation Offloading[J]. *IEEE Communications Surveys & Tutorials*, 2017, PP(3):1-1.
- [96] Ouyang T, Zhou Z, Chen X. Follow Me at the Edge: Mobility-Aware Dynamic Service Placement for Mobile Edge Computing[J]. *IEEE Journal on Selected Areas in Communications*, 2018.
- [97] Chen X, Li W, Lu S, et al. Efficient Resource Allocation for On-Demand Mobile-Edge Cloud Computing[J]. *IEEE Transactions on Vehicular Technology*, 2018, PP:1-1.
- [98] Halaas A, Svingen B, Nedland M, et al. A recursive MISD architecture for pattern matching[J]. *IEEE Transactions on Very Large Scale Integration Systems*, 2004, 12(7):727-734.
- [99] 姜婧妍. 面向边缘智能的资源分配和任务调度的研究[D]. 吉林大学, 2020. DOI:10.27162/d.cnki.gjlin.2020.000122.
- [100] 陈旭, 周知, 于帅. 边缘智能的使能技术[J]. *中国计算机学会通讯*, 2020, 16(01):17-22.
- [101] Jia G, Han G, Xie H, et al. Hybrid-LRU Caching for Optimizing Data Storage and Retrieval in Edge Computing-Based Wearable Sensors[J]. *IEEE Internet of Things Journal*, 2018:1-1.
- [102] Rausch T, Dustdar S. Edge Intelligence: The Convergence of Humans, Things, and AI[C]// 2019 IEEE International Conference on Cloud Engineering (IC2E'19). IEEE, 2019.
- [103] 林亚坤. 面向基于云边缘的内容分发网络的在线优化算法研究[D]. 山东大学, 2022. DOI:10.27272/d.cnki.gshdu.2022.001277.
- [104] 王婷婷, 甘臣权, 张祖凡. 面向工业物联网的移动边缘计算研究综述[J]. *计算机应用与软件*, 2023, 40(01):1-10+65.
- [105] Lane N, Bhattacharya S, Mathur A, et al. DXTK: Enabling Resource-efficient Deep Learning on Mobile and Embedded Devices with the DeepX Toolkit[C]// Eai International Conference on Mobile Computing. ICST (Institute for Computer Sciences, Social-Informatics and Telecommunications Engineering), 2016.
- [106] Teerapittayanon S, Mcdanel B, Kung H T. Distributed Deep Neural Networks over the Cloud, the Edge and End Devices. 2017.
- [107] Kang Y, Hauswald J, Gao C, et al. Neurosurgeon: Collaborative Intelligence Between the Cloud and Mobile Edge[J]. *ACM SIGOPS Operating Systems Review*, 2017.
- [108] Yu Z, Jie Y, Miao L, et al. Federated learning based intelligent edge computing

- technique for video surveillance[J] Journal on Communications, 2020,41(10):109-115.
- [109] Li E, Zeng L, Zhou Z, et al. Edge AI: On-Demand Accelerating Deep Neural Network Inference via Edge Computing[J]. IEEE Transactions on Wireless Communications, 2020, 19(1):447-457.
- [110] James S. Albus. Outline for a theory of intelligence.[J]. IEEE Trans. Systems, Man, and Cybernetics,1991,21(3).
- [111] Liu C, Zheng P, Xu X. Digitalisation and servitisation of machine tools in the era of Industry 4.0: a review[J]. International journal of production research, 2021, ahead-of-print, p. 1-33. doi: 10.1080/00207543.2021.1969462.
- [112] 陈世超,崔春雨,张华,马戈,朱凤华,商秀芹,熊刚.制造业生产过程中多源异构数据处理方法综述[J].大数据,2020,6(05):55-81.
- [113] Liu C, Vengayil H, Zhong R Y, et al. A systematic development method for cyber-physical machine tools[J]. Journal of Manufacturing Systems, 2018, 48. doi: 10.1016/j.jmsy.2018.02.001.
- [114] Wang C, Guo R, Yu H, Hu Y, Liu C & Deng C, Task offloading in Cloud-Edge Collaboration-based Cyber Physical Machine Tool[J] ROBOTICS AND COMPUTER-INTEGRATED MANUFACTURING, 2023, 79: 102439.
- [115] Jasperneite, Jürgen, Arne Neumann, and Florian Pethig. "OPC UA versus MTConnect." Computer&Automation (Sonderheft S2 2015 Control&Drives) S (2015): 16-21.
- [116] Yu H, Yu D, Hu Y & Wang C. Research on CNC Machine Tool Monitoring System Based on OPC UA[C]. 2019 Chinese Control And Decision Conference (CCDC). 2019.
- [117] Jian Z, Cd B, Pz D, et al. Development of an edge computing-based cyber-physical machine tool - ScienceDirect[J]. Robotics and Computer-Integrated Manufacturing, 67.
- [118] 张靖.高速数控加工的轮廓误差预测关键技术研究[D].成都:电子科技大学,2021.
- [119] 余永维,杜柳青,易小波,陈罡.基于时序深度学习的数控机床运动精度预测方法[J].农业机械学,2019(1):421-426.
- [120] 李彬,明雨,郝一浩,陈宋宋,王隗东.基于融合 FCN-TCN-LSTM 的工业大用户可调节潜力分析模型 [J].电力自动化设备 2022(10):1-8.
- [121] Xie Y, Lian K, Liu Q, et al. Digital twin for cutting tool: Modeling, application and service strategy[J]. Journal of Manufacturing Systems, 2020, 58(1).
- [122] Y Li, Liu C, Hua J, et al. A novel method for accurately monitoring and predicting tool wear under varying cutting conditions based on meta-learning[J]. CIRP Annals - Manufacturing Technology, 2019.
- [123] Sun H, Zhang J, Mo R, et al. In-process tool condition forecasting based on a

deep learning method[J]. Robotics and Computer-Integrated Manufacturing, 2020, 64(5–8):101924.

[124] Drahos P, Kucera E, Haffner O, et al. Trends in industrial communication and OPC UA[C]// Cybernetics & Informatics. IEEE, 2018:1-5.

[125] Lv Weixi, Dang Jianwu, Zhang Zhenhai, Min Yongzhi, Zuo Jing. Collaborative Trajectories Optimization for Tram and Connected Vehicles at Signalized Intersection[J]. Applied Sciences, 2023, 13(3).

致 谢

学位论文即将收笔，历时七年的硕博研究生涯到这里也即将接近尾声。还记得 2016 年夏天，我刚刚步入科研殿堂，心浮气躁踌躇满志，誓为祖国科研事业添砖加瓦。现如今漫漫科研路暂时告一段落，科研成果虽然微薄却也脚踏实地，正如胡适先生曾经说过，“怕什么真理无穷，进一寸有一寸的欢喜”。回首这漫长而又短暂的七年时光，有山重水复的迷茫和痛苦，也有柳暗花明的感动和欣慰，其中滋味可谓百感交集。如果说这一段旅程能够有所成就，那我必须要感谢一路的同行者，是他们的言传身教，让我有了前进的勇气和动力。

首先我要感谢我的博士导师于东研究员，能够成为您的研究生我倍感荣幸。科研过程中先生循循善诱，在我论文选题、研究方法到实验设计的各个阶段都给予了耐心细致的指导，一步一步带领我走上科研道路。工作中先生以身作则，无数个深夜办公室里明亮的灯火在我心中点亮灯塔，让我摆脱懒散的工作作风。生活中先生亦师亦友，在我面临选择感到前路迷茫时给我指引，让我学会脚踏实地，在我遭遇挫折时给予开导，让我摆脱精神内耗。师生七年，先生给与我的帮助和影响不胜枚举，知行合一的诠释了传道授业解惑的师者之名。在此再次感谢先生的谆谆教诲，由衷的祝愿您身体健康，万事顺遂。

感谢数字化车间实验室胡毅研究员。感谢您为我提供如此完备的实验环境，在七年的研究生期间给我提供了许多宝贵的意见，您一直毫无保留的信任和鼓励是我能够完成博士课题最有力的支撑，在此表示由衷的感谢！

感谢吴文江研究员、尹震宇研究员、王鸿亮研究员等各位老师对课题开展过程中给予的指导和建议。感谢张曦阳、吴迪、陶增、赵妍等各位老师在我实验环节给予我的帮助和支持。

感谢郭安、李备、吴昊天、刘劲松、王诗宇、毕筱雪等各位师兄师姐的指导 and 关心。感谢何无为、张丽鹏、周正等各位师弟们的支持和帮助。感谢你们这一路的同行和陪伴。

感谢研究生部丁健研究员对我在学业上的帮助与生活上的关心。同时，感谢宁绍鹏老师、李玉平老师、张玲老师及罗鸣老师在我整个研究生阶段给予的关怀和爱护。

感谢李岳博士、徐福龙博士两位同窗兼舍友，我们因为求学天南海北相聚在一起，你们的陪伴让我感受到家的温暖。感谢我的女友王楚婷博士，感谢有你陪伴的青春年华。

感谢我的父母和家人，感谢你们一直以来对我毫无保留的付出与支持，让我能够心无旁骛地完成博士学业，谁言寸草心，报得三春晖。

最后感谢伟大的祖国。欣逢盛世，在享受祖国繁荣富强带给我骄傲的同时，作为一名科研工作者，祖国未来建设的一员，我深切的明白热爱自己的祖国绝不仅仅是一句口号，更是一份沉甸甸的责任，此时此刻，愿自己不忘初心也祝愿祖国繁荣昌盛。

2023 年 6 月

作者简历及攻读学位期间发表的学术论文与其他相关学术成果

作者简历:

2011 年 9 月——2015 年 6 月, 在清华大学信息科学技术学院获得学士学位。

2016 年 9 月——2023 年 6 月, 在中国科学院大学沈阳计算技术研究所攻读博士学位(硕博连读)。

已发表(或正式接受)的学术论文:

- [1] Yu H, Yu D, Wang C, Hu Y, Li Y, Edge intelligence-driven digital twin of CNC system: architecture and deployment[J] ROBOTICS AND COMPUTER-INTEGRATED MANUFACTURING, 2023, 79: 102418.
- [2] Yu H, Yu D, Hu Y & Wang C. Research on CNC Machine Tool Monitoring System Based on OPC UA[C]. 2019 Chinese Control And Decision Conference (CCDC). 2019.
- [3] Yu H, Yu D, Hu Y & Wang C. IIoT Based Hierarchical Data Distribution Strategy over Edge and End Device[C]. 2020 IEEE 6th International Conference on Computer and Communications (ICCC). IEEE, 2020
- [4] Wang C, Guo R, Yu H, Hu Y, Liu C & Deng C, Task offloading in Cloud-Edge Collaboration-based Cyber Physical Machine Tool[J] ROBOTICS AND COMPUTER-INTEGRATED MANUFACTURING, 2023, 79: 102439.
- [5] Li Y, Yin Z, Ma Y, Xu F, Yu H, Han G & Bi Y. Heuristic Routing Algorithms for Time-Sensitive Networks in Smart Factories[J]. Sensors. 2022
- [6] Liu J, Yu D, Yu H, He W & Zhang L. CNC Machine Tool Fault Diagnosis Integrated Rescheduling Approach Supported by Digital Twin-Driven Interaction and Cooperation Framework[J]. IEEE Access. 2021
- [7] Wang C, Guo R, Hu Y & Yu H. Research on the Architecture of Cyber-Physical Machine Tool System[C]. IEEE 4th International Conference on Computer and Communications (ICCC). IEEE, 2018.
- [8] Wang C, Guo R, Hu Y & Yu H. DDNN based data allocation method for IIoT[J]. Procedia Computer Science, 2021, 183(4):23-31.
- [9] Yang X, Hu Y, Yu H & Wang C. Tool Wear Prediction Method Based on Residual Time Series Convolution Network[C]. The 5th International Conference on Algorithms, Computing and Systems (ICACS). 2021.
- [10] 于东, 毕筱雪, 刘劲松, 郎言书, 于皓宇, 黄艳. 开放式、智能化“蓝天数控”系统及应用实践[J]. 航空制造技术, 2019, 62(06): 22-29. DOI:10.16080/j.issn1671-833x.2019.06.022.

申请或已获得的专利:

- [1] 胡毅, 于皓宇, 张胜宝, 于东, 王楚婷, 张曦阳. 一种应用于工业物联网的边缘协

同数据分配方法[P]. 辽宁省: CN114385322A,2022-04-22.

- [2] 郭锐锋,王楚婷,王厚军,苏文举,胡毅,于皓宇,张曦阳. 一种基于分布式深度神经网络框架的数据划分方法[P]. 辽宁省: CN114384866A,2022-04-22.
- [3] 郭锐锋,王楚婷,胡毅,于皓宇,张曦阳,刘国泰,一种应用于刀具预测性维护领域的任务卸载方法.(202210690757.2)
- [4] 胡毅,周正,田立新,于东,张曦阳,于皓宇,王楚婷,一种基于 OPC UA 的多源异构数控系统监控服务器.(202010847576.7)
- [5] 于东,刘劲松,毕筱雪,胡毅,于皓宇,韩旭,基于 Spark 的数控机床运行状态监测方法(2018114726411)
- [6] 胡毅,于东,李广博,程世威,张曦阳,吴迪,于皓宇,一种共融 AGV 的柔性作业车间调度方法(2018116119324)
- [7] 胡毅,于东,毕筱雪,刘劲松,韩旭,于皓宇,基于偏好 NSGA-III算法的云制造服务组合优化选择方法(2018114161825)
- [8] 胡毅,杨晓辉,杨巍,张曦阳,于皓宇,一种基于时间卷积网络的数控机床刀具磨损预测方法(202110598073.5)
- [9] 胡毅,吴文江,李廉颇,周正,于皓宇,张曦阳,一种基于禁忌搜索遗传算法的车间柔性作业调度方法(202110841603.4)

参与起草国家标准(已发布):

- [1] GB/T 39561.2-2020, 数控装备互联互通及互操作 第 2 部分:设备描述模型[S].
- [2] GB/T 39561.3-2020, 数控装备互联互通及互操作 第 3 部分:面向实现的模型映射[S].
- [3] GB/T 39561.4-2020, 数控装备互联互通及互操作 第 4 部分:数控机床对象字典[S].
- [4] GB/T 39561.5-2020, 数控装备互联互通及互操作 第 5 部分:工业机器人对象字典[S].
- [5] GB/T 39561.6-2020, 数控装备互联互通及互操作 第 6 部分:数控机床测试与评价[S].
- [6] GB/T 39561.7-2020, 数控装备互联互通及互操作 第 7 部分:工业机器人测试与评价[S].

参加的研究项目及获奖情况:

参加的科研项目:

1. 智能制造综合标准化项目:面向智能制造的数控装备互联互通及互操作标准及试验验证(2016ZXFB02002)。
2. 智能制造综合标准化项目:数控装备故障信息数据字典标准研制及试验验证。
3. 国家科技重大专项:国产高档数控系统智能化技术研究开发及应用验证

(2018ZX04035-001)。

获奖情况：

1. 2017 年 7 月 中国科学院大学三好学生
2. 2018 年 2 月 中国科学院沈阳计算技术研究所优秀研究生
3. 2018 年 11 月 硕士研究生国家奖学金
4. 2019 年 6 月 2018 年度全国工业机械电气系统行业标准化先进工作者
5. 2020 年 9 月 中国科学院大学三好学生标兵
6. 2021 年 6 月 中国科学院大学三好学生