



中国科学院大学

University of Chinese Academy of Sciences

博士学位论文

智能化数控系统轨迹优化方法研究与应用

作者姓名：张丽鹏

指导教师：于东 研究员 中国科学院沈阳计算技术研究所

学位类别：工学博士

学科专业：计算机应用技术

培养单位：中国科学院沈阳计算技术研究所

2024年6月

**Research and Application of Trajectory Optimization Methods
for Intelligent CNC Systems**

A dissertation submitted to

University of Chinese Academy of Sciences

in partial fulfillment of the requirement

for the degree of

Doctor of Philosophy

in Technology of Computer Application

By

Zhang Lipeng

Supervisor: Professor Yu Dong

Shenyang Institute of Computing Technology

Chinese Academy of Sciences

June 2024

中国科学院大学

研究生学位论文原创性声明

本人郑重声明：所呈交的学位论文是本人在导师的指导下独立进行研究工作所取得的成果。承诺除文中已经注明引用的内容外，本论文不包含任何其他个人或集体享有著作权的研究成果，未在以往任何学位申请中全部或部分提交。对本论文所涉及的研究工作做出贡献的其他个人或集体，均已在文中以明确方式标明或致谢。本人完全意识到本声明的法律结果由本人承担。

作者签名：

日 期：

中国科学院大学

学位论文使用授权声明

本人完全了解并同意遵守中国科学院大学有关收集、保存和使用学位论文的规定，即中国科学院大学有权按照学术研究公开原则和保护知识产权的原则，保留并向国家指定或中国科学院指定机构送交学位论文的电子版和印刷版文件，且电子版与印刷版内容应完全相同，允许该论文被检索、查阅和借阅，公布本学位论文的全部或部分内容，可以采用扫描、影印、缩印等复制手段以及其他法律许可的方式保存、汇编本学位论文。

涉密及延迟公开的学位论文在解密或延迟期后适用本声明。

作者签名：

导师签名：

日 期：

日 期：

摘要

随着全球制造业的深入发展，计算机数字控制（Computer Numerical Control, CNC）系统在生产自动化和精细化水平方面扮演着核心角色。作为现代工业生产的重要基础设备，CNC 技术通过精确控制加工过程，极大地提升了产品质量和生产效率，推动了制造业从传统的劳动密集型向技术密集型转变。然而，面对激烈的市场竞争和用户需求的日趋多样化，传统的 CNC 系统正面临着诸多挑战，包括加工精度、效率以及用户体验等方面的提升需求。为了突破这些限制，智能化 CNC 系统的研究与应用成为了制造业技术革新的新方向。智能化数控系统不仅继承了传统 CNC 的基本功能，更通过融合最新的信息技术、人工智能算法和高级传感器技术，提供了更为精确和智能的加工能力。这些技术的融合使得智能化数控系统在处理复杂加工任务时，能够提供更精确的加工路径规划、更及时的加工轨迹仿真、更智能的预测性维护与状态监测以及更自动化的加工轨迹优化，从而实现更高效率的生产和更高质量的产品。智能技术的集成现已成为数控机床行业内产品竞争力的关键因素，并且逐渐变成高端数控设备的显著特征。

本文针对数控系统的智能化功能与轨迹优化方法与应用展开研究，主要研究内容包括以下几个方面：

1. 智能化数控系统与数控系统智能体模型研究。针对目前的数控系统智能化研究方面缺乏统一集成的系统模型和算法实现，数控装备中的数据是孤立、碎片化的，将低价值的大量数据转化成高价值的决策信息困难等问题，通过将智能系统方法论引入数控系统，建立了融合智能要素的数控系统功能结构，通过对数控系统智能化的需求分析，提出了数控系统的智能化扩展方案，并建立了智能化数控系统的智能体模型，提出了一种模块化的智能化数控系统抽象模型并建立了相应的体系结构，并基于此提出将智能数控系统中的信息系统作为一个智能体的概念，从而将人工智能方法、数字孪生等独立的知识领域融合在智能体中，为数控系统的智能化提供支持。

2. 基于智能体的数控系统加工路径优化方法。鉴于数控系统的加工过程十分复杂，计算机辅助制造(CAM)系统生成的加工路径通常是仅位置连续的分段线性路径。当前的自动化制造在工业实践中依赖于计算机数控机床和 CAM 之间的数据传输，CAM 系统规划了数控系统的加工过程，从根本上决定了加工的质量与效率。然而 CAM 系统直接生成的加工程序只关注位置上的连续，加工路径拐角明显、相邻路径不均匀、点位分布不均匀等情形均会对加工造成负面影响。针对此问题，本文在 CAM 系统与机床控制器之间建立了数据传输的闭

环, 将优化过程以应用的方式封装在信息物理系统(CPS)单元中, 从而与机床控制器进行集成, 实现加工路径特征的智能识别与优化。在优化过程中, 提出了加工路径的分解方法、负面加工路径的深度学习识别方法以及基于强化学习的加工路径自适应优化方法, 并以实验案例验证了所提方法的有效性。

3. 基于强化学习的数控加工轨迹压缩方法。在数控系统的加工流程中, 对于复杂曲面模型目前仍然普遍采用微小直线段逼近原始轮廓形状, 这种连续的小线段加工代码在 G 代码标准中通常被定义为 G01 代码。由于复杂零件和模型可能需要大量的坐标点来精确描述其形状, 因此 G 代码文件将变得非常庞大, 从而导致存储空间不足、传输速度变慢以及解析和执行 G 代码时性能降低等问题。因此高效的 G 代码数据压缩技术需要实现减小文件大小, 加快传输速度, 提高设备执行效率, 同时在保持原始数据几何特征的前提下确保最终产品的质量。针对以上问题, 提出了利用先进的人工智能技术解决数据压缩问题, 通过将 G01 代码的数据压缩作为序列决策问题, 利用先进的深度强化学习方法实现 G 代码数据压缩的自动化过程, 该过程中强化学习智能体可以通过自主学习和决策, 从而实现智能数据压缩功能。

4. 基于层次化强化学习的数控加工轨迹优化方法。随着数控加工技术的不断发展, 工件的几何形状和结构日益复杂, 生成的轨迹数据量也日益增多。这些遵循 G01 直线段加工规则的数据序列不仅增加了数据存储和传输的成本, 同时也会导致机床频繁的加减速, 影响数控机床的实时性能。同时, 数控加工中 G01 直线段形式的加工导致轨迹切向不连续, 加工速度低、精度差、表面质量差。针对这些问题, 提出层次化的强化学习方法结合三阶空间 B 样条曲线拟合方法优化加工轨迹, 第一层强化学习智能体用于在 G01 直线段的 B 样条曲线拟合中进行特征点的选择和拟合误差的控制, 第二层强化学习智能体用于调节拟合后的 B 样条控制点, 进行曲线的精细化调整, 设计了非对称 S 型曲线加减速方法进行速度控制, 在速度控制的同时考虑了机床的动力学特性, 并通过两个工件案例验证了所提方法的有效性。

关键词: 智能数控系统, 轨迹优化, 轨迹压缩, 深度强化学习, B 样条理论

Abstract

As the global manufacturing industry continues to evolve, Computer Numerical Control (CNC) systems play a pivotal role in enhancing the level of automation and precision in production. As critical equipment in modern industrial manufacturing, CNC technology has significantly improved product quality and production efficiency by precisely controlling the machining process, marking a shift from traditional labor-intensive methods to a technology-intensive approach. However, in the face of intense market competition and increasingly diverse user demands, traditional CNC systems are confronted with numerous challenges, including the need for improvements in machining accuracy, efficiency, and user experience. To break through these limitations, research and application of intelligent CNC systems have become a new direction for technological innovation in the manufacturing industry. Intelligent CNC systems not only inherit the basic functions of traditional CNC but also integrate the latest information technology, artificial intelligence algorithms, and advanced sensor technology, providing more precise and intelligent machining capabilities. The fusion of these technologies enables intelligent CNC systems to provide more accurate machining path planning, more timely machining trajectory simulation, more intelligent predictive maintenance and status monitoring, and more automated machining trajectory optimization, thus achieving higher production efficiency and product quality. The integration of intelligent technology has become a key factor in the competitiveness of products within the CNC machine tool industry and is increasingly becoming a prominent feature of high-end CNC equipment.

This paper focuses on the research of intelligent functions and trajectory optimization methods and applications of CNC systems, covering the following main areas:

1. Research on Intelligent CNC Systems and CNC System Agent Model. Addressing the need for a unified, integrated system model and algorithm implementation in intelligent CNC system research, where data in CNC equipment is isolated and fragmented, making it challenging to transform low-value data into high-value decision-making information, this study introduces intelligent system methodologies into CNC systems. An integrated functional structure of CNC systems with intelligent elements is established. An intelligent extension scheme for CNC systems is proposed through the analysis of the requirements for the intelligence of CNC systems, and an agent model for intelligent CNC systems is established. A modular abstract model of an intelligent CNC system is proposed, along with its corresponding architecture. It suggests considering the information system within intelligent CNC systems as an intelligent agent, thus integrating artificial intelligence methods and digital twins among other independent knowledge domains into the

intelligent agent, providing support for the intelligence of CNC systems.

2. Machining Path Optimization Method for CNC Systems Based on Agents.

Given the complexity of the machining process in NC systems, the machining paths generated by Computer-Aided Manufacturing (CAM) systems are usually just positionally continuous segmented linear paths. Current automation manufacturing relies on data transmission between computer numerical control (CNC) machines and CAM, where the CAM system plans the machining process, fundamentally determining the quality and efficiency of the machining. However, the machining programs directly generated by CAM systems only focus on positional continuity, with issues such as sharp machining path corners, uneven adjacent paths, and uneven distribution of points negatively affecting machining. To address this issue, a closed-loop data transmission between the CAM system and the machine controller was established, encapsulating the optimization process in a Cyber-Physical System (CPS) unit for integration with the machine controller, thus achieving intelligent identification and optimization of machining path features. During the optimization process, methods for decomposing machining paths, deep learning identification of adverse machining paths, and adaptive optimization of machining paths based on reinforcement learning were proposed, and the effectiveness of the proposed methods was verified through experimental cases.

3. Trajectory compression method for CNC machining based on reinforcement learning. In the machining process of NC systems, small straight segments are still commonly used to approximate the original contour shape of complex surface models, which are usually defined as G01 code in the G-code standard. Due to the complex parts and models that may require many coordinate points to accurately describe their shapes, the G-code files become very large, leading to insufficient storage space, slower transmission speed, and reduced performance in parsing and executing G-code. Therefore, efficient G-code data compression technology is needed to reduce file size, speed up transmission, and improve device performance efficiency while ensuring the quality of the final product by maintaining the original data's geometric features. An advanced artificial intelligence technology solution for data compression was proposed to address these issues. By treating the data compression of G01 code as a sequential decision problem, an automated process for G-code data compression was achieved through advanced deep reinforcement learning methods, where the reinforcement learning agent could perform intelligent data compression through autonomous learning and decision-making.

4. Trajectory optimization method for CNC machining based on hierarchical reinforcement learning. With the continuous development of CNC machining technology, the geometric shapes and structures of workpieces have become increasingly complex, and the volume of generated trajectory data has also grown. These data sequences, which follow the G01 linear segment machining rules, not only

increase the cost of data storage and transmission but also cause frequent acceleration and deceleration of the machine tool, the real-time performance of the CNC machine tool. Additionally, the G01 straight-line segment machining approach results in discontinuous cutting trajectories, leading to low machining speeds, poor accuracy, and substandard surface quality. To address these issues, a hierarchical reinforcement learning approach combined with third-order spatial B-spline curve fitting is proposed to optimize the machining trajectory. The first layer of the reinforcement learning agent is responsible for selecting feature points and controlling fitting errors in the B-spline curve fitting of the G01 straight segments. The second layer of the reinforcement learning agent adjusts the fitted B-spline control points for a refined curve adjustment. An asymmetric S-curve acceleration and deceleration method is designed for velocity control, considering the machine tool's dynamic characteristics while controlling speed. The effectiveness of the proposed method is validated through two workpiece case studies.

Key Words: Intelligent CNC Systems, Trajectory Optimization, Trajectory Compression, Deep Reinforcement Learning, B-Spline Theory.

目 录	
第 1 章 绪论	1
1.1 研究背景和意义	1
1.2 国内外研究现状	3
1.2.1 数控系统智能化技术研究现状	3
1.2.2 新一代人工智能技术研究现状	5
1.2.3 数控加工轨迹优化技术研究现状	10
1.3 课题来源及本文的研究内容	14
1.3.1 课题来源	14
1.3.2 本文的研究内容	14
第 2 章 基于智能体模型的智能化数控系统研究	17
2.1 智能数控系统	17
2.1.1 智能数控系统的概念	18
2.1.2 智能数控系统平台	22
2.2 数控系统智能体模型	26
2.2.1 数控系统智能化的需求	26
2.2.2 基于智能体的数控系统智能化扩展方法	28
2.2.3 基于智能体的数控系统抽象模型与体系结构	31
2.2.4 数控系统智能体模型构建	33
2.3 本章小结	39
第 3 章 基于智能体的数控系统加工路径优化方法研究	41
3.1 加工路径缺陷的特征与原因分析	41
3.2 加工路径优化的解决方案	43
3.3 基于智能体的加工路径优化实验与应用	45
3.3.1 加工路径优化的实验环境与整体流程	47
3.3.2 加工路径的层级分解方法	48
3.3.3 基于深度学习的加工路径特征分类与识别方法	51
3.3.4 基于 DDQN 的加工路径智能优化方法	54
3.3.5 加工路径优化的多线程处理方法	62
3.4 本章小结	65
第 4 章 基于强化学习的轨迹压缩方法研究	66
4.1 基于强化学习的轨迹压缩问题建模	66
4.1.1 轨迹压缩问题概述	66

4.1.2 轨迹压缩问题的强化学习模型.....	67
4.2 强化学习应用于轨迹压缩的实验验证	69
4.2.1 零件模型与数据处理.....	69
4.2.2 基于 DQN 的轨迹压缩算法流程	70
4.2.3 实验结果与分析.....	72
4.3 本章小结.....	76
第 5 章 基于层次化强化学习的轨迹优化方法研究.....	78
5.1 轨迹优化问题概述.....	78
5.2 基于智能体的数控加工轨迹优化框架.....	79
5.2.1 网络制造赋予数控系统的新特性.....	79
5.2.2 数控加工轨迹的智能优化技术方案.....	81
5.3 B 样条理论在轨迹优化中的应用基础	82
5.4 轨迹优化实验与应用.....	83
5.4.1 实验环境与主要实验流程.....	83
5.4.2 基于速度敏感点的轨迹分段方法.....	85
5.4.3 基于层次化强化学习的轨迹优化方法.....	87
5.4.4 轨迹优化的插补实验验证.....	101
5.5 本章小结.....	105
第 6 章 总结与展望	107
6.1 论文工作总结.....	107
6.2 未来研究展望.....	109
参考文献.....	111
致 谢.....	121
作者简历及攻读学位期间发表的学术论文与其他相关学术成果	123

图目录

图 1-1 数控加工的一般流程	1
图 1-2 机器学习领域构成	6
图 1-3 论文的组织结构	15
图 2-1 智能数控系统示意图	18
图 2-2 智能系统的组成	19
图 2-3 数控系统智能扩展结构	21
图 2-4 数控系统产品及配套应用	23
图 2-5 数控系统智能化硬件平台体系结构	23
图 2-6 智能数控系统二次开发软件平台	24
图 2-7 智能化数控系统的核心硬件及其通信结构	25
图 2-8 传统数控系统与智能数控系统	27
图 2-9 数控系统的智能化扩展方案	30
图 2-10 智能数控系统智能体模型	32
图 2-11 智能数控系统层次化体系结构	33
图 2-12 数控系统智能体建模过程	34
图 2-13 智能数控系统结构模型	34
图 2-14 Cyber 智能体模型图	35
图 2-15 基于智能体的数控系统架构	36
图 3-1 CAM 系统原始 NC 程序点位缺陷	42
图 3-2 a)传统的加工方式结构 b)添加了优化闭环的加工结构	42
图 3-3 Cyber 应用建立 CAM 与数控加工之间的桥梁	43
图 3-4 基于 Cyber 智能体的路径优化技术方案	44
图 3-5 实验环境和工作流程	47
图 3-6 OPC UA 中的加工路径信息模型	48
图 3-7 a)五角星凸台 CAM 模型 b) 由其生成的部分 G 代码示例	48
图 3-8 分解后的路径片段示例	50

图 3-9 部分聚类结果展示	50
图 3-10 深度学习算法网络结构与处理流程	52
图 3-11 算法的分类准确率和 ROC 曲线	53
图 3-12 算法分类结果的点云可视化	53
图 3-13 分类结果的点云可视化	54
图 3-14 不同特征的滤波优化效果对比	54
图 3-15 DDQN 执行过程(a)和详细的网络结构(b)	57
图 3-16 DDQN 训练中每一步的总奖励变化和每批次的平均损失变化	59
图 3-17 优化前后整体模型的可视化比较	59
图 3-18 优化前后加工路径和 G 代码坐标的局部细节比较	60
图 3-19 优化前后加工路径和 G 代码坐标的局部细节比较	62
图 3-20 路径优化应用整体结构	63
图 3-21 多线程流水线路径优化过程示例	64
图 3-22 串行和流水线方法 100 次执行时间的比较	64
图 4-1 问题的处理流程	67
图 4-2 马尔可夫决策过程	68
图 4-3 DQN 网络结构	69
图 4-4 灯盖模型和部分 G 代码	70
图 4-5 G 代码解析后的加工路径	70
图 4-6 DQN 数据压缩算法流程图	71
图 4-7 训练过程中的奖励收敛图	72
图 4-8 局部数据压缩结果	73
图 4-9 整体数据压缩结果	73
图 4-10 压缩结果对比	75
图 4-11 VM 算法的整体数据压缩结果	76
图 4-12 整体压缩结果的轮廓误差对比	76
图 5-1 网络制造赋予数控系统的新特性与新功能	79
图 5-2 数控系统模块化的抽象模型	80

图 5-3 利用智能体进行数控加工轨迹优化的整体技术方案	81
图 5-4 实验环境与工作流程	84
图 5-5 蝴蝶 CAM 模型(a)和奔驰零件 CAM 模型(b)	85
图 5-6 分段结果：蝴蝶模型(a)和奔驰零件模型(b)	87
图 5-7 DDQN 的执行流程(a)与网络结构(b)	89
图 5-8 压缩前后的数据序列以及拟合的三阶空间 B 样条曲线	91
图 5-9 DDQN 算法的奖励收敛效果和平均损失	92
图 5-10 使用 DDPG 智能体调整 B 样条控制点后的效果示例	95
图 5-11 调整前后的 B 样条曲线相对于原始数据的拟合误差	95
图 5-12 训练过程中 DDPG 智能体的奖励收敛过程	96
图 5-13 反曲点、曲率极值点、弓高特征点方法提取效果	97
图 5-14 初步拟合的 B 样条曲线效果	98
图 5-15 原始数据点到初始 B 样条的拟合误差	98
图 5-16 后处理得到的新特征点集	100
图 5-17 原始数据点到后处理得到的 B 样条曲线的拟合误差	100
图 5-18 蝴蝶模型的部分插补效果	103
图 5-19 蝴蝶模型的部分速度规划效果(速度、加速度、加加速度)	104
图 5-20 奔驰零件模型的部分插补效果	104
图 5-21 奔驰零件模型的部分速度规划效果(速度、加速度、加加速度)	105
图 5-22 整体插补结果：蝴蝶模型 (A) 和奔驰零件模型 (B)	105

表目录

表 3-1 特征统计分级	51
表 3-2 实验参数配置	55
表 4-1 DQN 算法参数配置	72

第1章 绪论

1.1 研究背景和意义

当前，全球制造业竞争日益激烈，工业 4.0、智能制造等概念的普及，使得智能化生产已成为提升国家制造业核心竞争力的关键途径。制造业也正在经历着以智能化、数字化、网络化为核心特征的深刻变革，旨在通过技术创新提高生产效率与质量，实现制造业的可持续发展。

数控系统是现代制造业的基础设备，它通过计算机技术对生产过程进行精确控制，实现了工件加工的自动化和精细化。自 20 世纪 50 年代以来，数控技术经历了从机械、电气到计算机的演进，尤其是近几十年中，随着计算机技术、网络技术、人工智能等技术的快速发展，数控技术也实现了从简单的路径控制到复杂的过程控制、智能控制的跨越。随着市场需求的日益多样化和个性化，传统数控系统在灵活性、智能化水平以及加工效率上已经无法完全满足现代制造业的需求，而智能化数控系统通过采用更先进的控制算法、更强大的硬件、大数据和人工智能技术、物联网和云计算等技术，提供了更高的精度、更高的效率、更强的智能性和更好的用户体验。

持续的信息通信技术创新，结合先进的制造技术快速融合，为制造业的高端化、智能化和绿色化提供了前所未有的机遇。在此背景下，全球的竞争和科技战越发激烈，各国纷纷将焦点对准制造业，推出如美国的“先进制造业领先战略”、德国的“2030 国家工业战略”和日本的“社会 5.0”等发展战略，以振兴制造业为核心，并将智能制造作为关键手段，旨在全球制造业竞争中占据优势^[1,2]。针对这一趋势，中国的“十四五”智能制造发展规划明确提出，应持续聚焦智能制造，推进产业技术的转型和升级，促进制造业的模式和企业形态的根本改变，目的是推动中国制造业在全球价值链中向更高端迈进。同时，也将智能制造系统建模仿真、工艺优化等技术作为关键核心技术列入攻关行动^[3]。




图 1-1 数控加工的一般流程

Figure 1-1 The general process of CNC machining

如图 1-1 所示，数控加工的一般流程主要包括以下几个步骤：

- **计算机辅助设计 (CAD)：**在这个阶段，设计人员使用 CAD 软件创建产品的三维模型，这是数控加工流程的起点。设计完成后，模型将包含所有必要的几何信息，用于后续的编程和加工过程。
- **计算机辅助制造 (CAM)：**CAD 模型完成后，需要将其导入 CAM 软件。在 CAM 软件中，工程师根据 CAD 模型制定具体的加工策略，包括选择合适的刀具、设定刀具路径、优化加工顺序、计算切削参数（如速度、进给率、切削深度等），并生成相应的数控编程代码。这一步骤决定了刀具在加工过程中的移动轨迹，即所谓的刀具路径 (Tool Path)。
- **数控编程与仿真 (CNC Programming & Simulation)：**CAM 软件生成的数控代码 (G 代码或 M 代码) 将被输入到数控机床的控制系统中。在正式加工前，工程师通常会在软件中运行仿真，这可以帮助检测程序中可能存在的错误，如碰撞检测、工具运动的合理性等，确保加工过程的安全性和效率。
- **机床驱动与实际加工 (Machine Driving & Machining)：**程序经过验证无误后，数控机床便开始按照预定的程序进行加工。数控系统通过解释数控代码来控制机床的驱动系统（如伺服电机），驱动各个轴的运动，确保刀具按照设定的轨迹进行精确的加工。在加工过程中，机床会实时监控刀具的运动路径和加工参数，保证加工质量。

在加工完成后，对产品进行质量检测，以确保加工件符合设计规范。如果检测结果满足要求，产品就可以进入下一步的装配或者后续处理流程。

总的来说，在数控加工流程中，从设计到实际加工，是一个系统化的工程，涉及多个阶段和技术环节。每一步都需要严格控制，确保加工过程高效、精准且安全。在以上加工流程中，每一个阶段都需要设计相应的算法或操作步骤进行精确的处理，然而，随着市场竞争的加剧和用户需求的多样化，对当今的高档数控系统功能提出了新的需求：

- 1) 要求通过使用数字化技术实现加工过程仿真等工序链的一体化。
- 2) 要求加工实现精确建模和加工优化，需要数控系统加工过程参数与数据的标准化以及数控装备之间的互联互通和互操作，并结合智能算法更精确的模拟机床的加工过程。
- 3) 要求数据传输和处理的高实时性和及时的反馈。
- 4) 管理和服务的智能化，在航空航天行业中，面对定制化的批量生产需求，必须在数控系统中融合感知加工现场、处理大数据、数字建模和智能化决策等先进功能，从而构建一个完整的制造过程闭环。这种集成旨在应对该领域特有的生产要求，确保高效和精准的制造输出。

以上这些现实需求促进了数控系统的智能化发展,通过集成先进的信息处理、自动控制技术和人工智能,使数控系统具有自学习、自适应、自优化和自诊断的能力,从而在加工流程中更加自动化、智能化。例如,通过智能化技术可以实现实时监控加工状态,自动调整切削参数,如刀具运动速度和进给量,以考虑实际机床的动力学特征。这种技术的应用使得加工过程更加高效,提高了自动化水平。自工业 4.0 提出以来,智能化技术构成了数控机床产品竞争力的新的重要因素,日益成为高端数控装置的重要标志。

《中华人民共和国国民经济和社会发展第十四个五年规划和 2035 年远景目标纲要》中提出:我国要深入实施智能制造,推动制造业高端化、智能化、绿色化以及高端数控机床等产业创新发展。因此,探索和研究实现智能化数控系统的方式和方法,对于提高制造业的核心竞争力具有重要的现实意义和长远的战略价值。为此,本文针对数控系统的智能化功能与实现展开研究,主要包括数控系统智能化的实施方法、CAM 阶段由系统生成的加工路径的智能优化方法、数控编程阶段加工轨迹的智能压缩方法以及加工轨迹的智能优化方法。

1.2 国内外研究现状

1.2.1 数控系统智能化技术研究现状

作为数控机床的大脑,数控系统伴随着信息技术的发展而不断演化^[4]。人工智能及信息技术的发展推动了数控系统朝着智能化方向发展,并促使其使用成本的降低。数控系统是推动制造业快速发展的强心剂,关系着我国在基础制造装备领域的核心竞争力^[5]。近些年来,国家有关部门高度重视数控技术的发展,促进了国产数控系统厂商自主研发能力的提升和研发水平的进步。同时随着信息与通信技术的发展,特别是传感器、物联网、大数据、人工智能技术的进步,促使许多国家对数控系统技术相关研究的高度关注和重视,同时新技术、新功能不断与数控系统的融合,为研制新一代智能数控系统创造了条件。随着传感器、信息通讯、数据存储、网络计算等技术的可靠性和承受能力提高,当今工业产品来自经济和环境的竞争迫使更多的车间和工厂采用更加智能的加工生产方式^[6-8]。

当前,日本、德国、美国等工业发达国家的数控技术都开始逐渐进入智能化的阶段。日本是全球数控技术研发集中和数控系统产量最多的国家之一,拥有多家数控系统企业,如发那科(FANUC)、马扎克(MAZAK)、大隈(OKUMA)等。马扎克第七代数控系统 Smooth X 提供了高品质、高性能的智能优化产品和服务,其振动智能模块具有实时记录原程序加工时主轴的振动曲线并智能优化的功能。欧洲以德国、意大利、法国等国为代表、拥有德玛吉(DMG)、海德汉(Heidenhain)、西门子(Siemens)等多家数控系统行业巨头企业,其数控系统质量、

功能、性能方面都居世界领先地位。西门子 SINUMERIK 840D sl 推出了“臻优曲面”(top surface)功能包,能够对双向往复铣削的加工轨迹进行方向无关的平滑,并对不平整的位置进行公差内的平滑,尽可能降低 CAM 数据质量差的影响。

我国数控系统技术经过几十年的发展,在高速高精、多轴联动、网络化、智能化等技术方面取得了一定的成果,建立了一批国产数控系统企业。广州数控 GSK 25i 系列数控系统加工时可采集现场实际圆度与预设标准圆进行对比和误差分析、数据可视化,实现 1000 段程序前瞻,加速度和加加速度控制实现平滑进给、在线轨迹光顺。北京精雕集团独创的“在机测量和智能修正技术”,通过在机检测过程品质,智能修正加工误差,实现了操作人员、机床、工艺与品质检测之间的高效协同。

自工业 4.0 概念提出以来,数控系统的智能化、数字化被不断的提及和研究^[9-16]。目前,关于数控系统的智能化扩展这一理念聚焦于基于人-信息-物理系统的数控系统和基于数字孪生的数控系统,其本质上均是实现信息世界和物理世界的深度融合。

1. 基于信息-物理系统的智能数控系统: 信息-物理系统是新一代智能制造领域中的一项技术概念,它通过在人与物理系统之间增加了网络系统从而辅助人类完成感知、分析和决策功能^[17]。周等人^[18]阐述了面向智能制造的 HCPS 演进,并分别从系统视角、技术视角分析了 HCPS 的特征。陈等人^[19]讨论了机床发展的三个阶段,即从手动操作机床、数控机床到智能机床,并介绍了智能机床的智能化实践。Liu 等人^[20]提出了一种信息物理机床的系统化开发方法,允许机床、加工过程和智能算法等通过网络集成。Liu 等人在^[21]中提出了一种基于 OPC UA 和 MTConnect 的 Cyber-Physical Machine Tools(CPMT)平台,用以实现应用程序与机床之间的通信。Wu 等人^[22]基于 CPS 的基本特征和分形理论,构建了智能工厂模型,认为具有 CPS 特征和不同尺度下资源的自相似性是工厂中不同规模制造资源的功能和结构抽象。谷艾^[23]提出了基于扩展故障树与攻击树相结合的评估模型,介绍了扩展故障树的构造流程及数学模型,针对 CPS 的安全问题,制定了功能安全和信息安全相结合的综合评估流程,将信息安全风险分析的攻击树模型与功能安全评估的故障树模型结合在一起,增加了 CPS 物理设备硬件功能安全评估的准确性。宋等人^[24]提出了基于数字孪生和 CPS 的数控装备可靠性分析方法,并通过数控装备主轴回转误差预测进行了验证。Habib 等人^[25]认为 CPS 需要四项关键技术: CPS 设备技术、CPS 计算技术、CPS 网络物理体系和 CPS 网络与通信技术。

2. 基于数字孪生的智能数控系统: 数字孪生技术关注于如何将信息映射到物理对象模型,并通过研究和操作信息模型从而控制、操纵物理对象模型,它的使用有助于解决制造工艺复杂变化的故障^[26-28]、信息物理系统中的人机交互

与可视化^[29-31]、不可逆设计方法缺陷的避免^[32-34]和制造系统及制造工具的预测性维护^[35,36]等问题。Wei 等人^[37]研究了一种数控机床数字孪生的一致性保持方法，通过滚动导轨为对象的磨损性能衰减案例展示了该方法的可行性。He 等人^[38]对于自动化系统中的虚拟建模、过程监控、诊断和优化控制进行集成并基于此建立了数据驱动的数字孪生系统。Zhou 等人^[39]建立了一个 5 维数字孪生模型，对离心叶轮的加工效率和空气动力性能构建了基于数字孪生的优化策略和实验验证。Yu 等人^[40]建立了边缘智能技术驱动的数控系统数字孪生模型，并讨论了模型的部署方法。

在业界，许多领先企业也应运而生了数字化产品或相关项目，例如，西门子公司的 MindSphere 数字孪生应用^[41]，DMG 的基于 CELOS 平台的集成数字化制造解决方案，FANUC 的自动化、数字化、智能化解决方案等。

近十年来，数字化、智能化制造技术展现出了巨大潜力，能够在复杂的环境中及时的实施智能控制策略，迎合了当今复杂和苛刻的制造系统，然而，大多数研究工作仅处于理论层面或处于实验阶段^[42]，国内外多数学者研究集中在基于某种型号或者某种专有协议的数控机床数据采集和实时状态监测，由于数控机床多源异构性、通讯协议种类繁多等特点，不仅需要建立统一领域模型，也要针对应用场景建立更为细致的有针对性的应用模型。

1.2.2 新一代人工智能技术研究现状

人工智能（AI）是指使机器模拟、扩展并增强人类的智能行为的技术。AI 不仅模仿人类的认知功能，如学习和解决问题，还在特定领域超越人类的能力，近年来在各个领域取得了巨大进展。而“新一代人工智能”则在传统人工智能技术的基础上，结合最新的研究成果和技术进步，发展出的更高级、更复杂、更有效的人工智能系统。这些系统通常具备更强的学习能力、更高级的决策和推理能力、更复杂的数据处理能力和更先进的人机交互方式。它是计算机科学的一个分支，涉及机器学习、深度学习、强化学习等多个子领域，其中机器学习领域的构成如图 1-2 所示。人工智能技术的发展正在不断推动着科技和社会的进步。




图 1-2 机器学习领域构成

Figure 1-2 Composition of Machine Learning Domain

机器学习是 AI 的一个核心领域，旨在开发算法让计算机通过数据学习，并基于这些学习做出决策或预测。它依赖于数据模式识别和推断规则，而不是显式的指令。机器学习包括监督学习、无监督学习和半监督学习等不同类型。简单来说，机器学习是一种使计算机能够通过学习数据来改善任务执行效率的科学。它允许计算机在没有显式编程的情况下进行学习和预测。在机器学习的过程中，算法会分析大量数据，识别数据中的模式和规律，并使用这些模式来预测新数据的属性或行为。

深度学习是机器学习的一个子集，它使用称为神经网络的复杂结构来模拟人类大脑处理信息的方式。深度学习特别擅长处理大规模和高维度的数据，广泛应用于图像识别、语音识别和自然语言处理等领域。深度学习的核心是深度神经网络，一种受人类大脑结构启发而设计的算法框架。这些网络通过层级结构模拟人脑的信息处理方式，能够自动学习并识别数据中的复杂模式和特征。

强化学习（Reinforcement Learning）作为机器学习的一个重要分支，正日益显示出其独特的价值和广泛的应用潜力。它区别于传统的监督学习和无监督学习，是一种基于交互和反馈的学习方法。它依赖于试错机制，机器通过与环境的交互获得奖励或惩罚来调整自己的行为。强化学习在自动控制、游戏、机器人路径规划等领域有重要应用。同时，强化学习与深度学习交叉融合，形成了所谓的深度强化学习（Deep Reinforcement Learning）。深度强化学习使用深度神经网络来处理高维度的复杂环境和状态信息，这使得算法能在更加复杂和接近现实的任务中学习有效的策略。

在机器学习方面，Trevor Hastie, Robert Tibshirani, 和 Jerome Friedman 共同撰写的统计机器学习一书^[43]中详细介绍了统计学习的广泛领域，包括监督学习

和无监督学习的理论基础、方法和应用，以深入浅出的方式覆盖了从线性回归、分类、支持向量机、神经网络到树模型、集成学习方法如随机森林和 Boosting，以及聚类和降维技术等多种统计学习算法，并讨论了模型选择与评估、偏差-方差权衡、交叉验证等关键概念。Pedro Domingos^[44]以一种直接且易于理解的方式向读者介绍了机器学习领域中的一些核心概念、常见的挑战及其应对策略。介绍了成功应用机器学习技术背后的一些关键因素，包括算法的基本构成、数据的重要性、模型选择、特征工程的关键角色、评估方法的选择、以及如何避免优化过程中的陷阱等。文章详细讨论了机器学习算法的三个基本组成部分：表示、评估和优化，强调了构建有效学习系统的必要性。他进一步阐述了泛化能力是评价算法性能的关键指标，同时指出更多的数据往往比复杂的算法更能提升模型的性能。文章中，Domingos 特别强调了简单模型在某些情况下因其优异的泛化能力而胜过复杂模型的事实，以及特征工程在提升模型性能中的不可或缺的作用。Andrew Ng 在机器学习和无监督特征学习方面经常被引用作为该领域的基础和突破性工作，他关于稀疏自编码器的文献^[45]中介绍了一种无监督学习模型，用于学习输入数据中的有效表示。稀疏自编码器由两部分组成：编码器和解码器。编码器的作用是将输入数据转换成一个较低维度的表示（隐藏层），而解码器则尝试将这个表示重构回原始数据。通过训练过程，自编码器学习到的隐藏层表示捕获了输入数据的重要特征，可以用于各种下游任务，比如分类、聚类等，并探讨了稀疏自编码器在特征学习和深度学习框架中的应用，展示了其在图像识别和其他机器学习任务中的有效性。他与 Quoc Le 等人^[46]提出了一种使用大规模无监督学习构建高级特征的方法，展示了无监督学习方法如何能够从大量未标记的数据中学习到有用的特征，进而在视觉识别任务中达到当时最先进的性能。Jordan 等人^[47]综述了机器学习领域的最新进展、核心方法以及面临的挑战，同时对未来的发展方向提出了展望。文章强调了采用数据密集型的机器学习方法在科学研究、个人和公共健康等多个生活领域带来了基于证据的决策制定，并讨论了机器学习算法的多样性，包括决策树、数学函数和通用编程语言等表示方法，以及优化算法和进化搜索方法等程序搜索空间的方式。最后，文章提出了对于未来机器学习领域发展的展望，包括与自然学习系统（如人类和其他动物）的比较研究、团队协作学习以及机器学习在隐私保护和数据所有权方面的法律和伦理问题。Batta Mahesh^[48]深入探讨了机器学习的各种算法和统计模型。这些模型和算法让计算机系统能够在未经明确编程的情况下执行特定任务，涵盖了从 Google 搜索引擎到数据挖掘、图像处理、预测分析等日常应用。文章强调了机器学习的广泛应用和其自动处理数据的能力。文中详细介绍了监督学习、决策树、朴素贝叶斯、支持向量机、非监督学习、主成分分析、K-均值聚类、半监督学习、集成学习以及神经网络等关键概念，并通过这些算法的讨论，展示了机器学习在处理大规模数据集时的有效性。

Koosha Sharifani 和 Mahyar Amini^[49]探讨了机器学习和深度学习这两个在众多领域（包括图像识别、语音识别、自然语言处理和医学等）迅速崛起的强大工具。文章旨在提供这些技术的方法、应用、优势、劣势以及潜在的未来发展方向的全面回顾，并讨论了这些技术所面临的挑战，包括数据隐私、伦理考虑以及决策过程中透明度的需求。作者们区分了机器学习和深度学习之间的差异，强调它们在不同行业中的革命性影响。机器学习被描述为发展算法的过程，这些算法使机器能够在没有明确编程的情况下从数据中学习。相比之下，深度学习是机器学习的一个子集，利用神经网络来模拟人脑的结构和功能，特别适用于处理复杂任务，如图像和语音识别。此外，斯坦福大学、麻省理工、卡内基梅隆大学等机构是机器学习和人工智能研究的领先中心，出版了大量高质量的研究论文，推动了理论研究的深入，也促进了机器学习技术在各行各业的广泛应用。

在深度学习方面，Alex Krizhevsky 等人^[50]介绍了一种新型的深度卷积神经网络（CNN），被称为 AlexNet。AlexNet 在当年的 ImageNet 大规模视觉识别挑战（ILSVRC）上取得了突破性的成果，大幅度提高了图像分类的准确率。该网络结构特别之处在于它的深度和使用 ReLU（线性修正单元）作为激活函数，以及使用了 dropout 和数据增强来防止过拟合。这项工作标志着深度学习在计算机视觉领域的重大进步，并且极大地推动了深度学习在各种领域的应用和发展。He 等人^[51]提出了残差网络（ResNet）来解决深层网络中的退化问题。这种架构允许网络层学习残差映射而非直接学习所需的输出，从而使得训练更深层次的网络成为可能。ResNet 在 2015 年的 ImageNet 视觉识别挑战赛中大放异彩，击败了其他模型并创下新的性能记录。这项工作对深度学习和计算机视觉的发展产生了深远影响，它不仅提高了图像识别任务的性能，还为训练更深、更强大的神经网络提供了可行的途径。Deng 等人^[52]介绍了 ImageNet 数据库，一个大规模的图像数据库，旨在使用网络收集和标注图片，以辅助视觉对象识别软件的研究和发展。ImageNet 的独特之处在于其规模和分层的类别结构，它基于 WordNet 层次结构组织超过 1400 万幅图像，涵盖了 2 万多个类别。通过提供这样一个庞大而丰富的图像和标签集合，ImageNet 极大地推动了机器视觉和深度学习的研究，尤其是在图像识别和分类任务中。这个数据库成为了许多计算机视觉挑战和竞赛的基础，特别是在推动了深度卷积神经网络在图像识别领域的突破方面扮演了关键角色。Yann 等人^[53]介绍了深度学习的起源和发展，特别强调了神经网络（尤其是多层感知机）的重要性，以及如何通过反向传播算法有效地训练这些网络，探讨了深度学习的一些关键技术和概念，例如卷积神经网络（CNNs）、递归神经网络（RNNs）、长短期记忆网络（LSTMs）以及其他重要的结构和训练技术并介绍了深度学习在各个领域的应用，包括语音识别、图像识别、自然语言处理等，展示了深度学习如何推动这些领域的技术进步，讨论了深度学习的未来发展方向，以及在理论和实际应用中面临的挑战，如如

何提高训练效率、避免过拟合、理解网络内部的表示等。Geoffrey Hinton、Yoshua Bengio 和 Yann LeCun：这三位科学家被公认为深度学习之父，他们对神经网络^[54-56]的研究，特别是在反向传播算法和卷积神经网络（CNN）方面的工作，极大地推动了深度学习的发展。他们因此获得了 2018 年的图灵奖。Ian Goodfellow、Yoshua Bengio 和 Aaron Courville 合著的《深度学习》^[57]是深度学习领域的经典参考书之一。该书详细介绍了深度学习的基础知识、关键技术，包括但不限于神经网络的训练、深度网络的结构和算法，以及深度学习在各种实际应用中的使用。同时，Ian Goodfellow 等人^[58]提出了生成对抗网络（GANs）的概念，介绍了 GANs 的原理、架构、挑战和应用。GANs 的核心概念，是通过一个生成网络（生成器）创造出近似真实的数据，同时一个判别网络（判别器）学习区分真假数据。接着，论文详细描述了这两个网络如何在训练过程中相互竞争、学习，以及如何通过这种对抗过程提高数据生成的质量。Ashish Vaswani 等人^[59]撰写提出了一种新的网络结构，即“Transformer”，它完全基于注意力机制，不再依赖于以往的循环神经网络（RNN）或卷积神经网络（CNN）。Transformer 模型通过自注意力（self-attention）机制能够同时处理序列中的所有单词，使得模型能够更有效地学习单词间的关联。这种结构大幅提高了处理长距离依赖关系的能力，并显著减少了训练时间。该论文对之后的 NLP 模型，如 BERT 和 GPT 系列产生了深远的影响，它标志着深度学习在自然语言处理领域一个新纪元的开始，极大地推动了整个领域的发展。

在强化学习方面，Google DeepMind 这个研究机构在强化学习领域取得了显著成就，AlphaGo 是该机构最著名的成果之一^[60]。这是一个利用深度学习和强化学习技术训练的程序，专门用来玩围棋。2016 年，AlphaGo 在对战世界冠军李世石时取得了 4:1 的胜利，这一成就标志着机器在复杂的人类游戏中取得的巨大进步。随后，DeepMind 的研究人员在文献中^[61]首次提出了结合深度学习和强化学习的概念，被称为深度强化学习（Deep Reinforcement Learning）。文章介绍了一种名为深度 Q 网络（DQN）的算法，它通过深度学习技术处理高维感知输入，并成功应用于玩 Atari 2600 视频游戏。DQN 的核心创新是利用卷积神经网络（CNN）直接从游戏画面的原始像素输入中学习决策策略。DQN 算法能够在多个游戏中实现超越人类水平的性能，展示了机器通过与环境的交互自主学习复杂任务的潜力，为之后在复杂环境中自动学习决策的系统的开发奠定了基础。Richard 等人^[62]的专著全面地介绍了强化学习的基本概念、理论框架和算法。它从强化学习的基础出发，详细解释了强化学习中的关键元素，如奖励、代理、环境、策略和价值函数等，并进一步探讨了各种强化学习算法，包括有模型和无模型的方法、时序差分学习和策略梯度方法等，对该领域的发展产生了深远影响。John Schulman 等人^[63]提出了一种信任域策略优化方法（TRPO）。TRPO 的核心思想是在强化学习中改进策略迭代过程，以提高学习算法的稳定

性和效率。具体而言，TRPO 通过引入所谓的“信任域”，这是一种限制策略更新步幅的方法，来保证策略迭代过程中的性能稳定提升。这种方法使得每次策略更新都在确保改善的前提下进行，从而避免了策略性能因过大更新而恶化的问题。TRPO 在实现复杂任务和处理高维动作空间方面表现出了显著优势，尤其是在连续动作空间的问题中。为解决深度强化学习中的稳定性和样本效率问题提供了一种有效的方法，并对后续的强化学习研究，如近似策略迭代和策略梯度方法等，产生了影响。与此同时，Timothy 等人^[64]提出了确定性策略梯度算法（DDPG），DDPG 算法是一种在连续动作空间中工作的强化学习方法，它结合了深度学习和策略梯度方法的优点。这个算法特别适用于需要精细控制的任務，比如机器人控制和游戏中的复杂运动。在 DDPG 算法中，主要创新是采用了确定性策略（即给定状态下产生单一动作，而非动作的概率分布），这有助于在连续动作空间中提高学习效率。算法使用了两个主要的网络：一是“行动者”网络，用于生成给定状态的最优动作；二是“评论者”网络，用于评估行动者网络生成动作的价值。这种“行动者-评论者”架构允许对策略和价值函数进行有效的更新，从而在连续的、复杂的任务中学习有效的策略。DDPG 算法还采用了经验回放（Experience Replay）和目标网络（Target Network）的技术来进一步稳定训练过程。通过这些创新，DDPG 在处理连续动作空间的问题上展现了很高的效率和效果，对深度强化学习领域的进一步的发展起到了推动作用。

1.2.3 数控加工轨迹优化技术研究现状

在数控加工的过程中，“路径”和“轨迹”是两个关键但不同的概念。“路径”指的是刀具按照 CAD 模型规划的理想移动线路，它代表了在理想状态下刀具应该遵循的路线，是一个静态的、预定的计划。相对地，“轨迹”则是刀具在实际加工过程中的实际移动情况，包括了刀具的速度、方向和加速度等动态信息。因此，虽然路径提供了理论上的指导，但轨迹则反映了刀具在真实加工环境中的具体行为，这种动态的特性使得轨迹优化成为提高加工效率和质量的关键。

数控加工是目前广泛应用于机械制造系统中的一种加工方法^[65]，在过去的几十年里，数控系统已经由简单的机器发展为高度复杂的计算机数控，计算机数控系统的机器程序通常由使用 CAD 信息的计算机辅助制造(CAM)系统生成。在输入计算机数控系统时，转换为由 G、T、M、S、F 等的数字代码定义成的 G 代码(ISO 6983)^[66]。CNC 控制器读取指令中的 G 代码，对其进行解释，最后则利用切削刀具在工件上进行插补。在上述步骤中均需要制定相应的算法规则以约束刀具所切割的方向、力、长度等物理要素，这些要素即为数控加工工艺的核心。然而由初始模型直接生成的 G 代码通常存在着加工缺陷，其根本原因

则在于原始 G 代码中不合理的轨迹。例如, 轨迹在刀路横向上的不均匀会引起表面刀纹不均匀; 轨迹不平滑引起进给轴的振动, 反应到工件表面, 也会形成表面加工缺陷^[67]; 数控系统加工路径优化技术是提升零件加工精度、加工效率和表面质量的综合应用技术, 路径平滑是曲面加工优化的重要技术手段。

随着现代制造业对高精度、高效率和高质量的持续追求, 数控加工轨迹的质量和效率是加工制造过程成功的直接因素, 决定了最终产品的性能表现。数控加工轨迹压缩是近几十年来在工业界和学术界都备受关注的研究领域, 如何有效地压缩轨迹, 减少冗余数据, 同时保证加工质量, 一直是研究者们努力探索的问题。数控加工轨迹压缩的核心目标是减少数据点的数量, 从而达到节省存储空间、提高数据处理速度、减少传输时间等目的。这对于大型数控机床尤为重要, 原因是它们处理的数据量大, 对精度要求高。如果不进行有效的压缩, 数据的存储和处理都将成为制约加工效率的重要因素。

数控加工轨迹优化是数控加工技术中的重要研究领域, 其目标是通过合理地规划刀具的移动路径, 来提高加工效率、减少工件的加工误差, 并延长机床和刀具的使用寿命。数控加工的核心是将 CAD 模型转化为 CNC 机床可识别的指令。这一过程中, 如何确定刀具在每一个时刻的位置和方向, 就成了一个关键问题。不同的加工轨迹会对加工效果、效率和成本产生巨大的差异。例如, 不合理的轨迹可能会导致刀具过度磨损或机床产生不必要的振动, 从而影响工件的表面质量。

综上所述, 加工路径优化、轨迹压缩和轨迹优化在数控加工中是互为补充的技术。通过对这些方面的持续研究和开发, 不仅可以提升数控机床的操作效率和加工速度, 还能够确保加工出的工件具有更高的精度和更好的表面质量, 进而满足现代制造业对高性能产品的需求, 对以上几方面的持续研究是非常有必要的。

在加工路径优化方面, Hu 等人^[68]提出了一种利用深度学习技术识别刀具路径特征点的方法, 通过将刀具路径点特征转换为图像进行视觉处理, 避免依赖于手工的方法从而提高了自动化效率。Dittrich 等人^[69]研究了一种用于 5 轴铣削的自动优化工艺规划方法, 使用机器学习方法预测产生的形状误差并调整刀具路径。Xiao 等人^[70]以粒子群优化算法和改进的遗传算法对加工中心切削参数进行了优化, 旨在实现 CNC 加工的节能、低成本。Hatem 等人^[71]将高性能蚁群算法和开放式系统架构控制应用到 CAD/CAM 中, 从而实现刀具路径的优化、缩短 NC 代码序列的制造时间。Chu 等人^[72]使用三次曲线生成刀具路径, 并通过类电磁机制优化算法来搜索最佳曲线控制点和由此产生的刀具路径, 从而提高刀具路径生成的计算效率和加工表面光洁度。Herraz 等人^[73]首先将曲面划分为具有相似局部几何特性的区域, 在此基础上使用无监督聚类算法, 将刀具路径规划算法应用于每个区域以优化路径、定义每个区域的最佳加工方向。Zhao 等

人^[74]提出了一种基于振动误差的机床轨迹规划方法,旨在给定加工路径的最佳位置和加工时间,并以整个轨迹中振动误差的平均值和波动为指标评估典型加工路径中的振动误差。

以往的研究工作大多集中在 G 代码生成之后的加工路径规划方法上,忽略了 G 代码本身的隐含价值,实际上通过工艺解析分析原始 G 代码中的信息就能够初步确定刀具的加工轨迹,在原始 G 代码中消除加工缺陷存在的路径从而生成加工质量高的 G 代码对于数控加工工艺的提升是巨大且高效的。

在轨迹压缩方面, Sun 等人^[75]概述了移动对象轨迹压缩算法的发展和趋势,并对近年来提出的典型移动对象轨迹压缩算法进行了分析。首先,概括了经典的移动对象轨迹压缩算法的策略和实现过程,然后讨论了移动对象及其轨迹的相关定义,接着引入了验证压缩算法性能和效率的验证标准。最后,还总结了一些应用场景,指出了移动对象轨迹压缩的潜在应用领域。Zhao 等人^[76]提出了一种基于主导点的双四元数 B 样条近似方法来生成平滑的工具路径,通过选取能够表征线性路径形状的主导点,该方法显著压缩了控制点的数量,减轻了计算负担,在五轴机床上进行的仿真和实验证明了所提方法的可行性和效率。Zhang 等人^[77]提出了一种基于最小二乘法的工具路径平滑和压缩算法,并设计了一个简单有效的双头蛇(DHS)算法,将复杂曲线离散成直线和圆弧段的组合。实验表明,与等弦误差方法和商业 CAM 软件相比,DHS 算法在相同轮廓误差阈值的约束下可以获取更少的轨迹数据。Du 等人^[78]针对在数控插补中对微线工具路径进行 B 样条曲线逼近的问题,提出了一种基于主导点的误差有界 B 样条曲线逼近方案。首先,文章提出了一种基于双弦误差测试的方法来选择控制微线工具路径整体形状的主导点。其次,利用这些主导点构造初始 B 样条曲线,并通过引入一个新的几何偏差模型来估计初始 B 样条曲线与微线工具路径之间的偏差,从而在全局路径优化中考虑这些偏差。Jin 等人^[79]为高速加工线性工具路径设计了基于 G2 连续贝塞尔曲线的最优进给插补器,提出了一种基于 G2 连续贝塞尔曲线的最优进给插补器。首先基于连续短线段(CSS)的几何特征筛选出适合拟合的区域,并使用最小二乘法将 CSS 压缩并拟合成 G2 连续的贝塞尔曲线。然后生成一系列三次贝塞尔曲线,并通过调整控制点和在相邻贝塞尔曲线之间插入过渡曲线来构建 G2 连续的工具路径。在三轴 XK714 数控铣床上进行了仿真和实验,验证了提出的算法在压缩和平滑线性路径方面的有效性。

以往的工作中对于数控加工轨迹压缩的研究集中在样条拟合后的主导点选择上,这种方式计算复杂,投入应用时更需大量的由研到产的适配工作,如何实现简单高效的数控加工轨迹压缩方法仍是一个有待完善的问题。

在轨迹优化方面, Du 等人^[78]使用双弦误差测试来选择主导点,进而构建初始 B 样条曲线,通过开发的几何偏差模型估算与初始 B 样条曲线之间的偏差,

并进行全局刀具路径优化。Lyu 等人^[80]在三轴数控加工中,通过基于轨迹几何特征的粗筛选法筛选出疑似缺陷点,然后通过趋势轨迹和箱线图的精筛选法从疑似点中筛选出真正的缺陷点。最后,利用 NURBS 曲线重构刀具位置点,并通过实验验证了优化效果。Zhang 等人^[77]提出了双头蛇算法将 NURBS 曲线离散化为较大的直线和圆弧段来显著减少刀具路径描述所需的数据量。Hu 等人^[81]提出了一种三轴 NURBS 刀具路径的进给速度调度方法,能够减少弦高误差和舍入误差,并生成连续的速度、加速度和急动性能的轮廓。Sun 和 Yusuf^[82]提出了一种用于五轴数控机床加工的 G3 连续工具路径平滑方法。针对线性工具路径段之间的连接点,通过实施 Bezier 样条插值和路径误差校正,以实现工具路径的 G3 几何连续性。Liang 等人^[83]提出了一种基于遗传算法优化的全局时间最优 B 样条进给速度调度方法。该方法通过建立 B 样条曲线代表的进给速度轮廓,采用遗传算法求解优化模型,以最小化加工时间同时考虑到几何和驱动约束。Liu 等人^[84]提出了一种先进的迭代逼近及其变种的预处理技术,旨在加快收敛速度同时保持计算效率,用于 B 样条曲线和曲面插值的几何迭代方法收敛速率的提升。Sun 等人^[85]通过对五轴线性片段进行三次贝塞尔样条平滑以优化曲率,并修改了限制急动度的进给速率规划算法,以确保每个不同的预定进给速率阶段的时间间隔是轴位置控制回路闭合时间的整数倍,旨在减少进给速率的波动并提高计算效率。Dittrich 等人^[86]研究了一种用于 5 轴铣削的自动优化工艺规划方法,使用机器学习方法预测产生的形状误差并调整刀具路径。Xiao 等人^[87]以粒子群优化算法和改进的遗传算法对加工中心切削参数进行了优化,旨在实现 CNC 加工的节能、低成本。Hatem 等人^[88]将高性能蚁群算法和开放式系统架构控制应用到 CAD/CAM 中,从而实现刀具路径的优化、缩短 NC 代码序列的制造时间。Chu 等人^[89]使用三次曲线生成刀具路径,并通过类电磁机制优化算法来搜索最佳曲线控制点和由此产生的刀具路径,从而提高刀具路径生成的计算效率和加工表面光洁度。Herraz 等人^[90]首先将曲面划分为具有相似局部几何特性的区域,在此基础上使用无监督聚类算法,将刀具路径规划算法应用于每个区域以优化路径、定义每个区域的最佳加工方向。Zhao 等人^[91]提出了一种基于振动误差的机床轨迹规划方法,旨在给定加工路径的最佳位置和加工时间,并以整个轨迹中振动误差的平均值和波动为指标评估典型加工路径中的振动误差。Bosetti 和 Bertolazzi 提出^[92]了一种最优控制问题(OCP)的方法来实现这一目标。该方法能够在保证加工精度的同时,提高机床的加工效率。Zhang 等人^[93]提出了一种优化方法,通过考虑加速度的限制,生成平滑的轨迹。该方法通过将轨迹生成问题表述为一般的最优控制问题,并应用控制向量参数化(CVP)方法转换为非线性规划(NLP)问题来解决,通过实例展示了该方法在提高 CNC 系统轨迹生成的平滑性和效率方面的有效性。Mercy 等人^[94]为数控机床开发一种新的基于 B 样条的轨迹生成方法,提出了解决最优控制问题的

方法，目标是在考虑工具轴的速度、加速度和急动限制的同时，最小化刀具的运动时间，并通过实验验证了该方法在 CNC 机床轨迹生成中的有效性和优势。

Paing^[95]使用三次 B 样条对轨迹进行参数化，以保证加速度和加加速度（Jerk）的连续性，采用凸包和 B 样条的局部修改特性，通过应用不同的几何路径、运动学限制和问题网格大小，采用限制加加速度的时间最优轨迹生成方法进行评估。模拟结果显示，提出的方法在满足所有运动学约束的情况下，保证了轨迹的平滑性和时间最优性。

综上所述，先前的研究主要集中在提高刀路规划方法的优化上，特别是在切削路径间隔和切削步长的计算方法上。但是，曲面加工中不同位置的刀具路径生成算法通常不会变化，忽视了复杂曲面几何特性的影响。因此，传统刀具路径规划方法的适应性较弱，相对降低了加工效率。自由曲面的加工效率和质量很大程度上依赖于规划的刀具路径、笛卡尔空间中的进给率和关节空间中的轨迹。这些问题紧密相关且相互耦合，但同时考虑刀具路径、进给速度和轨迹规划是一项挑战。刀具加工轨迹直接影响加工质量，加剧刀具磨损甚至引起加工振动。因此，在刀具轨迹规划过程中，不仅要考虑曲面的几何特性，还要考虑进给速度等物理因素，以实现高质量、高效率的加工。因此，迫切需要开发一种适应性强、加工质量高、加工效率高的刀具轨迹优化有效解决方案。

1.3 课题来源及本文的研究内容

1.3.1 课题来源

本文的研究课题来源于国产高档数控系统智能化技术研究开发及应用验证（项目编号：2018ZX04035-001），国家 2022 年产业基础再造和制造业高质量发展专项：航空航天薄壁零件关键加工技术装备项目—国产五轴数控系统应用技术研究，项目编号“TC220H05S-003”；高档数控机床与基础制造装备—数控系统与基础制造装备关键技术国际标准制定及应用验证，项目编号“2019ZX04004-001”；直升机发动机空间动力传动单元体高精高效智能化加工应用示范，项目编号“2018ZX04002001”；以及辽宁省“兴辽英才计划”项目—面向智能制造的数控装备及工业互联网技术研发与应用示范（XLYC1902091）。

1.3.2 本文的研究内容

本文围绕智能制造对数控系统的新要求，研究数控系统智能化方法与技术，研究数控加工路径优化方法、数控加工轨迹压缩方法、数控加工轨迹优化方法，本文的主要研究内容与组织结构见图 1-3：

第一章：绪论。阐述了智能化数控系统研究的背景和重要性，指出了目前国内外在该领域的研究现状和存在的不足。详细地分析了数控系统智能化技术、

加工路径优化、轨迹压缩技术和轨迹优化技术的研究进展，概述了数控加工的一般流程，为后续研究提供了理论基础和技术支持。

第二章：基于智能体模型的智能化数控系统研究。第二章介绍了智能化数控系统的智能体模型，首先介绍了智能化数控系统的概念，其次，探讨了数控系统智能化的需求，提出了数控系统智能化的扩展方案，构建了一个模块化的智能数控系统抽象模型和层次化的体系结构，并建立了数控系统智能体模型。

第三章：基于智能体的数控系统加工路径优化方法研究，第三章首先分析了以往 CAM 与 CNC 系统之间数据传输方式的不足，通过一种新的工作方式建立了 CAM 系统与机床控制器之间数据传输的闭环。在此基础上，提出了加工路径优化的解决方案。然后，开发了一套流水线路径优化过程和相应的应用程序，以提高路径优化的效率和过程分析的实时性能。最后，通过一个应用实例介绍了工艺解析的原理和所提出的路径层级分解算法、路径生成过程和路径优化过程。在路径优化过程中，给出了路径分割的聚类算法、路径缺陷特征的深度学习分类算法和路径优化的自适应滤波算法。




图 1-3 论文的组织结构

Figure 1-3 Organizational structure of the paper

第四章：基于强化学习的轨迹压缩方法研究，第四章从数控系统的加工 G 代码的数据压缩问题与先进人工智能方法结合的角度入手，分析了数控系统智能化，加工过程数字化的趋势和 G01 代码的数据压缩方法的研究现状与不足，通过将 G 代码加工程序进行文件解析后生成的三维坐标的关键点选择作为一个序列决策问题，建立马尔可夫决策过程模型，并结合深度 Q 网络的迭代学习理念实现了自动化的学习和决策过程，并通过实验案例表明了所提出基于 DQN 的 G01 数据序列压缩方法能够有效的进行数据压缩和轮廓的保持。

第五章：基于层次化强化学习的轨迹优化方法研究，第五章首先描述了智能化数控加工轨迹优化的问题，构建了一个基于网络制造的架构轨迹智能优化框架，阐述了网络制造背景下的智能数控系统、抽象模型的建立以及轨迹优化的技术方案。其次，介绍了 B 样条的理论基础以及层次化的强化学习方法在轨迹优化中的使用，并通过由两个工件的 G 代码优化实验展示了轨迹优化的过程，并进行了插补验证。

第六章：总结与展望，总结了本文的研究成果，并对智能化数控系统轨迹优化方法的未来研究方向进行了展望。本文的研究成果不仅在理论上丰富了智能数控系统的研究内涵，而且在实践上为高效、高精度的智能制造提供了新的解决思路和技术支持，具有一定的理论价值和应用前景。

第2章 基于智能体模型的智能化数控系统研究

数控机床是工业母机，是国家装备制造业的支柱，是实现自造强国战略的重要保障，也是制造业升级和国家综合实力的集中体现。数控系统作为指导机床加工的“大脑”，是机床智能化的重要载体。而通过建立模型来描述和抽象数控系统的工作过程是促进数控技术理论发展的关键技术，由于缺乏统一集成的系统模型和算法实现，数控装备中的数据是孤立、碎片化的，如何将这些低价值的大量数据转化成高价值的决策信息是一个具有挑战性的问题。

本章首先讨论了智能数控系统，包括智能数控系统的概念与构建智能数控系统的软硬件平台。其次，通过分析智能制造对数控系统提出的发展需求，提出了基于智能体的数控系统模型，并基于此提出将信息系统作为一个智能体的概念，从而将人工智能方法、数字孪生等独立的知识领域融合在智能体中，为数控系统的智能化提供支持。

2.1 智能数控系统

随着新一代人工智能技术、网络技术与智能制造技术的深度融合，数控系统正迎来智能化的发展浪潮。工业互联网和云计算的兴起，加上网络基础设施的持续改善，不仅催生了以“互联网+”为基础的新商业模式，也为数控技术提供了全新的发展机遇。在这样的背景下，智能数控系统逐渐成为智能制造领域的关键研究对象，因其独特的能力，将人、信息、设备连接成一体，推动了制造业向网络化和智能化的转型。

如图 2-1 所示，智能数控系统集成了高级的感知、分析、学习和决策执行功能，不仅极大地减轻了人工劳动强度，而且提升了系统自动化水平和信息利用效率。它通过精确控制数控设备的操作，使得加工更加精细和高效，同时也为机械制造系统带来了高度的灵活性和适应性。




图 2-1 智能数控系统示意图

Figure 2-1 Schematic diagram of intelligent CNC system

为了应对智能化转型的需求，研发智能数控系统成为了行业内的必然选择。智能数控系统通过其自主决策生成的最佳控制策略，体现了人工智能技术在实际操作中的应用，它是现代智能制造领域技术革新的产物。因此，智能数控系统的研究与发展，不仅顺应了制造业网络化、智能化的趋势，更是满足了制造业发展主要需求的关键技术基础。在这个基础上，本章将进一步探讨什么是智能数控系统。

2.1.1 智能数控系统的概念

在 Albus 的著作^[96]中，智能被定义为那些产生成功行为的系统的能力。更具体地说，智能系统的行为是合适的，即那些能增加成功概率的行为，其中成功被视为达成支持系统最终目标的行为子目标的实现。智能既包括生物系统也包括机械系统，它涵盖从简单到复杂的各种行为和能力。智能系统可以概括为以下几个部分的组成，如图 2-2 所示：




图 2-2 智能系统的组成

Figure 2-2 Composition of intelligent systems

传感器 (Sensors): 传感器为智能系统提供了与外界环境交互的手段。它们可能包括各种类型的传感器,如视觉亮度和颜色传感器、触觉力量和扭矩定位器、速度振动和声学测距器,以及用于监测外部世界状态和智能系统内部状态的的压力和温度测量设备。

感知处理 (Sensory Processing): 感知元素通过将感官观察与内部世界模型生成的期望进行比较来实现感知。这个过程整合了观察与期望之间的相似性和差异,从而在世界中检测事件并识别特征、物体和关系。

世界模型 (World Modeling): 世界模型是智能系统对世界状态的最佳估计。它包括有关世界的知识数据库及一个数据库管理系统,用于存储和检索信息,并含有产生期望和预测的仿真能力。世界模型为行为生成系统元素提供服务,以便进行智能规划和行为选择。

价值判断 (Value Judgment): 价值判断系统元素决定了什么是好的和坏的、奖励和惩罚、重要和琐碎、确定和不可预测。它对观察到的世界状态和假设计划的预测结果进行评估,计算观察情境和计划活动的成本、风险和收益。

行为生成 (Behavior Generation): 行为由选择目标和计划并执行任务的行为生成系统元素产生。任务被递归分解为子任务,子任务被排序以实现目标。行为生成系统通过行为生成、世界建模和价值判断元素之间的循环互动选择目

标和生成计划。

执行器 (Actuators): 智能系统的输出是通过执行器产生的, 它们移动、施加力量和定位手臂、腿、手和眼睛。执行器产生力量来定位传感器、激活换能器、移动操作器、处理工具以及驾驶和推进运动。智能系统可能拥有从几十个到数百万个执行器, 所有这些都必须协调一致以执行任务和实现目标。

以上这些元素在智能系统中不是孤立存在的, 而是通过一个互连的系统架构进行互动和通信。这种架构定义了智能系统的分区和模块化, 将系统元素分解成计算模块, 并通过网络和层次结构相互连接。

智能系统的智能水平, 即它执行任务和做出决策的能力, 主要取决于以下几个关键因素:

1. **大脑 (或计算机) 的计算能力:** 这是指智能系统处理信息和执行算法的能力。高计算能力意味着系统能够更快地处理复杂数据和执行复杂算法, 从而更有效地做出决策。
2. **用于感知处理、世界建模、行为生成、价值判断和全域通信的算法的复杂性:** 这些算法的复杂性决定了系统解决问题的能力。更复杂的算法能够更好地处理复杂问题, 例如, 精细的感知处理算法能够更准确地解释传感器数据, 复杂的世界建模算法可以更好地预测和模拟环境变化。
3. **系统在其记忆中存储的信息和价值。** 智能系统的记忆中存储的信息量和质量直接影响其决策和行为。丰富的信息存储可以增强系统对环境的理解, 改善决策质量。同时, 系统内置的价值观也会影响其决策, 因为它决定了系统在各种情况下优先考虑什么。

总体来说, 智能系统的智能水平取决于它的计算能力、所运用的算法的复杂度以及它存储的信息和价值观。这些因素共同作用, 决定了系统处理信息、适应环境和执行任务的能力。

将以上智能系统的定义应用并扩展到智能数控系统中时, 本文认为智能数控系统被视为具有传感、决策、学习和执行功能的集成系统。它能够在复杂和不确定的加工环境中, 自主产生和执行最优控制策略, 以达成提升加工质量、提高效率和确保设备安全的子目标。智能数控系统借助其层级架构和世界模型, 整合外部信息和内部状态, 运用这些信息进行高效的任务分解和行为规划, 实现自动化和智能化控制。它是智能制造领域技术进步的产物, 体现了智能在现代制造系统中的应用。如图 2-3 所示。




图 2-3 数控系统智能扩展结构

Figure 2-3 Intelligent Extended Architecture of CNC Systems

值得注意的是，智能系统是层级化的，但并非每个子系统都包括之前提到的那六个部分（传感器、感知处理、世界模型、价值判断、行为生成和执行器）。这种层级化结构通常指的是整个系统在不同的抽象层面上的功能和处理流程。在层级化的智能系统中，较低层通常负责更直接和具体的任务，如传感数据的即时处理和基本的行为响应。而在较高层级，系统可能涉及更复杂的决策过程、长期规划和整体目标的设定。这些层级相互作用，每一层都根据其职能提供信息和指令给其他层级。例如，在智能数控系统中，较低层的子系统可能直接处理来自传感器的数据，执行基本的机器操作，而较高层的子系统则可能涉及整个生产流程的规划、资源分配以及更高级别的决策。虽然高层子系统可能不直接包含感应器或执行器，但它们会使用来自低层子系统的信息来做出决策，并将这些决策下发给低层子系统以指导其操作。

具体的说，将上述智能系统的理论应用于构建智能数控系统时，可以将六个核心部分及其对应的智能水平的影响因素相应的扩展如下：

传感器 (Sensors)：在智能数控系统中，传感器负责收集机床状态和加工环境的数据。这包括测量切削力、振动、温度、工件和刀具的位置、速度等。这些数据是系统进行有效决策和调整的基础。例如，温度传感器可以监测机床的热变形，振动传感器可以检测刀具磨损或断裂。

感知处理 (Sensory Processing)：将从传感器收集的原始数据转换为有用的信息。这涉及数据清洗、噪声过滤、特征提取等。在智能数控系统中，这包

括识别异常条件、判断刀具磨损状态等。例如通过分析振动数据来识别刀具磨损模式，或者从切削力数据中提取切削状态特征。

世界模型 (World Modeling): 基于收集的数据和先验知识构建对加工环境和过程的内部模型，用于预测和决策支持，构建对加工过程和机床状态的理解和模拟。例如，模拟不同切削参数对加工质量的影响，预测刀具寿命或产品质量。

价值判断 (Value Judgment): 系统根据预设目标和约束（如质量、效率、耗能）评估不同加工方案。它决定何种加工参数或策略最能达到期望的加工质量和效率。例如，决定是否更换刀具，选择最优的切削速度和进给率以平衡加工时间和质量。

行为生成 (Behavior Generation): 基于前述分析和判断，制定具体的行动计划和指令来达成目标以及调整加工策略。例如，生成适应当前工件材料和形状的加工路径，或在检测到刀具磨损时自动调整切削深度。

执行器 (Actuators): 根据生成的加工路径精确移动机床，实施切削动作。实际执行系统的决策和命令，如移动机床的各个轴、控制刀具转弯等。

而智能数控系统的智能水平的影响因素，也相应的扩展为：

计算能力: 强大的计算能力允许智能数控系统快速处理大量数据，并执行复杂的算法来进行优化和决策。

算法复杂性: 高级的算法能更精确地模拟加工过程，更有效地进行判断和预测。包括机器学习和人工智能算法在内的先进技术，可以显著提高决策和预测的准确性。

信息和知识存储: 包括加工参数、历史数据、刀具特性等的丰富知识库，可以提供更准确的决策支持。存储的信息越多，系统能够更好地适应新的加工情况。

适应性和学习能力: 系统能够从经验中学习并优化其行为，对新情况作出适应。学习能力是智能数控系统区别于传统系统的关键特点之一。

互联互通: 系统能够与外部系统（如 CAD/CAM 系统、质量管理体系）进行数据交换和协调。这增强了整体制造过程的智能化和自动化程度。

总体而言，智能数控系统的智能水平受到其计算能力、所运用的算法的复杂度、存储的信息和知识量，以及其学习和适应能力的共同影响。随着这些因素的提升，智能数控系统在自动化、精确度、效率和自适应方面的能力也会相应提高。

2.1.2 智能数控系统平台

针对新一代人工智能与数控系统的融合，实验室建立了智能控制技术实验平台、数字孪生实验平台、可靠性实验环境以及检测与验证实验环境。在“高档

数控机床与基础制造装备”等国家科技重大专项的支持下，形成了系列化的高档型、标准型及专用型数控系统产品，产品在航空航天领域配套应用并批量出口，形成了以高性能为特色的数控产品品牌，产品入选工业和信息化部产业发展促进中心编写的《中国数控机床技术水平评价体系研究分析报告（2021 年度）》。其中，数控系统产品及配套应用如图 2-4 所示。



图 2-4 数控系统产品及配套应用

Figure 2-4 CNC system products and supporting applications

针对新一代信息技术发展以及航空航天等领域的智能制造需求，基于已有的开放式数控系统开发平台，构建了可重构的系统软硬件平台。其中，如图 2-5 所示的智能化硬件平台提供可重构式人机接口单元（HMU）和控制单元（NCU），可以根据客户需求，可实现人机接口单元和控制单元的多对多连接模式。




图 2-5 数控系统智能化硬件平台体系结构

Figure 2-5 Hardware platform architecture for intelligent numerical control systems

智能化数控系统的硬件平台包括中央处理单元（CPU）、可重构的人机接口单元（HMU）、控制单元（NCU）、监控屏幕以及各类机床和现场设备。CPU 作为系统的大脑，负责处理所有的数据和指令，确保系统的高效运转。它们之间

的紧密连接通过高速数据传输线路，提供了强大的数据处理能力和多任务并发处理的能力。

人机接口单元（HMI）是操作员与数控系统沟通的桥梁，它允许用户输入指令，实时监控机床状态，并对生产过程进行调整和控制。通过其可重构性，HMI 可以根据特定的生产需求进行定制和调整，使得用户操作更为直观和高效。

控制单元（NCU）则是数控系统与机床之间的纽带，它将 CPU 的指令转换为机床可以理解和执行的动作。NCU 的高度可配置性和可重构性使得数控系统能够适用于各种复杂的加工任务，并可以针对不同的生产需求快速重新配置。在系统的监控看板可以显示系统状态和生产管理信息。这允许管理人员实时监控整个生产流程，及时发现和解决问题，提高生产效率和产品质量。

可见，智能化数控系统的硬件平台涵盖了从数据处理到用户交互，再到机床控制的各个层面，每一部分都为整个生产系统的智能化、灵活化和高效化做出了贡献。通过这些高度集成和可重构的组件，数控系统能够提供精确的加工能力，同时保持足够的适应性以应对快速变化的生产需求。

智能化数控系统的软件平台是一个多层次、高度集成的结构，如图 2-6 所示，它包括底层的硬件支持层、中间的服务功能层、二次开发接口层以及顶层的用户界面层。在底层，该平台支持基于 Windows 和 Linux 的多种操作系统环境，并兼容 x86 和 ARM 处理器架构，确保了广泛的硬件兼容性和高效的资源管理。此层还负责处理各种工业通讯协议，如 EtherCAT、Modbus 以及串行通讯标准，保障了与现场的机器、设备和传感器之间的无缝通信。




图 2-6 智能数控系统二次开发软件平台

Figure 2-6 Secondary development software platform for INC systems

服务功能层为数控系统提供了核心的功能，如实时数据处理、任务调度、人机交互、机器视觉、PLC 控制、IO 控制等，这些服务是机器高效运行和任务

二次开发接口层则提供了一套丰富的开发工具和 SDK，如 Qt、J2ME、Android SDK、iOS SDK 等，让开发者可以根据特定需求创建定制化的应用程序。这为系统功能的拓展和用户体验的优化提供了必要的工具和接口，使得平台不仅可以满足当前的操作需求，还能适应未来技术的进步。

综上所述，利用图 2-6 展示的智能化软件开发平台具备的自适应和自调节特性，开发人员能够创造出可扩展、可伸缩、可移植的应用程序，以支持智能数控系统。这些应用程序能够适应包括工件原型分析、CAD/CAM 的工艺设计、加工程序的管理、刀具的管理与维护、机床的控制与调度以及系统的诊断与维护等数控工艺链需求。




Figure 2-7 The Core Hardware and Communication Structure of Intelligent CNC System

系统的内部通信由 PCI 总线架构支持,这是一种高速的本地计算机总线,

它允许多个硬件设备在主板上直接或间接地与 CPU 进行数据交换。这种总线架构为系统提供了高带宽和低延迟的数据传输能力。SuperIO 则是负责各种输入输出任务的集成电路，如串口和并口通信，以及接入键盘和鼠标等操作设备，它在硬件层面支持了系统的基本交互功能。

在与工业现场的各种设备的互联互通方面，系统通过 SSBI、Modbus 和 EtherCAT 等工业以太网通信协议与外部设备如伺服驱动器、IO 模块和各类传感器连接。这些接口支持了高速且可靠的数据交流，确保了机床的精准控制和实时监控，允许系统与工业现场的其他设备如机床、机器人等进行直接交互，能够与现场的各种设备和模块进行高速、稳定的数据交换，从而实现对整个生产流程的精准控制和优化。这不仅提升了生产过程的自动化和智能化水平，也极大增强了生产线的灵活性和可扩展性。这样的硬件结构是实现智能化、自动化生产的关键。数控系统的这种通信结构不仅提升了现场设备的操作效率和精度，还使得生产流程能够快速适应变化的市场需求，保持生产系统的竞争力。

基于上述的软硬件平台与通信总线结构，支撑了智能化数控系统的构建。这种集成化的软硬件框架为数控系统提供了高效、可靠的数据处理能力、灵活的人机交互界面以及精确的机械控制功能。这些元素共同构成了一个能够应对复杂生产任务的高级智能系统。特别是其通信结构，确保了系统与工业现场设备的高速、稳定数据交换，这对于提高生产过程的自动化和智能化水平至关重要。

然而，要使数控系统具有自主学习和自适应能力，仅有先进的硬件和通信基础是不够的。还需要在此基础上建立一个高效的智能体架构，集成复杂的人工智能算法。这一智能体架构使数控系统不仅能执行预定任务，还能通过不断的学习和优化，适应新的工作环境和生产要求。例如，通过集成深度学习、模式识别和自适应控制算法，智能数控系统可以实时分析加工数据，自动调整加工策略，以适应不同材料的加工要求或应对刀具磨损等变化。这种智能体结构不仅提升了系统的效率和灵活性，还增加了对复杂任务的适应能力，为满足航空航天等高端制造业的精密制造需求提供了可能。

下文将对数控系统的智能体架构展开描述，探讨如何通过集成先进的人工智能算法，使智能数控系统在加工精度、效率和自适应性方面具有自主学习能力。

2.2 数控系统智能体模型

2.2.1 数控系统智能化的需求

作为制造技术与信息技术融合的产物，数控系统伴随着信息技术的发展而不断演化^[97]。近年来，计算机辅助技术(CAD/CAM)发展迅速，在智能制造领域

发挥着越来越重要的作用。信息与通信技术的极大进步，特别是传感器、物联网、大数据、人工智能以及边缘计算的发展，对数控系统提出了新的要求，扩展了数控系统的结构，同时为研制智能化数控系统提供了条件^[98]。以上这些技术的进步正在为物理世界和信息世界的融合提供机会，这也是解决问题的必然趋势。




图 2-8 传统数控系统与智能数控系统

Figure 2-8 Traditional CNC System and Intelligent CNC System

数控系统的智能化是为了应对现代生产制造环境中日益增长的复杂性和效率需求。如图 2-8 所示，传统的数控系统主要包括 CNC 控制器、执行器和机床，主要执行插补和伺服控制的闭环过程，过程中的问题和故障主要依赖于人工检测和处理。而新一代的智能数控系统添加了计算机、数字孪生以及切削过程的反馈和优化闭环，能够实时模拟和预测机床的运行状态和数据，从而优化生产流程，预警或排除故障。

智能数控系统通过引入数字孪生技术以及人工智能技术，实现制造流程的自动化和智能化。数字孪生作为实体机床的虚拟复制，实现对机床运行状态的实时模拟和预测，深度学习、机器学习、强化学习等技术的引入，能够帮助数控系统更好地理解和控制加工过程，提高加工效率和质量，减少人工干预，实现更高层次的智能化和自动化。同时，智能化数控系统通过集成先进的信息处理技术、自动控制技术和人工智能技术，使得数控加工更加自动化和智能化，提高加工的质量和效率。相较于传统的数控加工，智能化数控系统的优势主要体现在以下几个方面：

感知能力的提升：智能化数控系统通过整合先进的传感器网络和复杂的数

据处理算法，显著增强了对加工环境和过程的实时感知能力。这些传感器能够高精度地捕捉刀具磨损、工件变形、负载波动等关键信息，并将这些信息实时反馈给中央处理单元。借助于深度学习等人工智能算法，系统能够对感知到的数据进行深层次的分析 and 处理，实现对加工过程的智能监控和控制。

计算能力的提升：随着云计算和边缘计算能力的融合，智能化数控系统在算力上实现了质的飞跃。云计算为数控系统提供了几乎无限的存储和计算资源，使得大规模数据处理和复杂算法运算成为可能。边缘计算则在数据源头提供实时的数据处理能力，减少了数据传输的延时，保证了加工控制的即时响应。这种算力的提升为处理复杂的优化模型和算法提供了硬件保障，使得数控加工能够在保证高精度的同时，实现更高效的操作。

实时通信能力的提升：智能化数控系统的网络化能力，为实现机器间的实时通信和数据交换提供了基础。通过高速以太网或无线通信协议，数控机床能够与计算平台进行数据交互。这种实时通信能力是实现数控加工过程中数字孪生仿真的前提，使得加工过程可以在虚拟环境中得到精确模拟和优化，从而在实际加工前预测并避免可能的问题。

加工质量和效率的提升：智能化数控系统利用先进的算法优化加工参数，如切削速度、进给率和轨迹等，这不仅提升了加工效率，也优化了加工质量。智能监控和自适应控制技术能够确保加工过程稳定，并在检测到偏差时自动进行调整。此外，通过预测性维护和刀具寿命的智能管理，系统能够减少意外停机时间，延长设备的使用寿命和保养周期。

知识驱动的决策支持：智能化数控系统能够积累和分析大量的生产数据，形成知识库，这为生产决策提供了强大的数据支持。使用先进的数据分析和人工智能技术，如深度学习和强化学习，系统能够从历史数据中学习，并提出优化生产过程的建议，这种基于数据驱动的决策支持系统，有助于持续改进生产效率和产品质量。

灵活性和定制化：智能化数控系统的架构能够适应定制化的生产需求。通过模块化设计和可编程性，系统可以快速从一个任务转换到另一个任务，降低了为特定生产线定制设备的成本和时间。此外，智能系统可以利用机器学习算法自动优化生产流程，适应复杂或非标准化的设计，使得小批量、多样化的生产成为可能，满足了现代消费市场对个性化产品的需求。

2.2.2 基于智能体的数控系统智能化扩展方法

根据前述内容对数控系统智能化的需求分析，提出如图 2-9 所示的数控系统智能化扩展方案，本文认为数控系统的智能化扩展需要使得数控系统与现场设备之间具有可靠的互联互通及互操作，在此基础上具有对物理世界的虚拟实现、对输入的自主感知和处理、对工艺的自主评估及对故障的自主诊断、具有

自适应的决策与优化等特征。

也就是说，智能化数控系统是指集成了先进计算机控制技术、人工智能、传感器技术以及网络通信技术的数控系统。与传统数控系统相比，智能数控系统能够进行自学习、自适应、自优化和自诊断，使得机床在加工过程中能够自动调整操作参数，以适应不同的加工条件和要求，显著提升了加工精度、效率和智能水平。在智能数控系统中，数控机床不再仅仅是执行预编程指令的设备，它们通过集成的传感器网络实时收集数据，监测加工状态和环境变化。这些数据包括刀具的磨损状况、工件的变形、加工力的变化、机床的热变形等多种物理量。通过对这些数据的实时分析，智能数控系统能够预测和识别潜在的加工问题，并在不影响加工质量的情况下，自动调整加工参数或路径，甚至是在必要时停止机床运行以防止损害。

智能数控系统的核心优势在于其自主学习和决策能力。它们可以通过机器学习算法，特别是强化学习，不断从历史加工数据中学习，以找到最佳的加工策略和参数设置。随着时间的推移，这些系统能够不断改进其性能，提供更加稳定和可靠的加工过程。此外，智能数控系统的网络化能力使得它们可以与制造执行系统（MES）、企业资源规划（ERP）系统以及供应链管理（SCM）系统等其他企业级系统无缝对接。这种集成为实现智能制造和工业 4.0 提供了坚实的基础，使得整个生产过程变得更加透明和可控。智能数控系统可以借助数字孪生技术在没有风险的情况下测试和优化加工程序，提前发现问题并进行必要的调整，从而确保实体加工的高效和准确。

智能数控系统代表了制造技术的未来发展方向，它不仅提高了机床的操作效率和产品质量，而且通过自学习和自适应的能力，极大地增强了生产的灵活性和自动化水平。随着技术的进步，智能数控系统将继续推动工业生产向智能化、数字化、网络化和绿色化的转型。




图 2-9 数控系统的智能化扩展方案

Figure 2-9 Intelligent Expansion Scheme for CNC Systems

图 2-9 展示了智能化数控系统的框架，表明了传统的数控系统如何与数字孪生技术、人工智能等技术相结合，提升数控机床的自主性能。在数字孪生模型部分，通过高级的计算机模拟与实体机床的物理特性和性能相对应。这一模型是通过集成先进的传感器数据，如温度、压力、振动等，收集而来的实时信息来构建的。数字孪生不仅能够实时监测和模拟实际机床的状态，还能通过分析这些数据来提取关键特征，预测未来的性能表现，以及可能出现的问题。

在自主学习部分，模型通过奖励和惩罚机制进行强化学习，以此优化机床的操作策略。这个过程涉及到任务规划、动作决策和状态估计等多个复杂的计算步骤。系统通过不断地学习和调整，能够自主地优化加工过程中的参数选择和行为决策，使得机床操作更加精确和高效。

在自主执行部分，数控机床根据数字孪生提供的优化指令执行具体的加工任务。这意味着机床能够在无需人工干预的情况下自动完成加工流程，从而大大提升加工效率和准确性。自主执行的过程包括从数字孪生到实体机床的数据传输和指令下达，确保虚拟空间中的优化能够在现实世界中得到准确实施。

而物理机床则是整个系统的执行主体。它是一个配备了先进数控系统和众多传感器的现代机床，这些传感器负责收集加工过程中的各种数据，包括刀具的位置、速度、加工材料的特性等，这些信息将被反馈给数字孪生进行进一步的分析和学习。从数据采集开始，传感器收集的原始信息被处理和分析，以实现机床状态的精确感知。这些数据不仅用于机床的自我评估和自我诊断，以便于及时发现和预防潜在问题，而且还用于自主优化和决策过程，进一步提升机床的操作智能化水平，并通过数字孪生技术与机器学习的融合，实现数控机床操作的自主性和优化。

2.2.3 基于智能体的数控系统抽象模型与体系结构

基于图 2-9 的方案，进一步提出如下智能化数控系统的抽象模型，通过建立模型来描述和抽象数控系统的工作过程是促进数控技术理论发展的必要手段，数控系统作为包含的功能部件具有各自的功能和特点，因此，数控系统的信息物理抽象模型可以通过将其功能部件的抽象模型进行归纳而获得。如图 2-10 所示，将智能数控系统的整体归纳为不同区域，对每个区域内建立了抽象的功能结构模型，模型之间箭头的连接和方向表示了模块之间的交互。而 cyber 区域内的核心智能元素可以抽象为数控系统的智能体，为数控系统提供智能算法支持。

- **Perceptual processing**。Perceptual processing 模块包含对 CAM 系统的输入和 Sensor 模块输入的数据的算法处理，主要功能是对系统输入的特征的感知计算。包括距离、形状、方向、表面特征和动力学属性等，从而实现特征提取、模式识别和分类等具体功能。
- **Assessment and diagnosis**。Assessment and diagnosis 模块对系统要素进行评估，对系统的好恶、行为的奖惩、特征重要性、预测可能性等进行判别，并对将要或已经产生的故障进行提醒和诊断。
- **Optimization and decision**。Optimization and decision 模块对系统评估为差的结果进行优化以及从诸多行动中选择最优的决策，产生下一步的工作计划，比如插补、轨迹规划、预测和维护等行为的决定。
- **Actuator**。Actuator 模块为系统执行和输出，它是工作计划的执行者并将最终的执行结果在环境中呈现。
- **World model**。负责与上述几个模块的实时交互。世界模型模块包含数控系统对于自身数据的持久化以及对本体状态的认识，数据在世界模型模块中进一步提取为知识，以提供数控系统对于当前状态的认知、评估和预测。
- **Sensor**。传感模块，主要为信息系统提供输入，数据来自于机床部署的传感器以及数控系统的内控数据。

在该抽象模型中可以看出，对于信息系统的输入来自于两个部分，一部分是由人类参与的，另一部分则是由物理系统中传感器收集的。智能化、数字化的理念，可以减少一些重复性和危险性工作的人力参与，但并不是使人在生产活动中脱离，而是要实现人与技术的良好融合，发挥各自的优势。智能化通过运用先进的技术和系统来提高生产活动的效率和质量，减少错误和资源浪费。数字化的概念则涉及将数据和信息转化为数字形式，以便更好地进行存储、处理和分析。




图 2-10 智能数控系统智能体模型

Figure 2-10 Intelligent numerical control system intelligent agent model

结合以上已经构建的抽象模型，根据数控系统任务和应用的的需求，提出一种层次化的智能数控系统体系结构。如图 2-11 所示，分为三层。

- 设备层。该层由数控车间现场设备组成，包括执行设备和感知设备，比如 CNC 控制器、PLC、传感器、伺服设备、轴承、机床、刀具等，是对系统产生输入的对象。
- Cyber 层。该层处理数据并以接口的形式向上层提供服务，包括五个子层，数据采集主要处理结构化数据(如车间 ERP 系统或企业数据库数据)、半结构化数据（如网络文件数据）及非结构化数据（如传感器的数据，数控加工的工艺数据）的采集，数据传输则包含常见的工业现场数据传输协议。平台支持主要包含当前流行的大数据、人工智能算法支持平台，为上层的数据处理提供支持。CPS 单元则关注于前文信息系统中的核心智能元素的实现。数据服务关注采用的算法逻辑和性能，例如实时性高的任务数据可采用边缘计算的方式进行处理，智能算法包含下层提供的算法支持和企业算法库。CPS 单元中箭头的意义表明了 CPS 单元相同类型模块之间数据的交互和共享，为应用的多样化提供支持。
- 应用层。这一层是接近用户的一层，是数控系统各种工作需求和应用场景的呈现，如加工路径优化、刀具寿命预测、加工轨迹规划、机器

实时监控与故障诊断等，为用户提供智能化管理的服务。




图 2-11 智能数控系统层次化体系结构

Figure 2-11 Hierarchical Architecture of Intelligent CNC System

2.2.4 数控系统智能体模型构建

现有的数控系统结构倾向于关注物理世界。建立数控系统的智能体模型则有助于物理实体与数字实体的交互融合，从而更好的实现加工过程中的加工路径优化与实时反馈，建模过程如图 2-12 所示，数控系统智能体与物理实体之间通过数字线程实现信息的实时交互。Cyber 系统内的智能元素可以抽象为智能体，起到了智能代理的作用。在数控系统智能体模型建立期间，首先对系统的输入建立信息模型，其次则是构建处理该信息的机理算法，从而告知系统接收到了怎样的信息以及如何去处理。




图 2-12 数控系统智能体建模过程

Figure 2-12 Modeling process of intelligent agents in CNC systems

智能数控系统的结构模型如图 2-13 所示，数控系统类聚合了六个智能元素类以实现智能化的扩展，同时各个智能元素类关联了相应的接口以提供行为和方法。智能元素之间的信息交互依赖于通信方法和其包含的数据。上述数控系统结构模型构建了系统的整体和局部的功能结构，明确了系统模块的划分及其之间的相互作用。




图 2-13 智能数控系统结构模型

Figure 2-13 Intelligent CNC System Architecture Model

Cyber 智能体：为了更好的表达智能数控系统的智能化水平，将 Cyber 系统抽象为智能体，从三个因素描述其智能程度，并建立了其模型图如图 2-14 所示。

- **Computing Power.** 描述系统的大脑，即计算机的计算能力。
- **Algorithm.** 描述系统用于处理输入的数据、建立模型、生成工作计划、奖惩判断和模块间实时通信算法的复杂性和功能性。
- **Data.** 描述系统存储在其存储空间中的数据以及数据具备的价值。




图 2-14 Cyber 智能体模型图

Figure 2-14 Cyber Agent Model Diagram

Cyber 智能体具有算法、算力、数据模块以及与其它模块交互通信的方法，本文主要关注算法在加工路径优化这一应用中的利用。在算法模块中，集成常用机器学习(如 sklearn)、深度学习(如 pytorch)、强化学习等框架提供的算法或自行编码实现的算法。为加工路径优化或者其他智能功能提供算法支持，从而有助于构建处理数控系统任务的机理模型。

数控系统的智能体模型是一种先进的技术集成，它能够将现代智能制造技术的多个方面有效结合，实现数控加工的智能化和自动化。这种模型通过整合计算力、算法和数据三大核心元素，形成一个多层次、可扩展的智能体系统。这样的系统不仅能够提升数控系统的操作效率和加工精度，还增强了其自适应环境变化和处理复杂任务的能力。




图 2-15 基于智能体的数控系统架构

Figure 2-15 Architecture of intelligent agent based CNC system

如图 2-15 所示，智能体模型通过综合应用多种前沿技术来实现对整个制造过程的智能控制和管理。包括机器学习、深度学习、物联网技术、云计算和边缘计算等，它们共同作用于数控系统的不同环节，从而实现高度的数据集成和智能决策支持。数控系统的智能体模型采用多层次的架构设计，这种设计不仅优化了信息流和控制流，还增强了系统的可维护性和扩展性。在底层，传感器和执行器直接与物理加工过程相连，收集实时数据并响应控制指令。中间层则包括数据处理单元和决策支持系统，它们处理从底层收集来的数据，运用算法模型进行分析，并生成相应的控制策略。最顶层则是用户接口和系统管理模块，它们提供用户交互和系统监控功能，确保操作的便捷性和系统的稳定性。

在智能体模型中，算力、算法和数据是三个核心元素，它们相互依赖，共同工作，驱动整个数控系统的智能化，共同体现了数控系统的智能水平，由于智能体模型中算力可以进行扩展，因此，可以在实践中提供必要的硬件资源来支持高速数据处理和复杂算法的运行，可以是本地部署的高性能计算服务器，也可以是云平台提供的计算资源。在此基础上，通过实现和部署各种优化算法、预测模型和学习算法来分析数据，优化操作参数，提高生产效率和产品质量。

其中，算力是实现高效数据处理和复杂算法运算的关键要素。系统可以通过云计算和边缘计算的结合提供了强大的计算资源，支持高度复杂的数控任务，如加工路径优化和机器状态监控。关于云计算在智能数控系统中的应用和扩展方面讨论如下：

强大的算力支持：云计算为智能数控系统提供了核心的计算力支持，使得大规模数据存储和高性能计算成为可能。通过将数据和计算任务迁移到云端，数控系统能够利用云服务商提供的强大硬件资源，如多核处理器和高速存储系统，来处理大量的生产数据和复杂的算法。

模型训练与深度学习：云平台提供的 GPU 加速功能使得深度学习模型能够快速训练。数控系统可以利用这些资源进行机器学习模型的训练，如刀具磨损预测模型和加工质量评估模型，这些模型能够从历史加工数据中提取有价值的信息，用于实时优化加工路径和加工参数。

大数据分析：云计算强大的数据处理能力支持对收集到的大量数据进行实时分析，识别出生产过程中的关键趋势和潜在问题。例如，通过分析传感器数据，系统可以实时监测设备状态，预测设备故障，从而减少非计划停机时间。

资源共享与协作：云计算支持不同地理位置的设备和系统之间的数据共享与协作。这使得制造企业可以集中管理其全球分布的生产设施，优化资源分配，提高生产效率。

而在智能体模型中，通过算力扩展，部署和使用边缘节点，利用边缘计算技术，可以有效的对算力进行升级。边缘计算通过在数据产生的地点进行处理，解决了云计算中数据传输延迟的问题。在智能数控系统中，边缘计算使得数据处理更加快速和高效，尤其是在需要即时响应的应用场景中：

即时数据处理：边缘计算设备如工业 PC 或嵌入式系统直接部署在数控机床上，能够即时处理从传感器等设备收集来的数据，如振动分析、温度监控等。这种处理方式大大减少了数据传输时间，提高了系统的响应速度。

局部决策执行：在一些关键的生产过程中，边缘计算设备可以根据实时分析结果立即做出决策，如调整刀具速度、改变加工路径等，而无需等待云端的指令，这对于保证加工质量和效率至关重要。

数据预处理：在数据上传至云端进行深入分析前，边缘计算可以对数据进行初步的筛选和预处理，只将必要的信息发送至云端，这样可以有效减少数据传输量，节省存储空间，降低成本。

通过将云计算和边缘计算相结合，智能数控系统不仅能够处理大规模数据和复杂算法，还能保证在关键任务中的即时响应和高效执行。这种双重计算力的配置极大地增强了数控系统的智能化水平，提高了生产的灵活性和自适应能力，为实现高度自动化的智能制造提供了强有力的支持。

在智能数控系统的算法部分，核心目标是通过先进的计算模型和技术，提高加工精度、优化操作流程，并提升系统的整体智能化水平。在图 2-13 中，系统集成机器学习、深度学习和强化学习框架，支持多样化的算法应用和定制，具体的实践应用说明如下：

1. 深度学习算法：深度学习在图像识别、预测分析和自动决策等方面的应

用，为数控系统提供了强大的数据解析能力。在数控系统中，深度学习算法可以应用于以下几个方面：

工件质量检测：使用卷积神经网络来分析工件图像，自动识别加工缺陷如裂纹、不平整等，实时确保产品质量。

预测性维护：通过分析机床历史运行数据，深度学习模型能够预测设备故障和维护需求，减少停机时间，优化生产流程。

加工参数优化：基于历史数据训练的神经网络，能够自动调整加工参数，如切削速度和进给率，以适应不同材料和设计要求，优化加工效率和质量。

2. 强化学习算法：强化学习在智能数控系统中主要用于动态优化加工路径和操作策略，无需事先编程就能自主学习如何达到最优操作。具体包括：

路径规划：利用强化学习算法，数控机床可以通过试错学习找到最佳的加工路径。系统通过评估每一步操作的结果来调整策略，以减少加工时间和材料浪费。

自适应控制：在加工过程中，强化学习模型能够根据实时反馈调整操作参数，适应复杂的加工条件，如材料硬度变化或工件变形。

优化决策支持：强化学习可以提供基于当前系统状态的最佳决策建议，帮助操作员或自动化系统选择最适合的生产策略。

3. 机器学习算法：机器学习算法用于模式识别、预测分析和分类任务，在数控系统中可以应用于：

特征识别：通过算法识别和分类加工过程中的关键特征，如刀具磨损模式、工件尺寸偏差等，提高加工精度和监控效果。

数据分析和优化：使用监督学习和无监督学习算法对收集的大量数据进行分析，提取有价值的信息，为制造决策提供支持。

故障诊断：应用机器学习模型对异常状态进行分类，快速准确地诊断设备故障原因，提供维修或调整建议。

4. 企业自定义算法

智能数控系统能够根据具体应用场景定制和开发算法。例如，在高精度要求的航空航天部件制造中，可以开发专门的算法来优化极其复杂的加工路径和参数设置。系统通过集成如 PyTorch、Keras 或 TensorFlow 这类开放源代码的机器学习和深度学习库，允许开发者快速实现和测试新的算法，实现快速迭代和优化。通过这样的集成和扩展，智能数控系统不仅能够提升操作效率和产品质量，还能增强其自适应和学习能力，使得生产过程更加智能和自动化。这一过程的核心在于算法的不断进化和优化，使数控系统能够在面对不断变化的生产要求时，持续提供最优解决方案。

最后，在智能数控系统中，数据的收集、处理和应用同样至关重要，因为它直接影响到系统的决策质量和操作效率。智能数控系统依赖于高质量、实时

的数据来进行所有类型的计算和决策。

数据来源包括但不限于：

传感器数据：包括温度、压力、振动、位置和速度等各种物理量。传感器部署在数控机床和加工材料上，实时收集关键操作参数和环境数据。

操作数据：操作员的输入、预设的机床设置和历史操作数据，这些都是优化当前和未来任务的重要信息源。

质量控制数据：通过视觉系统和其他测量工具获得的关于工件质量的数据，如尺寸偏差、表面完整性等。

收集到的原始数据需要经过处理后可用于决策支持和操作优化，数据处理步骤包括：进行数据清洗，去除噪声和修正错误值，确保输入数据的质量和可用性。进行特征提取，从复杂的数据中提取有用的信息，如从振动数据中识别出潜在的刀具磨损模式。实施数据融合，整合来自不同来源和传感器的数据，提供一个全面的视角来分析和理解生产过程。

随后，通过应用统计方法和机器学习算法，对处理后的数据进行深入分析，以构建预测模型或识别模式。包括：使用历史数据来预测未来的趋势，例如预测刀具磨损或工件质量问题；使用历史数据来预测未来的趋势，例如预测刀具磨损或工件质量问题；分析数据来理解生产过程中发生了什么，帮助诊断问题和改进过程；通过数据分析提出具体的操作建议，如调整加工参数来优化生产效率和产品质量；

基于上述数据分析的结果，智能数控系统可以提供数据驱动的决策支持：系统可以自动调整参数或改变操作策略来适应监测到的条件或优化目标；利用实时数据来动态调整生产过程，提高响应速度和灵活性；分析长期数据趋势来优化生产计划和维护策略，提高整体操作效率和设备可靠性；

总而言之，通过在智能数控系统中充分利用计算能力、复杂的算法及有价值的数

2.3 本章小结

本章着重讨论了智能化数控系统智能体模型各个关键方面。首先集中于智能数控系统的概述和平台介绍，接着，介绍了数控系统智能化的必要性和实施方案，分析了数控系统在现代制造业中面临的挑战和对智能化的迫切需求，强调了将智能化技术整合进数控系统的重要性，以提高其自动化水平和效率。随后则是对智能化扩展方案的详细讨论。不仅提出了具体的智能化措施，还探讨了这些措施如何有效地提升数控系统的整体性能和应对复杂工作环境的能力。最后，提出了智能数控系统的抽象模型和体系结构，建立了数控系统智能体模

型，为理解和改进智能化数控系统提供理论基础和实践参考。本章的研究内容支持了国家自然科学基金联合基金项目——“基于统一模型的数控系统复杂曲面处理方法研究”的立项。

第3章 基于智能体的数控系统加工路径优化方法研究

数控系统的加工是一个十分复杂的过程, 计算机辅助制造(CAM)系统生成的加工路径通常是仅位置连续的分段线性路径, 不考虑运动时的情形, 因此导致其加工路径较为粗糙, 存在一些负面特征点及特征边缘。加工路径拐角明显、相邻路径不均匀、点位分布不均匀等情形均会对加工造成负面影响。因此, 为了保证加工效率和加工质量, 研究数控系统加工路径智能优化方法是有必要的。

针对此问题, 本章在 CAM 系统与机床控制器之间建立了数据传输闭环, 将优化过程以 Cyber 应用的方式封装在信息物理系统(CPS)单元中, 从而与机床控制器进行集成, 实现加工路径特征的智能识别与优化。

3.1 加工路径缺陷的特征与原因分析

新一代人工智能技术及信息技术的进步正在推动着数控系统朝着智能化的方向发展。特别是数字孪生、物联网、大数据、边缘计算等技术与数控系统的融合, 使得数控系统的功能更加丰富、数控系统的结构得到了扩展^[99-103]。同时, 技术的进步也催生了工业生产方式的转变, 经济和商业环境的竞争使得更多的车间和工厂采用更加智能的加工生产方式^[104-107]。数控系统作为加工制造业的核心, 其下达命令的精准程度直接影响着加工质量的好坏。因此, 需要对数控系统加工路径智能优化方法进行研究。

当前的自动化制造在工业实践中依赖于计算机数控机床和计算机辅助制造系统(CAM)之间的数据传输, CAM 系统规划了数控系统的加工过程, 从根本上决定了加工的质量与效率^[108]。然而 CAM 系统直接生成的加工程序只关注位置上的连续, 不考虑运动时的情形, 因此导致其加工路径较为粗糙, 存在一些负面特征点及特征边缘。如图 3-1 所示, 加工路径拐角明显、相邻路径不均匀、点位分布不均匀等情形均会对加工造成负面影响。

在以往的工作中, CAM 系统的数据输入仅在程序设计阶段、并且不允许根据加工过程中收集的数据做出工艺决策, CAM 与机床控制器之间的数据传输是单向的, 如图 3-2.a)所示。对于负面特征点的优化通常依赖于 CNC 程序员的参与, 这样的处理方式必须付出大量的人工努力并且受到操作者技术水平、工件形状等客观因素的影响和制约。






图 3-1 CAM 系统原始 NC 程序点位缺陷

Figure 3-1 CAM system original NC program point defects



(a) 传统处理加工处理方式



(b) 添加了优化闭环的加工处理方式

图 3-2 a)传统的加工方式结构 b)添加了优化闭环的加工结构

Figure 3-2 a) The traditional processing method structure b) adds an optimized closed-loop processing structure

因此，需要考虑采用更加高效、智能的方式来提高生产效率、优化生产质量。针对此问题，建立了如图 3-2.b)的新工作方式。在 CAM 系统与机床控制器之间建立了数据传输的闭环，将优化过程以数字孪生应用的方式封装在智能体平台中，从而与机床控制器进行集成，这样的方式有诸多好处：

- 1) 自动优化加工路径以提高工件的加工质量，缩短生产周期。
- 2) 辅助工程师的工艺设计，减轻工艺开发和监控的负担。
- 3) 减少识别工艺过程缺陷的时间。

综上所述，本节从 CAM 系统与机床控制器的集成角度出发，研究基于智能体的数控系统加工路径的智能优化方法。

3.2 加工路径优化的解决方案

虽然数字化技术已经得到了长足的发展，但是在目前的制造模式中设计与制造通常处在不同的阶段，也就是说，工件的设计与实际的加工过程是割裂的，工件的刀路缺陷只有在制造过程中产生了负面结果以后被人为观察到才能对设计过程有所反馈，并且对工件模型的重新设计、调整和改进的工作量不仅繁重而且需要丰富的经验和较高的领域知识水平。

本章提出的新工作流程如图 3-3 所示，以往的数控加工流程在 CAM 系统生成原始加工路径以后就用于数控系统的加工制造，蓝色虚线框内新增的工作流程则是本章主要的工作内容，将 CAM 系统的再设计功能进行了集成，建立了 CAM 系统与 CNC 之间的数据沟通桥梁。




图 3-3 Cyber 应用建立 CAM 与数控加工之间的桥梁

Figure 3-3 Cyber application establishes a bridge between CAM and CNC machining

在目前的数控信息采集技术中，由于各个不同的数控系统厂商使用的都是自己的标准，通信端口与协议之间缺乏兼容性，提高了数据采集的成本，阻碍

了现场设备之间信息的共享。新兴的数字线程技术（如 OPC UA，MTConnect）由于实时性、准确性、标准化等优点已越来越受到青睐。MTConnect 可以通过标准化的方式使数控设备的数据交互保持一致性，OPC UA 采用面向对象的地址空间建立信息模型，支持属性、特征、方法和事件等多种数据类型。OPC UA 可以在服务器运行时通过添加、删除和修改节点来动态调整信息模型，考虑到前期研究开发的中间件及所建立的信息模型与 OPC UA 的契合，以及 OPC UA 在工业现场为用户自定义模型提供的便利性，本章的研究工作采用 OPC UA 方法建立模型。具体的技术方案如图 3-4 所示。




图 3-4 基于 Cyber 智能体的路径优化技术方案

Figure 3-4 Path optimization technology scheme based on Cyber intelligent agent

原始 G-code 文件通过人类输入智能体平台，经过感知处理、评估诊断、优化决策过程后形成优化后的 G-code 文件，并通过 FTP 协议输入 CNC，CNC 进行加工的指令控制，同时通过 OPC UA 以发布/订阅模式将进给轴位置和主轴转速信息实时反馈给智能体平台进行数字孪生的加工模拟。CNC 系统中自定义的动态链接库数据读取函数与 OPC UA 节点数据源绑定，实现运行时数据的采集和传输。在感知处理、评估诊断、优化决策的任一阶段均可以将当前的加工路径信息传递给数字孪生应用进行可视化路径生成和展示，这里使用了进程间通信和事件处理机制，当有新的数据从被监控进程的输出流中读取出来时，会触发一个事件，并调用事件处理函数。在这个案例中，人类在感知处理模块中起到了监督判断的作用，并且运用知识和经验参与了评估诊断模块中评估准则的定义。加工路径的信息模型见下一小节，在感知处理、评估诊断、优化决策模块中的算法处理流程共同建立了路径优化的机理模型，首先在感知处理模块中完成工艺文件解析、路径生成与分解过程，以人类的直观判断决定后续过程的

必要性。其次,在评估诊断模块中,完成聚类分割与特征识别过程,通过定义描述路径起伏特征的数学公式对路径的缺陷特征进行等级划分。最后在优化决策模块中基于特征等级进行自适应的路径优化。

本章使用的机床数字孪生的模型开发过程是使用 AutoCAD(2019)软件根据机床图纸的详细尺寸建立并使用 Unity3D(2021)软件进行模型渲染,在 Unity3D 中对分属于不同进给轴的物体组件进行绑定,并为其添加运动的 C#脚本,同时在 C#脚本中集成了 OPC UA 客户端,以订阅模式读取数控系统加工路径信息,实现加工过程的监控和模拟。为了便于更加详细的观察刀具轨迹,开发了实验研究章节的应用的用户图形界面(GUI),一旦数字孪生模型接收到路径信息,处于开启状态的 GUI 客户端即可同步读取并进行加工路径的展示。

实施这个加工路径优化框架的优势有:

1: 缺陷提前发现: 加工路径的信息经过工艺解析后即可进行路径生成的可视化和基于数字孪生的模拟加工,提前发现路径上的缺陷以便于 CAD/CAM 重新设计或者后续的利用程序优化。

2: 优化过程自动化: 以程序自动化的方式实现 G-code 的修正,无需工艺人员的大量手工劳动。

3: 加工路径的多种视角展示: 点云图像和轨迹图像的可视化使得在生产计划阶段就可以进行加工优化,并可以在模拟加工期间显示主轴转速、进给率等工艺信息,有助于缺陷定位。

3.3 基于智能体的加工路径优化实验与应用

CAM 系统生成的加工路径通常是仅位置连续的分段线性路径。程序段之间不连续,即切向不连续,会导致数控系统频繁降速,影响加工效率。此外,根据 CAM 生成的 G 代码在实际加工时也会出现“槽点”以及有加减速的一些特征边缘,类似“扩散纹”,如果降速不充分,还会造成机床的剧烈振动,影响加工质量。为确保加工的效率与质量,平滑的加工路径是高性能数控系统关键功能之一。在当前数控加工行业中,由于编程直观和 CNC 系统的高效支持,直线与圆弧路径在生产中仍广泛应用作为刀具轨迹。然而,直线路径间的接合不够平滑导致刀具需频繁变速,引发进给率与加速度的剧烈波动,特别是在一些角度较大的转折点,可能需要大幅减速以通过,这不仅影响了工件的表面质量,还减缓了加工速度。因此需要一定的技术手段对 NC 程序加工中生成的负面轨迹特征点进行识别和消除。

特征点识别是经典的模式识别问题,一般可分为两种类型,传统的手工方法和基于深度学习的方法。对于手工制作的方法,通过定制一些规则描述旨在反映点的内在或外在统计属性,从中可以识别特征点。而基于深度学习的方法

原则上需要建立加工路径负面特征点的特征工程,需要人工收集大量的视觉数据集,这项任务十分巨大因此在实际应用中尚未得到普及。

近年来,深度学习在图像处理、语音识别、决策等诸多应用中得到了广泛的关注并表现出卓越的性能,文献^[109]在特征点识别方面也有一些相关的工作。Wu 等人^[110]提出了一种新的卷积运算 PointConv,它可以看作是一个非线性函数,由权重和密度函数组成,并设计了一个基于 PointConv 的深度学习网络用于点云的语义分割。通过将点云划分为等间距的 3D 体素,并通过体素特征编码层构建点的特征表示,Zhou 等人^[111]从 LiDAR 中识别点云的特征。此外,还有一些其他的用于特征检测和识别的深度学习网络,Zhang 等人的 SO-Net^[112],Dai 等人的 ScanNet^[113]。

对于在以上相关研究中完成的工作,总体思路是为特定任务设计一个特殊的深度学习网络,它们主要用于 3D 一般无序点云或体素。关于 CNC 加工刀具轨迹上的特征点识别,研究较少。通过对加工路径的 CL 点进行三角测量,Zhou 等人^[114]根据加工路径的几何特性识别沿进给方向的特征点。Su 等人^[115]定义了一种称为滑动电弧管的刀具,并将加工路径的特征点识别为进给速度限制区间的边界点。Lee 等人^[116]提出了一种两步法,首先用 Zhang 等人^[112]的方法粗略识别特征点,然后根据特征点沿加工路径交叉方向的连续性细化未识别的结果。Deng 等人^[117]所做的工作中,将特征点简单地作为加工路径的硬断点,它既可以是刀具运动变化点,也可以是一些基本几何实体的端点,如长线、圆弧、圆锥和螺旋。文献^[114-116]使用的这些方法,属于传统的手工制作方法,严重依赖于一些手动定义的加工路径参数(例如,曲率阈值和加工路径长度)和使用困难,缺乏通用性。

目前,关于通过深度学习进行加工路径特征点识别的工作研究比较少。最新的一个研究是胡等人^[118]提出了一种新的基于深度学习的方法,可以自动准确地识别加工路径的特征点。首先为每个刀具位置(CL)点定义一组几何描述符,然后将其转换为输入深度学习管道的图像。基于残差学习的卷积神经网络(CNN)称为特征点 CNN (FP-CNN),旨在将转换后的图像作为输入,将识别的结果作为输出。

可见、深度学习算法可以通过对加工数据的特征分析寻找出加工异常的“槽点”,从而定位问题路径所在,对于槽点的抹除,可以采用适合的曲线拟合与平滑操作来实现,深度学习的智能可以通过样本和设定一定的策略来学习,因此可以通过深度学习算法实现对加工路径的最优平滑具有可行性。

针对上述问题,本节以基于智能体的数控系统模型为例,建立加工路径的数字化优化过程,并通过提出的路径分解和优化算法对 NC 程序进行优化。

3.3.1 加工路径优化的实验环境与整体流程

实验的物理环境、数字孪生模型和工作过程如图 3-5 所示，图中的数控系统是由中科数控自主研发的 GJ 430 数控系统，数据处理设备是一台独立主机，搭建有 OPC UA 服务，该主机为上述数控系统智能体提供算法和算力支持，配备了英伟达 3090 显卡。

图 3-5 中工作的基本流程如下：首先，对 CAD/CAM 模型进行后处理，生成 CNC 工艺文件，由数据采集程序进行处理，解析工艺文件，完成加工路径的生成和初步缺陷路径分析，并对路径进行分层分解。其次，深度学习用于识别有缺陷的路径。最后，使用基于强化学习的自适应路径优化算法对路径进行优化，以在客户端生成可视化结果，并在数字孪生模型中模拟加工，从而形成对 CNC 系统的反馈。




图 3-5 实验环境和工作流程

Figure 3-5 Experimental environment and workflow

在加工路径的优化过程中，需要构建信息模型用于通信传输，具体展示在图 3-6 中。图中描述了如何利用 OPC UA 技术构建并传输信息模型，创建了一个加工路径信息的类，并在 OPC UA 的地址空间中以对象节点形式呈现，类中

的数据项则转化为变量节点。在该信息模型中，涵盖路径编号、主轴和进给轴的
细节。进给轴信息细化到加速度和坐标。

DisplayName	BrowseName	NodeId
√ Root	0:Root	i=84
√ Objects	0:Objects	i=85
> Aliases	0:Aliases	i=23470
> Server	0:Server	i=2253
√ GJ430	2:GJ430	ns=2;i=31
> Component	2:Component	ns=2;i=32
> Configuration Attribute	2:Configuration Attribute	ns=2;i=55
√ Process Attribute	2:Process Attribute	ns=2;i=56
√ MachiningPathInformation	2:MachiningPathInformation	ns=2;i=58
√ FeedAxisInformation	2:FeedAxisInformation	ns=2;i=59
> AxisCoordinates	2:AxisCoordinates	ns=2;i=60
√ SpindleInformation	2:SpindleInformation	ns=2;i=64
> Feedrate	2:Feedrate	ns=2;i=65
> Spindle Speed	2:Spindle Speed	ns=2;i=66
> Static Attribute	2:Static Attribute	ns=2;i=57
> Types	0:Types	i=86
> Views	0:Views	i=87

图 3-6 OPC UA 中的加工路径信息模型

Figure 3-6 The machining path information model in OPC UA

3.3.2 加工路径的层级分解方法

在众多数控系统编程语言中，G 代码是最为普遍应用的一种^[119]，主要负责指示机床的具体加工操作。如图 3-7.(a)展示了一个五角星凸台的 CAD 模型，而图 3-7.(b)展现了其中的一部分 G 代码示例。




图 3-7 a)五角星凸台 CAM 模型 b) 由其生成的部分 G 代码示例

Figure 3-7 a) A pentagram boss CAM model and b) A partial G code example generated by it

在该 G 代码的加工过程进行解析时，首先需要进行词法分析，提取出表示加工点在三维空间中的位置信息。接着，通过设定一个随着路径点而动、与 z 轴垂直的检测平面，识别出在轴向上的变化点，从而将复杂的路径划分为多个较为连贯的片段。该路径层次分割算法的详细步骤展示在算法 3.1 中。

Algorithm 3.1

路径分割算法

```

1: Input:
2: all_points: 所有的三维空间坐标点集
3: division_axis: 用于划分平面的坐标轴方向
4: threshold_distance: 点到划分平面的最大容许距离
5: min_points: 单个层级中最少点的数量
6: weight_alpha: 指数加权平均的系数
7: Output:
8: segmented_paths: 分层后的路径段集合
9: procedure
10: 初始化路径段集合 segmented_paths 为空列表
11: 初始化当前路径段 current_path_segment 为空列表
12: 初始化平面位置 plane_pos 为第一个点的 division_axis 轴坐标值
13: 对 all_points 中的每一个点 point 进行迭代:
14:   计算点到平面的距离 distance 为 point[division_axis] - plane_pos
15:   点计数器 points_count 自增
16:   if distance 的绝对值小于 threshold_distance, then:
17:     将 point 加入到 current_path_segment
18:     更新 points_count
19:     计算移动步长 step_length 为 weight_alpha
20:     设置 plane_pos = plane_pos + step_length × distance
21:   else if current_path_segment 的长度达到 min_points, then:
22:     将 current_path_segment 加入到 segmented_paths
23:     重置 current_path_segment 为包含当前点 point 的新列表
24:     重置平面位置 plane_pos 为当前点的 division_axis 轴坐标
25:     重置点计数器 points_count 为 1
26:   endif
27: if current_path_segment 的长度大于等于 min_points, then:
28:   将 current_path_segment 加入到 segmented_paths
29: endif
30: 返回 segmented_paths 作为最终的分层路径集合

```

在本研究的实验阶段，所采用的算法参数被设定为：使用 z 轴（通过设置 $division_axis$ 为 2）作为路径划分的依据，设置点到分割平面的距离阈值 $threshold_distance$ 为 0.01，要求每个分割出的路径段至少包含 10 个点（ $min_points = 10$ ），并且指定指数加权平均的系数 $weight_alpha$ 为 0.1。图 3-8 中展示的是某些路径在 z 轴上的投影视图，通过这种分层划分，我们能够明显观察到某些路径段存在缺陷，特别是在图 3-8 的第四部分(d)中，缺陷位置较为集中。对这一部分的放大观察，如图 3-8 的(e)所示，提供了更清晰的视角来识别和分析路径缺陷。




图 3-8 分解后的路径片段示例

Figure 3-8 Example of decomposed path fragments

在进一步细化缺陷路径分析的过程中，特别对图 3-8 中的(e)部分显示的缺陷路径实施了环状分割策略。这种方法通过以路径起点的一个坐标轴值作为基准线，定义数据点在跨越该基准线两次后形成一个环，以此方式实现对缺陷路径的环形层次划分。




图 3-9 部分聚类结果展示

Figure 3-9 Partial examples of clustering results

为了深入分析缺陷路径的细节特征，并提高处理这些缺陷的适应能力，采用 DBSCAN 算法对形成环状的缺陷路径进行了聚类分割。该算法通过设置特定

的扫描半径为 2.5 以及最少点数为 2，能够有效地揭示并分割星形环状路径的局部结构，如图 3-9 中展示的部分星形环状路径示例。

3.3.3 基于深度学习的加工路径特征分类与识别方法

在分析聚类后的路径点集时，采用了法向量作为关键工具来描绘每个簇中点集的局部形态变化。当某个簇中的路径点较为平坦时，该簇内各点的法向量方向变化通常较小；相对地，如果簇内路径点的起伏较大，则法向量方向的变化也会更加显著。

为了具体衡量这一特征，对每个簇的邻近点间法向量进行了计算，特别是通过计算法向量之间的夹角。进一步地，通过在以 k 为大小的邻域内统计这些夹角的累计平均值，从而量化了在 k 大小的邻域范围内点集整体的起伏变化情况。

假设有一个序列由数据点 $p_1, p_2, \dots, p_k$ (其中 $k > 2$) 组成，与之相对应的法向量分别是 $v_1, v_2, \dots, v_{k-1}$ ，这些向量代表从 p_1 到 p_2 、 p_2 到 p_3 ，一直到 p_{k-1} 到 p_k 的向量。在这种情况下，可以通过计算相邻法向量间的夹角的平均值来评估数据序列在 k 邻域内的整体起伏度，其计算公式如下：

$$Avgdeg = \frac{1}{k} \sum_{i=1}^{k-2} \arccos \left(\frac{v_i v_{i+1}}{|v_i| |v_{i+1}|} \right) \quad (3.1)$$

其中， $Avgdeg$ 的值越高，表明数据点序列的不平整度越显著。在实验观察中发现，当 $k=20$ 时，这一特征的区分能力较为明显。具体的统计数据展示在表 3-1 中，该表列出了 367 个长度为 20 的序列段中的 $Avgdeg$ 值的分布和比例，并据此对数据点序列的起伏程度进行了等级划分，从而对不同等级的凹凸不平情况进行了分类描述。

表 3-1 特征统计分级

Table 3-1 Statistical table of feature classification

$Avgdeg$	数目	占比	特征描述	缺陷等级
$Avgdeg \geq 10.0$	136	37.06%	路径凹凸不平，偏移点多，对加工影响大	III
$Avgdeg \in (3, 10)$	146	39.78%	路径缺陷较严重，部分路径不平坦，对加工有影响	II
$Avgdeg \leq 3$	85	23.16%	路径缺陷较轻，对加工影响小	I

基于上述的特征工程，为了便于操作员对工艺的审查，使用深度学习方法对路径的特征进行识别和分类，所建立的深度学习网络结构如图 3-10 所示，输入数据为上述 376 个长度为 20 的三维数据的前两列，省去第三个维度的原因是

考虑到第三列数据变化较小，对特征的贡献不明显。在数据输入神经网络前将其重塑为 $376 \times 1 \times 20 \times 2$ 的形状，其中 1 是通道数，之后数据会按批次输入卷积神经网络训练，神经网络有两个卷积层，分别使用了 32 和 64 个 2×2 的卷积核，并且都使用了步长为 1 的滑动窗口和 1×1 的填充。图 3-10 中标明了每一层输入和输出的数据尺寸。模型采用了 Adam 优化器，学习率为 0.001，采用了交叉熵损失函数，训练周期数为 1000，批量大小为 10。针对样本数量可能带来的限制，为确保模型的泛化能力，实验中将数据集划分为训练集（70%）、验证集（15%）和测试集（15%），并采用了 5 折交叉验证的方法来训练和验证模型。具体来说，实验中将数据集随机分为 5 个互斥的子集，每个子集轮流作为测试集，其余 4 个子集作为训练集。实验中算法框架均采用 Python 3.9 编程语言，使用了 PyTorch 2.0.0 作为深度学习框架，因其提供了灵活且高效的计算图功能，适合复杂模型的训练。此外，为了处理机器学习中的科学计算，使用了 SciPy 1.7.1 库，它包含了大量优化算法和数学工具函数。在本章的后续强化学习部分，采用了 Gym 0.21.0，这是一个广泛用于开发和比较强化学习算法的工具库。




图 3-10 深度学习算法网络结构与处理流程

Figure 3-10 Network structure and processing flow of deep learning model

为了表明模型的有效性，采用了此分类算法的训练和测试准确率以及 receiver operating characteristic (ROC) 曲线为评价指标。ROC 曲线作为评估分类模型效果的标准工具之一，被用来展示模型在不同决策阈值下的真正例率（TPR）和假正例率（FPR）之间的关系。通过计算曲线下面积（AUC），能够获得一个单一的性能指标来衡量模型在各种阈值设置下的整体表现。此外，ROC 曲线的分析也有助于确认模型是否对某一类别的识别存在偏差，这对于处理不平衡数据集尤为重要。如图 3-11 所示，其中图 3-11.a 为此分类算法的训练和测试准确率图示，图 3-11.b 为此三分类模型的 ROC 曲线，模型在三个类别上的 ROC 曲线的 AUC 值分别为：类别 1 的 0.90，类别 2 的 0.97，以及类别 3 的 0.93，均展现了良好的区分能力。图 3-12 展示了算法分类的结果。




图 3-11 算法的分类准确率和 ROC 曲线

Figure 3-11 Accuracy and ROC curves for the classification algorithm




图 3-12 算法分类结果的点云可视化

Figure 3-12 Visualization of point clouds for algorithmic classification results

而基于手工的分类识别方法结果如图 3-13 所示。




图 3-13 分类结果的点云可视化

Figure 3-13 Visualization of point cloud classification results

3.3.4 基于 DDQN 的加工路径智能优化方法

在分析和统计了特征序列后，明显地，各个 k 邻域内的数据序列展现出了不同的特性，这表明统一的处理策略对于所有的数据序列并不总是有效。因此，根据每种缺陷特性的具体情况，选择了几种不同的滤波平滑技术来进行数据处理，包括高斯滤波器、二阶指数平滑方法和 Savitzky-Golay 滤波。

其中高斯滤波器主要通过将数据点与其周围点的加权平均来实现数据平滑和噪声抑制。该方法的特点是权重随着距离中心点的增加而递减，最中心点的权重最大。此滤波方法特别适用于减少符合正态分布的随机噪声。二阶指数平滑法是对移动平均算法的一种扩展，特别适合于处理展示出短期趋势性的数据。而 Savitzky-Golay 滤波方法通过对一定数量的连续数据点进行多项式最小二乘拟合，以达到平滑和去噪的目的。S-G 滤波的一个重要优点是它能在去除噪声的同时保留数据信号的形态和特征，其平滑效果取决于所选择的窗口宽度，使其能够适应多种不同的应用场景。这些滤波平滑算法的选用依据了对数据序列特征的分析，用于提升处理结果的质量和适应性。




图 3-14 不同特征的滤波优化效果对比

Figure 3-14 Comparison of different filtering effects for three defect levels

表 3-2 实验参数配置

Table 3-2 Parameter configuration in the experiment

优化方法	参数配置
高斯滤波	$wsiz e = 9, \sigma = 5$
二阶指数平滑	$a = 0.3$
S-G 滤波	$sgwsiz e = 7, \beta = 3$

图 3-14 中的各个滤波优化参数配置如表 3-2 所示, 在图 3-14 中, 展现了通过应用不同滤波技术对 k 邻域内特定序列数据进行优化的效果对比。从图中的结果观察到, 对于图 3-14 中的(a)部分, 呈现的数据序列较为不规则且分散, 没有明显的线性趋势或关系, 应用高斯滤波处理显示出了较为优越的性能, 有效平滑了数据并降低了噪声。在图 3-14 的(b)部分, 展示的数据序列显示出一定的线性趋势, 凸凹变化不太明显, 此时二阶指数平滑技术表现出了更佳的处理效果, 使得数据趋势得到了更好的体现。而对于图 3-14 中的(c)部分, 数据序列本身较为平滑, 起伏变化小, 采用 Savitzky-Golay 滤波处理能够更加精确地优化和拟合这类数据, 保留了数据的主要特征同时减少了噪声。

据此, 提出利用强化学习 Double Deep Q-Networks (DDQN)^[120]算法 3.2 来自动选择最佳滤波器的自适应滤波算法。具体来说, 希望保留的发现(以 0.7 的概率), 但同时给予强化学习智能体一些自主决策的权力, 以辅助实现更好的滤波效果。在优化过程中, 通过设置一个 $[0,1)$ 内的随机数 $sample$ 和一个值为 0.7 的 $prop$ 概率常数, 结合 ϵ -贪婪策略来实现强化学习智能体的决策, 具体地, 当 $sampled$ 大于 $prop$, 则按照公式 (3.1) 中的 $Avgdeg$ 划分的缺陷等级进行滤波, 否则, 就基于智能体的学习和 ϵ -贪婪策略来选择使用的滤波方法。基于这个思想, 定义强化学习环境如下:

状态(s): 大小为 $k=20$ 的连续 3D 数据块。

动作(a): 有三个动作 $\{0,1,2\}$, 动作 0 对应高斯滤波, 动作 1 对应指数平滑, 动作 2 对应 S-G 滤波。

奖励(r): 在奖励中考虑两个因素, 一是原始数据与平滑后数据之间的差异, 二是连续平滑块之间的一致性。使用动态时间规整(DTW)^[121]来度量上述差异, 假设 $A = [a_1, a_2, \dots, a_n]$ 和 $B = [b_1, b_2, \dots, b_m]$ 是两个数据序列, 其中 n 和 m 分别是 A 和 B 的长度。DTW 的目标是找到一种路径来最小化两个序列之间的距离度量。这个路径是通过以下动态规划方程(3.2)来找到的:

$$D(i, j) = d(a_i, b_j) + \min\{D(i-1, j), D(i, j-1), D(i-1, j-1)\} \quad (3.2)$$

其中 $d(a_i, b_j)$ 是 a_i 和 b_j 之间的欧几里得距离, $D(i, j)$ 是从 $A[1:i]$ 到 $B[1:j]$ 的最小距离。初始条件为 $D(0, j) = \infty, D(i, 0) = \infty, D(0, 0) = 0$, 最终的 DTW(A, B) 距离的值为 $D(n, m)$ 。

定义奖励函数为：

$$r(s, a) = -(DTW(s, S) + DTW(S_{prev}, S_{first})) \quad (3.3)$$

其中， s 是当前的状态，即当前状态中选定的数据块， S 是应用动作 a 平滑后的当前数据块，其中 S_{prev} 是前一个平滑块的最后一个数据点，而 S_{first} 是当前平滑块的第一个数据点。奖励函数中前者代表了基于原始数据与平滑后数据之间的差异，后者表明了连续平滑块之间的一致性。考虑到奖励函数 (3.3) 中两部分的数据量级的差异，在算法中分别维护了每个部分的最大最小值，并在计算奖励时进行最大最小归一化，即：

$$r(s, a) = -(DTW(s, S)_{norm} + DTW(S_{prev}, S_{first}))_{norm} \quad (3.4)$$

在强化学习中，使用 Q 函数代表在给定的状态 s 下采取某个动作 a 所能获得的预期未来回报，表示为 $Q(s, a)$ 。其递归定义如下：

$$Q(s, a) = r + \gamma \max_{a'} Q(s', a') \quad (3.5)$$

其中， r 是采取动作 a 在状态 s 下获得的即时奖励， γ 是折扣因子，决定了未来回报的重要性， s' 是采取动作 a 后的下一个状态，而 $\max_{a'} Q(s', a')$ 是在状态 s' 下所有可能动作的最大 Q 值。在实际应用中， Q 函数通常通过神经网络来近似。本章使用的 $DDQN$ 算法中使用了两个相同的神经网络，分为策略网络和目标网络，策略网络用于选择动作，而目标网络用于评估这些动作的价值。这种分离有助于减少 Q 值的过度估计。在训练中，首先使用策略网络(其参数为 θ_t)选择一个动作 a' 使得 Q 值最大化，见公式(3.6)：

$$a' = \operatorname{argmax}_a Q(s', a; \theta_t) \quad (3.6)$$

接着，使用目标网络(其参数为 θ^-)评估策略网络选择的动作 a' 的价值：

$$Q_{max} = Q(s', a'; \theta^-) \quad (3.7)$$

其中 Q_{max} 是在状态 s' 下的最大 Q 值。用于评估当前的 ϵ -greedy 贪婪策略。然后结合即时奖励 r 和未来的 Q 值来计算目标 Q 值：

$$Q_{target} = r + \gamma Q_{max} = r + \gamma Q(s', \operatorname{argmax}_a Q(s, a; \theta_t); \theta^-) \quad (3.8)$$

最后，策略网络利用公式(3.9)为给定的状态 s 和动作 a 计算预测的 Q 值：

$$Q_{pred} = Q(s, a; \theta_t) \quad (3.9)$$

这样，就可以使用 Q_{target} 和 Q_{pred} 的差异来更新策略网络的参数，从而逐步逼近真实的 Q 函数。这个过程示意如图 3-15 所示，其中 3-15.(a)展示了 $DDQN$ 学习的大致过程，3-15.(b)详细给出了策略网络的结构，策略网络与目标网络结构上是相同的，图中标名了每一层输入输出的维度尺寸。




图 3-15 DDQN 执行过程(a)和详细的网络结构(b)

Figure 3-15 DDQN execution process (a) and detailed network structure (b)

据此, 提出以下自适应滤波优化算法, 整体的算法流程和超参数设置见算法 3.2, 算法 3.2 中滤波器的参数配置同表 3-2:

Algorithm 3.2

基于 DDQN 的自适应滤波优化算法

1: Input:

2: $Data = \{Data_1, Data_2, \dots, Data_n\}$: 输入的三维原始数据集

3: k : 邻域的大小

4: $lr = 0.001$ 学习率

5: $C = 10000$ 记忆池容量

6: $\gamma = 0.99$ 折扣因子

7: $EPS_START=0.9, EPS_END=0.05, EPS_DECAY=200$ ϵ -贪婪策略的参数

8: $BATCH_SIZE = 128$ 每次优化步骤中使用的经验样本数

9: $TARGET_UPDATE = 10$ 目标网络更新频率

10: $num_episodes = 1000$ 训练总周期数

11: $prop = 0.7$ 基于 Avgdeg 的滤波器使用概率

12: Output:

13: $Data'$: 优化后的数据序列集合

14: Procedure

15: Initialize replay memory M to an empty list with capacity C

16: Compute $avgdeg$ for each k neighborhood according to formula (1), and save in list

$Avgdeg$

17: Initialize environment env , policy network $policy_net$, target network $target_net$

18: $steps_done \leftarrow 0, Data' = []$

19: **for** $episode = 1$ to $num_episodes$ **do**

20: Initialize state $s \leftarrow \{Data_1, Data_2, \dots, Data_k\}$, $done \leftarrow False$, $chunk_idx \leftarrow 0$

21: **while** not $done$ **do**:

22: Get the corresponding $avgdeg$ value from $Avgdeg[chunk_idx]$ for the current chunk

23: Generate a random number $sample$ within $[0, 1)$

24: **if** $sample < prop$ **then**

25: **if** $avgdeg > 10$ **then**

```

26:         action  $a \leftarrow 0$ 
27:         else if  $3 \leq avgdeg \leq 10$  then
28:              $a \leftarrow 1$ 
29:         else  $a \leftarrow 2$ 
30:         end if
31:     else
32:          $\varepsilon = (EPS\_START - EPS\_END) * \exp(-steps\_done / EPS\_DECAY) +$ 
EPS_END
33:         if  $sample > (\varepsilon + prop)$  then
34:              $a \leftarrow$  Action selected based on formula (6)
35:         else
36:              $a \leftarrow$  random selection from  $\{0, 1, 2\}$ 
37:         end if
38:     end if
39:     Execute action in the environment, Calculate the reward  $r$  according to equation (4),
get next_state  $s'$ , done
40:     Get smoothed_data based on current state  $s$  and selected action  $a$ 
41:     Update replay memory with the tuple  $(s, a, r, s')$ 
42:      $s \leftarrow s', steps\_done \leftarrow steps\_done + 1, chunk\_idx \leftarrow chunk\_idx + 1$ 
43: end while
44: Randomly extract experience of size BATCH_SIZE from replay memory  $M$  as  $B$ 
45: for each  $(s, a, r, s')$  in  $B$  do
46:     Use formula (6) with policy_net to compute the action  $a'$  that maximizes the Q
value
47:     Use the target_net to compute the  $Q_{max}$  value for next_state using equation (7)
48:     Set the target Q value  $Q_{target}$  using formula (8)
49:     Compute the predicted Q value of policy_net  $Q_{pred}$  using formula (9)
50:     Compute loss:  $L = \sum (Q_{pred} - Q_{target})^2$ 
51:     Optimize policy_net using RMS_prop optimizer to reduce loss  $L$ 
52:     Update weights of policy_net:  $\theta_t = \theta_t + lr * \nabla L$ 
53: end for
54: Update target_net every TARGET_UPDATE time steps
55: Add smoothed_data to the end of Data'
56: end for
57: return Data'

```

图 3-16 显示了优化步骤的每个 *BATCH_SIZE* 的平均损失和整个 DDQN 训练中每个步骤的总奖励的变化。从图中可以看出，优化步骤的每个 *BATCH_SIZE* 的平均损失随着训练步骤数的增加而逐渐减少。相比之下，每一步的总奖励逐渐增加。这表明该模型正在学习更好地平滑数据，并且所选择的平滑策略变得更加准确。






图 3-16 DDQN 训练中每一步的总奖励变化和每批次的平均损失变化

Figure 3-16 DDQN execution process (a) and detailed network structure (b)

应用算法 3.2 优化前后的模型如图 3-17 所示, 优化前后的局部细节和坐标值如图 3-18 所示。与优化前相比, 优化后的路径的平滑度和相邻路径的一致性显著提高, 图 3-18 中的局部细节更清楚地说明了这一点。



(a) The model before optimization



(b) The model after optimization

图 3-17 优化前后整体模型的可视化比较

Figure 3-17 Visual comparison of the overall model before and after optimization




图 3-18 优化前后加工路径和 G 代码坐标的局部细节比较

Figure 3-18 Comparison of local details of machining paths and G-code coordinates before and after optimization

为了验证所提出的基于 DDQN 的加工路径智能优化方法的有效性, 设计了区别于 DDQN 的自适应路径优化方法进行实验对比, 在该优化方法中, 不适用 DDQN 智能体来进行决策, 而是直接根据公式 (3.1) 中的 Avgdeg 划分的缺陷等级进行滤波。算法过程见算法 3.3, 算法中的参数配置与表 3-2 中的参数配置相同。算法中的辅助函数 calculateNormVectors() 和 sumOfAngles() 分别为计算法向量和计算法向量之间的角度的函数。

Algorithm 3.3

自适应滤波优化算法

1: Input:

2: clusters: 聚类分割后形成的簇集合

```
3: neighborhoodSize: 邻域大小
4: thresholdHigh: 高斯滤波适用的平均角度阈值
5: thresholdLow: SG 滤波适用的平均角度阈值
6: Output:
7: optimizedSequences: 优化后的数据序列集合
8: for each cluster in clusters do
9:   points  $\leftarrow$  cluster
10:  normVectors  $\leftarrow$  calculateNormVectors(points)
11:  for i from 0 to len(normVectors) - 1 step neighborhoodSize do
12:    deg  $\leftarrow$  sumOfAngles(normVectors, i, neighborhoodSize)
13:    averageAngle  $\leftarrow$  deg / neighborhoodSize
14:    if averageAngle  $\geq$  thresholdHigh then
15:      points  $\leftarrow$  applyGaussianFilter(points)
16:    elif averageAngle > thresholdLow then
17:      points  $\leftarrow$  applyExponentialFilter (points)
18:    else points  $\leftarrow$  applySGFilter (points)
19:    endif
20:  endfor
21:  optimizedSequences.append(points)
22: endfor
23: return optimizedSequences
```

应用算法 3.3 优化前后的加工路径如图 3-19 所示。可以看出优化后的加工路径比优化前的加工路径在平滑度和相邻路径一致性方面有所提高。




图 3-19 优化前后加工路径和 G 代码坐标的局部细节比较

Figure 3-19 Comparison of local details of machining paths and G-code coordinates before and after optimization

3.3.5 加工路径优化的多线程处理方法

如图 3-20 所示为路径优化应用的整体结构，应用分为前端 UI 和后端逻辑处理。可视化客户端将路径优化过程划分为路径生成、路径优化以及实时可视化三个线程，可视化客户端为主线程，提供可视化的窗口用于加工路径的生成和渲染，线程一中的路径生成过程包括了工艺文件解析、路径可视化生成和路径分解过程，路径分解后得到若干路径片段，需要优化的路径片段在线程二的路径优化过程中进行聚类分割、路径特征分级与自适应的路径优化。当前期实验中人类的工作完成后，上述过程即可形成固定的流程，以流水线方式运行。




图 3-20 路径优化应用整体结构

Figure 3-20 Multithreaded structure of path optimization application

在路径生成阶段，系统后端首先对 G 代码和辅助代码（包括 M、T 代码）等进行解析，获取插补方法、进给速度、主轴转速等相关信息，并根据相关工艺信息进行路径生成，在此过程中可获取各个路径中的进给轴位置信息，并利用位置信息生成路径与点云图像，并将加工过程分解为一系列加工路径。进给轴位置信息时序相关，在本章开发的应用中以序列数据的方式存储为位置向量信息；路径优化过程通过本章后续提出的路径优化算法对进给轴位置数据进行优化，系统前端通过可视化窗口向用户实时反馈路径生成和优化的相关过程。在加工复杂结构件时，加工工艺文件中会包含大量加工指令，其路径生成和路径优化过程会产生较大的时延，因此串行方式难以实现加工路径的实时可视化。

改进的前端流水线结构通过三个线程依次处理路径段。当优化过程的流水线完成时，路径生成、路径优化和实时可视化过程并行执行，每个路径片段对应的处理周期可以输出路径优化的可视化结果，可以大大提高可视化过程的实时性，方便操作人员实时监控和调试优化过程。图 3.21 显示了一个多线程流水线路径优化过程的示例。




图 3-21 多线程流水线路径优化过程示例

Figure 3-21 Example of a multithreaded pipeline path optimization process

为了评估本节中描述的多线程流水线工作模式的效率，测量了 100 次串行和流水线方式的执行时间，如图 3-22 所示。效率提高是通过取串行模式和流水线模式下的平均执行时间之间的差，然后将该差除以串行模式的平均执行速度来计算的。结果表明，与串行模式相比，流水线模式的执行效率提高了 18.602%。




图 3-22 串行和流水线方法 100 次执行时间的比较

Figure 3-22 Comparison of 100 execution times between serial and pipelined methods

为了测量优化前后加工路径的差异，将公式 (3.10) 中的 $AvgDiff$ 定义为优化前后每类数据之间的平均平滑度差异，分别计算优化前 (BO) 和优化后 (AO) 每类的数据，其中 n 是每类的总数， k 是邻域的大小。 $Avgdeg$ 是由等式 (3.1) 定义的平滑度。

$$AvgDiff = \frac{1}{n} \sum_{i=1}^n \frac{BO[i]_{Avgdeg} - AO[i]_{Avgdeg}}{k} \quad (3.10)$$

统计结果显示, 利用算法 3.2 的 DDQN 路径优化算法后, 类别 I、类别 II 和类别 III 的 *AvgDiff* 分别为 4.006%、13.191% 和 39.490%。这表明三个类的平均平滑度都有不同程度的提高。第一类的改善较小, 第二类的改善中等, 第三类的改善更显著。利用算法 3.3 的自适应路径优化算法后, 类别 I、类别 II 和类别 III 的 *AvgDiff* 分别为 6.547%、11.052% 和 37.126%。对比可知, 算法 3.2 的使用 DDPG 智能体的路径优化算法相对于类别 II 和类别 III 的加工路径优化效果优于不采用 DDPG 智能体的直接优化方法, 说明采用 DDPG 智能体进行自主决策的路径优化算法在路径缺陷较明显时相比于直接优化方法更有优势。

3.4 本章小结

本章主要围绕基于智能体的数控系统加工路径优化方法进行深入研究。首先, 分析了以往 CAM 与 CNC 系统之间数据传输方式的不足, 通过一种新的工作方式建立了 CAM 系统与机床控制器之间数据传输的闭环。接着, 参照第二章中所提出的抽象的智能化数控系统模型建立方法, 提出了加工路径优化的数字化解决方案。然后, 开发了一套流水线路径优化过程, 以提高路径优化的效率和过程分析的实时性能。最后, 通过一个应用实例介绍了工艺解析的原理和所提出的路径层级分解算法、路径特征分类与识别过程和路径优化算法。

第4章 基于强化学习的轨迹压缩方法研究

在数控系统的加工流程中，首先需要在 CAM 系统中根据零件的几何轮廓生成数控加工程序，在复杂曲面模型中目前仍然普遍采用微小直线段逼近原始轮廓形状，由于复杂零件和模型可能需要大量的坐标点来精确描述其形状，导致 G 代码文件将变得非常庞大。因此高效的 G 代码轨迹压缩技术需要实现减小文件大小，同时在保持原始轨迹几何特征的前提下确保最终产品的质量。

本章结合了先进的人工智能技术解决加工轨迹压缩问题，通过将 G01 代码的数据压缩作为序列决策问题，利用先进的深度强化学习方法实现 G 代码轨迹压缩的自动化过程。

4.1 基于强化学习的轨迹压缩问题建模

4.1.1 轨迹压缩问题概述

近年来，在制造业领域中有着先进人工智能技术与先进制造技术结合的趋势，通过新一代人工智能和制造技术的深度融合，研发拥有感知、学习、决策并自主执行的新一代智能数控系统，是数控系统发展的一大趋势。智能数控系统期望通过自主学习生成最佳策略，并执行生成的控制策略，从而提高系统的自动化程度。

然而，在数控系统的加工流程中，首先需要在 CAD / CAM 系统中根据零件的几何轮廓生成 NC 程序，对于复杂曲面模型目前仍然普遍采用微小直线段逼近原始轮廓形状，这种连续的小线段加工代码在 G 代码标准中通常被定义为 G01 代码^[122]。它包含了大量用于指导设备运动的坐标点信息，由于复杂零件和模型可能需要大量的坐标点来精确描述其形状，因此 G 代码文件将变得非常庞大，从而导致存储空间不足、传输速度变慢以及解析和执行 G 代码时性能降低等问题。因此高效的 G 代码数据压缩技术需要实现减小文件大小，加快传输速度，提高设备执行效率，同时在保持原始数据几何特征的前提下确保最终产品的质量。

以往的 G 代码数据压缩通常采用传统数值计算的方式进行，以人为的统计计算和数值优化方法结合为主，不能做到自主的学习与决策。为了响应制造业发展的智能化需求，本章结合了先进的人工智能技术解决数据压缩问题，通过将 G01 代码的数据压缩作为序列决策问题，利用先进的深度强化学习方法 DQN 实现 G 代码数据压缩的自动化过程，该过程中强化学习智能体可以通过自主学习和决策，从而智能数据压缩功能。

通过建立模型来描述和抽象 G 代码数据的压缩过程是非常有必要的，它能够建立对问题的清晰直观的认知，本文的解决方案是将数据压缩过程作为一个

序列决策问题, 该序列决策问题可以建模为一个马尔可夫决策过程(MDP), 随后使用 DQN 方法建立处理过程。

4.1.2 轨迹压缩问题的强化学习模型

一、问题的处理流程

如图 4-1 所示, 首先对图 4-1. a) 中的 CAD/CAM 模型进行后置处理, 对导出的 G 代码进行解析, 如图 4-1. b), 随后提取出 G01 加工的三维坐标序列, 如图 4-1. c), 接着, 将对三维坐标序列的决策问题抽象为建立马尔可夫决策过程, 如图 4-1. d), 进一步的, 将该马尔可夫决策过程与强化学习过程结合, 建立深度学习神经网络进行算法处理, 如图 4-1. e), 并完成三维数据序列的压缩, 以压缩后的坐标序列反馈到原有的 G01 代码进行替换, 如图 4-1. f)。




图 4-1 问题的处理流程

Figure 4-1 Problem Handling Process

二、马尔可夫决策过程

在本章的 G01 代码数据压缩问题中, 将三维坐标的序列决策问题建模为一个马尔可夫决策过程 (MDP), 它是一个四元组 (S, A, P, R), 其中 S 是状态空间, A 是动作空间, P 是状态转移概率, R 是奖励函数, 如图 4-2 所示:




图 4-2 马尔可夫决策过程

Figure 4-2 Markov decision process

- **状态 s :** 由于 G01 坐标序列为三维，因此状态 s 是一个三元组 (x, y, z) ，代表了一个 3 维坐标点。
- **动作 a :** 动作空间大小为 2，即有两个可能的动作，保留当前的数据点（动作 1）和不保留当前的数据点（动作 0）。
- **状态转移概率 (p):** 当选择保留或不保留当前坐标点时，状态将转移到下一个坐标点。在本章中，由于在三维点序列中从当前坐标点转移到下一个坐标点的过程是确定性的，因此相邻点的状态转移概率为 1。
- **奖励函数 r :** 奖励函数用于衡量采取动作的好坏，从而引导动作的决策。由于对三维坐标序列的选择同时要做到尽可能的选择少量的数据点并保持原来的轮廓形状，因此奖励函数定义如下：

$$r(s, a) = -\lambda * d(i, j, k) - (1 - \lambda) * c(a) \quad (4.1)$$

其中， $d(i, j, k)$ 表示从第 i 个数据点到第 j 个数据点的距离与从第 i 个数据点经过第 k 个数据点到第 j 个数据点的距离之差， $c(a)$ 是一个惩罚项，表示选择数据点的代价。 λ 是一个权重参数，用于控制保留几何形状特征与选择较少数据点之间的权衡。具体而言，如果决定保留当前的数据点 ($a=1$)，那么会得到一个负的奖励（惩罚），因为希望尽可能减少保留的数据点。而如果决定不保留当前的数据点 ($a=0$)，那么会得到一个与当前数据点和上一个保留的数据点之间的欧几里得距离成比例的负奖励。这是因为希望尽可能保持原始数据的形状，所以距离越大，形状保持得越差，得到的惩罚应该越大。

三、DQN

将问题建模为一个 MDP 后，可以使用 DQN (Deep Q-Network) 算法来寻找在给定状态下选择动作的最佳策略。DQN 通过训练一个神经网络来近似 Q 值函数，从而在每个状态下确定最佳动作。通过迭代训练过程，最终可以找到能够最小化误差并最大化压缩率的策略。本章所使用 DQN 中 Q 网络和目标网络

的结构如图 4-3 所示:




图 4-3 DQN 网络结构

Figure 4-3 DQN Network Architecture

其中, 输入数据点(状态)是一个大小为 3 的向量, 表示一个三维坐标点, 全连接层(FC1)将输入状态映射到一个具有 64 个神经元的隐藏层, 激活函数是 ReLU。全连接层(FC2)将第一个隐藏层的输出映射到一个具有 32 个神经元的隐藏层, 激活函数是 ReLU。全连接层(FC3)将第二个隐藏层的输出映射到一个具有 2 个神经元的输出层, 表示每个动作的 Q 值。

为了实现对与上述 MDP 的求解, 定义 Q 函数 $Q(s, a)$ 公式如下:

$$Q(s, a) = r(s, a) + \gamma * \sum P(s'|s, a) * \max_{a'} Q(s', a') \quad (4.2)$$

$Q(s, a)$ 用以表示在状态 s 下采取动作 a 后, 获得的期望总回报, 其中 $r(s, a)$ 是奖励函数, γ 是折扣因子, $P(s'|s, a)$ 是状态转移概率, s' 是下一个状态, a' 是在状态 s' 下可能采取的动作。Q 函数的近似计算使用了上述神经网络。同时, 为了稳定训练过程, 本章使用了经验回放和目标网络, 经验回放是在训练过程中, 将每个经历的四元组 (s, a, r, s') 存储在经验池中, 并在每一步, 从经验池中随机抽取一个小批量的四元组, 然后用这些四元组来更新 Q 网络。这样做一方面可以打破数据之间的时间相关性, 另一方面可以多次利用历史数据。目标网络与 Q 网络结构相同, Q 网络用来选择动作, 目标网络用来计算目标 Q 值。Q 网络每一步都更新, 而目标网络每隔一段时间才更新一次, 更新时直接复制 Q 网络的参数。这样做可以防止目标 Q 值随着 Q 网络的更新而快速变化, 从而导致训练不稳定。

4.2 强化学习应用于轨迹压缩的实验验证

4.2.1 零件模型与数据处理

如图 4-4 所示是一个灯盖 CAD/CAM 模型和由该模型导出的部分 G 代码。

通过定义正则匹配，解析其 G01 代码的三维坐标并生成加工路径，如图 4-5 所示。




图 4-4 灯盖模型和部分 G 代码

Figure 4-4 Lamp cover model and its part G-code




图 4-5 G 代码解析后的加工路径

Figure 4-5 Machining path parsed by G01-code

4.2.2 基于 DQN 的轨迹压缩算法流程

算法的主要流程可以概述为：首先，初始化环境、代理和神经网络并对数据点序列进行预处理。其次，为代理设置 ϵ -greedy 策略并训练。最后，用训练好的 Q 网络进行数据压缩，随后进行结果的计算和可视化，如图 4-6 所示。




图 4-6 DQN 数据压缩算法流程图

Figure 4-6 DQN data compression algorithm flowchart

其中，算法的训练过程见算法 4.1：

算法 4.1: DQN 训练流程

- 1: Initialize the replay memory buffer size M to capacity N
- 2: **for** episode = 1: episodes **do**
- 3: Initialization status $s_1 = \{\text{Data}_1\}$
- 4: **for** $t = 1: T$ **do**
- 5: Calculate $Q(s, a)$ using Q network
- 6: according to ϵ - Greedy policy selection action a
- 7: Execute action a to receive a reward r and a new state s'
- 8: Store (s, a, r, s') in the replay memory buffer

```
9:   Extract a batch of data from the replay memory buffer and train the Q
network|
10:   Update status s=s'
11:   Every C steps update the parameters of the target network
12: end for
13: end for
```

4.2.3 实验结果与分析

本章中所采用的算法参数配置如表 4-1 所示：

表 4-1 DQN 算法参数配置

Table 4-1 DQN algorithm parameter configuration

参数	意义	值
Total training rounds(episodes)	总训练轮次	1000
Batch size(batch_size)	批量大小	64
Discount factor(γ)	折扣因子	0.99
ϵ - Greedy value (ϵ)	ϵ -贪婪参数	0.95
replay memory buffer size	记忆重放缓冲区大小	10000
Target network update interval(C)	目标网络更新间隔	5

训练过程中的奖励收敛图如图 4-7 所示：




图 4-7 训练过程中的奖励收敛图

Figure 4-7 Reward convergence graph during training process

执行算法后, 压缩前后的局部数据对比如图 4-8 所示, 整体上某层的压缩对比如图 4-9 所示。




图 4-8 局部数据压缩结果

Figure 4-8 Local data compression results




图 4-9 整体数据压缩结果

Figure 4-9 Overall data compression results

图 4-8 展示了局部数据序列的压缩前后对比, 图 4-8 中其中上边的图例是压缩前后数据点的对比, 可以看出利用 DQN 算法对数据点序列进行了有效的选择, 压缩后的数据量明显减少, 下边的图例是分别对压缩前后的数据点序列进行了 3 阶 B 样条的拟合曲线, 拟合前后的曲线轮廓并无差异, 说明采用 DQN 算法对数据点序列的压缩没有形成可见的轮廓误差。图 4-9 的灯盖模型内部轮廓整体

压缩对比图证实了这一点。最后统计压缩前后数据量结果表明，数据压缩率为 49.7%。

为了更好的说明所提出算法的有效性，本节使用经典的数据压缩算法 Visvalingam-Whyatt (VW) 算法进行实验对比，VW 算法是一种简化线条的有效技术，适用于减少序列数据中的数据点数量或图形渲染中的折线点数。这个算法的核心思想是在尽量保持线条整体外形的前提下，移除那些对总体轮廓贡献最小的点。具体的说，通过计算每个点与其相邻点构成的三角形的面积来判定该点的重要性。面积越小，表明该点对线条的总体形状贡献越小，因此可以被移除。其核心理论如下：

设有三个连续的点 A,B,C, $\overrightarrow{AB}=B-A$ 和 $\overrightarrow{AC}=C-A$ 分别为点 A 到 B 方向的向量和点 A 到 C 方向的向量。要计算中间点 B 的重要性。可以通过计算两个向量的叉积的长度的一半来得到，具体公式见公式 4.3：

$$S_{\Delta ABC} = \frac{1}{2} \overrightarrow{AB} \times \overrightarrow{AC} = \frac{1}{2} \begin{bmatrix} i & j & k \\ AB_x & AB_y & AB_z \\ AC_x & AC_y & AC_z \end{bmatrix} \quad (4.3)$$

其中 i, j, k 是单位向量，而 AB_x, AB_y, AB_z 和 AC_x, AC_y, AC_z 是向量 $\overrightarrow{AB}$ 和 $\overrightarrow{AC}$ 的坐标分量。

VM 算法的流程为：首先遍历折线中的每个点（除了首尾点），计算每个点与其前后相邻点形成的三角形的面积。将计算得到的面积放入最小堆（或优先队列）中进行排序，然后依次从堆中取出面积最小的点并移除之，同时更新相关点构成的三角形的面积，直到达到预设的点数或压缩比率。

实验对比结果如图 4-10 所示，其中 4-10.(a)为本节所提出的基于 DQN 的轨迹压缩结果，4-10.(b)为对应的压缩后的轮廓误差。此时，对于该段轨迹，数据压缩率为 48.84%，同样使用 VM 算法将数据压缩率设置为 48.84%时的结果如图 4-10.(c)，压缩后的轮廓误差结果见图 4-10.(d)，可以看出同样的数据压缩率的情况下，基于 DQN 的轨迹压缩效果略优于 VM 算法的轨迹压缩效果。




图 4-10 压缩结果对比

Figure 4-10 Comparison of compression results

对于整体的轮廓, 同样设置数据压缩率为 49.7%, 采用 VM 算法的整体压缩效果如图 4-11 所示。压缩后的轮廓误差对比如图 4-12 所示, 其中 4-12.(a)为基于 DQN 的轨迹压缩算法轮廓误差, 4-12.(b)为 VM 算法的轨迹压缩后的整体轮廓误差。可以看出基于 DQN 的轨迹压缩效果在整体压缩效果上优于 VM 算法的轨迹压缩效果。




图 4-11 VM 算法的整体数据压缩结果

Figure 4-11 Overall data compression results of VM algorithm




图 4-12 整体压缩结果的轮廓误差对比

Figure 4-12 Comparison of contour errors in overall compression results

4.3 本章小结

本章从问题的提出开始，通过深入的实验研究，对轨迹压缩方法进行了全面的探索和分析。从数控系统的加工 G 代码的数据压缩问题与先进人工智能方法结合的角度入手，分析了数控系统智能化，加工过程数字化的趋势和 G01 代码的数据压缩方法的研究现状与不足，通过将 G 代码加工程序进行文件解析后生成的三维坐标的关键点选择作为一个序列决策问题，建立马尔可夫决策过程模型，并结合深度 Q 网络的迭代学习理念实现了自动化的学习和决策过程，章节末的实验案例表明，提出的基于 DQN 的 G01 数据序列压缩方法能够有效的进行数据压缩和轮廓的保持，展现了 DQN 算法在轨迹压缩方面的良好潜力，这一方法是创新性的，能够为类似数据处理问题提供新的解决方案和思路。同时，

进行了与传统方法的实验对比，结果表明，本章所提方法具有一定的优越性。

第5章 基于层次化强化学习的轨迹优化方法研究

在目前的数控加工中,遵循 G01 代码的线性加工路径在路径转角处不连续、无法有效适应复杂的几何形状,使用参数曲线进行 G01 直线段的轨迹优化通常会引入大量的计算。针对这些问题,本章提出了一种结合参数曲线拟合的二阶段的层次化深度强化学习方法,第一阶段在 G01 直线段的三维轨迹点曲线拟合中进行轨迹点压缩和初步的误差控制,第二阶段校验拟合误差并进行精细化的优化,之后,设计了速度控制算法进行插补验证。最后的实验案例表明,提出的方法能够有效的进行轨迹压缩与误差控制,改善 B 样条拟合的质量,从而在数控加工轨迹优化任务中具有重要的应用价值。

5.1 轨迹优化问题概述

随着先进信息技术与先进制造技术的深度融合,网络制造正逐渐成为制造业的新兴模式,为传统制造业注入了新的活力^[123-127]。这种模式凭借其在实现制造资源的数字化、网络化和智能化方面的独特优势,为传统的制造业带来了革命性的变化,促使更多的车间和工厂转向智能化的加工生产方式,作为加工制造业的基础装备,数控系统加工轨迹的优化是实现高效率、高质量生产的关键环节。在这样的背景下,研究网络制造环境中数控加工轨迹优化的方式和方法具有显而易见的理论意义和实践价值。

数控系统的加工是一个复杂的过程,通常的处理流程是首先通过 CAD 建模工具对工件的几何形状进行建模,之后使用 CAM 系统规划加工路径,再输入到数控系统中经过一系列计算实现加工。在此过程中,G01 直线段因其简单、通用的特点而被广泛采用,这种非光滑加工路径在直线段交点处虽然满足位置连续性,却因切向突变而导致过转角时的大幅减速,从而影响轨迹的连续性。这种不连续性可能会导致轨迹速度降低、加工精度受损或表面质量不佳。随着先进数控加工技术的不断发展和应用,要求的工件精度与表面质量也越来越高,对于 G01 直线段的轨迹优化问题越来越受到学术界和工业界的关注。

在传统的 G01 直线段轨迹优化中,参数化曲线的使用已成为主流方法^[128-130]。多项式、B 样条、A 样条和 C 样条等技术,都被广泛应用于曲线拟合,以实现更平滑、连续的加工路径。这些技术能够有效地改善加工轨迹,提高加工效率和产品质量。然而,在处理复杂的加工零件模型时,由于 G01 直线段的数据点通常分布非常密集,直接对所有数据点进行参数曲线拟合可能会导致不必要的计算复杂度和资源消耗。在不牺牲精度的前提下进行特征点的选择,也就是实施轨迹压缩,是一种有效的解决方案,然而,提取哪些点,提取多少点,往往依赖于经验判断或静态的规则,缺乏对实时数据的支持,也不具备智能化

的决策机制，并且由于数控系统的结构相对封闭，智能化能力不足，在满足现代制造业对生产效率和产品质量的严格要求方面面临挑战。

在此背景下，借助网络制造与第二章提出的数控系统智能体结构解决传统的数控加工轨迹优化问题成为了一种新的途径。网络制造环境中的实时数据收集和分析能力，为数控加工轨迹的优化提供了动态性和灵活性。通过在智能体中整合先进的人工智能与数据分析技术，可以实现对数控加工轨迹的实时优化和智能化的决策支持。这种方法不仅能够提高加工效率、确保产品质量，还在降低生产成本方面展现了巨大潜力。

5.2 基于智能体的数控加工轨迹优化框架

5.2.1 网络制造赋予数控系统的新特性

随着工业 4.0 的发展和数字化制造的日益广泛应用，数控系统智能化和其在网络制造(Cyber Manufacturing)中的整合与应用已成为研究和产业界的热点话题。本章将介绍一个基于网络制造的数控加工轨迹智能化优化框架，探讨数控系统在网络制造背景下的新特性、融合网络制造的抽象模型及数控加工轨迹优化的详细方案。




图 5-1 网络制造赋予数控系统的新特性与新功能

Figure 5-1 Cyber Manufacturing endows CNC systems with new features and functions

随着制造业的数字化转型，数控系统伴随着先进信息技术与制造技术的发展而不断演化。网络制造工业 4.0 的变革性技术之一，将互连系统中的数据转

化为预测性和规范性操作^[131]，结合传感器、物联网、大数据、人工智能以及边缘计算等信息技术的巨大进步，为数控加工提供更加高效、灵活和智能的解决方案。

如图 5-1 所示，传统的数控系统由 CNC 控制器、执行器和机床组成，主要的功能是通过执行插补和伺服控制进行工件的加工。而在网络制造的背景下，数控系统扩展了其结构边界，增加了新的功能和特性，可以通过数字化技术、网络技术和人工智能技术实现工序链的一体化集成、高实时性的数据传输和处理、智能决策支持和加工过程的仿真与优化等功能。

在现代工业自动化中，数控系统体现了计算能力、通信技术与物理加工过程的紧密融合。数控系统在执行精确的加工任务时，依赖于实时的数据反馈和动态的控制逻辑。在这一过程中，传感器收集的物理世界数据被转换成数字信号，经由计算模块处理后，又通过执行机构影响物理过程，形成一个闭环控制系统。而网络制造通过计算、网络和物理资源的利用，赋予了数控系统模块化的特性，以适应快速变化的生产需求和复杂的生产环境。因此，可以构建一个抽象模型来体现这一工作过程，如图 5-2 所示。




图 5-2 数控系统模块化的抽象模型

Figure 5-2 An Abstract Model of Modular CNC System

图 5-2 中展示了数控系统模块化的抽象模型，将数控系统划分为人-信息-物理区域，在数控系统的执行过程中，工程师和操作人员利用 CAM 系统生成 G 代码，作为加工过程的初始输入。感知处理模块对输入的 G 代码数据进行解析和处理，提取出 G 代码中的进给轴坐标、转动轴姿态、进给速度等加工信息。奖惩评估模块评估加工过程中的每个动作，根据预定的质量标准和效率指标进行奖惩判定。通过奖惩机制不断调整系统参数，以驱动系统性能向最优方向发展。决策优化模块基于感知数据和奖惩评估结果，运用优化算法和人工智能技术进行决策制定，并将优化后的决策转化为机床的实际动作指令，在此过程中，仿

真器模块通过数字孪生仿真预测可能的问题，避免实际加工中的错误。

由于数控系统的结构通常是相对封闭且自足的，并且算力有限，因此，Cyber 系统可以被进一步抽象化为一个智能体，它独立于数控系统之外，具有相对强大计算能力，不仅能够为数控系统提供必要的额外算力，还能通过集成先进的人工智能算法，赋予数控系统智能化功能。接下来将介绍该实现该智能体的详细技术细节。

5.2.2 数控加工轨迹的智能优化技术方案

智能体在数控系统中引入了自主性和智能化的决策能力。在本章的轨迹优化过程中，集成了双重深度 Q 网络（DDQN）和深度确定性策略梯度（DDPG）深度强化学习算法，从而赋予数控系统自主学习的能力。通过使用网络通信技术，进程间通信(IPC)和 OPC UA 通信技术进行数据传输，以实现智能体中的功能模块化。




图 5-3 利用智能体进行数控加工轨迹优化的整体技术方案

Figure 5-3 The overall technical solution for optimizing CNC machining trajectory using intelligent agents

如图 5-3 所示，首先，由操作员将设计的工件模型导出为 G-code 加工代码，输入到智能体中，智能体中的感知处理模块对 G-code 文件进行解析，提取出加工的进给轴坐标等信息，继而对加工的坐标数据进行自适应的分段处理。其次，在奖惩评估模块中，依序对分段后的坐标序列进行三阶空间 B 样条的拟合，并定义和计算当前拟合后曲线的精度、速度和强化学习算法的奖励函数等指标，对拟合过程进行评估。接着，在决策优化模块中，使用层次化强化学习方法对拟合后的数据点序列进行优化，优化过程分两个阶段进行，DDQN 智能体对原始轨迹数据进行压缩，保留那些重要的特征点并得到压缩后的特征点和拟合的

B 样条曲线的控制点，DDPG 智能体则对控制点进行迭代优化，直到达到满意的精度。在以上过程中，任何一个阶段的输出都可以使用进程间通信机制进行数据传输，从而在仿真器中模拟验证，在仿真器模块中使用 Unity3d(2019)软件开发了物理机床对应的数字孪生模型，可以按照轨迹的坐标数据进行模拟加工，从而预演加工结果。数控系统中搭建了 OPC UA 服务器，可以通过 OPC UA 的发布/订阅模式实时的将加工的轨迹数据传输到仿真器模块中进行同步模拟。

5.3 B 样条理论在轨迹优化中的应用基础

B 样条是一种数学工具，常用于计算机图形学和数值分析中。其主要优点是可提供平滑、连续的曲线。B 样条曲线的形状主要由控制点决定，其控制点对曲线具有局部控制的特性。

B 样条曲线的数学表示为：

$$C(u) = \sum_{i=0}^n N_{i,k}(u)P_i \quad (5.1)$$

其中 $C(u)$ 是 B 样条曲线上的点， $N_{i,k}(u)$ 是基函数， P_i 是控制点， n 为控制点的数量减一， k 是 B 样条的阶数。

B 样条的基函数表示为：

$$N_{i,0}(u) = \begin{cases} 1 & \text{if } u_i \leq u < u_{i+1} \\ 0 & \text{otherwise} \end{cases} \quad (5.2)$$

$$N_{i,k}(u) = \frac{u - u_i}{u_{i+k} - u_i} N_{i,k-1}(u) + \frac{u_{i+k+1} - u}{u_{i+k+1} - u_{i+1}} N_{i+1,k-1}(u)$$

其中 u 是参数值， u_i 是节点向量中的值， k 是 B 样条的阶数。

累计弦长参数化：在这种参数化方法中，每个数据点的参数值是基于从第一个点到当前点的所有线段长度的累积。给定一系列数据点 $P_0, P_1, \dots, P_n$ ，每个点的参数值 t_i 由以下方式计算：

$$t_0 = 0$$

$$t_i = t_{i-1} + \|P_i - P_{i-1}\| \quad (5.3)$$

其中 $\|\cdot\|$ 表示表示向量的欧几里得范数，即两点之间的距离。在累计弦长参数化的过程中，首先计算每个数据点的参数值，使其基于从第一个点到当前点的所有线段长度的累积。但这样计算出来的最后一个参数值 t_n 通常大于 1，因为它是所有线段长度的总和。

为了将所有的参数值归一化到 $[0, 1]$ 的范围内，需要将每个参数值除以 t_n ，即

$$t_i = \frac{t_i \sum_{j=1}^i \|P_j - P_{j-1}\|}{t_n \sum_{j=1}^n \|P_j - P_{j-1}\|} \quad (5.4)$$

这种参数化方法通常在 B 样条曲线拟合中使用，因为它为数据点之间的真实距离提供了考虑，从而在曲线拟合中更多被采用。

结点向量：节点向量是 B 样条定义中的一系列递增的数值。对于非均匀 B 样条，结点向量是基于参数值生成的：

$$t'_{i+k} = \frac{1}{k} \sum_{j=i}^{i+k-1} t_j \quad (5.5)$$

其中 t' 是结点向量中的值， k 是 B 样条的阶数。

求解控制点：为了从给定的 G01 代码数据点求解出控制点，需要设置一个线性系统。假设有 m 个型值点和 n 个控制点，可以通过求解以下线性系统得到控制点：

$$\begin{bmatrix} N_{0,3}(t_0) & N_{1,3}(t_0) & \cdots & N_{n,3}(t_0) \\ N_{0,3}(t_1) & N_{1,3}(t_1) & \cdots & N_{n,3}(t_1) \\ \vdots & \vdots & \ddots & \vdots \\ N_{0,3}(t_m) & N_{1,3}(t_m) & \cdots & N_{n,3}(t_m) \end{bmatrix} \begin{bmatrix} P_0 \\ P_1 \\ \vdots \\ P_n \end{bmatrix} = \begin{bmatrix} F(t_0) \\ F(t_1) \\ \vdots \\ F(t_m) \end{bmatrix} \quad (5.5)$$

其中： $F(t)$ 是给定的型值点， $N_{i,j}$ 是第 j 个基函数在第 i 个数据点的参数值上的值。使用最小二乘法求解这个系统可以得到 B 样条的控制点。

5.4 轨迹优化实验与应用

5.4.1 实验环境与主要实验流程

本章的实验环境与主要的工作过程见图 5-4，其中数控系统控制器采用 Golding GJ430 数控系统，并在该数控系统中搭建了 OPC UA 服务器，网络系统的硬件实体采用一台 windows 服务器，搭载 Intel i9 11900K CPU，NVIDIA GeForce RTX 3090 GPU，同时在该服务器中建立了 OPC UA 客户端，用于和机床控制器的实时交互通信。




图 5-4 实验环境与工作流程

Figure 5-4 Experimental environment and workflow

工作的基本流程如下：

首先，人类工程师使用计算机辅助设计和制造（CAD/CAM）软件进行零件设计，并生成相应的 G-code 文件，通过程序解析得到代加工的 G01 坐标序列，输入到网络系统中。

由于加工程序通常具有庞大的数据量，数控系统无法一次性处理，因此，需要对坐标序列进行按序分割，在这个步骤中，零件的坐标序列被分割成多个片段。

为了减少制造路径的复杂性，同时保持生产质量，引入了双深度 Q 网络（DDQN）对每个片段进行轨迹压缩。在这个步骤中进行了原始轨迹点的压缩，同时进行三阶 B 样条拟合时的轮廓误差控制。接着，使用了深度确定性策略梯度（DDPG）进行每个片段拟合曲线的微调，这个步骤是对原始 B 样条曲线的精细化改进，使得曲线更平滑以适应特定的制造需求。

在所有优化步骤后，进行动力学运动规划，确保不违反机床的动力学约束。规划完毕的数据随后输入机床控制器进行插补和加工。此外，开启的 OPC UA 服务将插补位置信息映射到数字孪生机床模型，允许在真实加工前对优化路径

进行可视化验证，确保预期效果。

以下小节将详细介绍每个步骤的理论及算法实现。

5.4.2 基于速度敏感点的轨迹分段方法

如图 5-5 所示，是由 Unigraphics NX 12.0 软件生成的 CAM 模型，其中 5-5.(a)是蝴蝶轮廓模型，对其上表面的轮廓进行点集处理后得到 500 个三维数据点表示的几何轮廓，这些连续的点组成了加工时刀具的运动轨迹。5-5.(b)是梅赛德斯奔驰零件的轮廓模型，由该零件模型生成的 G 代码加工文件则有数十万行，通过定义正则匹配提取其 G01 代码的三维坐标序列 32 万组。




图 5-5 蝴蝶 CAM 模型(a)和奔驰零件 CAM 模型(b)

Figure 5-5 Butterfly CAM model (a) and Mercedes Benz parts CAM model (b)

通常，在面对复杂的数控加工任务时，轨迹点的数据量庞大，超出了数控系统一次性处理的能力，因此，需要对数据序列进行合理的分段，确保数控系统能按照特定的顺序逐段处理，从而避免因数据过载造成的处理延迟或系统故障。由于数控加工时对速度的变化敏感，轨迹点之间的速度和加速度变化可能会导致机器产生冲击或振动，从而直接影响到加工效果，因此，本章采用速度敏感点进行数据分段，这样做的好处是可以确保每个分段内的轨迹点具有相对相似的速度特性。

对于三维离散数据序列 $p(x_i, y_i, z_i)$ ，其中 $i \in [1, n]$ ，则对于相邻的点 $p_i(x_i, y_i, z_i)$ 与 $p_{i+1}(x_{i+1}, y_{i+1}, z_{i+1})$ 速度向量 v_i 的定义由公式(5.6)给出：

$$v_i = \sqrt{(x_{i+1} - x_i)^2 + (y_{i+1} - y_i)^2 + (z_{i+1} - z_i)^2} \quad (5.6)$$

这里的 v_i 描述了单位时间内相邻点的位移量，从而提供了速度的量化度量。而加速度常被定义为速度的变化率。对于连续的速度值 v_i 与 v_{i+1} ，加速度 a_i 由公式(5.7)表示：

$$a_i = v_{i+1} - v_i \quad (5.7)$$

速度敏感点的鉴定是基于连续加速度值的分析。特别地，当连续两个加速

度值出现符号变化时，可以推断出速度经历了极值。即，如果 $a_i \times a_{i+1} < 0$ ，则 p_{i+1} 被认定为速度敏感点。基于速度敏感点分段的具体算法流程见算法 5.1:

算法 5.1. 基于速度敏感点的轨迹分段算法

Input:

Points[1..*n*]: 三维点序列

min_segment_length: 最小分段长度

Output:

segments: 分段数据的数组

Procedure:

```

1: Extract x, y, and z coordinates from Points.
2: Initialize an velocity array v[1..n - 1]
3: for i ← 1 to n - 1 do:
4:   Calculate  $v_i$  based on velocity Points according to formula (5.6)
5: end for
6: Initialize an acceleration array a[1..n - 2]
7: for i ← 1 to n - 2 do:
8:   Calculate  $a_i$  based on v according to formula (5.7)
9: end for
10: Initialize an speed sensitive points array sensitive_points[]
11: for i ← 1 to n - 2 do:
12:   if  $a_i \times a_{i+1} < 0$  then
13:     Add i + 2 to sensitive_points
14:   endif
15: end for
16: Initialize an index array index[] with the first element of sensitive_points
17: for i ← 1 to length(sensitive_points) - 1 do:
18:   if sensitive_points[i] - last(index) ≥ min_segment_length then
19:     Add sensitive_points[i] to index
20:   endif
21: end for
22: Initialize segmented array segments[]
23: for i ← 0 to length(index) - 2 do:
24:   Add Points[index[i]:index[i + 1]] to segments
25: end for
26: Add Points[last(index):n] to segments
27: return segments

```

在算法 5.1 中，当确定了速度敏感点后，为确保每个分段都有足够的数据点，设定了最小的分段长度 *min_segment_length*，本章中对于蝴蝶模型该值设置为 100，而对于奔驰零件模型该值设置为 200，算法 5.1 中的 *length*(*array*) 操作是用于返回数组的长度的函数，*last*(*array*) 则用于获取数组的最后一个元素。

应用算法 5.1 处理后，确定的分段情况如图 5-6 所示。




图 5-6 分段结果：蝴蝶模型(a)和奔驰零件模型(b)

Figure 5-6 Segmentation results: Butterfly model (a) and Mercedes Benz part model (b)

5.4.3 基于层次化强化学习的轨迹优化方法

随着数控加工技术的不断发展，工件的几何形状和结构日益复杂，生成的轨迹数据量也日益增多。这些遵循 G01 直线段加工规则的数据序列不仅增加了数据存储和传输的成本，同时也会导致机床频繁的加减速，影响数控机床的实时性能。因此，需要有效地压缩轨迹数据，同时保持加工精度。

传统上对于离散数据点的曲线拟合，是通过定义一些可以描述原始曲线轨迹基本形状的特征点，如反曲点、曲率极值点和弓高特征点，通过提取出的主要特征点进行曲线拟合可以降低计算次数，提高拟合效率^[132-134]。近年来，深度学习和强化学习技术在众多领域的进展为轨迹数据的压缩提供了新的思路，本节提出一种创新的方法，结合深度强化学习和 B 样条曲线拟合技术，对数控加工过程中的 G 代码轨迹进行压缩，同时确保轮廓精度。该方法使用双重深度 Q 网络 (DDQN) 在 B 样条拟合曲线中选择性保留数据点，将特征点提取过程作为一个序列决策问题从而实现轨迹压缩过程的自主学习与决策。

在强化学习中主要关注的是智能体 (Agent) 在环境 (Environment) 中学习针对特定的状态如何采取动作以最大化其累积奖励。这个过程可以建模为一个马尔可夫决策过程 (MDP)，由状态，动作，状态转移概率和奖励函数组成，对于本小节的特征点提取问题，将每一个坐标点的取舍作为一个动作决策的学习过程，因此，定义 DDQN 的环境如下：

状态 s ：状态是当前的数据点，用其三维坐标表示， $s_t = (x_t, y_t, z_t)$ 。

动作 a ：动作空间是离散的，包含两个可能的动作，保留当前点 $a_t = 1$ 或跳过当前点 $a_t = 0$ 。

状态转移概率 $P(s_{t+1}|s_t, a_t)$ ：由于在三维点序列中从当前坐标点转移到下

一个坐标点的过程是确定性的，因此相邻点的状态转移概率为 1。即当选择动作 a_t 时，环境将从状态 s_t 转移到状态 s_{t+1} 。

奖励函数 $R(s_t, a_t, s_{t+1})$: 在状态 s_t 执行动作 a_t 并转移到状态 s_{t+1} 时获得的奖励，奖励函数用于衡量采取动作的好坏，从而引导动作的决策。由于对三维坐标序列的选择同时要做到尽可能的选择少量的数据点并保持适当的轮廓精度，因此在奖励函数中考虑了选择特征点时的准则，奖励函数定义见公式(5.8):

$$R(s, a) = -d(p_{i-1}, p_i, p_{i+1})I_{\{d>0.0005\}} - cost_{int}I_{\{interval>10\}} - cost_{err}I_{\{error>0.05\}} \quad (5.8)$$

其中， $d(p_{i-1}, p_i, p_{i+1})$ 表示当前点到由前一个点和后一个点形成的直线的距离，用于衡量当前点相对于前后点形成直线段的偏离程度。 I 是指示函数，如果 $\{ \}$ 内相应的条件成立，则指示函数值为 1，否则为 0。 $cost_{int}$ 是当两个相继选择的数据点之间的索引间隔超过最大允许间隔时施加的惩罚权重，用以确保所选择的点不会相隔太远。 $cost_{err}$ 是当计算得到的轮廓误差超过轮廓误差阈值时施加的惩罚权重，用于确保压缩后的数据点能够保留原始轮廓的形状。本章中最大允许的偏离程度值设置为 0.0005mm、最大的点索引间隔值为 10、轮廓误差的阈值为 0.05mm、 $cost_{int}$ 值为 10、 $cost_{err}$ 值为 100。

在传统 Q-Learning 中，使用动作价值函数 $Q(s, a)$ 代表在给定的状态 s 下采取某个动作 a 所能获得的预期未来回报，更新公式见公式(5.9):

$$Q(s_t, a_t) = Q(s_t, a_t) + \alpha(R(s_t, a_t, s_{t+1}) + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t)) \quad (5.9)$$

其中 α 是学习率，决定了新信息覆盖过去信息的程度， γ 是折扣因子，衡量未来奖励的当前价值， $\max_{a'} Q(s_{t+1}, a')$ 是下一个状态 s_{t+1} 下所有可能动作的最大 Q 值。

DDQN 通过深度神经网络来近似 Q 函数，从而在每个状态下确定最佳动作。本章中的 DDQN 智能体使用了两个相同结构但参数不同的神经网络：行为网络 $Q(s, a; \theta)$ 用于选择动作，目标网络 $Q(s, a; \theta^-)$ 用于评估该动作的价值。

在每个时间步 t ，智能体根据行为网络的输出采取动作 a_t ，并观察得到的奖励 $R(s_t, a_t, s_{t+1})$ 和下一个状态 s_{t+1} ，将观察结果存储在经验回放缓冲区中。在学习过程中，智能体会从缓冲区中随机抽取一批经验进行学习，使用行为网络估计在状态 s_{t+1} 下的最佳动作 a_{t+1} ，并用目标网络评估这个动作的价值。行为网络的权重 θ 的更新公式见公式(5.10):

$$\begin{aligned}
Q(s_t, a_t; \theta) &= Q(s_t, a_t; \theta) \\
&+ \alpha \left(R(s_t, a_t, s_{t+1}) \right. \\
&+ \gamma Q(s_{t+1}, \operatorname{argmax}_{a'} Q(s_{t+1}, a'; \theta); \theta^-) \\
&\left. - Q(s_t, a_t; \theta) \right)
\end{aligned} \quad (5.10)$$

其中, $\operatorname{argmax}_{a'} Q(s_{t+1}, a'; \theta)$ 是由行为网络选择的下一个状态 s_{t+1} 下的最佳动作, 而 $Q(s_{t+1}, \operatorname{argmax}_{a'} Q(s_{t+1}, a'; \theta); \theta^-)$ 是目标网络对于此动作的价值估计, 这种分离的更新机制有助于减轻价值函数的过高估计。因此, 可以以最小化公式(5.11)所示的损失函数为目标, 通过梯度下降法更新行为网络的权重的 θ , 以最小化预测的 Q 值和目标 Q 值之间的平方差异。

$$\begin{aligned}
L(\theta) &= \left(R(s_t, a_t, s_{t+1}) + \gamma Q(s_{t+1}, \operatorname{argmax}_{a'} Q(s_{t+1}, a'; \theta); \theta^-) \right. \\
&\left. - Q(s_t, a_t; \theta) \right)^2
\end{aligned} \quad (5.11)$$

DDQN 的结构与执行过程如图 5-7.a 所示, 详细的网络结构如图 5-7.b 所示, 在图 5-7.b 中分别展示了网络的输入层、隐藏层和输出层, 隐藏层中使用了三个全连接层, 详细的尺寸和数据流的维度已标明。




图 5-7 DDQN 的执行流程(a)与网络结构(b)

Figure 5-7 The execution process (a) and network structure (b) of DDQN

使用 DDQN 进行特征点选择的算法流程见算法 2:

算法 5.2. 基于 DDQN 的特征点选择算法

Input:

$segment[1..n]$: 算法 5.1 处理后的分段数据

$C \leftarrow 10000$: 经验重放缓冲池内存容量

$error_threshold \leftarrow 0.05$: 拟合误差阈值

$\alpha \leftarrow 0.001$: 学习率

$\gamma \leftarrow 0.99$: 折扣因子

$BATCH_SIZE \leftarrow 64$: 从经验重放缓冲池采样的批量大小

$episodes \leftarrow 500$: 训练次数

$max_interval \leftarrow 10$: 选点之间允许的最大间隔

$cost_{int} \leftarrow 10$: 间隔代价成本

$cost_{err} \leftarrow 100$: 拟合误差代价成本

Output:

$CompressedData$: 压缩后的特征点序列

Procedure:

1: Initialize replay memory M to capacity C

2: Initialize behavior network Q with random weights θ

3: Initialize target network Q' with weights $\theta^- \leftarrow \theta$

4: **for** $episode \leftarrow 1$ to $episodes$ **do**

5: Initialize state $s_t \leftarrow segment[1]$, $done \leftarrow False$

6: **while** not $done$ **do**:

7: Select a random action a_t with ε -greedy, otherwise select $a_t = \operatorname{argmax}_a Q(s, a; \theta)$

8: Calculate reward r according to formula (5.8)

9: Update the previous selected data point index and move to the next state s_{t+1}

10: If s_{t+1} is the end of the $segment$, set $done \leftarrow True$

11: Store transition (s_t, a_t, r, s_{t+1}) in replay memory M

12: Sample random $BATCH_SIZE$ of transitions from M

13: Update the weights θ of the behavior network Q according to formula (5.10)

14: Minimize the loss function using gradient descent according to formula (5.11)

15: Every $TARGET_UPDATE$ steps, update the target network: $\theta^- \leftarrow \theta$

16: **end while**

17: **end for**

18: $CompressedData \leftarrow$ Select points using the trained DDQN agent

19: **return** $CompressedData$

在算法 5.2 中, 使用了 ε -greedy 策略, 初始时 ε 值为 1, 随机选择动作, 在每一个轮次的训练中, ε 值利用公式(5.12)更新, 作用是随着时间的推移, 算法将越来越多地依赖其学习到的策略, 而不是随机探索。

$$\varepsilon = \max(\varepsilon \times 0.995, 0.01) \quad (5.12)$$

另外需要说明的是, 智能体选择特征点时首尾的点通过设置动作为 1 进行了强制选择, 在学习的过程中通过维护一个索引数组记录上次选择的特征点的位置, 用以判断是否超过了最大索引间隔, 轮廓误差 $error$ 的计算首先需要将输

入的该段数据点的所有数据利用第三节介绍的三阶 B 样条进行拟合，这个过程包括找到一个参数化向量 u 和曲线的控制点，然后，在该曲线上均匀采样 10000 个点以获得拟合曲线的近似点集，接着，计算每个已选择的特征点到拟合的 B 样条曲线上采样点的欧几里得距离，并计算每个已选择特征点到曲线上所有点的最小距离，选取所有最小距离中的最大值作为轮廓误差。假设已选择的特征点集为 A，曲线上采样得到的点集为 B，则轮廓误差 $error$ 表示为公式(5.13):

$$error = \max_{p \in A} (\min_{q \in B} (dist(p, q))) \quad (5.13)$$

其中， $dist(p, q)$ 表示点 p 和 q 之间的欧几里得距离。

应用算法 5.2 之后对于部分分段数据的特征点选择结果与 B 样条曲线拟合结果如图 5-8 所示。




图 5-8 压缩前后的数据序列以及拟合的三阶空间 B 样条曲线

Figure 5-8 Data sequences before and after compression, as well as fitted third-order spatial

B-spline curves

在图 5-8 中, 图 5-8(A)与 5-8(B)展示的是蝴蝶模型中的分段后轮廓压缩前后的数据对比以及压缩后的数据拟合出的三阶空间 B 样条的拟合误差, 5-8(C)展示的是奔驰零件模型中的分段后的某个轮廓点集压缩前后的数据对比以及压缩后的数据拟合出的三阶空间 B 样条的拟合误差。可见压缩后的效果良好, 均能够使得压缩的轮廓在设定的阈值之内。

也就是说, 在算法 5.2 中对每个数据分段进行了特征点的提取和初步的 B 样条曲线拟合, 提取到的特征点与拟合出的 B 样条曲线之间的拟合精度小于 0.05mm, 然而, 此时, 并不能完全保证没有被选择的那些点的拟合精度也在 0.05mm 之内, 通常的解决方法是进行数据的拟合精度校验, 即, 将未被选择的且拟合误差大于阈值的点作为特征点加入特征点集, 而本章则提出了一种新的方式, 使用深度确定性策略梯度 (DDPG) 算法来优化 B 样条曲线的控制点, 通过逐步的调整控制点进而最小化拟合曲线与原始数据点的拟合误差, 具体的思路是输入分段后的每一段原始数据点集和轨迹压缩后初步拟合的曲线, 检查拟合误差不满足阈值的点, 如果有, 则找到拟合误差最大的数据点和与该点最邻近的控制点, 对控制点进行迭代调整, 在此过程中设置合适的奖励函数和控制点移动的方向, 利用强化学习智能体学习进行调整。

训练过程中, DDQN 算法的奖励收敛效果和平均损失如图 5-9 所示。




图 5-9 DDQN 算法的奖励收敛效果和平均损失

Figure 5-9 The Reward Convergence Effect and Average Loss of DDQN Algorithm

区别于 DDQN 方法, DDPG 是一种用于连续动作空间的强化学习算法, 定义 DDPG 的环境如下:

状态 s : 状态 s_t 是当前的三维控制点集 $ctp[1...n]$ 。

动作 $\mathbf{a}$: 动作 $\mathbf{a}_t$ 是对当前选定控制点的微小调整。它是一个三维向量 $[\Delta x, \Delta y, \Delta z]$ ，每个元素的值范围是 $[-0.001, 0.001]$ 。

奖励 $R(\mathbf{s}, \mathbf{a})$: 奖励函数的主要目标是量化当前 B 样条曲线与目标点集之间的误差，并根据误差大小给出奖励值。希望奖励值能反映出曲线接近目标点集的程度，从而引导算法调整控制点，使曲线更好地逼近目标点。因此，奖励函数的定义见公式(9)：

$$R(\mathbf{s}, \mathbf{a}) = -\max_i \min_u \|C(u) - P_i\| \quad (5.14)$$

其中， $C(u)$ 表示 B 样条曲线上的点， P_i 表示目标点集中的点， u 是曲线的参数。

状态转移过程: 由于给定状态 $\mathbf{s}_t$ 和动作 $\mathbf{a}_t$ ，下一个状态 $\mathbf{s}_{t+1}$ 是直接计算出来的，因此状态转移概率为 1，而下一个状态 $\mathbf{s}_{t+1}$ 的更新则需要在环境中的状态转移过程中定义，本节的 DDPG 智能体的状态更新遵循以下规则：

1. 智能体计算出一个动作 $\mathbf{a}_t$ ，并在环境中执行该动作，对应的操作是将这个动作向量的每一个分量值依次相应的加到当前选定的控制点上。

2. 使用更新后的控制点重新进行 B 样条拟合，以反映出这个调整对曲线形状的影响。

3. 计算每个目标点到曲线上最近点的距离并找到所有最小距离中的最大值 d_{max} 。

4. 如果 d_{max} 小于一个误差阈值 0.05mm，则认为曲线足够接近目标点，给予零奖励并结束。否则，记录最远的目标点 p_f ，并确定与之最近的曲线上的点 c_f ，并确定对应的 u 值，进而找到相关的控制点 ctp_f ，这个控制点是对曲线在参数 u 处形状影响最大的点，并利用公式 (5.15) 对其进行调整。

$$ctp_f = ctp_f + \frac{d_{max}}{10} (p_f - c_f) \quad (5.15)$$

5. 使用公式 (5.14) 计算奖励并开始新一轮的迭代。

在这个过程中，智能体会逐步调整曲线，直到曲线形状与目标点集的偏差达到阈值规定的程度为止。

DDPG 智能体的核心是使用演员-评论家 (actor-critic) 网络框架，Actor 网络 $\mu(\mathbf{s}; \theta^\mu)$ 接收状态来生成连续的动作，Critic 网络 $Q(\mathbf{s}, \mathbf{a}; \theta^Q)$ 来评估状态-动作对的值函数，并使用一对 Actor 网络和 Critic 网络的复制品作为目标网络，目标网络的权重被缓慢地更新，以稳定学习过程。

不同于 DDQN 中选择使得动作价值函数 $Q(\mathbf{s}, \mathbf{a})$ 最大的动作，DDPG 通过 Actor 网络的策略函数直接输出实数值动作。

$$\mathbf{a}_t = \mu(\mathbf{s}_t; \theta^\mu) \quad (5.16)$$

其中, μ 是由深度神经网络实现的确定性策略函数, θ^μ 是网络参数。

Actor 网络的目的是产生能够最大化 Critic 网络估计的 Q 值的动作。Actor 网络的参数 θ^μ 通过公式(12)的梯度上升规则更新:

$$\theta^\mu = \theta^\mu + \alpha^\mu E[\nabla_{\theta^\mu} \mu(s; \theta^\mu) \nabla_a Q(s, a; \theta^Q)|_{a=\mu(s; \theta^\mu)}] \quad (5.17)$$

其中, α^μ 是演员网络的学习率, $\nabla_{\theta^\mu} \mu(s; \theta^\mu)$ 表示 Actor 网络的输出动作 a 关于其参数 θ^μ 的梯度, $\nabla_a Q(s, a; \theta^Q)|_{a=\mu(s; \theta^\mu)}$ 表示 Critic 网络输出的动作价值函数 Q 关于动作 a 的梯度, 评估在当前状态下 Actor 网络产生的动作。这两个梯度的乘积给出了策略梯度, 即 Actor 网络参数应该如何变化以最大化 Critic 网络估计的期望回报。

Critic 网络的参数 θ^Q 通过最小化预测的 Q 值与目标 Q 值之间差异的损失函数来更新。目标 Q 值 y 是根据即时奖励以及 Critic 网络预测的下一状态的 Q 值计算得出的。评论家网络的参数更新遵循公式(5.18)的梯度下降规则:

$$\theta^Q = \theta^Q - \alpha^Q \nabla_{\theta^Q} L(\theta^Q) \quad (5.18)$$

损失函数 $L(\theta^Q)$ 的定义为公式(5.19):

$$L(\theta^Q) = E[(Q(s, a; \theta^Q) - y)^2] \quad (5.19)$$

其中 $y = R(s, a) + \gamma Q(s', \mu(s'; \theta^{\mu'}); \theta^{Q'})$ 是目标 Q 值, γ 是折扣因子, s' 是下一个状态, α^Q 是 Critic 网络的学习率, 梯度 $\nabla_{\theta^Q} L(\theta^Q)$ 是损失函数相对于 Critic 网络参数 θ^Q 的梯度, 这个梯度通过从经验回放缓冲区中采样的一批经验来估计, $\theta^{\mu'}$ 与 $\theta^{Q'}$ 分别是目标 Critic 和目标 Actor 的参数。而目标网络的更新使用公式(5.20)的软更新技术:

$$\begin{aligned} \theta^{\mu'} &= \tau \theta^\mu + (1 - \tau) \theta^{\mu'} \\ \theta^{Q'} &= \tau \theta^Q + (1 - \tau) \theta^{Q'} \end{aligned} \quad (5.20)$$

其中, τ 是介于 0 和 1 之间的软更新系数, 这种更新方法有助于稳定学习过程。

DDPG 的主要训练流程与前文中的 DDQN 类似, 主要区别在于网络结构上, Actor 网络负责生成动作, 即对 B 样条曲线控制点的调整。本章中的 Actor 网络包括输入层、隐藏层和输出层, 其中输入层的大小等于输入的状态的大小, 即输入的控制点的总数与维度数的乘积, 隐藏层包括第一隐藏层和第二隐藏层, 均具有 256 个神经元, 使用 ReLU 激活函数。输出层的大小与动作的大小相同, 即控制点数量乘以每个控制点的调整量的维度, 使用了 Tanh 激活函数。

Critic 网络也具有输入层、隐藏层和输出层, 输入层的大小为状态大小与动作大小之和。第一隐藏层和第二隐藏层均具有 256 个神经元, 使用 ReLU 激活函数。输出层只有一个神经元, 用于输出状态-动作对的价值评估。

这两个网络均使用 Adam 优化器。Actor 网络的学习率为 10^{-4} ，而 Critic 网络的学习率设为 10^{-3} ，软更新系数为 10^{-3} 。

基于以上 DDPG 智能体对图 5-8(A)中的压缩后的控制点精细化调整后的结果如图 5-10 所示。




图 5-10 使用 DDPG 智能体调整 B 样条控制点后的效果示例

Figure 5-10 Example of the effect of using DDPG intelligent agent to adjust B-spline control points

调整前后的 B 样条曲线相对于原始数据的拟合误差结果如图 5-11 所示。




图 5-11 调整前后的 B 样条曲线相对于原始数据的拟合误差

Figure 5-11 The fitting error of the B-spline curve before and after adjustment relative to the original data

训练过程中的 DDPG 算法的奖励收敛图如图 5-12 所示。




图 5-12 训练过程中 DDPG 智能体的奖励收敛过程

Figure 5-12 The reward convergence process of DDPG agents during training

如前所述，传统上对于离散数据点的曲线拟合，是通过定义如反曲点、曲率极值点和弓高特征点等进行初步的特征点提取，拟合出初步的 B 样条，之后再逐步的添加新的特征点，直到所有数据点的拟合误差满足阈值。

为了更好的说明基于层次化强化学习的轨迹优化方法的优越性，以传统方法中定义反曲点、曲率极值点和弓高特征点的方式来进行实验对比，曲率 k 的计算公式为：

$$k = \frac{\|y' \times y''\|}{\|y'\|^3} \quad (5.21)$$

其中， y' 和 y'' 分别是该点的一阶、二阶导数， $\|\cdot\|$ 表示欧几里得范数。曲率极值点是曲线上曲率函数达到局部最大或最小的点。对于曲率极值点的确定，需要检查曲率函数 $k(t)$ 的一阶导数的符号变化。这里包括曲率极大值点和曲率极小值点。曲率极大值点是指曲率从增加转为减少的点，在这一点上，曲率函数的一阶导数 $k'(t)$ 会从正值变为负值。反之，曲率极小值点是指曲率从减少转为增加的点，在这一点上，曲率函数的一阶导数 $k'(t)$ 会由负变正。

而反曲点则指的是曲线曲率改变符号的点，即曲线从凹变凸或从凸变凹的地方。利用公式 5.21，可以通过检查曲率 k 的符号变化来识别反曲点。

弓高特征点是曲线与其某个特定线段（通常是由相邻特征点定义的直线段）之间的最大垂直距离超过某个阈值的点。这里的相邻特征点指的是已定义的反曲点与曲率极值点，使用递归搜索算法进行计算：首先，对于每一对相邻特征

点 A 和 B，计算中间点到由 A 和 B 定义的直线的距离。如果某个点 P 的距离超过了设定的阈值，标记这个点为弓高特征点，并将其加入特征点集。进而对 A 到 P 和 P 到 B 之间再次执行相同的过程，直到没有新的特征点被添加。该过程中设置点 P 到线段的距离阈值为 0.05mm。

由以上步骤处理后得到的图 5-8.(A)中的轨迹如图 5-13 所示。




图 5-13 反曲点、曲率极值点、弓高特征点方法提取效果

Figure 5-13 Extraction effect of methods for inflection points, curvature extremum points, and arch height feature points

此时原始数据点到提取到的特征点拟合的初步 B 样条的拟合结果见图 5-14。原始数据点到该 B 样条的拟合误差结果见图 5-15。




图 5-14 初步拟合的 B 样条曲线效果

Figure 5-14 Preliminary fitting of B-spline curve effect




图 5-15 原始数据点到初始 B 样条的拟合误差

Figure 5-15 The fitting error from the original data point to the initial B-spline

以上步骤的处理结果为对于 122 个原始的数据点，初步处理后得到 86 个，然而初步处理后得到的 B 样条还不满足轮廓误差为 0.05mm 的要求，需要进一步后处理，后处理步骤中需要将那些原始数据点中到该初始 B 样条的距离大于轮廓误差的点逐步加入特征点集合中直到得到的 B 样条轮廓相对于所有原始数据点的最小距离都满足阈值要求。后处理步骤的具体过程见算法 5.3:

算法 5.3. 优化拟合曲线的特征点后处理算法**Input:***data*: *m* 原始三维点序列*feature_data*: 已提取到的反曲点、曲率极值点与弓高特征点集合*contour_error_threshold*: 轮廓误差阈值**Output:***posted_feature_data*: 新的特征点集合**Procedure:**1: *point_status*[1..*n*] = False 将 *data* 中的点初始化为未选状态2: 从 *feature_data* 中提取索引 *feature_data_indices*3: 对 *feature_data_indices* 进行排序**4: Repeat**5: 使用 *feature_data_indices* 中的点拟合 B 样条曲线6: 初始化 *point_added* = False7: 初始化 *max_error* = 0 和 *max_error_index* = None8: **for** *i* $\leftarrow$ 1 to *n* **do**9: **if** *point_status*[*i*] = False **then**10: 计算点 *data*[*i*] 到 B 样条曲线的最短距离 *min_distance*11: **if** *min_distance* > *max_error* **then**12: *max_error* = *min_distance*13: *max_error_index* = *i*14: **endif**15: **endif**16: **end for**17: **if** *max_error_index* is not None and *max_error* > *contour_error_threshold* **then**18: **if** *max_error_index* not in *feature_data_indices* **then**19: 将 *max_error_index* 添加到 *feature_data_indices*20: *point_status*[*max_error_index*] = True21: *point_added* = True22: **endif**23: **endif**24: **until** *point_added* = False25: **return** *feature_data_indices* 索引的 *data* 中的点

经过算法 5.3 处理后, 得到的新的特征点集合如图 5-16, 可以看到示例中新增加了 10 个点。而由新的特征点集合拟合的 B 样条曲线相对于原始数据点的轮廓误差见图 5-17。




图 5-16 后处理得到的新特征点集

Figure 5-16 New feature point set obtained from post-processing




图 5-17 原始数据点到后处理得到的 B 样条曲线的拟合误差

Figure 5-17 Fitting error of B-spline curve obtained from raw data points to post-processing

结合图 5-16 与图 5-17，可以看出此时得到的 B 样条曲线是符合要求的，与前述所提出的基于层次化强化学习方法的轨迹优化过程对比来看，前述方法中在第一层强化学习中提取的特征点只需要 69 个，并且在后续的第二层强化学习阶段不需要额外添加特征点只需调整 B 样条的控制点就能达到轮廓误差阈值的要求，而基于反曲点、曲率极值点和弓高特征点的方法在第一阶段提取到的特征点为 86 个，后处理阶段提取出的特征点为 10 个，也就是需要 96 个特征点才能够达到误差要求，因此可以得出结论，本章提出的方法更具有优越性。

5.4.4 轨迹优化的插补实验验证

在数控加工中，精确的轨迹插补是保证加工精度和动态性能的关键。在5.4.3节中得到的压缩后的轨迹特征点与B样条拟合曲线在插补过程中还需要关注机床的动力学特性以及轮廓精度，轮廓精度通常在插补时采用弦高误差来定义，而机床的动力学特性则由插补过程的速度，加速度和加加速度来表示，高精高效的插补方法需要同时考虑满足轮廓精度和动力学特性的约束，因此本节实现了基于轮廓精度和机床动力学特性的插补方法，包括以下几个阶段。

首先，需要建立B样条曲线参数化表示(u)与曲线的弧长(s)表示之间的映射关系，给定一条B样条曲线 $C(u)$ ，其中 $u \in [0,1]$ 是曲线的参数。曲线的弧长函数 $s(u)$ 定义为从曲线起点到参数值为 u 处点的弧长。它可以通过积分曲线的速度向量的模得到：

$$s(u) = \int_0^u \|C'(t)\| dt \quad (5.22)$$

其中 $C'(t)$ 是曲线在参数 t 处的一阶导数，即速度向量。通过计算不同参数值下的累积弧长，可以建立从参数 u 到弧长 s 的映射。这个步骤需要根据辛普森规则计算弧长，给定参数区间 $[a, b]$ ，基本的辛普森规则为：

$$s(a, b) = \frac{b-a}{6} (s(a) + 4f(\frac{a+b}{2}) + s(b)) \quad (5.23)$$

进而，如果 $S(a, b) - (S(a, \frac{a+b}{2}) + S(\frac{a+b}{2}, b))$ 的值大于设定的误差阈值（本章中该值为 10^{-4} ），则递归地将区间 $[a, b]$ 细分为更小的子区间 $[a, \frac{a+b}{2}]$ 和 $[\frac{a+b}{2}, b]$ ，并对每个子区间分别应用辛普森规则，直到达到预定的误差阈值，并将所有子区间的结果相加。

其次，需要根据预定义的弦高误差参数计算速度约束。本章中设定的约束值和参数为：最大弦高误差 $\delta = 0.0005\text{mm}$ 、最大速度 $v_{\max} = 100\text{mm/s}$ 、最大加速度 $a_{\max} = 1000\text{mm/s}^2$ 、最大加加速度 $j_{\max} = 20000\text{mm/s}^3$ 、初始速度 $v_{\text{init}} = 100\text{mm/s}$ 以及控制周期 $\text{cycle} = 0.002\text{s}$ 。弦高误差是在数控加工中用于衡量轨迹精度的一个重要参数。它指的是在曲线上两点之间的弦线与曲线之间的最大距离。弦高误差的计算公式为：

$$\delta = R - \sqrt{R^2 - (\frac{L}{2})^2} \quad (5.24)$$

其中， R 是曲率半径， L 是两点间的弦长。其中 $R = \frac{1}{k}$ ， k 为该点处的曲率，曲率 k 的计算公式为见公式5.21。

接着，根据每个点的曲率和给定的最大弦高误差 δ ，计算每个点的弦高误差约束速度，具体公式为：

$$v_{chord} = \frac{2\sqrt{R^2 - (R - \delta)^2}}{cycle} \quad (5.25)$$

这个计算过程确保了在每个插补点上弦高误差都被考虑，从而保证了插补过程的准确性和平滑性，有助于优化加工轮廓的精度和质量。同时，计算最大加速度约束速度和最大加加速度约束速度，以确保插补过程中的速度满足机床的动力学特性。最大加速度约束速度 $v_{amax} = \sqrt{\frac{a_{max}}{k}}$ ，最大加加速度约束速度 $v_{jmax} = \sqrt[3]{(\frac{1}{k^2}) \times j_{max}}$ ，最后，对于每个插补点，取弦高误差约束速度、最大加速度约束速度、最大加加速度约束速度以及最大进给速度 v_{max} 的最小值作为该点的最终速度 v_{limit} 。

其次，则需要对速度进行合理的规划，虽然已经得到了符合约束的速度 v_{limit} ，但考虑到机床的机械特性，本章采用了非对称 S 型加减速规划方法，目的是在加速或减速过程中最小化加加速度（即加速度的变化率），从而减少机床的震动和冲击。这种规划方法将每个运动段分为七个阶段：加加速、匀加速、减加速（ T_1, T_2, T_3 ）、匀速（ T_4 ）和加减速、匀减速和减减速（ T_5, T_6, T_7 ）。根据起始速度 v_s 、终止速度 v_e 、最大速度 v_{max} 、最大加速度 a_{max} 、最大减速度 d_{max} 、最大减加速度 j_{dec_max} ，起始速度 v_s 、最大加加速度 j_{max} 和轨迹长度 S_{seg} ，计算每个阶段的时长并自适应的调整最大速度，保证各阶段的平滑过渡。

对于加加速和减加速阶段，根据动能定理，该阶段能够完成速度变化的最小路径长度 $S_{acc_min} = \frac{(v_e^2 - v_s^2)}{2a_{max}}$ ，如果实际路径长度 S_{seg} 不足以容纳在最大加速度 a_{max} 和最大减速度 $-a_{max}$ 的约束下从起始速度 v_s 加速至最大速度 v_{max} 再减速至结束速度 v_e 的全过程，则需采取二分法来调整 v_{max} ，首先，设置一个初始的最大速度范围，这个上下界分别是当前的最大速度 v_{max} 和 $\max(v_s, v_e)$ ，在每次迭代中，计算这个上下界的平均值作为新的最大速度值，并估算在当前加速度和减速度条件下的总路径长度，如果估算长度大于实际长度，说明需要降低最大速度，因此调整速度范围的上限为当前中值。反之，如果估算长度小于实际长度，可以提高最大速度，因此调整速度范围的下限为当前中值。当速度范围的上下限之差小于 10^{-6} 时结束迭代过程。

当前的中值即被视为调整后的最大速度 v_{max_adj} ，用于 S 型曲线参数计算，具体如下：

- 加速阶段(T_1, T_2, T_3): 如果 $v_{max_adj} - v_s > \frac{a_{max}^2}{j_{max}}$ ，则存在匀加速段，此时， $T_1 = \frac{a_{max}}{j_{max}}$, $T_2 = \frac{v_{max_adj} - v_s}{a_{max}} - T_1$, $T_3 = T_1$ ，位移 $S_a = v_s \cdot (2 \cdot T_1 + T_2) + \frac{1}{2} j_{max} \cdot T_1^2 \cdot (T_1 + T_2) + \frac{1}{2} a_{max} \cdot T_2^2$ ，否则， $T_1 = \sqrt{\frac{v_{max_adj} - v_s}{j_{max}}}$, $T_2 = 0$, $T_3 = T_1$ ，位移

$$s_a = v_s \cdot T_1 + \frac{1}{2} j_{\max} \cdot T_1^2。$$

- 减速阶段(T_5, T_6, T_7): 如果 $v_{\max_adj} - v_e > \frac{d_{\max}^2}{j_{\max_dec}}$, 则存在匀减速段, 此时, $T_5 = \frac{d_{\max}}{j_{\max_dec}}$, $T_6 = \frac{v_{\max_adj} - v_e}{d_{\max}} - T_5$, $T_7 = T_5$, 位移 $s_d = v_{\max_adj} \cdot (2 \cdot T_5 + T_6) - \frac{1}{2} j_{\max_dec} \cdot T_5^2 \cdot (T_5 + T_6) - \frac{1}{2} d_{\max} \cdot T_6^2$, 否则, $T_5 = \sqrt{\frac{v_{\max_adj} - v_e}{j_{\max_dec}}}$, $T_6 = 0$, $T_7 = T_5$, 位移 $s_d = v_{\max_adj} \cdot T_5 - \frac{1}{2} j_{\max_dec} \cdot T_5^2$ 。
- 匀速阶段(T_4): 如果 $S_{\text{seg}} > s_a + s_d$, 则存在匀速段, 此时, $T_4 = \frac{S_{\text{seg}} - s_a - s_d}{v_{\max_adj}}$, 否则, $T_4 = 0$ 。

最后, 返回修正后的 $v_{\max_adj}$ 以及 S 曲线加减速在各个阶段的持续时间 T_{1-7} , 并基于上述结果, 在给定周期 $cycle$ 下, 对位移 s_t 、速度 v_t 、加速度 a_t 和加加速度 j_t 进行离散时间点的计算, 用于生成路径轮廓。

基于以上方法进行实验, 得到的插补点部分图例及相应的速度、加速度、加加速度曲线如图 5-18、5-19、5-20、5-21 所示。其中图 5-18 是蝴蝶模型分段后曲线的插补效果, 5-19 是其速度规划效果, 图 5-20 是奔驰零件模型分段后曲线的插补效果, 5-21 是其速度规划效果。




图 5-18 蝴蝶模型的部分插补效果

Figure 5-18 Partial interpolation effect of butterfly model




图 5-19 蝴蝶模型的部分速度规划效果(速度、加速度、加加速度)

Figure 5-19 Partial speed planning effect of butterfly model (speed, acceleration, acceleration)




图 5-20 奔驰零件模型的部分插补效果

Figure 5-20 Partial interpolation effect of Mercedes Benz part model





图 5-21 奔驰零件模型的部分速度规划效果(速度、加速度、加加速度)

Figure 5-21 Partial speed planning effect of Mercedes Benz part model (speed, acceleration, acceleration)

整体的插补效果如图 5-22 所示：



(A)蝴蝶模型插补结果

(B)奔驰零件模型插补结果

图 5-22 整体插补结果：蝴蝶模型 (A) 和奔驰零件模型 (B)

Figure 5-22 Overall interpolation results: Butterfly model (A) and Mercedes Benz part model (B)

5.5 本章小结

本章主要探讨了基于层次化强化学习的轨迹优化方法。首先从问题的提出开始，分析了在先进信息技术与先进制造技术深度融合的背景下，基于网络制造的数控加工模式的优点，并介绍和分析了传统的 G01 直线段轨迹优化中的主流方法与不足之处，提出了利用先进的人工智能与数据分析技术对数控加工提供轨迹的实时优化和智能化的决策支持。

其次，介绍了在网络制造中的智能化数控系统的新特征，并建立了基于网络制造的智能化数控系统模块化的抽象模型，详细的介绍了应用该模型在数控加工轨迹优化中的解决方案，介绍了 B 样条理论的基础知识，为后续的实验研究提供理论基础。

最后，在实验研究部分详细介绍了基于层次化强化学习的数控加工轨迹优化方法，一方面，对于传统的数控加工轨迹的拟合误差控制问题，使用了基于 DDQN 的深度强化学习进行轨迹特征点的选择，并在特征点选择过程中融合了 B 样条拟合与误差控制。另一方面，对前述步骤中得到的初始 B 样条，再次利用深度强化学习中的 DDPG 方法进行控制点的精细化调整，使得轮廓误差得到严格的约束。在以上步骤中完成了数控加工轨迹的分段平滑过渡。之后，设计了一种基于非对称 S 型加减速控制的速度规划方法用于轨迹的插补，该插补方法的核心在于两方面的优化：首先，通过精确计算弦高误差，本方法能够保证插补轨迹在空间中的准确性和光滑性。弦高误差是插补轨迹与原始设计轨迹之间的最大距离，控制这一误差是确保加工质量的重要因素。通过对弦高误差的严格控制，本方法可以确保加工轨迹严格遵循设计轮廓，避免因插补精度不足导致的加工误差。

总体来说，本章不仅系统地介绍了轨迹优化的理论和技术框架，还通过实验研究证实了层次化强化学习在轨迹优化方面的有效性。这些研究成果对于推动数控加工技术的发展具有借鉴意义，为未来的研究提供了有益的参考。

第6章 总结与展望

6.1 论文工作总结

本文针对智能化数控系统轨迹优化方法进行了深入研究与应用，旨在提高数控加工效率和精度。本章将总结前文的主要研究成果，并对未来的研究方向进行展望。论文的主要工作总结如下：

首先，本文在绪论中（第 1 章）详细阐述了研究的背景、意义以及国内外在相关领域的研究现状。通过对数控系统智能化技术、加工路径优化、轨迹压缩技术以及轨迹优化技术的现状进行深入分析，为本文的研究定下了坚实的理论基础。同时，明确了研究的来源和主要内容，基于本章节的工作基础，论文主要展开了如下方面的工作：

1. 智能化数控系统智能体模型及体系结构研究。在第 2 章中，深入探讨了智能化数控系统智能体模型的构建，这是本文的核心部分之一。智能体模型是智能化数控系统的理论基础，它将人类的决策、网络空间的数据处理和物理空间的数控加工有机结合，形成一个多层次、互联互通的智能系统。本章首先详细介绍了智能数控系统的概念和智能数控系统的软硬件平台，并提出了对该平台架构实施数控系统智能化扩展的方案。接着，本章讨论了数控系统的智能化需求。随着制造业的发展和市场需求的变化，对数控系统的智能化提出了更高的要求。本章分析了当前数控系统面临的挑战，如加工复杂性的增加、加工效率和精度的提高需求，以及智能化技术在数控系统中的应用潜力。基于这些需求，本章提出了数控系统智能化的扩展方案，包括算法集成、数据感知、人工智能应用等方面。最后，探讨了数控系统的抽象模型与体系结构，建立了数控系统智能体模型。这一部分有助于理解数控系统的工作原理和智能化扩展的思路。通过这些理论模型和体系结构的分析，为后续章节中数控系统的加工优化方法提供了理论框架和实验环境基础。

2. 基于智能体的数控系统加工路径优化方法。第 3 章中探讨了基于智能体的数控系统加工路径优化方法。本章的研究从问题的提出开始，逐步深入到建模过程和实验研究，全面系统地展开了对加工路径优化方法的探索和验证。首先，在问题的提出部分，明确了加工路径优化在数控加工中的重要性。针对加工路径拐角明显、相邻路径不均匀、点位分布不均匀等问题，提出了优化加工路径的需求，并分析了当前的自动化制造中设计与实际加工通常处于割裂的不同阶段，针对该问题，建立了新的工作流程，以完成从设计、优化、到加工与反馈的数据流闭环。接着，阐述了基于智能体模型进行优化的理论依据和实际意义。智能体模型的引入有助于更好地理解数控系统的复杂性，为加工路径优化提供了一个新的视角，基于以上分析与第 2 章的工作内容，完成了用于数控

加工中加工路径优化问题的模型。接着,在实验研究部分,首先介绍了实验环境与整体的实验流程,通过一个应用实例介绍了工艺解析的原理和所提出的路径层级分解算法、路径生成过程和路径优化过程。在路径优化过程中,给出了路径分割的聚类算法、路径缺陷特征的深度学习分类算法和基于深度强化学习的自适应路径优化算法,并展示了建立的 Cyber 应用。

3. 基于强化学习的轨迹压缩方法。第 4 章中研究了基于强化学习的轨迹压缩方法,该方法是本文的研究工作中首次提出,旨在解决数控系统中 G 代码数据量庞大的问题。首先,本章在问题提出部分阐述了制造业领域中智能化的趋势,特别是先进人工智能技术在数控系统中的应用。针对传统数控加工中使用大量微小直线段逼近复杂曲面模型,导致 G 代码文件庞大的问题,指出了 G 代码数据压缩的必要性和重要性。高效的 G 代码数据压缩技术不仅能减小文件大小,加快传输速度,还能提高设备执行效率,同时保持原始数据的几何特性,确保最终产品质量。接着,在问题建模部分,采用马尔可夫决策过程(MDP)来对 G01 代码数据压缩问题进行抽象,将其建模为一个序列决策问题。该模型包括状态、动作、状态转移概率和奖励函数,能够清晰直观地描述问题并为解决方案的制定提供理论支持。最后,详细介绍了实验的建立和算法流程。通过定义正则匹配解析 G01 代码的三维坐标,生成加工路径,并将其决策问题抽象为马尔可夫决策过程。接着,结合深度强化学习方法 DQN 实现 G 代码数据的自动化压缩,展示了如何使用 DQN 网络结构来近似 Q 值函数,并通过迭代训练过程找到最优化的数据压缩策略。在结果分析部分,通过实验对比展示了算法的有效性。通过 DQN 算法对数据点序列进行压缩后,数据量显著减少,且保持了原始数据的形状。这证明了 DQN 算法在轨迹压缩方面的有效性和实用性。

4. 基于层次化强化学习的数控加工轨迹优化方法。在第 5 章中,主要介绍了利用层次化强化学习技术来优化数控加工轨迹。章节开头阐述了集成先进信息技术与制造技术的必要性,指出了在现代网络制造环境中,智能化数控系统的重要性。随后,章节介绍了智能数控系统中,特别是在 G01 直线段轨迹优化方面,传统方法的局限性。为应对这些挑战,提出了结合人工智能和数据分析技术的解决方案,旨在实现数控加工轨迹的实时优化和智能化决策。接下来,详细介绍了基于网络制造的智能化数控系统的新特征,建立了一种模块化的抽象模型,用于优化数控加工轨迹。通过 B 样条理论,为该模型提供了理论基础,为后续实验研究提供了理论支持。最后,在实验部分,重点介绍了基于层次化强化学习的轨迹优化方法。这包括使用 DDQN 技术选取轨迹特征点,并结合 B 样条拟合和误差控制,以及使用 DDPG 方法进一步调整 B 样条控制点。此外,还介绍了一种基于非对称 S 型加减速控制的速度规划方法,用于精确控制插补轨迹,确保加工精度和质量。

6.2 未来研究展望

未来,智能化数控系统的研究和应用将会更加深入和广泛。一方面,随着人工智能、大数据、云计算等技术的不断发展,将有更多创新技术被应用于数控系统的智能化改造中。例如,深度学习在图像处理和数据分析方面的应用,可能为数控加工中的复杂形状识别和加工质量评估提供新的解决方案。另一方面,随着智能制造和工业 4.0 的推进,数控系统将更加注重与其他工业系统的互联互通和协同工作,如何有效集成和优化这些系统,将是未来研究的重点。此外,针对数控加工过程中的节能减排、资源优化利用等问题,未来的研究可以探索更为高效和环保的加工技术和管理策略。例如,通过优化刀具设计、改进切削参数和路径规划,可以有效减少能源消耗和材料浪费。

并且,随着科技的不断进步和市场需求的多样化,未来的数控系统将面临更多新的挑战 and 机遇。如何结合最新的科技成果,持续推动数控技术的创新和发展,将是未来研究工作的重要方向。同时,加强产学研用的深度融合,将研究成果更快更好地转化为生产力,也是未来发展的关键。

因此,未来研究的趋势可以归纳为以下几个方面:

1.技术提升与创新: 继续探索和发展更高级的算法和技术,进一步提升数控加工轨迹优化的效率和准确性。例如,研究更加复杂的强化学习模型或结合其他先进的机器学习技术。

2.系统集成与应用扩展: 将数控加工轨迹优化技术与更广泛的智能制造系统集成,扩展其应用领域。例如,将其应用于不同类型的数控机床或不同的制造过程。

3.实时数据处理与反馈: 研究如何实时收集和处理数控加工数据,并快速反馈到轨迹优化过程中,以实现更加动态和自适应的优化策略。

4.优化策略的细化与个性化: 根据不同的加工需求和条件,发展更加细化和个性化的轨迹优化策略,以提高加工效果和适应性。

5.与工业 4.0 和智能制造的深度融合: 研究如何将数控加工轨迹优化技术与工业 4.0 和智能制造的其他元素(如物联网、大数据、云计算等)更深度地融合,以实现更全面的智能制造解决方案。

以上这些研究将有助于推动数控加工技术的发展,实现更高效、精确和智能的制造过程。

综上所述,本文的研究工作为智能化数控系统轨迹优化方法提供了一定的理论基础和实践参考,对推动相关领域的科技进步和产业发展具有理论和实际意义。同时,未来的研究将面临更多机遇和挑战,希望能够不断探索新的理论、技术和应用,进一步推进数控技术和智能制造领域的发展。随着科技的进步和市场需求的变化,未来数控系统的研究将更加注重创新和高效,从而为制造业

带来更广泛的影响和变革。

参考文献

- [1] 牟华伟,宋颖昌,孙刚等. 美国《先进制造业国家战略》对我国提升产业链供应链韧性的启示 [J]. 工业技术创新, 2023, 10 (06): 1-6. DOI:10.14103/j.issn.2095-8412.2023.12.001.
- [2] 沈立. 德国国家工业战略 2030 及其对中国的启示 [J]. 中国经贸导刊 (中), 2021(03):51-53.
- [3] 董凯. “十四五” 智能制造发展规划解读及趋势研判 [J]. 中国工业和信息化, 2022(01):26-29. DOI:10.19609/j.cnki.cn10-1299/f.2022.01.004.
- [4] 于永初. 智能化控制系统赋予数控机床“智慧大脑” [J]. 汽车工艺师, 2022, (04): 14-16. DOI:10.16173/j.cnki.ame.2022.04.003.
- [5] 钟荣丙. “互联网+制造 2025” 的协同创新生态体系研究 [J]. 技术与创新管理, 2018, 39 (01): 10-18. DOI:10.14090/j.cnki.jscx.2018.0103.
- [6] 李君,邱君降,邵明堃等. 我国两化融合关键技术、产品及产业生态国际竞争力现状、制约因素及提升对策研究 [J]. 计算机集成制造系统, 2019, 25 (09): 2334-2343. DOI:10.13196/j.cims.2019.09.020.
- [7] González Rodríguez G, Gonzalez-Cava JM, Méndez Pérez JA. An intelligent decision support system for production planning based on machine learning. *Journal of Intelligent Manufacturing*. 2020;31(5):1257-73. <https://doi.org/10.1007/s10845-019-01510-y>.
- [8] Imad M, Hopkins C, Hosseini A, Yussefian N, Kishawy H. Intelligent machining: a review of trends, achievements and current progress. *International Journal of Computer Integrated Manufacturing*. 2022;35(4-5):359-87. <https://doi.org/10.1080/0951192X.2021.1891573>.
- [9] Tao F, Qi Q, Liu A, et al. Data-driven smart manufacturing[J]. *Journal of Manufacturing Systems*, 2018, 48: 157-169.
- [10] Kusiak A. Smart manufacturing[J]. *International Journal of Production Research*, 2018, 56(1-2): 508-517.
- [11] Dafflon, B., Moalla, N. & Ouzrout, Y. The challenges, approaches, and used techniques of CPS for manufacturing in Industry 4.0: a literature review. *Int J Adv Manuf Technol* 113, 2395–2412 (2021). <https://doi.org/10.1007/s00170-020-06572-4>.
- [12] Tong X, Liu Q, Pi S, et al. Real-time machining data application and service based on IMT digital twin[J]. *Journal of Intelligent Manufacturing*, 2020, 31: 1113-1132.
- [13] Morgan J, Halton M, Qiao Y, Breslin JG. Industry 4.0 smart reconfigurable manufacturing machines. *Journal of Manufacturing Systems*. 2021;59:481-506.

- [14] Pang J, Zhang N, Xiao Q, Qi F, Xue X. A new intelligent and data-driven product quality control system of industrial valve manufacturing process in CPS. *Computer Communications*. 2021;175:25-34.
- [15] Ghosh AK, Ullah AS, Teti R, Kubo A. Developing sensor signal-based digital twins for intelligent machine tools. *Journal of Industrial Information Integration*. 2021;24:100242.
- [16] Wang B, Tao F, Fang X, Liu C, Liu Y, Freiheit T. Smart manufacturing and intelligent manufacturing: A comparative review. *Engineering*. 2021;7(6):738-57.
- [17] Zhou J, Li P, Zhou Y, Wang B, Zang J, Meng L. Toward new-generation intelligent manufacturing. *Engineering*. 2018;4(1):11-20.
- [18] Zhou J, Zhou Y, Wang B, Zang J. Human-cyber-physical systems (HCPSS) in the context of new-generation intelligent manufacturing. *Engineering*. 2019;5(4):624-36. <https://doi.org/10.1016/j.eng.2019.07.015>.
- [19] Jihong Chen, Pengcheng Hu, Huicheng Zhou, Jianzhong Yang, Jiejun Xie, Yakun Jiang, Zhiqiang Gao, Chenglei Zhang, Toward Intelligent Machine Tool, *Engineering*, Volume 5, Issue 4, 2019, Pages 679-690, ISSN 2095-8099, <https://doi.org/10.1016/j.eng.2019.07.018>.
- [20] Chao Liu, Hrishikesh Vengayil, Ray Y. Zhong, Xun Xu, A systematic development method for cyber-physical machine tools, *Journal of Manufacturing Systems*, Volume 48, Part C, 2018, Pages 13-24, ISSN 0278-6125, <https://doi.org/10.1016/j.jmsy.2018.02.001>.
- [21] Chao Liu, Hrishikesh Vengayil, Yuqian Lu, Xun Xu, A Cyber-Physical Machine Tools Platform using OPC UA and MTConnect, *Journal of Manufacturing Systems*, Volume 51, 2019, Pages 61-74, ISSN 0278-6125, <https://doi.org/10.1016/j.jmsy.2019.04.006>.
- [22] Wu Wei, Jianfeng Lu, and Hao Zhang. "Smart factory reference architecture based on CPS fractal." *IFAC-PapersOnLine* 52.13 (2019): 2776-2781.
- [23] 谷艾. 面向信息物理系统的安全机制与关键技术研究[D].中国科学院大学(中国科学院沈阳计算技术研究所), 2021. DOI:10.27587/d.cnki.gksjs.2021.000005.
- [24] 宋林, 王立平, 吴军, 关立文, 刘知贵. 基于信息物理融合和数字孪生的可靠性分析 [J]. *吉林大学学报 (工学版)*, 2022, 52(02):439-449. DOI:10.13229/j.cnki.jdxbgxb20211230.
- [25] Habib MK, Chimsom C. CPS: Role, characteristics, architectures and future potentials. *Procedia Computer Science*. 2022;200:1347-58.
- [26] Wang J, Li Y, Huang Z, Qiao Q. Digital twin-driven fault diagnosis service of rotating machinery. *Digital twin driven service*: Elsevier; 2022. p. 119-38.
- [27] Deebak B, Al - Turjman F. Digital - twin assisted: Fault diagnosis using deep transfer learning for machining tool condition. *International Journal of Intelligent Systems*. 2022;37(12):10289-316. <https://doi.org/10.1002/int.22493>.
- [28] Jiang Y, Yin S, Li K, Luo H, Kaynak O. Industrial applications of digital twins.

- Philosophical Transactions of the Royal Society A. 2021;379(2207):20200360.
- [29] Niermann D, Doernbach T, Petzoldt C, Isken M, Freitag M. Software framework concept with visual programming and digital twin for intuitive process creation with multiple robotic systems. *Robotics and Computer-Integrated Manufacturing*. 2023;82:102536. <https://doi.org/10.1016/j.rcim.2023.102536>.
- [30] Leng J, Zhou M, Xiao Y, Zhang H, Liu Q, Shen W, et al. Digital twins-based remote semi-physical commissioning of flow-type smart manufacturing systems. *Journal of Cleaner Production*. 2021;306:127278.
- [31] Fan Y, Yang J, Chen J, Hu P, Wang X, Xu J, et al. A digital-twin visualized architecture for Flexible Manufacturing System. *Journal of Manufacturing Systems*. 2021;60:176-201. <https://doi.org/10.1016/j.jmsy.2021.05.010>.
- [32] Gopal L, Singh H, Mounica P, Mohankumar N, Challa NP, Jayaraman P. Digital twin and IOT technology for secure manufacturing systems. *Measurement: Sensors*. 2023;25:100661. <https://doi.org/10.1016/j.measen.2022.100661>.
- [33] Liu L, Zhang X, Wan X, Zhou S, Gao Z. Digital twin-driven surface roughness prediction and process parameter adaptive optimization. *Advanced Engineering Informatics*. 2022;51:101470. <https://doi.org/10.1016/j.aei.2021.101470>.
- [34] Cao X, Zhao G, Xiao W. Digital Twin-oriented real-time cutting simulation for intelligent computer numerical control machining. *Proceedings of the Institution of Mechanical Engineers, Part B: Journal of Engineering Manufacture*. 2022;236(1-2):5-15. <https://doi.org/10.1177/0954405420937869>.
- [35] Van Dinter R, Tekinerdogan B, Catal C. Predictive maintenance using digital twins: A systematic literature review. *Information and Software Technology*. 2022;107008. <https://doi.org/10.1016/j.infsof.2022.107008>.
- [36] Luo W, Hu T, Ye Y, Zhang C, Wei Y. A hybrid predictive maintenance approach for CNC machine tool driven by Digital Twin. *Robotics and Computer-Integrated Manufacturing*. 2020;65:101974. <https://doi.org/10.1016/j.rcim.2020.101974>.
- [37] Wei Y, Hu T, Zhou T, Ye Y, Luo W. Consistency retention method for CNC machine tool digital twin model. *Journal of Manufacturing Systems*. 2021;58:313-22. <https://doi.org/10.1016/j.jmsy.2020.06.002>.
- [38] He R, Chen G, Dong C, Sun S, Shen X. Data-driven digital twin technology for optimized control in process systems. *ISA transactions*. 2019;95:221-34. <https://doi.org/10.1016/j.isatra.2019.05.011>.
- [39] Zhou Y, Xing T, Song Y, Li Y, Zhu X, Li G, et al. Digital-twin-driven geometric optimization of centrifugal impeller with free-form blades for five-axis flank milling. *Journal of Manufacturing Systems*. 2021;58:22-35. <https://doi.org/10.1016/j.jmsy.2020.06.019>.
- [40] Yu H, Yu D, Wang C, Hu Y, Li Y. Edge intelligence-driven digital twin of CNC system: Architecture and deployment. *Robotics and Computer-Integrated Manufacturing*. 2023;79:102418. <https://doi.org/10.1016/j.rcim.2022.102418>.

- [41] Pauli T, Fiert E, Matzner M. Digital industrial platforms. *Business & Information Systems Engineering*. 2021;63:181-90. <https://doi.org/10.1007/s12599-020-00681-w>.
- [42] Liu M, Fang S, Dong H, Xu C. Review of digital twin about concepts, technologies, and industrial applications. *Journal of Manufacturing Systems*. 2021;58:346-61. <https://doi.org/10.1016/j.jmsy.2020.06.017>.
- [43] Hastie T, Tibshirani R, Friedman JH, Friedman JH. The elements of statistical learning: data mining, inference, and prediction. Springer; 2009.
- [44] Domingos P. A few useful things to know about machine learning. *Communications of the ACM*. 2012;55(10):78-87.
- [45] Ng A. Sparse autoencoder. *CS294A Lecture notes*. 2011;72(2011):1-19.
- [46] Le QV. Building high-level features using large scale unsupervised learning. 2013 IEEE international conference on acoustics, speech and signal processing: IEEE; 2013. p. 8595-8.
- [47] Jordan MI, Mitchell TM. Machine learning: Trends, perspectives, and prospects. *Science*. 2015;349(6245):255-60.
- [48] Mahesh B. Machine learning algorithms-a review. *International Journal of Science and Research (IJSR)[Internet]*. 2020;9(1):381-6.
- [49] Sharifani K, Amini M. Machine learning and deep learning: A review of methods and applications. *World Information Technology and Engineering Journal*. 2023;10(07):3897-904.
- [50] Krizhevsky A, Sutskever I, Hinton GE. Imagenet classification with deep convolutional neural networks. *Advances in neural information processing systems*. 2012;25.
- [51] He K, Zhang X, Ren S, Sun J. Deep residual learning for image recognition. *Proceedings of the IEEE conference on computer vision and pattern recognition* 2016. p. 770-8.
- [52] Deng J, Dong W, Socher R, Li L-J, Li K, Fei-Fei L. Imagenet: A large-scale hierarchical image database. 2009 IEEE conference on computer vision and pattern recognition: Ieee; 2009. p. 248-55.
- [53] LeCun Y, Bengio Y, Hinton G. Deep learning. *nature*. 2015;521(7553):436-44.
- [54] Bengio Y, Courville A, Vincent P. Representation learning: A review and new perspectives. *IEEE transactions on pattern analysis and machine intelligence*. 2013;35(8):1798-828.
- [55] Hinton GE, Osindero S, Teh Y-W. A fast learning algorithm for deep belief nets. *Neural computation*. 2006;18(7):1527-54.
- [56] LeCun Y, Boser B, Denker JS, Henderson D, Howard RE, Hubbard W, et al. Backpropagation applied to handwritten zip code recognition. *Neural computation*. 1989;1(4):541-51.
- [57] Goodfellow I, Bengio Y, Courville A. *Deep learning*. MIT press; 2016.

- [58] Goodfellow I, Pouget-Abadie J, Mirza M, Xu B, Warde-Farley D, Ozair S, et al. Generative adversarial networks. *Communications of the ACM*. 2020;63(11):139-44.
- [59] Vaswani A, Shazeer N, Parmar N, Uszkoreit J, Jones L, Gomez AN, et al. Attention is all you need. *Advances in neural information processing systems*. 2017;30.
- [60] Silver D, Huang A, Maddison CJ, Guez A, Sifre L, Van Den Driessche G, et al. Mastering the game of Go with deep neural networks and tree search. *nature*. 2016;529(7587):484-9.
- [61] Mnih V, Kavukcuoglu K, Silver D, Graves A, Antonoglou I, Wierstra D, et al. Playing atari with deep reinforcement learning. *arXiv preprint arXiv:13125602*. 2013.
- [62] Sutton RS, Barto AG. *Reinforcement learning: An introduction*. MIT press; 2018.
- [63] Schulman J, Levine S, Abbeel P, Jordan M, Moritz P. Trust region policy optimization. *International conference on machine learning*: PMLR; 2015. p. 1889-97.
- [64] Lillicrap TP, Hunt JJ, Pritzel A, Heess N, Erez T, Tassa Y, et al. Continuous control with deep reinforcement learning. *arXiv preprint arXiv:150902971*. 2015.
- [65] 姜明磊. 数控加工参数优化的研究现状与进展 [J]. *南方农机*, 2020, 51 (23): 118+121.
- [66] 麦启明,张建强. 数控雕刻机路径优化技术研究 [J]. *机床与液压*, 2021, 49 (16): 60-66.
- [67] 李敏,袁巨龙,吴喆等. 复杂曲面零件超精密加工方法的研究进展 [J]. *机械工程学报*, 2015, 51 (05): 178-191.
- [68] Hu P, Song Y, Zhou H, Xie J, Zhang C. Feature Points Recognition of Computerized Numerical Control Machining Tool Path Based on Deep Learning. *Computer-Aided Design*. 2022;149:103273. <https://doi.org/10.1016/j.cad.2022.103273>.
- [69] Marc-André Dittich, Florian Uhlich, Self-optimizing compensation of surface deviations in 5-axis ball-end milling based on an enhanced description of cutting conditions, *CIRP Journal of Manufacturing Science and Technology*, Volume 31, 2020, Pages 224-232, ISSN 1755-5817, <https://doi.org/10.1016/j.cirpj.2020.05.013>.
- [70] Yongmao Xiao, Zhigang Jiang, Quan Gu, Wei Yan, Ruping Wang, A novel approach to CNC machining center processing parameters optimization considering energy-saving and low-cost, *Journal of Manufacturing Systems*, Volume 59, 2021, Pages 535-548, ISSN 0278-6125, <https://doi.org/10.1016/j.jmsy.2021.03.023>.
- [71] Noor Hatem, Yusri Yusof, Aini Zuhra A. Kadir, Kamran Latif, M.A Mohammed, A novel integrating between tool path optimization using an ACO

- algorithm and interpreter for open architecture CNC system, *Expert Systems with Applications*, Volume 178, 2021, 114988, ISSN 0957-4174, <https://doi.org/10.1016/j.eswa.2021.114988>.
- [72] Chih-Hsing Chu, Hsiang-Yun Chen, Chun-Hao Chang, Continuity-preserving tool path generation for minimizing machining errors in five-axis CNC flank milling of ruled surfaces, *Journal of Manufacturing Systems*, Volume 55, 2020, Pages 171-178, ISSN 0278-6125, <https://doi.org/10.1016/j.jmsy.2020.03.004>.
- [73] Mahfoud Herraz, Jean-Max Redonnet, Mohammed Sbihi, Marcel Mongeau, Toolpath planning optimization for end milling of free-form surfaces using a clustering algorithm, *Procedia CIRP*, Volume 99, 2021, Pages 139-144, ISSN 2212-8271, <https://doi.org/10.1016/j.procir.2021.03.021>.
- [74] Zhao Y, Mei J, Niu W. Vibration error-based trajectory planning of a 5-dof hybrid machine tool[J]. *Robotics and Computer-Integrated Manufacturing*, 2021, 69: 102095.
- [75] Sun P, Xia S, Yuan G, Li D. An overview of moving object trajectory compression algorithms. *Mathematical Problems in Engineering*. 2016;2016.
- [76] Zhao X, Zhao H, Li X, Ding H. Path smoothing for five-axis machine tools using dual quaternion approximation with dominant points. *International Journal of Precision Engineering and Manufacturing*. 2017;18:711-20.
- [77] Zhang L, Lu J, Ou C, Ma J, Liao X. Smoothing and compressing algorithm of toolpath with complex contour in NC machining. *The International Journal of Advanced Manufacturing Technology*. 2023;125(9):4841-54.
- [78] Du X, Huang J, Zhu L-M, Ding H. An error-bounded B-spline curve approximation scheme using dominant points for CNC interpolation of micro-line toolpath. *Robotics and Computer-Integrated Manufacturing*. 2020;64:101930.
- [79] Jin Y, Zhao S, Wang Y. An optimal feed interpolator based on G2 continuous Bézier curves for high-speed machining of linear tool path. *Chinese Journal of Mechanical Engineering*. 2019;32:1-10.
- [80] Lyu D, Song Y, Liu P, Zhao W. Screening and optimization method of defect points of G code in three axis NC machining. *International Journal of Computer Integrated Manufacturing*. 2022;36(4):524-41. <https://doi.org/10.1080/0951192x.2022.2128211>.
- [81] Hu Y, Jiang X, Huo G, Su C, Zhou S, Wang B, et al. A novel feed rate scheduling method with acc-jerk-continuity and round-off error elimination for non-uniform rational B-spline interpolation. *Journal of Computational Design and Engineering*. 2023;10(1):294-317. <https://doi.org/10.1093/jcde/qwad004>.
- [82] Sun S, Altintas Y. A G3 continuous tool path smoothing method for 5-axis CNC machining. *CIRP Journal of Manufacturing Science and Technology*. 2021;32:529-49. <https://doi.org/10.1016/j.cirpj.2020.11.002>.

- [83] Liang F, Yan G, Fang F. Global time-optimal B-spline feedrate scheduling for a two-turret multi-axis NC machine tool based on optimization with genetic algorithm. *Robotics and Computer-Integrated Manufacturing*. 2022;75. <https://doi.org/10.1016/j.rcim.2021.102308>.
- [84] Liu C, Qiu Y, Zhang L. Preconditioned geometric iterative methods for B-spline interpolation. *Mathematics and Computers in Simulation*. 2024;219:87-100. <https://doi.org/10.1016/j.matcom.2023.12.010>.
- [85] Sun S, Zhao P, Zhang T, Li B, Yu D. Smoothing interpolation of five-axis tool path with less feedrate fluctuation and higher computation efficiency. *Journal of Manufacturing Processes*. 2024;109:669-93. <https://doi.org/10.1016/j.jmapro.2023.12.012>.
- [86] Dittrich M-A, Uhlich F. Self-optimizing compensation of surface deviations in 5-axis ball-end milling based on an enhanced description of cutting conditions. *CIRP Journal of Manufacturing Science and Technology*. 2020;31:224-32. <https://doi.org/10.1016/j.cirpj.2020.05.013>.
- [87] Xiao Y, Jiang Z, Gu Q, Yan W, Wang R. A novel approach to CNC machining center processing parameters optimization considering energy-saving and low-cost. *Journal of Manufacturing Systems*. 2021;59:535-48. <https://doi.org/10.1016/j.jmsy.2021.03.023>.
- [88] Hatem N, Yusof Y, Kadir AZA, Latif K, Mohammed M. A novel integrating between tool path optimization using an ACO algorithm and interpreter for open architecture CNC system. *Expert Systems with Applications*. 2021;178:114988. <https://doi.org/10.1016/j.eswa.2021.114988>.
- [89] Chu C-H, Chen H-Y, Chang C-H. Continuity-preserving tool path generation for minimizing machining errors in five-axis CNC flank milling of ruled surfaces. *Journal of Manufacturing Systems*. 2020;55:171-8. <https://doi.org/10.1016/j.jmsy.2020.03.004>.
- [90] Herraz M, Redonnet J-M, Sbihi M, Mongeau M. Toolpath planning optimization for end milling of free-form surfaces using a clustering algorithm. *Procedia CIRP*. 2021;99:139-44. <https://doi.org/10.1016/j.procir.2021.03.021>.
- [91] Zhao Y, Mei J, Niu W. Vibration error-based trajectory planning of a 5-dof hybrid machine tool[J]. *Robotics and Computer-Integrated Manufacturing*, 2021, 69: 102095.
- [92] Bosetti P, Bertolazzi E. Feed-rate and trajectory optimization for CNC machine tools. *Robotics and computer-integrated manufacturing*. 2014;30(6):667-77.
- [93] Zhang Q, Li S, Guo J. Smooth time-optimal tool trajectory generation for CNC manufacturing systems. *Journal of manufacturing Systems*. 2012;31(3):280-7.
- [94] Mercy T, Jacquod N, Herzog R, Pipeleers G. Spline-based trajectory generation for CNC machines. *IEEE Transactions on Industrial Electronics*. 2018;66(8):6098-107.

- [95] Paing MS, Uchiyama N. A spline-based approach to smooth and time-optimal trajectory generation for CNC machines with guaranteed kinematic constraints. *The International Journal of Advanced Manufacturing Technology*. 2022;121(5-6):3385-98.
- [96] Meystel AM, Albus JS. *Intelligent systems: architecture, design, and control*. John Wiley & Sons, Inc.; 2000.
- [97] 王眇,张振明,李龙,谢云.数控技术发展状况及在智能制造中的作用[J].航空制造技术,2021,64(10):20-26.
- [98] 闫辉.数控技术发展趋势——智能化数控系统[J].时代农机,2019,46(10):1-2.
- [99] Wang J, Niu X, Gao RX, Huang Z, Xue R. Digital twin-driven virtual commissioning of machine tool. *Robotics and Computer-Integrated Manufacturing*. 2023;81:102499. <https://doi.org/10.1016/j.rcim.2022.102499>.
- [100] Martinov GM, Ljubimov AB, Martinova LI. From classic CNC systems to cloud-based technology and back. *Robotics and Computer-Integrated Manufacturing*. 2020;63:101927. <https://doi.org/10.1016/j.rcim.2019.101927>.
- [101] Armstrong M, Mehrabi H, Naveed N. An overview of modern metal additive manufacturing technology. *Journal of Manufacturing Processes*. 2022;84:1001-29. <https://doi.org/10.1016/j.jmapro.2022.10.060>.
- [102] Chen W. Intelligent manufacturing production line data monitoring system for industrial internet of things. *Computer communications*. 2020;151:31-41.
- [103] He, B., Bai, KJ. Digital twin-based sustainable intelligent manufacturing: a review. *Adv. Manuf.* 9, 1–21 (2021). <https://doi.org/10.1007/s40436-020-00302-5>.
- [104] 肖文磊,曹宪,赵罡等. 面向数控加工的数字孪生系统 [J]. 航空制造技术, 2020, 63 (Z2): 46-55. DOI:10.16080/j.issn1671-833x.2020.23/24.046.
- [105] 崔伟业,刘畅,杨琪. 信息物理系统在数控机床智能诊断中的应用 [J]. 机床与液压, 2023, 51 (24): 169-175.
- [106] Shan, S, Wen, X, Wei, Y, Wang, Z, Chen, Y. Intelligent manufacturing in industry 4.0: A case study of Sany heavy industry. *Syst Res Behav Sci*. 2020; 37 679– 690. <https://doi.org/10.1002/sres.2709>.
- [107] Liu W, Kong C, Niu Q, Jiang J, Zhou X. A method of NC machine tools intelligent monitoring system in smart factories. *Robotics and computer-integrated manufacturing*. 2020;61:101842.
- [108] Lynn R, Helu M, Sati M, Tucker T, Kurfess T. The State of Integrated CAM/CNC Control Systems: Prior Developments and the Path Towards a Smarter CNC. *The ASTM Journal of Smart and Sustainable Manufacturing*. 2020;4(2). <https://doi.org/10.1520/SSMS20190046>.
- [109] Guo Y, Wang H, Hu Q, Liu H, Liu L, Bennamoun M. Deep learning for 3d point clouds: A survey. *IEEE transactions on pattern analysis and machine intelligence*.

- 2020;43(12):4338-64.
- [110] Wu W, Qi Z, Fuxin L, editors. Pointconv: Deep convolutional networks on 3d point clouds. Proceedings of the IEEE/CVF Conference on computer vision and pattern recognition; 2019.
- [111] Zhou Y, Tuzel O, editors. Voxelnet: End-to-end learning for point cloud based 3d object detection. Proceedings of the IEEE conference on computer vision and pattern recognition; 2018.
- [112] Zhang Z, Jaiswal P, Rai R. Featurenet: Machining feature recognition based on 3d convolution neural network. Computer-Aided Design. 2018;101:12-22.
- [113] Dai A, Chang AX, Savva M, Halber M, Funkhouser T, Nießner M, editors. Scannet: Richly-annotated 3d reconstructions of indoor scenes. Proceedings of the IEEE conference on computer vision and pattern recognition; 2017.
- [114] Zhou H, Lang M, Hu P, Su Z, Chen J. The modeling, analysis, and application of the in-process machining data for CNC machining. The International Journal of Advanced Manufacturing Technology. 2019;102:1051-66.
- [115] Su Z, Zhou H, Hu P, Fan W. Three-axis CNC machining feedrate scheduling based on the feedrate restricted interval identification with sliding arc tube. The International Journal of Advanced Manufacturing Technology. 2018;99:1047-58.
- [116] Lee C-H, Yang F, Zhou H, Hu P, Min K. Cross-directional feed rate optimization using tool-path surface. The International Journal of Advanced Manufacturing Technology. 2020;108:2645-60.
- [117] Deng T, Li Y, Liu X, Wang P, Lu K. A data-driven parameter planning method for structural Parts NC machining. Robotics and Computer-Integrated Manufacturing. 2021;68:102080.
- [118] Hu P, Song Y, Zhou H, et al. Feature Points Recognition of Computerized Numerical Control Machining Tool Path Based on Deep Learning[J]. Computer-Aided Design, 2022, 149: 103273.
- [119] 董靖川,王太勇,徐跃. 基于数控流水线技术的开放式数控系统 [J]. 计算机集成制造系统, 2009, 15 (06): 1130-1139. DOI:10.13196/j.cims.2009.06.92.dongjch.017.
- [120] Van Hasselt H, Guez A, Silver D. Deep reinforcement learning with double q-learning. Proceedings of the AAAI conference on artificial intelligence 2016. <https://doi.org/10.1609/aaai.v30i1.10295>.
- [121] Senin P. Dynamic time warping algorithm review. Information and Computer Science Department University of Hawaii at Manoa Honolulu, USA. 2008;855(1-23):40.
- [122] 张梅,闫伟,袁春明等. 数控加工中的二次曲线拟合与最优插补控制算法 [J]. 中国科学:信息科学, 2011, 41 (11): 1388-1400.
- [123] 周佳军,姚锡凡,刘敏等. 几种新兴智能制造模式研究评述 [J]. 计算机集成制

- 造系统, 2017, 23 (03): 624-639. DOI:10.13196/j.cims.2017.03.020.
- [124] 李佳,贾仕齐. 网络协同制造模式及标准化方向研究 [J]. 制造业自动化, 2024, 46 (01): 161-164+185.
- [125] 石硕,郭保琪,冷君阁等. 数控机床产业集聚区域网络协同制造大数据平台架构研究 [J]. 制造业自动化, 2023, 45 (10): 191-195+210.
- [126] 李思远. 网络协同制造视角下完善工业互联网标准体系的建议 [J]. 仪器仪表标准化与计量, 2023, (04): 5-8.
- [127] 邹涛,张慧峰,高万鑫等. 面向智能制造的多模态网络应用技术研究 [J]. 电信科学, 2023, 39 (06): 61-72.
- [128] Wu Q, Yuan C-M, Shen L-Y, He S-T, Gao X-S. Cubic time-spline fitting and interpolation for five-axis CNC machining. *Journal of Computational Design and Engineering*. 2023;10(6):2345-60.
- [129] Du X, Wang B. A C3-continuous NURBS transition scheme for the CNC machining of short linear segments. *Precision Engineering*. 2022;73:1-10.
- [130] Lu T-C, Chen S-L. Real-time local optimal Bézier corner smoothing for CNC machine tools. *IEEE Access*. 2021;9:152718-27.
- [131] Lee J, Bagheri B, Jin C. Introduction to cyber manufacturing. *Manufacturing Letters*. 2016;8:11-5. <https://doi.org/10.1016/j.mfglet.2016.05.002>.
- [132] 刘启通,刘强,孙鹏鹏. 自由曲面数控加工混合刀具路径生成算法研究 [J]. 机床与液压, 2018, 46 (19): 8-14.
- [133] Li J, Liu Y, Li Y, Zhong G. S-model speed planning of NURBS curve based on uniaxial performance limitation. *IEEE Access*. 2019;7:60837-49.
- [134] Kong T, Zhang Y, Fu X. The model of feature extraction for free-form surface based on topological transformation. *Applied Mathematical Modelling*. 2018;64:386-97.

致 谢

随着我在这段漫长而又充实的博士学习旅程即将落幕，我满怀感激地回顾过去数年间那些激励和支持我的人们。首先，我要特别感谢我的导师于东研究员，他不仅是我学术探索的引路人，更是我人生旅程中的良师益友。于老师的深邃洞察力、严谨的科学态度和对学术的无限热情深深影响了我，他在我遇到研究困难时给予的耐心指导和鼓励，是我能够坚持到最后并取得成功的关键。

我也要感谢我的实验室的兄弟姐妹们，包括何无为、周正、吴聪、刘信君等，他们不仅是学习中的伙伴，也是生活中值得信赖的朋友。在这个富有挑战的研究领域里，我们在实验室里度过的无数日夜，在论文撰写和实验设计上的深入讨论，都是我宝贵的学术财富。

我还要感谢员工武南、曹阳、田小明和韩文业。他们在数控加工领域提出的实际问题不仅丰富了我的研究，也让我在寻求解决方案的过程中获得了宝贵的经验。他们的实际案例是我研究的灵感来源，也是我成长的重要部分。

研究生部的丁老师、宁老师和李老师在学术生活中也扮演了重要角色。他们的关心和鼓励对我来说非常重要，由衷地感谢各位老师。

我亦不能忘记我的家人，他们对我的爱和支持是我最坚实的后盾。我的父母始终相信我，鼓励我追求梦想，他们的无私和坚持是我学习的榜样。在我最需要的时候，是他们给了我无尽的安慰和支持。

在这一段学术旅程的尾声，我想说的不仅仅是感谢。每一次挑战和失败都让我更加坚强和成熟，每一次成功和成就都让我更加感恩和谦卑。我对生活充满感激，因为它给予我无数的机会和挑战，让我不断学习和成长。我期待着将我所学到的知识和经验应用到未来的工作和生活中，为社会做出我的贡献。

2024年6月

作者简历及攻读学位期间发表的学术论文与其他相关学术成果

作者简历:

2013 年 09 月——2017 年 06 月, 在河南大学计算机与信息工程学院获得学士学位。

2017 年 09 月——2020 年 06 月, 在中国科学院沈阳计算技术研究所获得硕士学位。

2020 年 09 月——2024 年 06 月, 在中国科学院沈阳计算技术研究所攻读博士学位。

已发表(或正式接受)的学术论文:

[1] **Zhang Lipeng**, Yu Dong, Hu Yi, et al. Research and Test on Software Performance Index of Open CNC System[C]// (ICCC). IEEE, 2021: 1299-1303.(EI, 已发表)

[2] **Zhang Lipeng**, Yu Dong, Hu Yi, et al. A Method for CNC Machining Trajectory Compression Based on Deep Q-Network (DQN) [C]// (ICTCT). IEEE, 2023. (EI, 已录用)

[3] **Zhang Lipeng**, Yu Haoyu, Wang Chuting, et al. A digital solution for CPS-based machining path optimization for CNC systems. [J]. Journal of Intelligent Manufacturing. (SCI IF:8.3, 已发表)

[4] 何无为, **张丽鹏**, 胡毅, 等. A Hybrid-Model-Based CNC Machining Trajectory Error Prediction and Compensation Method. Electronics.2024,1143. (SCI IF:2.9, 已发表)

[5] 郎言书, **张丽鹏**, 何无为, 等. Abnormal Control and Trajectory Optimization in CNC System[C] (CCDC). IEEE,2024.

[6] 王品, 王婧如, **张丽鹏**, 等.一种改进的 Douglas-Peucker 数控加工轨迹压缩方法[J].小型微型计算机系统.(已发表)

[7] Jingru Chang, Yu Dong, **Lipeng Zhang**, et al. A Multi-Objective Flexible Job Shop Intelligent Scheduling System Based on Soft Dueling Double Deep Q-Networks.The 35th Chinese Control and Decision Conference.2023(EI, 已发表)

专利:

于东, **张丽鹏**, 胡毅, 周光远, 何无为, 周正, 一种数控加工刀具路径的自适

应滤波优化方法. (CN116700149A)

王品, 王婧如, **张丽鹏**, 王森, 荆东东, 一种改进的 Douglas-Peucker 数控加工轨迹压缩方法 (202311212953.X)

于东, 谭雯月, 胡毅, **张丽鹏**, 等, 一种基于深度学习的数控系统工件加工路径特征识别方法 (202311216344.1)

参与的研究项目:

作为主要参加人之一, 攻读博士学位期间参与了中国科学院沈阳计算技术研究所高档数控国家工程研究中心以下课题及项目研究工作:

辽宁省“兴辽英才计划”项目-面向智能制造的数控装备及工业互联网技术研发与应用示范 (XLYC1902091)

航空航天薄壁零件关键加工技术装备项目—国产五轴数控系统应用技术研究(TC220H05S-003);

面向工业母机的质量与可靠性试验检测评价服务平台-典型减材装备及关键功能部件质量与可靠性服务平台(2022-232-223-01);

数控系统与基础制造装备关键技术国际标准制定及应用验证(2019ZX04004-001);